

Aplicación de Técnicas de Aprendizaje Automático para el Análisis y Predicción de Patrones de Sueño Usando Variables Fisiológicas y de Actividad Diaria

Juan David Riveros Pérez,
Asesor: Fernando Lozano

*Universidad de los Andes, Departamento de Ingeniería Eléctrica y Electrónica
Bogotá D.C., Colombia
Diciembre de 2024*

Resumen

El sueño es fundamental para la salud humana, afectando el bienestar físico y mental. Problemas como la apnea del sueño impactan negativamente la calidad del descanso, lo que hace necesario el uso de herramientas predictivas. Este proyecto de grado busca aplicar aprendizaje automático para predecir la calidad del sueño y la apnea del sueño, utilizando XGBoost. Se identificaron variables clave como BMI, saturación de oxígeno y etapas del sueño. A través del análisis de importancia de variables y técnicas de clustering, se segmentaron a los participantes en tres grupos, generando recomendaciones personalizadas basadas en sus características prediciendo la calidad del sueño y si tiene una condición de apnea el individuo. A pesar de las limitaciones de un dataset pequeño, los modelos mostraron un buen desempeño, especialmente XGBoost, lo que abre la puerta a futuras aplicaciones en monitorización en tiempo real mediante dispositivos como smartwatches.

Palabras Claves: *Calidad del sueño, Apnea del Sueño, Aprendizaje automático, XGBoost, Recomendaciones personalizadas.*

1. Introducción

En la sociedad actual, los trastornos del sueño se han convertido en un problema de salud pública significativo con implicaciones graves para la calidad de vida y el bienestar general de las personas. Factores relacionados con el estilo de vida, como el estrés, el sedentarismo, una dieta inadecuada y el uso excesivo de dispositivos electrónicos, alteran los patrones de sueño, incrementando el riesgo de desarrollar enfermedades crónicas, deterioro cognitivo y trastornos de salud mental. Según un estudio realizado por el Centers for Disease Control and Prevention (CDC), más del 35 % de los adultos en Estados Unidos reportan dormir menos de las siete horas recomendadas por noche, lo que se asocia con un mayor riesgo de condiciones como hipertensión, diabetes, enfermedades cardiovasculares y problemas de salud mental [1].

Entender los factores que afectan la calidad del sueño y cómo estos influyen en la aparición de trastornos como la apnea del sueño es esencial para abordar esta problemática. Variables fisiológicas como el Índice de Masa Corporal (BMI), la saturación de oxígeno y la distribución del tiempo en las etapas del sueño han mostrado una relación directa con estos trastornos, convirtiéndose en indicadores clave para el análisis. En este contexto, el presente trabajo de grado emplea técnicas de aprendizaje automático para analizar estas variables y desarrollar modelos predictivos que permitan caracterizar los patrones de sueño, con un enfoque particular en identificar casos de apnea del sueño y la calidad del sueño de las personas.

El uso de algoritmos avanzados proporciona un marco robusto para procesar y analizar grandes volúmenes de datos fisiológicos y de comportamiento. Estos modelos no solo permiten realizar predicciones precisas, sino que también ofrecen la capacidad de interpretar qué variables tienen mayor influencia en los resultados. A lo largo del desarrollo del proyecto, se han integrado datos relevantes para maximizar el rendimiento de los modelos y se ha realizado un análisis exploratorio detallado para identificar patrones y correlaciones en los datos [12][13].

A partir de esta base, el presente proyecto de grado se centra en construir y comparar modelos predictivos que permitan identificar las características individuales que influyen en la calidad del sueño y en la probabilidad de padecer apnea. Este enfoque proporciona una herramienta para el análisis y la prevención de estos trastornos, sentando las bases para intervenciones personalizadas que puedan contribuir de manera efectiva al bienestar de las personas afectadas.

2. Marco Teórico

Esta sección presenta los conceptos y fundamentos utilizados para el análisis de patrones de sueño y la predicción de la calidad del sueño a través de técnicas de aprendizaje automático.

2.1. Etapas del Sueño

El sueño se divide en distintas fases que cumplen funciones específicas:

La fase P (Preparation stage) es la etapa previa a la grabación PSG, utilizada para preparar al participante y configurar el equipo [9]. La fase W (Wake stage) corresponde al estado en el que el individuo está despierto y se usa como referencia para diferenciar las otras fases del sueño [9]. La fase N1 (Non-rapid eye-movement - NREM Stage 1) es la primera etapa del sueño no REM; se trata de un estado ligero que sirve de transición hacia un sueño más profundo [9]. Durante la fase N2 (NREM Stage 2), la temperatura corporal y la actividad cerebral disminuyen, consolidando el sueño [9]. La fase N3 (NREM Stage 3), conocida como sueño de ondas lentas, es crucial para la recuperación física y la mejora cognitiva [9][6]. Por último, la fase R (REM) es aquella en la que ocurren la mayoría de los sueños y es fundamental para el procesamiento de emociones y el almacenamiento de memoria [6][9].

2.2. BMI y Apnea del sueño

En esta sección se presentan definiciones claves relacionadas con el Índice de Masa Corporal (BMI), el índice de despertares (Arousal Index) y diferentes tipos de apnea del sueño. Estas definiciones proporcionan el contexto necesario para entender los factores fisiológicos y clínicos que influyen en la calidad del sueño y la prevalencia de la apnea, estableciendo la base teórica para el análisis posterior.

Índice de Masa Corporal (BMI): es una herramienta utilizada para evaluar si una persona tiene un peso saludable en relación con su altura. Un BMI entre 18.5 y 24.9 se considera normal, entre 25 y 29.9 se considera sobrepeso, y un BMI de 30 o más se clasifica como obesidad. Aunque es ampliamente utilizado en la práctica clínica para identificar riesgos de salud relacionados con el peso, no diferencia entre masa muscular y grasa corporal, lo cual puede limitar su precisión en algunos individuos [2].

Arousal Index: mide la cantidad de despertares o interrupciones que ocurren por hora de sueño, un indicador clave para evaluar la fragmentación del sueño. Valores altos en este índice pueden indicar la presencia de trastornos del sueño como la apnea, afectando la calidad del descanso y, a largo plazo, la recuperación física y el rendimiento cognitivo [3].

Apnea del Sueño: es un trastorno en el que se producen interrupciones repetidas en la respiración durante el sueño, lo que puede durar desde unos segundos hasta minutos. Estas pausas pueden resultar en una desaturación de oxígeno y fragmentación del sueño, afectando significativamente la calidad del descanso. La apnea se asocia con un mayor riesgo de problemas cardiovasculares, hipertensión y alteraciones metabólicas [3][4].

Apnea Obstructiva del Sueño (OSA): es el tipo más común de apnea del sueño y ocurre cuando los músculos de la garganta se relajan excesivamente, obstruyendo las vías respiratorias durante el sueño. Este tipo de apnea está estrechamente relacionado con el sobrepeso y la obesidad, ya que el tejido graso adicional en el cuello puede contribuir a las obstrucciones. Las

personas con OSA a menudo presentan síntomas como ronquidos fuertes, despertares frecuentes y somnolencia durante el día [3][4].

2.3. Índices y Parámetros Médicos

En este apartado se describen los índices y parámetros médicos más relevantes utilizados en este estudio, como el AHI y la saturación de oxígeno, entre otros. Estos parámetros son esenciales para evaluar y clasificar la gravedad de los trastornos del sueño y comprender mejor su relación con las variables fisiológicas y del comportamiento.

AHI (Apnea-Hypopnea Index): Mide el número de eventos de apnea e hipopnea por hora de sueño, siendo un indicador de la gravedad de la apnea del sueño [5][6].

OAHÍ (Obstructive Apnea-Hypopnea Index): Se enfoca en eventos obstructivos, excluyendo otros tipos de apneas [6].

Mean SaO₂: Indica la saturación media de oxígeno durante el sueño; valores bajos se asocian con episodios severos de apnea [6][9].

DBP (Presión Arterial Diastólica): Es la presión en las arterias cuando el corazón está en reposo entre latidos. Un valor elevado de DBP indica un mayor riesgo de enfermedades cardiovasculares [15].

SBP (Presión Arterial Sistólica): Es la presión en las arterias cuando el corazón late y bombea sangre. Un valor elevado de SBP está relacionado con un mayor riesgo de enfermedades cardíacas y accidentes cerebrovasculares [15].

2.4. Modelos de Machine Learning

Se implemento y analizo estos tres modelos:

Random Forest: Algoritmo que utiliza múltiples árboles de decisión para mejorar la precisión de la clasificación. Es robusto contra el sobreajuste y permite identificar las variables más influyentes en el modelo [7][8].

XGBoost: Algoritmo de boosting que combina árboles de decisión de forma secuencial para mejorar las predicciones. Es eficiente y, en muchos casos, supera a otros métodos supervisados en precisión [7][8].

Regresión Logística: Modelo lineal ampliamente utilizado para problemas de clasificación binaria. Este modelo estima la probabilidad de ocurrencia de un evento utilizando una función sigmoidea. Es especialmente útil para interpretar el impacto de cada variable en la predicción, lo que facilita la comprensión de los factores clave en los resultados del modelo. La regresión logística conocida por su simplicidad y eficiencia [14].

2.5. Clustering (agrupamiento)

Para el agrupamiento de individuos según patrones de sueño y estilos de vida, se utilizó el algoritmo K-means. Este método divide los datos en un número predefinido de grupos (clusters) de tal manera que los

individuos dentro de un mismo grupo sean más similares entre sí que a los de otros grupos. La simplicidad y eficiencia de K-means lo convierten en una opción ideal para segmentar poblaciones con características comunes y explorar subgrupos que puedan beneficiarse de intervenciones personalizadas [11].

3. Metodología

Para modelar esta sección se hizo un diagrama de flujo de trabajo donde se muestran las principales secciones del proyecto de grado.




Figura 1: Flujo de Trabajo.

3.1. Parte 1: Recopilación y Preparación de Datos

Esta sección cubre las primeras etapas del proceso, enfocándose en la obtención y limpieza del dataset para asegurar su calidad y consistencia.

Selección del Dataset: Para este estudio, se eligió el dataset de Wisconsin Sleep Cohort (WSC), un estudio longitudinal en curso que investiga las causas, consecuencias y la historia natural de los trastornos del sueño, con un enfoque particular en la apnea del sueño. El WSC utiliza estudios nocturnos de sueño en laboratorio (in-patient studies), realizados en el ICTR's CTRC de la Universidad de Wisconsin-Madison, con una muestra base de 1,500 empleados del estado de Wisconsin, evaluados cada cuatro años. Este estudio ha generado aproximadamente 100 publicaciones científicas, destacándose por sus hallazgos clave sobre la prevalencia generalizada de la apnea del sueño y su asociación longitudinal con problemas cardiovasculares, de salud mental y mortalidad.

Además, el estudio mantiene colaboraciones nacionales e internacionales con instituciones líderes como Stanford, la Universidad de Chicago, Harvard, Toronto y grupos de investigación en el Reino Unido, Polonia y Francia, entre otros. La contribución del WSC al conocimiento científico sobre el sueño y sus trastornos es ampliamente reconocida, y su dataset es compartido con la comunidad científica a través de la National

Sleep Research Resource.

Este dataset fue seleccionado debido a su amplia disponibilidad de datos fisiológicos y relacionados con la apnea del sueño, incluyendo información sobre si los participantes presentan o no apnea, AHI (índice de apnea-hipopnea), y otras variables clave como la saturación de oxígeno y el índice de masa corporal (BMI), entre otros. Aunque el conjunto de datos no es de gran tamaño, es uno de los más relevantes para el estudio de la apnea del sueño debido a su longitud y detalle [16] [17].

Estructuración y Limpieza Inicial: En esta fase, se llevó a cabo una limpieza y verificación inicial de los datos para garantizar su calidad. Se eliminaron las filas correspondientes a participantes que contenían datos incompletos o erróneos. Dado que el conjunto de datos original contenía 687 variables, se seleccionaron solo las variables más relevantes para el análisis de patrones de sueño y apnea del sueño. Este proceso de selección permitió reducir la complejidad del dataset y enfocarse en aquellas variables más directamente relacionadas con la calidad del sueño y la apnea. Posteriormente, se manejaron valores faltantes en algunas de estas variables.

Integración de Datos: Los datos originales estaban distribuidos en diferentes archivos, por lo que se procedió a unificar todos los registros en un único dataset para facilitar su posterior análisis. Esta integración se realizó utilizando herramientas de manipulación de datos en Google Colab, mediante scripts de Python y pandas. Se utilizaron funciones como merge para combinar los archivos según el identificador único de los participantes (SID). Además, se revisaron y aseguraron consistencias entre las diferentes fuentes de datos antes de proceder con el análisis. El proceso de integración también incluyó la creación de un archivo final, que consolidó todos los registros en un formato adecuado para los análisis posteriores.

3.2. Parte 2: Análisis Exploratorio y Preprocesamiento de Datos

En esta parte se abordan las técnicas utilizadas para explorar y preparar los datos antes de aplicar cualquier modelo predictivo.

Análisis Exploratorio de Datos (EDA): Se realizaron diversas visualizaciones estadísticas para explorar las distribuciones y patrones de las principales variables del dataset, tales como edad (AGE), índice de masa corporal (BMI), AHI, y total de sueño (Total Sleep). Para entender mejor las diferencias por género, se utilizaron gráficos de caja (boxplots), lo que permitió identificar variaciones significativas entre hombres y mujeres en variables clave como BMI y AHI como se puede observar en la Figura 2 para el caso de AHI. También se aplicaron histogramas y gráficos de densidad (KDE) para observar las distribuciones de cada variable, lo que ayudó a detectar sesgos, valores atípicos y la necesidad de segmentar el análisis en grupos específicos.




Figura 2: Gráficos de caja AHI

Preprocesamiento de Datos: se abordaron los valores faltantes mediante imputación: las variables categóricas se imputaron con el valor modal y las variables numéricas con la media. Además, se eliminaron filas con información incompleta que podrían haber afectado la calidad del análisis. Para preparar las variables numéricas, se utilizó StandardScaler para normalizar los datos, garantizando que todas las variables tuvieran la misma escala y, por lo tanto, no tuvieran un impacto desproporcionado en los modelos predictivos. Asimismo, las variables categóricas fueron transformadas a formato numérico usando label encoding para su inclusión en los modelos de aprendizaje automático, asegurando que los algoritmos pudieran procesar los datos correctamente.

Normalización y Escalamiento: se utilizó para garantizar que los modelos de aprendizaje automático funcionaran de manera eficiente. Utilizando StandardScaler, se normalizaron las variables como BMI, AHI, y Mean_SaO2, lo que facilitó la comparación entre las variables al tener una media de 0 y una desviación estándar de 1. Aunque algunos modelos, como Random Forest y XGBoost, no requieren escalado debido a su naturaleza, este paso resultó esencial para modelos como regresión logística.

3.3. Parte 2-3: Definición de Variables

Durante el análisis exploratorio de datos (EDA), se identificaron diferencias significativas en las correlaciones de las variables, especialmente en función del género de los participantes. Si bien no se segmentaron los modelos específicamente por género, se observó que el género podría influir en las relaciones entre las variables y en los patrones de sueño. Esto resaltó la importancia de considerar características como la edad, el Índice de Masa Corporal (BMI) y la saturación de oxígeno (Mean_SaO2) al construir los modelos, ya que estas variables están estrechamente relacionadas con el riesgo de apnea del sueño. Esta elección de variables fue el resultado de un análisis tanto teórico como práctico, basándose en estudios previos sobre factores fisiológicos y demográficos que afectan la calidad del sueño [10].

Además, se evaluaron las correlaciones entre las variables y su peso relativo en el contexto del problema, lo que ayudó a seleccionar las variables más influyentes [6].

La selección de variables fue una de las etapas más importantes en este proceso. A partir del análisis teórico y práctico, se eligieron las variables más relevantes para el análisis de apnea del sueño y la calidad del sueño, tomando en cuenta no solo la literatura previa, sino también las correlaciones observadas en los datos. Se incluyeron variables relacionadas con las etapas del sueño, que proporcionan información sobre los patrones del sueño. Además, se consideraron variables que reflejan el estilo de vida y la salud física de los participantes, debido a su relevancia en la predicción de la calidad del sueño y la apnea.

El diagrama de caja negra muestra cómo las variables de entrada se utilizan en los modelos predictivos. El modelo genera dos salidas principales: Calidad del Sueño y Probabilidad de Apnea. Al adaptar los modelos para cada grupo, se busca una mayor precisión en las predicciones y recomendaciones, asegurando que las intervenciones sean específicas y efectivas para cada población.




Figura 3: Diagrama Caja Negra

3.4. Parte 3: Desarrollo y Evaluación de Modelos Predictivos

La tercera parte se centra en la construcción, evaluación y optimización de los modelos de aprendizaje automático.

Selección de Algoritmos: Para el desarrollo de los modelos predictivos, se compararon diversos algoritmos de aprendizaje automático, y finalmente se seleccionaron Random Forest, XGBoost y Regresión Logística debido a su desempeño superior en relación con el problema de predicción de la calidad del sueño y la apnea. Ambos algoritmos de Random Forest y XGBoost se eligieron principalmente por su capacidad para manejar un gran número de parámetros y su flexibilidad al adaptarse a diferentes escenarios. Estos algoritmos son particularmente útiles cuando se tienen muchos atributos de entrada, ya que permiten modelar relaciones no lineales complejas y capturan interacciones entre las variables, lo cual es esencial en el contexto de la apnea del sueño. Además, su robustez ante el sobreajuste y su capacidad para manejar datasets de tamaño medio, como el utilizado en este estudio, son ventajas signifi-

cativas en este tipo de análisis.

Por otro lado, Regresión Logística fue elegida debido a su simplicidad y eficiencia, especialmente considerando que el conjunto de datos utilizado no es muy grande. Este algoritmo es ideal para evitar el sobreajuste en situaciones con datos limitados, ya que proporciona interpretaciones claras sobre el impacto de cada variable en la predicción. Si bien es menos flexible que los modelos basados en árboles, su uso como modelo base ayuda a evitar modelos excesivamente complejos que podrían sobreajustarse a los datos.

Entrenamiento y Validación: Los modelos fueron entrenados utilizando el 80 % de los datos para el conjunto de entrenamiento y el 20 % restante para el conjunto de prueba. Este enfoque permitió evaluar el rendimiento del modelo en datos no vistos durante el proceso de entrenamiento, asegurando una evaluación más realista de su capacidad de generalización.

Durante la evaluación, se prestó especial atención a maximizar la precisión (accuracy) del modelo, ya que era importante que las predicciones fueran lo más precisas posibles. Se utilizó accuracy como la métrica principal, debido a su relevancia para medir el rendimiento general del modelo. Además, se evaluaron las predicciones con respecto al recall, que es especialmente importante en el contexto de la apnea del sueño, ya que garantiza que los casos de apnea sean correctamente identificados.

Optimización y Evaluación Final: En la fase de optimización, se realizaron ajustes a los hiperparámetros de cada modelo para mejorar su rendimiento. Inicialmente, se ajustaron manualmente siguiendo los parámetros base recomendados por la teoría y la documentación de cada algoritmo. Sin embargo, para obtener un rendimiento óptimo, se utilizó GridSearchCV, que permite explorar de manera exhaustiva las combinaciones posibles de hiperparámetros y encontrar aquellos que maximizan la precisión (accuracy) del modelo.

Para Random Forest y XGBoost, los hiperparámetros más importantes ajustados fueron:

Número de árboles: A mayor cantidad de árboles, mayor capacidad de generalización del modelo, pero también mayor tiempo de cómputo. Se evaluaron valores en un rango de 50 a 200 árboles.

Profundidad de los árboles: La profundidad controla cuán complejos son los árboles. Se probó con diferentes profundidades, desde valores pequeños (para evitar sobreajuste) hasta más grandes para capturar más interacciones.

Tasa de aprendizaje (learning rate): En XGBoost, la tasa de aprendizaje tiene un gran impacto en la convergencia y precisión del modelo. Se evaluaron valores entre 0.01 y 0.1 para ajustar la velocidad con la que el modelo actualiza los pesos durante el entrenamiento.

Para Regresión Logística, se enfocó principalmente en el parámetro de regularización C, que controla la penalización de los coeficientes en el modelo. Un valor demasiado bajo de C podría llevar a un modelo demasiado simple (underfitting), mientras que un valor alto puede causar un modelo demasiado complejo (overfit-

ting). Se evaluaron valores entre 0.01 y 10.

Después de realizar estos ajustes, se compararon los resultados de los modelos, y se determinó cuál de ellos proporcionó la mejor precisión sin incurrir en un sobreajuste. La optimización permitió que los modelos generaran predicciones más precisas y robustas.

3.5. Parte 4: Análisis de Resultados y Recomendaciones

La última parte se enfoca en la interpretación de los resultados y la formulación de recomendaciones basadas en el análisis realizado con la siguiente estructura.

Análisis de Resultados: Se centra en interpretar las principales variables influyentes en la predicción de la calidad del sueño y la apnea, así como en los patrones detectados en los subgrupos de participantes. Se evaluaron las correlaciones entre las variables y su impacto en la predicción, y se utilizó clustering para identificar subgrupos con características similares. Los hallazgos específicos se detallan en la siguiente sección de resultados, donde se exploran más a fondo las implicaciones de estos patrones.

Recomendaciones Personalizadas: A partir de los perfiles identificados, se desarrollaron recomendaciones específicas para los subgrupos con mayor riesgo de apnea o calidad del sueño reducida. Las intervenciones sugeridas están basadas en características fisiológicas y comportamentales, adaptadas a cada grupo.

Estrategias de Mejora y Futuras Investigaciones: Se proponen estrategias para futuras investigaciones, que incluyen la incorporación de nuevas variables y la optimización de los modelos. Se sugieren ajustes en la selección de características y el uso de técnicas avanzadas para mejorar la precisión de los modelos.

4. Resultados y Discusión

4.1. Análisis Exploratorio de Datos (EDA)

El análisis exploratorio de los datos (EDA) permitió obtener una visión general de las distribuciones y relaciones entre las principales variables del dataset. Durante este proceso, se examinaron las distribuciones de variables clave como edad, índice de masa corporal, AHI, y total de horas en el sueño.

A continuación, se muestra la matriz de correlación entre las variables más influyentes. Esta matriz destaca la relación entre variables como BMI, AHI, y Mean_SaO2, donde se observa una fuerte correlación entre BMI y AHI, así como una correlación negativa entre AHI y Mean_SaO2, lo que refuerza la importancia de estas variables en el diagnóstico y predicción de apnea del sueño.




Figura 4: Correlación de Variables Fisiológicas.

De este análisis se obtuvo que el BMI y AHI muestran una fuerte correlación, lo que indica que el sobrepeso y la obesidad están estrechamente relacionados con la severidad de la apnea. También se evidencio que la saturación del oxígeno en la sangre está inversamente correlacionado con el AHI, lo que es esperado dado que una mayor frecuencia de eventos de apnea reduce la saturación de oxígeno en sangre. Por ultimo, Las etapas del sueño también mostraron correlaciones interesantes, con un mayor tiempo en N1 (sueño ligero) asociado a una menor calidad del sueño, y un mayor tiempo en N3 (sueño profundo) correlacionado con una mejor calidad del sueño.

4.2. Predicción de Apnea y Calidad del Sueño

Los resultados para la predicción de apnea fueron evaluados utilizando Random Forest, XGBoost, y Regresión Logística. A continuación se analizan las métricas más importantes: accuracy, precision, recall, y F1-Score.

Modelo	Accuracy	Precision	Recall	F1-Score
Random Forest	0.902	0.87	0.9	0.87
XGBoost	0.91	0.87	0.92	0.86
Regresión Logística	0.893	0.85	0.89	0.86

Cuadro 1: Resultados para la Predicción de Apnea utilizando un conjunto de datos con un total de 1200 participantes del estudio Wisconsin Sleep Cohort [16][17].

En la predicción de apnea, XGBoost y Random Forest fueron los mejores modelos, con XGBoost obteniendo la accuracy más alta (0.91). Esto indica que ambos modelos fueron efectivos para hacer predicciones correctas en general. La accuracy alta de XGBoost muestra su capacidad para manejar un conjunto de datos complejo, capturando correctamente tanto los casos positivos como negativos. En comparación, Regresión Logística, a pesar de ser un modelo más simple, logró una accuracy de 0.893, lo cual es bueno, pero inferior a los modelos basados en árboles. La diferencia en los resultados se puede atribuir a que los modelos basados en árboles como XGBoost y Random Forest son más adecuados para manejar relaciones no lineales y capturar interacciones complejas entre las variables, lo cual

es crucial en este caso con variables como BMI y AHI.

Por otra parte, el recall es una métrica que nos funciona cuando se trata de detectar correctamente los casos positivos, como en la predicción de apnea, donde es importante identificar todos los casos de apnea posibles. XGBoost mostró el mejor recall (0.92), lo que significa que fue el modelo más efectivo para identificar todos los casos de apnea del sueño. La alta puntuación de recall de XGBoost confirma que, aunque Random Forest también obtuvo un buen recall de 0.90, XGBoost fue más eficiente en este aspecto. La Regresión Logística, por otro lado, presentó un recall de 0.89, que es aceptable, pero más bajo, lo que sugiere que este modelo no logró identificar correctamente tantos casos positivos de apnea como los modelos basados en árboles. Esta diferencia en el rendimiento puede atribuirse a la capacidad de XGBoost para manejar más interacciones entre las variables y su mayor flexibilidad en el ajuste de hiperparámetros.

La diferencia en el desempeño de XGBoost y Random Forest en comparación con Regresión Logística se debe, en gran parte, a la capacidad de los modelos basados en árboles para manejar datos más complejos y a su flexibilidad. XGBoost, en particular, sobresale porque es un algoritmo más robusto que puede manejar un mayor número de características y relaciones no lineales, lo que es crucial para datos como los de apnea del sueño, donde las interacciones entre las variables son complejas. Sin embargo, Regresión Logística muestra sus limitaciones cuando se enfrentan a conjuntos de datos más complejos y con múltiples interacciones entre variables. Los modelos más simples tienden a subajustar los datos en estos casos. Esto nos lleva a la elección de XGBoost, que no solo mostró los mejores resultados en términos de recall, sino también en accuracy.

Modelo	Accuracy	Precision	Recall	F1-Score
Random Forest	0.53	0.56	0.53	0.5
XGBoost	0.55	0.59	0.55	0.53
Regresión Logística	0.497	0.5	0.5	0.49

Cuadro 2: Resultados para la Predicción de Calidad del Sueño utilizando un conjunto de datos con un total de 1200 participantes del estudio Wisconsin Sleep Cohort [16][17].

En la predicción de calidad del sueño, los modelos mostraron un desempeño mucho más bajo que en la predicción de apnea. XGBoost obtuvo la mejor accuracy (0.55), mientras que Random Forest tuvo una accuracy de 0.53, y Regresión Logística alcanzó solo 0.497. La baja precisión en esta predicción se puede atribuir a la insuficiencia de datos, ya que la falta de una muestra suficientemente representativa de los participantes dificultó la capacidad de los modelos para generalizar los patrones de calidad del sueño. XGBoost, a pesar de ser el mejor modelo en este caso, aún tuvo dificultades debido a la escasez de datos.

El recall también fue bajo para todos los modelos, con XGBoost obteniendo el mejor recall (0.55). Sin embargo, Random Forest y Regresión Logística obtuvieron recall de 0.53 y 0.50, respectivamente, lo que indica

que los modelos no fueron capaces de identificar correctamente todos los casos de baja calidad del sueño. La baja calidad del sueño en los datos de entrenamiento, combinada con la limitación en la cantidad de muestras, causó que los modelos tuvieran dificultades para identificar correctamente los casos de calidad reducida del sueño.

En todo caso, los modelos de XGBoost y Random Forest fueron, nuevamente, más efectivos debido a su capacidad para manejar la complejidad de los datos, pero la limitación de datos fue un factor clave en su rendimiento. A pesar de que ambos algoritmos intentaron capturar las relaciones entre las variables, como las etapas del sueño y el BMI, la falta de datos adecuados para entrenar y validar correctamente los modelos generó alta variabilidad en los resultados. XGBoost fue más eficiente en capturar interacciones no lineales, pero los resultados aún fueron insatisfactorios debido a la insuficiencia de datos representativos para la calidad del sueño.

A pesar de la variabilidad observada en los resultados debido a la limitación en la cantidad de datos, los modelos XGBoost y Random Forest lograron buenos resultados en la predicción tanto de apnea como de calidad del sueño. Esta variabilidad es esperada, ya que un mayor volumen de datos permitiría reducir el error y mejorar la capacidad de generalización de los modelos. Sin embargo, los resultados obtenidos aún ofrecen insights valiosos sobre los factores que afectan la calidad del sueño y la apnea, y proporcionan un buen punto de partida para futuras investigaciones, donde la ampliación del conjunto de datos podría llevar a una mayor precisión y confiabilidad en las predicciones.

4.3. Importancia de las Variables

En el caso de la predicción de apnea, el análisis de importancia de las variables realizado con XGBoost mostró que las variables clave que influyen en la predicción de apnea son principalmente BMI, Mean_SaO2, y AHI. El gráfico de importancia de variables ilustra claramente que BMI es la característica más influyente, seguida por Mean_SaO2. Esta información respalda la relación bien establecida en la literatura, que indica que el índice de masa corporal elevado y la baja saturación de oxígeno son factores importantes para el riesgo de apnea del sueño.

El gráfico muestra cómo BMI tiene un peso considerable en el modelo, lo que es coherente con el hecho de que el sobrepeso y la obesidad son factores de riesgo conocidos para la apnea obstructiva del sueño. Mean_SaO2, que indica los niveles de oxígeno en sangre durante el sueño, también juega un papel importante, ya que las caídas en estos niveles son una señal característica de la apnea del sueño. Por otro lado, AHI (Índice de Apnea-Hipopnea) también es una variable significativa, como era de esperar, ya que directamente mide la severidad de la apnea y, por tanto, está directamente relacionada con la presencia de este trastorno.




Figura 5: Gráfico de Importancia Variables para Modelo de Apnea del Sueño.

En la predicción de la calidad del sueño, el gráfico de importancia de variables revela que las variables relacionadas con las etapas del sueño también son importantes para entender la calidad del sueño. De estas el tiempo total en la fase de sueño ligero y el tiempo total en sueño profundo son las más influyentes.

El gráfico refleja que el tiempo invertido en N1 (sueño ligero) tiene un impacto negativo en la calidad del sueño, lo que es consistente con la literatura, que sugiere que un aumento en esta fase puede estar relacionado con una menor calidad de descanso. Total_Time_N3, que corresponde al sueño profundo, es una variable positiva, ya que más tiempo en esta fase se asocia generalmente con una mejor calidad de sueño. Además, variables como Total_Sleep y Weekend_Sleep también son importantes, ya que el número total de horas de sueño, especialmente durante el fin de semana, afecta directamente la percepción de la calidad del sueño [6].

También se demuestra cómo las diferentes etapas del sueño tienen un peso diferencial en la calidad del sueño, sugiriendo que la cantidad de tiempo en sueño profundo (N3) es más indicativa de una buena calidad de sueño, mientras que una mayor proporción de sueño ligero (N1) puede indicar que el sueño no es reparador.




Figura 6: Gráfico de Importancia Variables para Modelo de Calidad del Sueño.

Esta información sobre la importancia de las variables obtenidas a partir de los modelos es extremadamente relevante para este estudio, ya que nos permite identificar las principales causas y factores que afectan la calidad del sueño y el riesgo de apnea. Al conocer

cuáles son las variables más influyentes, como BMI, Saturación de Oxígeno, y el tiempo en las etapas del sueño, podemos entender mejor qué aspectos fisiológicos y de comportamiento contribuyen a que una persona no duerma bien. Esta información será fundamental para, como se verá más adelante, segmentar a los participantes en subgrupos mediante el análisis de clustering, lo que nos permitirá generar recomendaciones personalizadas adaptadas a las necesidades específicas de cada grupo. Así, se podrá abordar de manera más efectiva los problemas relacionados con la apnea y la calidad del sueño, ofreciendo intervenciones más precisas y eficaces.

4.4. Segmentación por Clustering

Ahora, se utilizó el método de clustering para identificar subgrupos en los datos que comparten características similares. Esto nos permitió segmentar a los participantes en grupos específicos, lo cual es clave para hacer recomendaciones personalizadas en función de sus características fisiológicas y comportamentales. Los dos métodos empleados para determinar el número óptimo de clusters fueron el Método del Codo y el Coeficiente de Silueta, que nos ayudaron a encontrar la segmentación más adecuada.




Figura 7: Métodos para Obtención de Numeros de Clusters.

El Método del Codo es una técnica comúnmente utilizada para determinar el número óptimo de clusters en un conjunto de datos. Este método evalúa la suma de distancias cuadráticas de cada punto a su centroide para diferentes cantidades de clusters. A medida que se aumenta el número de clusters, la inercia disminuye, ya que los puntos dentro de cada cluster se agrupan más cerca de su centroide. Por otra parte, el Coeficiente de Silueta mide la separación entre los clusters, ayudando a determinar qué tan bien definidos están. Este coeficiente varía entre -1 y 1, donde un valor cercano a 1 indica que los puntos dentro de un cluster están bien agrupados y alejados de otros clusters. Un valor cercano a 0 sugiere que los puntos están en la frontera entre clusters, y valores negativos indican que los puntos podrían estar en el cluster equivocado.

Después de aplicar ambos métodos, 3 clusters fueron seleccionados como el número óptimo. La segmentación de los datos resultó en tres grupos bien diferenciados, con características específicas en términos de edad, índice de masa corporal, AHI, saturación de oxígeno, y otros factores fisiológicos y de estilo de vida. A

continuación, se presentan las características promedio de cada cluster:

Cluster 0:

Este grupo está compuesto principalmente por personas con características asociadas a una mayor prevalencia de apnea:

Índice de Masa Corporal: 33.21 (elevado, indica mayor riesgo de apnea).

Índice de Apnea-Hipopnea: 26.16 (alta frecuencia de apnea).

Saturación de Oxígeno Promedio: 94.91 (sugiere un mayor riesgo de apnea severa).

Tiempo en Sueño REM: Más tiempo en sueño REM en comparación con otros grupos.

Horas de Sueño entre Semana: 7.93 horas.

Prevalencia de Apnea: 1 (alta prevalencia de apnea).

Este cluster se caracteriza por un mayor riesgo de apnea, con un BMI elevado y una mayor prevalencia de apnea, lo que sugiere que los participantes en este grupo requieren intervenciones específicas para la apnea obstructiva del sueño.

Cluster 1:

Este grupo está compuesto por personas con un BMI moderadamente alto y características ligeramente distintas a las del Cluster 0:

Índice de Masa Corporal: 33.69 (moderadamente alto).

Índice de Apnea-Hipopnea: 25.04 (algo más bajo que en Cluster 0).

Saturación de Oxígeno Promedio: 94.51 (baja, pero superior a Cluster 0).

Horas de Sueño entre Semana: 6.17 horas (menor en comparación con Cluster 0).

Horas de Sueño en el Fin de Semana: 6.61 horas (menor en comparación con Cluster 0).

Prevalencia de Apnea: 0 (menor prevalencia de apnea comparado con Cluster 0).

Este cluster se caracteriza por un BMI elevado, pero con menor prevalencia de apnea en comparación con el Cluster 0, lo que sugiere que este grupo podría tener un riesgo moderado o bajo de apnea.

Cluster 2:

El tercer cluster está compuesto por personas con un BMI más bajo y una mayor calidad de sueño:

Índice de Masa Corporal: 29.34 (menor que en los otros clusters).

Índice de Apnea-Hipopnea: 11.79 (menor severidad de apnea).

Saturación de Oxígeno Promedio: 95.89 (alta saturación de oxígeno).

Tiempo en Sueño Profundo: 19.91 minutos (más tiempo en sueño profundo).

Horas de Sueño entre Semana: 6.91 horas.

Horas de Sueño en el Fin de Semana: 7.81 horas.

Prevalencia de Apnea: 0 (baja prevalencia de apnea).

Este cluster se caracteriza por un BMI más bajo y una mayor saturación de oxígeno, lo que sugiere que

los participantes en este grupo tienen una menor prevalencia de apnea y una mejor calidad del sueño, con un mayor tiempo en sueño profundo (N3).

La segmentación en tres clusters nos permitió identificar grupos de participantes con características fisiológicas y comportamentales similares. Estos clusters son muy relevantes para la formulación de recomendaciones personalizadas. Por ejemplo, las personas del Cluster 0, con BMI elevado y alta prevalencia de apnea, pueden beneficiarse de intervenciones centradas en la reducción de peso y tratamientos para la apnea, como el uso de CPAP. Los individuos del Cluster 2, con un BMI más bajo y menos problemas de apnea, podrían beneficiarse de recomendaciones sobre la higiene del sueño y mantener su estilo de vida saludable [5].

El uso de estas segmentaciones, combinadas con el análisis de importancia de variables, nos permite generar recomendaciones más específicas y dirigidas a las necesidades individuales de cada grupo.

4.5. Generación de Recomendaciones Personalizadas

Para finalizar el apartado de resultados, las recomendaciones personalizadas se basaron principalmente en dos fuentes clave de información: el análisis de importancia de variables y los resultados del clustering realizado mediante K-means. Aunque el clustering mediante K-means fue útil para segmentar a los participantes en tres grupos, se decidió priorizar la información derivada de la importancia de variables por encima del análisis de clusters, debido a la inestabilidad inherente a K-means. Como se discutió previamente, el algoritmo K-means puede ser sensible a la variabilidad en los datos y no siempre garantiza resultados consistentes, especialmente cuando se trabaja con un conjunto de datos limitado y con relaciones no lineales complejas. Por ello, el análisis de importancia de variables realizado con XGBoost proporcionó una base más sólida y confiable para la toma de decisiones.

Una vez que se identificaron las variables más relevantes a través del análisis de importancia, se combinó esta información con los resultados de clustering y con conocimientos técnicos adicionales sobre los trastornos del sueño para generar recomendaciones personalizadas [4]. Este enfoque integrado permitió considerar tanto las características fisiológicas clave (como BMI, Mean_SaO2, y las etapas del sueño) como los patrones de sueño específicos de cada grupo de participantes.

En la siguientes tablas se puede observar el resultado de las recomendaciones para 3 diferentes tipos de paciente, cada uno con características diferentes que los separa el clúster y el análisis de importancia de variables:

Categoría	Valor
Participante	1
Cluster	0
Calidad del Sueño	2 (Regular)
Tiene apnea del sueño?	1 (Sí)

Cuadro 3: Recomendaciones para el Cluster 0: Apnea Alta y BMI Elevado.

Recomendación: La persona tiene apnea del sueño con calidad de sueño regular. Consultar a un especialista para tratar la apnea y optimizar la calidad del sueño. El índice de masa corporal indica obesidad. Consultar con un nutricionista y aumentar la actividad física. Apnea severa detectada. Buscar tratamiento urgente, como el uso de CPAP. La saturación de oxígeno está dentro del rango normal. (Continuar con hábitos saludables). Presión arterial en prehipertensión. Adoptar un estilo de vida saludable para prevenir complicaciones. La duración del sueño es insuficiente. Dormir al menos 6 horas por noche.

Categoría	Valor
Participante	2
Cluster	1
Calidad del Sueño	2 (Regular)
Tiene apnea del sueño?	0 (No)

Cuadro 4: Recomendaciones para el Cluster 1: BMI Moderado y Bajo Riesgo de Apnea.

Recomendación: La persona no tiene apnea del sueño y calidad de sueño regular. Establecer horarios consistentes y priorizar el sueño. El índice de masa corporal indica obesidad. Consultar con un nutricionista y aumentar la actividad física. Evitar el consumo de alcohol y dormir de lado. La saturación de oxígeno está dentro del rango normal. (Continuar con hábitos saludables). Presión arterial en prehipertensión. Adoptar un estilo de vida saludable para prevenir complicaciones. La duración del sueño es insuficiente. Dormir al menos 6 horas por noche.

Categoría	Valor
Participante	3
Cluster	2
Calidad del Sueño	3 (Buena)
Tiene apnea del sueño?	0 (No)

Cuadro 5: Recomendaciones para el Cluster 2: Baja Apnea y Buen Sueño.

Recomendación: La persona no tiene apnea del sueño y calidad de sueño buena. (Mantener los hábitos actuales para un descanso saludable). El índice de masa corporal indica sobrepeso. Considerar cambios en la

dieta y ejercicio regular. El índice de apnea-hipoapnea es normal. (Mantener hábitos saludables). La saturación de oxígeno esta dentro del rango normal. (Continuar con hábitos saludables). La presión arterial esta en niveles normales. (Continuar con hábitos saludables). La duración del sueño es insuficiente. Dormir al menos 6 horas por noche.

5. Trabajo Futuro

El principal desafío identificado durante el desarrollo de este proyecto fue la limitación del tamaño del dataset. Sería ideal contar con un conjunto de datos mucho más grande y diverso, lo que permitiría mejorar la precisión de los modelos y, en consecuencia, aumentar la exactitud de las mediciones de eficiencia, como accuracy, recall y precision. Una mayor cantidad de datos proporcionaría una mejor representatividad de la población general y permitiría a los modelos aprender patrones más complejos de manera más efectiva.

En cuanto al trabajo futuro, sería particularmente interesante implementar el sistema de predicción de calidad del sueño y apnea en una aplicación móvil o asociada a dispositivos como smartwatches. Estos dispositivos podrían recoger datos en tiempo real sobre el sueño, como las etapas del sueño y la saturación de oxígeno, y alimentar el modelo predictivo. De esta manera, los usuarios podrían obtener recomendaciones personalizadas directamente en su dispositivo, lo que fomentaría una gestión proactiva de la salud del sueño.

Además, sería innovador aplicar una inteligencia artificial conversacional, como un chatbot basado en GPT o tecnologías como Google CX, que pueda interactuar con los usuarios de manera más fluida y personalizada. Este sistema de recomendación podría analizar los resultados de sueño y ofrecer sugerencias detalladas, adaptadas a cada individuo, basadas en millones de bases de datos médicas. La integración de un sistema de IA conversacional permitiría a los usuarios seguir una conversación sobre su calidad de sueño y recibir respuestas precisas y contextuales, mejorando la experiencia de seguimiento y tratamiento del sueño.

6. Conclusiones

El proyecto de grado alcanzó los objetivos generales y específicos planteados al inicio, proporcionando un análisis de los patrones de sueño y apnea mediante el uso de modelos predictivos basados en técnicas de aprendizaje automático. Se logró identificar las principales variables que influyen en la calidad del sueño y la prevalencia de la apnea, y se desarrollaron recomendaciones personalizadas para tres grupos de participantes segmentados por el análisis de clustering. La integración de métodos como XGBoost y K-means permitió obtener una segmentación relevante y recomendaciones precisas basadas en características fisiológicas y del comportamiento de los individuos.

Debido a las limitaciones de los datasets disponibles, que debido a su confidencialidad son relativamen-

te pequeños, el modelo obtenido tiene un alcance limitado en cuanto a la generalización de sus resultados. Aunque el tamaño de los datos influye en la precisión y robustez de los modelos, el desempeño de los algoritmos utilizados fue satisfactorio y permitió generar recomendaciones útiles para la mejora de la calidad del sueño de los participantes. A pesar de las restricciones en la cantidad de datos, se obtuvieron resultados valiosos que brindan una base sólida para futuras investigaciones.

A lo largo de este proyecto, he aprendido de manera práctica y teórica sobre el funcionamiento de los modelos de aprendizaje automático, particularmente sobre el uso de XGBoost, Random Forest, y Regresión Logística. La capacidad de estos modelos para manejar grandes volúmenes de datos y aprender patrones complejos fue muy interesante, y me permitió entender la importancia de seleccionar y ajustar adecuadamente los hiperparámetros. La experiencia adquirida en la implementación de estos modelos no solo me ha proporcionado un conocimiento técnico valioso, sino que también me ha dado herramientas para abordar otros problemas de predicción y clasificación en proyectos futuros.

Otro aspecto relevante del proyecto fue la integración de diferentes fuentes de datos y el análisis para generar recomendaciones personalizadas. Este enfoque me permitió comprender la importancia de la personalización en sistemas de salud, especialmente en el contexto del sueño. El uso de herramientas como XGBoost y el análisis de importancia de variables ofreció una visión más clara sobre cómo los diferentes factores, como el BMI, las etapas del sueño y la saturación de oxígeno, contribuyen a la predicción de apnea y calidad del sueño. Este aprendizaje puede aplicarse a otros campos relacionados con el bienestar, mostrando cómo los modelos predictivos pueden tener un impacto significativo en el diseño de sistemas de salud personalizados.

7. Agradecimientos

Quiero agradecer profundamente a mi familia, especialmente a mis padres, por su apoyo incondicional a lo largo de toda mi carrera universitaria. Han sido fundamentales para que pudiera alcanzar este logro. También agradezco a los profesores y mentores de la universidad por su ayuda constante, orientación y por contribuir significativamente a mi desarrollo académico y profesional.

Quiero expresar mi más sincero agradecimiento al National Sleep Research Resource (NSRR), especialmente a los responsables del Wisconsin Sleep Cohort Study, por permitirme acceder a los datos fundamentales para el desarrollo de este proyecto. Este estudio fue apoyado por el National Institutes of Health de los EE. UU., el National Heart, Lung, and Blood Institute (R01HL62252), el National Institute on Aging (R01AG036838, R01AG058680) y el National Center for Research Resources (1UL1RR025011). Además, el National Sleep Research Resource fue respaldado por

el National Institutes of Health de los EE. UU., el National Heart Lung and Blood Institute (R24 HL114473, 75N92019R002).

Referencias

- [1] Centers for Disease Control and Prevention (CDC). (n.d.). Sleep and Sleep Disorders. Recuperado de <https://www.cdc.gov/sleep/index.html>
- [2] Mayo Clinic. (2023). Obesity - Symptoms and Causes. Recuperado de <https://www.mayoclinic.org/diseases-conditions/obesity/symptoms-causes/syc-20375742​>
- [3] Cleveland Clinic. (2023). Body Mass Index (BMI): What It Is & How To Calculate. Recuperado de <https://my.clevelandclinic.org/health/articles/9464-body-mass-index-bmi​>
- [4] National Heart, Lung, and Blood Institute (NHLBI). (n.d.). What Is Sleep Apnea? Recuperado de <https://www.nhlbi.nih.gov/health-topics/sleep-apnea>
- [5] Luyster, F. S., Strollo, P. J., Zee, P. C., & Walsh, J. K. (2012). Sleep: A health imperative. *Sleep*, 35(6), 727-734.
- [6] Watson, N. F., Badr, M. S., Belenky, G., Bliwise, D. L., Buxton, O. M., Buysse, D., & Tasali, E. (2015). Recommended amount of sleep for a healthy adult: a joint consensus statement of the American Academy of Sleep Medicine and Sleep Research Society. *Journal of Clinical Sleep Medicine*, 11(6), 591-592.
- [7] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- [8] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer.
- [9] PhysioNet. (2022). DREAMT Telemetry Dataset. Recuperado de <https://physionet.org/content/dreamt/1.0.0/>
- [10] Academic Journal. (2024). The Impact of BMI on Sleep Apnea Severity. *Journal of Endocrinology and Metabolism*. Recuperado de <https://academic.oup.com>
- [11] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer.
- [12] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
- [13] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785-794).
- [14] Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression*. Wiley.
- [15] "Blood Pressure Definition," American Heart Association, 2023. Recuperado de <https://www.heart.org/en/health-topics/high-blood-pressure/understanding-blood-pressure-readings>.
- [16] Zhang GQ, Cui L, Mueller R, Tao S, Kim M, Rueschman M, Mariani S, Mobley D, Redline S. The National Sleep Research Resource: towards a sleep data commons. *J Am Med Inform Assoc*. 2018 Oct 1;25(10):1351-1358. doi: 10.1093/jamia/ocy064. PMID: 29860441; PMCID: PMC6188513.
- [17] Young T, Palta M, Dempsey J, Peppard PE, Nieto FJ, Hla KM. Burden of sleep apnea: rationale, design, and major findings of the Wisconsin Sleep Cohort study. *WMJ*. 2009 Aug;108(5):246-9. PMID: 19743755; PMCID: PMC2858234.