

See discussions, stats, and author profiles for this publication at: <https://www.researchgate.net/publication/327446205>

Aplicación de Deep Learning para la detección de Apnea e Hipoapnea del Sueño basado en Señales de Polisomnografía

Conference Paper · October 2016

CITATION

1

READS

1,443

3 authors:



[Diego Mellado](#)

Universidad de Valparaíso (Chile)

17 PUBLICATIONS 79 CITATIONS

[SEE PROFILE](#)



[Carolina Saavedra](#)

Universidad de Valparaíso (Chile)

38 PUBLICATIONS 256 CITATIONS

[SEE PROFILE](#)



[Rodrigo Salas](#)

Universidad de Valparaíso (Chile)

145 PUBLICATIONS 1,180 CITATIONS

[SEE PROFILE](#)

Aplicación de *Deep Learning* para la detección de Apnea e Hipoapnea del Sueño basado en Señales de Polisomnografía

Diego Mellado¹, Carolina Saavedra¹ y Rodrigo Salas¹

Abstract—La apnea del sueño es un trastorno donde la respiración de un individuo es obstruida mientras se está dormido, provocando respuestas fisiológicas acumulativas en el cuerpo, las cuales son asociadas a enfermedades cardiovasculares y metabólicas. En este contexto es necesario una herramienta que permita predecir con cierto grado de certeza eventos de apnea utilizando señales obtenidas a través de los exámenes de polisomnografía. En el presente artículo se diseñó una red neuronal profunda para clasificar eventos de apnea en señales de respiración. El desempeño fue comparado con modelos de *Máquinas de Vectores de Soporte (SVM)* y *Análisis de Discriminante Cuadrático (QDA)*. Los resultados obtenidos con la técnica propuesta de *Deep Learning* muestran que esta técnica logra superar significativamente el desempeño de clasificadores clásicos y ampliamente utilizados tales como SVM y QDA. Sin embargo al realizar un análisis detallado de la calidad de detección con los datos de Test, se observa que la técnica presenta dificultades y abre un espacio para futuras mejoras.

I. INTRODUCCIÓN

La apnea del sueño (SAS por su sigla en inglés) se refiere a la ocurrencia de pausas anormales en la respiración durante el sueño. Estas suelen durar desde algunos segundos a minutos y son causantes de respuestas inflamatorias, cardiovasculares y metabólicas; aumentando la morbilidad de los pacientes que padecen este síndrome. Estimaciones indican que este trastorno posee una prevalencia mundial de alrededor de un 3.1–7.5 % en hombres y entre 1.2–4.5 % en mujeres pre-menopáusicas; aumentando post-menopausia a los niveles vistos en hombres [1]. El estudio de esta enfermedad es altamente relevante desde el punto de vista de la salud pública debido a su incidencia, considerando que su diagnóstico y posterior tratamiento permite mejorar la calidad de vida y del sueño de los individuos afectados con esta enfermedad.

Para su diagnóstico se recomienda el uso de equipos de polisomnografía (PSG), los cuales se utilizan para diagnosticar trastornos del sueño, en un examen realizado de manera nocturna. En esta prueba se registran parámetros tales como el flujo aéreo naso-bucal, la actividad cardíaca mediante electrocardiografía (EKG), el índice de saturación de oxígeno (SPO_2), electroencefalografía (EEG), entre otros [2]. La cantidad de eventos de apnea registrados utilizando PSG por hora de sueño se registra y se estudia mediante el índice de apnea e hipopnea (Apnea Hypopnea Index, AHI en inglés).

En el presente artículo se analizará el desempeño de una red neuronal artificial profunda (*Deep Learning* en inglés)

frente al análisis de señales de flujo aéreo nasal de PSG en segmentos, según el tipo de evento de apnea presente. El modelo propuesto será comparado a dos métodos populares para realizar tareas de clasificación, Máquinas de Vectores de Soporte (*Support Vector Machine*, SVM) y Análisis de discriminante cuadrático (*Quadratic Discriminant Analysis*, QDA), a modo de evaluar el desempeño del modelo en el problema de detección de diferentes tipos de apnea.

El artículo se organiza en secciones, donde la sección II presenta el marco teórico, el cual comprende una revisión de los tipos de apnea y aplicaciones de Máquinas que Aprenden (*machine learning*) relacionadas al tema de estudio. La sección III presenta la base de datos utilizada y el modelo propuesto basado en *Deep Learning* para detectar diferentes tipos de apnea. Los resultados se encuentran en la sección IV. Finalmente, la sección V presenta las conclusiones y el trabajo futuro a desarrollar.

II. MARCO TEÓRICO

II-A. Estudio de polisomnografía

La polisomnografía (PSG) es un estudio principalmente utilizado para el diagnóstico de enfermedades relacionadas al sueño. Este examen permite la adquisición continua de múltiples señales relevantes para el estudio del sueño, tales como electrocardiografía (EKG), saturación parcial de oxígeno (spO_2), electroencefalografía (EEG), flujo de aire respiratorio, presión sanguínea, entre otros [2]. Este examen es el estándar clínico de referencia para el estudio de la apnea del sueño, pese a que puede incurrir en errores por parte del especialista quien analiza la información adquirida en este [3].

Gracias a este, se han logrado identificar cuatro tipos diferentes de eventos de SAS: (1) La **apnea obstructiva**, que corresponde al cese del flujo de aire con un intento de respirar; (2) la **apnea central**, donde existe un cese del flujo de aire sin intento de respirar; (3) la **Apnea Mixta**, la cual inicialmente se evidencia como apnea central pero se logra un intento de respirar y finalmente (4) la **hipoapnea**, donde no existe mayor consenso clínico, pero consiste en una disminución del flujo respiratorio. Todos estos eventos se deben producir por al menos 10 segundos según criterio clínico[4].

II-B. Machine Learning aplicado a la detección de Apnea

Recientemente ha habido un surgimiento de aplicaciones utilizando redes neuronales, y en especial técnicas de *machine learning* para la clasificación y predicción de eventos de apnea.

¹ Escuela de Ingeniería C. Biomédica, Universidad de Valparaíso. General Cruz 222, Valparaíso. Contacto: diego.mellado@postgrado.uv.cl

Una comparación de diferentes algoritmos tales como *AdaBoost*, *kNN*, *REPTree* para clasificar eventos de apnea mediante señales de SPO_2 y EEG se puede encontrar en [5].

Un ejemplo mas reciente, utilizando *Supersparse Linear Integer Models* en una serie de datos de PSG, junto al historial clínico logró crear un modelo predictivo de SAS [6], sus resultados indican que datos como la edad, sexo, IMC, entre otros permiten un mayor índice de predicción de SAS.

Como aplicación utilizando *Deep Learning* en SAS, [7] realizó la extracción de características mediante una red de *Autoencoders* en datos de EKG para evaluación de apnea para su uso en un sistema basado en dispositivos móviles.

III. MATERIALES Y MÉTODOS

III-A. Base de datos de PSG

Se utilizó la base de datos *MIT-BIH Polysomnographic Database* [8] disponible en *PhysioNet*. La versión pública de esta base de datos comprende 18 series de datos de PSG provenientes de 16 sujetos hombres entre 32–56 años (media 43) y peso entre 89–152 kg (media 119 kg). Se adquirieron señales de EKG, presión sanguínea, EEG y flujo respiratorio nasal muestradas a 250 Hz, además se incluyen anotaciones sobre el estado del sueño del sujeto y la presencia de hipoapnea, apnea obstructiva o apnea central, en secciones de 30 segundos para cada anotación. En el presente artículo se utilizaron señales de 8 sujetos distintos, proveniente de la base de datos mencionada, los cuales presentan más de un tipo de evento de apnea. Para realizar la clasificación sólo se utilizaron las señales de flujo respiratorio nasal. Un ejemplo con señal sin evento y para cada tipo de apnea se muestra en la figura 1.




Fig. 1. Señales de flujo respiratorio nasal.

III-B. Herramientas de Software para la implementación de Deep Learning, SVM y QDA

En los experimentos se utilizó el paquete de *TensorFlow* desarrollado por Google Brain Team, en el cual se representan series de operaciones matemáticas como nodos, agrupa-

dos en grafos y cuyos datos ingresados son interpretados como tensores [9]. Los algoritmos alternativos implementados son una *Support Vector Machine* de kernel lineal y el Análisis de Discriminante Cuadrático (*QDA*), ambos disponibles en la librería para Python *Scikit-Learn* [10].

III-C. Algoritmos utilizados

La técnica de *deep learning* se basa en el uso de múltiples capas de redes neuronales del tipo Perceptrón Multicapa para obtener un modelo representativo de los datos de forma más abstracta y de alto nivel. Esto permite aprender cómo las características presentes en la señal se relacionan entre ellas en forma tanto espacial como temporal [11], [12].

Su estructura se basa en la unión de múltiples capas de redes neuronales, basadas en neuronas artificiales de distintos tipos, según sean estas especificadas, y cuya salida es utilizada como entrada para la posterior capa de neuronas [13]. Este método ha permitido, gracias a la abstracción de la información que se realiza, el resolver diversos problemas basados en datos de alta dimensionalidad [12]. Entre los cuales se pueden mencionar la clasificación de imágenes, procesamiento de textos, entre otros.

Una de las funciones matemáticas comúnmente utilizadas como función de activación dentro de este tipo de redes es la función de unidad lineal Rectificadora (Rectified Linear Unit *ReLU*, en inglés), presentada en la ecuación (1).

$$f(x) = \max(0, x) \quad (1)$$

siendo x la entrada de la neurona.

Esta función de activación se acepta como un modelo más cercano a la biología, en comparación con la función sigmoidea, regularmente utilizada en redes neuronales [14].

En toda red neuronal puede existir problemas de sobre-ajuste, por lo que se ha planteado el uso de un modelo de desconexión (*dropout*) de neuronas de manera aleatoria (ecuación 2).

$$\begin{aligned} r_j^{(l)} &\sim \text{Bernoulli}(p), \\ \tilde{\mathbf{x}}^{(l)} &= \mathbf{r}^{(l)} \cdot \mathbf{x}^{(l)} \end{aligned} \quad (2)$$

donde $\mathbf{r}$ es un vector aleatorio de distribución Bernoulli con una probabilidad p de ser 1. El vector $\mathbf{x}$ corresponde a la entrada, previo a su aplicación a la neurona. Este método, aplicado en redes de múltiples capas, reduce el sobre-ajuste y mejora el desempeño de sistemas de clasificación, en especial en tareas de aprendizaje supervisado. [15]

III-D. Propuesta de arquitectura de Deep Learning

Se diseñó una red neuronal de 6 capas, cuya arquitectura se muestra en la figura 2. Se utilizó como función de activación la función *ReLU* como se evidencia en la ecuación 1, además de *dropout* de neuronas entre cada capa para evitar el sobre-ajuste del modelo.

$$\begin{aligned} \tilde{\mathbf{x}} &= \text{dropout}(p, \mathbf{x}) \\ f(\tilde{\mathbf{x}}) &= \mathbf{W}\tilde{\mathbf{x}} + b \\ \hat{\mathbf{y}} &= \text{ReLU}(f(\tilde{\mathbf{x}})) \end{aligned} \quad (3)$$

donde $\mathbf{x}$ es el vector de entrada, p la probabilidad del dropout. El vector $\tilde{\mathbf{x}}$ corresponde a la entrada desactivada, $\mathbf{W}$ es el vector de pesos de la neurona y b el *bias* de la función. Finalmente, la salida de la neurona es designada por $\tilde{y}$. El valor utilizado en la capa de entrada para el *dropout* fue de 0,8, y en las capas siguientes (ocultas) fue de 0,5. Cada capa de la red de entrenamiento tiene 750 neuronas cada una, sumando un total de 3750 unidades. La capa de salida esta compuesta de 4 neuronas, cada neurona entrega una probabilidad de que el dato de entrada corresponda a cierta etiqueta (tipo de apnea). La clase final de la señal corresponderá al $\arg\max(\tilde{\mathbf{y}})$ de las salidas de la capa de clasificación.

El costo de la red fue reducido mediante una función *softmax* para reducción de la entropía cruzada entre los valores predichos $\tilde{\mathbf{y}}$ y los valores de etiqueta reales de la señal $\mathbf{y}$, utilizando un algoritmo optimizador Adam [16].




Fig. 2. Arquitectura de la red neuronal *deep learning* utilizada.

III-E. Preparación del Conjunto de Entrenamiento

Se creó una matriz de datos con secciones de 30 s por tipo de anotación y tipo de señal en cada una de las señales. Se utilizó la señal de flujo de aire nasal obtenida del examen de PSG con un total de 4786 eventos, cada evento está compuesto de 7500 muestras. La lista de anotaciones de cada señal permitió agrupar la matriz en cuatro clases: (a) sin evento (2952 muestras); (b) hipoapnea (393 muestras); (c) apnea obstructiva (1408 muestras) y (d) apnea central (33 muestras). Cabe destacar que el problema de clasificación es multiclase, desbalanceado y altamente dimensional.

IV. RESULTADOS

Para la realización del experimento, se utilizó un computador HP con procesador Intel Xeon ES-2620 de 2.0 GHz×12 con una GPU Nvidia GeForce GTX960 de 4GB, con CUDA 7.5 y CudNN 5.1 para ejecutar los procesos en TensorFlow.

Se promediaron 20 experimentos en donde se separaron de manera aleatoria un 70 % de los datos para entrenamiento y un 30 % para el test.

IV-A. Medidas de desempeño

Se evaluó el desempeño calculando la exactitud (4), precisión (5), sensibilidad (*recall*) (6) y valor F (7) de cada clasificador en comparación a las clases obtenidas de las anotaciones disponibles de la señal realizadas por un experto en la base de datos. A continuación se presentan las ecuaciones de las medidas de desempeño:

$$\text{Exactitud} = \frac{VP + VN}{P + N} \quad (4)$$

$$\text{Precisión} = \frac{VP}{VP + FP} \quad (5)$$

$$\text{Sensibilidad} = \frac{VP}{VP + FN} \quad (6)$$

$$\text{Valor F} = \frac{2VP}{2VP + FP + FN} \quad (7)$$

En la tabla I se muestra el promedio de los 20 experimentos por cada clasificador, es posible apreciar que el modelo propuesto mejora los resultados de los otros clasificadores, mediante ANOVA se obtuvo que las diferencias obtenidas son estadísticamente significativas ($p < 0,01$) en comparación a los otros clasificadores.

TABLE I

RESULTADO DE COMPARACIÓN ENTRE ALGORITMOS DE CLASIFICACIÓN

	Deep Learning	QDA	SVM
Exactitud	0,682 ± 0,0149	0,416 ± 0,0106	0,617 ± 0,0147
Precisión	0,673 ± 0,0155	0,488 ± 0,0129	0,455 ± 0,1178
Sensibilidad	0,682 ± 0,0149	0,416 ± 0,0105	0,617 ± 0,0147
Valor F	0,674 ± 0,0149	0,438 ± 0,0086	0,473 ± 0,0184

Debido a que los datos presentan la característica de no estar balanceados, se analizó el desempeño del clasificador para cada clase mediante una matriz de confusión multiclase. La figura 3 corresponde a la matriz de confusión del algoritmo propuesto, en esta se evidencia que el clasificador sólo logra identificar de manera aceptable el estado normal y la apnea obstructiva. Sin embargo el clasificador manifiesta confusión al tratar de detectar la hipoapnea al confundirla con las señales sin evento, las razones podrían deberse a que las señales de hipoapnea tienen una forma muy similar a las de sin evento. Y por otro lado, no es capaz de detectar los eventos de Apnea Central, posiblemente esto puede deberse a la poca cantidad de datos presentes en su entrenamiento (24 en entrenamiento), por lo que el algoritmo no es capaz de aprender adecuadamente las características de la señal.

Con el fin de mejorar el desempeño de la detección de los eventos, se podrían utilizar las otras señales de PSG, como también podrían aplicarse técnicas de preprocesamiento y extracción de características. No obstante, los resultados obtenidos sirven como una línea base para futuras mejoras.

V. DISCUSIÓN Y CONCLUSIONES

En el presente trabajo se estudió el desempeño de una red de *deep learning* comparado con clasificadores clásicos frente a datos de respiración de PSG. Se demostró que el algoritmo diseñado es capaz de clasificar señales de flujo




Fig. 3. Matriz de confusión de clasificador basado en *Deep Learning*

respiratorio nasal para la detección de distintos tipos de apnea. Este problema posee cuatro clases diferentes, las que corresponden a hipoapnea, apnea central, apnea obstructiva y señales normales, es decir sin evento de apnea. Además, el algoritmo propuesto obtiene mejores resultados de desempeño, en comparación con dos algoritmos clásicos de clasificación, SVM y QDA. No obstante al realizar un análisis más cuidadoso del desempeño del clasificador, podemos observar que la técnica propuesta manifiesta confusión en la detección de los eventos. Sin embargo, los resultados obtenidos sirven como base para el desarrollo de futuras mejoras.

Una de las dificultades presentes al momento de evaluar los datos, corresponde a la baja cantidad de datos disponibles para algunas clases, lo cual influyó en el desempeño general de todas las máquinas. Por lo que se hace necesario aumentar el tamaño de la base de datos de entrenamiento y test.

Como trabajo futuro, se espera integrar otras señales obtenidas durante el examen de PSG para apoyar la toma de decisiones en la clasificación, a través de la expansión del modelo propuesto para extraer características de señales provenientes de fuentes diferentes. Además, se evaluará el uso de técnicas de sobremuestreo de datos, como por ejemplo los algoritmos SMOTE o ADASYN, para aumentar el conjunto de datos de las clases más desbalanceadas y así aumentar el desempeño del algoritmo.

REFERENCIAS

- [1] F. Nogueira, C. Nigro, H. Cambursano, E. Borsini, J. Silio, and J. Ávila, "Guías prácticas de diagnóstico y tratamiento del síndrome de apneas e hipopneas obstructivas del sueño," *Medicina (Buenos Aires)*, vol. 73, no. 4, pp. 349–362, 2013. [Online]. Available: <http://medicinabuenosaires.com/revistas/vol73-13/4/349-362-med5849-A.pdf>
- [2] C. Esquinas López, "Síndrome de apnea-hipopnea del sueño y factores de riesgo cardiovascular," *TDX (Tesis Doctorals en Xarxa)*, Dec. 2013. [Online]. Available: <http://repositori.udl.cat/handle/10803/131160>
- [3] C. A. Kushida, M. R. Littner, T. Morgenthaler, C. A. Alessi, D. Bailey, J. Coleman Jr, L. Friedman, M. Hirshkowitz, S. Kapen, M. Kramer *et al.*, "Practice parameters for the indications for polysomnography and related procedures: an update for 2005," *Sleep*, vol. 28, no. 4, pp. 499–521, 2005.

- [4] "SLEEP - Sleep-Related Breathing Disorders In Adults: Recommendations For Syndrome Definition And Measurement Techniques In Clinical Research," *SLEEP*, vol. 22, no. 5, 1999. [Online]. Available: <http://www.journalsleep.org/ViewAbstract.aspx?pid=24156>
- [5] B. Xie and H. Minn, "Real-Time Sleep Apnea Detection by Classifier Combination," *IEEE Transactions on Information Technology in Biomedicine*, vol. 16, no. 3, pp. 469–477, May 2012.
- [6] B. Ustun, M. B. Westover, C. Rudin, and M. T. Bianchi, "Clinical Prediction Models for Sleep Apnea: The Importance of Medical History over Symptoms," *Journal of Clinical Sleep Medicine*, vol. 12, no. 02, pp. 161–168, Feb. 2016. [Online]. Available: <http://www.aasmnet.org/jcsm/ViewAbstract.aspx?pid=30453>
- [7] A. Kaguara, K. M. Nam, and S. Reddy, "A deep neural network classifier for diagnosing sleep apnea from ECG data on smartphones and small embedded systems."
- [8] Y. Ichimaru and G. B. Moody, "MIT-BIH Polysomnographic Database," 1992. [Online]. Available: <https://doi.org/10.13026/C23K5S>
- [9] M. Abadi, A. Agarwal, P. Barham, E. Brevdo, Z. Chen, and *et al.*, "TensorFlow: Large-scale machine learning on heterogeneous systems," 2015, software available from tensorflow.org. [Online]. Available: <http://tensorflow.org/>
- [10] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [11] V. Dhar, "The Scope and Challenges for Deep Learning," *Big Data*, vol. 3, no. 3, pp. 127–129, Sep. 2015. [Online]. Available: <http://online.liebertpub.com/doi/abs/10.1089/big.2015.29000.vdb>
- [12] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015. [Online]. Available: <http://www.nature.com/nature/journal/v521/n7553/abs/nature14539.html>
- [13] J. Schmidhuber, "Deep learning in neural networks: An overview," *Neural Networks*, vol. 61, pp. 85–117, 2015. [Online]. Available: <http://www.sciencedirect.com/science/article/pii/S0893608014002135>
- [14] X. Glorot, A. Bordes, and Y. Bengio, "Deep Sparse Rectifier Neural Networks," in *Aistats*, vol. 15, 2011, p. 275. [Online]. Available: <http://www.jmlr.org/proceedings/papers/v15/glorot11a/glorot11a.pdf>
- [15] N. Srivastava, G. E. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: a simple way to prevent neural networks from overfitting," *Journal of Machine Learning Research*, vol. 15, no. 1, pp. 1929–1958, 2014. [Online]. Available: <http://www.jmlr.org/papers/volume15/srivastava14a.old/source/srivastava14a.pdf>
- [16] D. Kingma and J. Ba, "Adam: A method for stochastic optimization," *arXiv preprint arXiv:1412.6980*, 2014. [Online]. Available: <http://arxiv.org/abs/1412.6980>