

Escuela Politécnica Superior

20
21

Trabajo fin de grado

Correlación y predicción de señales de poligrafía nocturna



Andrés Mena Godino

Escuela Politécnica Superior
Universidad Autónoma de Madrid

Contacto: andresmenagodino@gmail.com

**UNIVERSIDAD AUTÓNOMA DE MADRID
ESCUELA POLITÉCNICA SUPERIOR**



Grado en Ingeniería Informática

TRABAJO FIN DE GRADO

**Correlación y predicción de señales de poligrafía
nocturna**

**Autor: Andrés Mena Godino
Tutor: Pablo Varona Martinez**

mayo 2021

Todos los derechos reservados.

Queda prohibida, salvo excepción prevista en la Ley, cualquier forma de reproducción, distribución comunicación pública y transformación de esta obra sin contar con la autorización de los titulares de la propiedad intelectual.

La infracción de los derechos mencionados puede ser constitutiva de delito contra la propiedad intelectual (*arts. 270 y sgts. del Código Penal*).

DERECHOS RESERVADOS

© 3 de Noviembre de 2017 por UNIVERSIDAD AUTÓNOMA DE MADRID

Francisco Tomás y Valiente, nº 1

Madrid, 28049

Spain

Andrés Mena Godino

Correlación y predicción de señales de poligrafía nocturna

Andrés Mena Godino

Grupo de neurocomputación biológica

Departamento de Ingeniería Informática

Escuela Politécnica Superior

IMPRESO EN ESPAÑA – PRINTED IN SPAIN

RESUMEN

En este trabajo de fin de grado se aborda el estudio del tratamiento de datos para la recomendación de diagnóstico del síndrome de la apnea de sueño, con el objetivo de intentar extraer conclusiones para simplificar el diagnóstico de la enfermedad. El método referente para la detección de esta patología es la poligrafía nocturna, prueba en la que se registran simultáneamente múltiples señales del paciente como el flujo respiratorio, frecuencia cardíaca, nivel de saturación en sangre, movimientos corporales y el sonido mientras el paciente duerme, entre otras. La información para llevar a cabo el estudio ha sido proporcionada por el Hospital Fundación de Alcorcón, en particular se ha dispuesto de datos de la prueba de poligrafía nocturna domiciliaria de 55 pacientes.

Un requisito previo para llevar a cabo el estudio ha sido el tratamiento de los datos anonimizados de cada uno de los pacientes a partir del registro hospitalario, el cual se puede monitorizar usando la herramienta Noxturnal. Tras un proceso de exportación a formato CSV, se ha utilizado el lenguaje de programación Python para llevar a cabo el estudio.

El primer objetivo del trabajo ha sido la caracterización de señales de la poligrafía nocturna en términos de la correlación entre las principales señales que se registran en esta prueba, así como el estudio del retraso existente entre las mismas. La principal conclusión extraída de este estudio ha sido que las señales de pulso y saturación de oxígeno se encuentran muy correlacionadas, y no están retrasadas la una frente a la otra. Esto nos ha sido de utilidad a la hora de mejorar el modelo de aprendizaje para la predicción de la señal de saturación.

El segundo objetivo del trabajo ha sido la predicción de la evolución de la señal de saturación. Dicha señal tiene una relevancia especial, ya que los episodios de apnea generalmente se encuentran acompañados de una desaturación. En este contexto, si somos capaces de predecir cuando un paciente va a sufrir una desaturación, podríamos alertar de un potencial episodio de apnea y tomar alguna medida preventiva. Para ello se han aplicado el algoritmo del perceptrón multicapa con una codificación temporal, y la red neuronal recurrente LSTM. Los mejores resultados se han obtenido con la red LSTM, haciendo uso de las señales del pulso y la saturación para predecir la evolución de la saturación.

PALABRAS CLAVE

Poligrafía nocturna, trastorno de sueño, apnea, correlación señales de origen biológico, retraso en series temporales multivariadas, predicción de series temporales biológicas, redes neuronales, perceptrón multicapa, redes neuronales recurrentes, LSTM

ABSTRACT

This end-of-degree project is a study on the data processing for the diagnosis and recommendation of the sleep apnea syndrome, with the aim of trying to draw conclusions to simplify the diagnosis of the disease. The reference method for the detection of this pathology is the overnight polygraphy, a test in which several body signals such as air flow, heart rate, oxygen level in blood, body movements and sound are collected simultaneously from the patient while he is sleeping, among others. The information to carry out this study has been provided by the Fundación of Alcorcón Hospital, in particular data from 55 patients who underwent the at-home version of the overnight polygraphy.

A prerequisite for carrying out this study was the treatment of anonymized data from the patients, from which we had the hospital record stored in the Noxturnal software platform. After a process of exporting the data to CSV format, the data has been treated using the programming Language Python in order to carry out the study.

The first objective of this project has been the characterization of the signals collected during the overnight polygraphy in terms of correlation between the main signals of the sleep study, as well as the delay between the signals. The main conclusion drawn from this study has been that the heart rate and the oxygen level in blood are highly correlated, and there is no delay between them. This has been very useful for improving the learning model for the prediction of the evolution of the oxygen level signal.

The second objective of this project has been the prediction of the evolution of the oxygen level signal. This signal has a special relevance, given that the apnea episodes are usually followed by a desaturation. In this context, if we are able to predict when a patient is going to suffer a desaturation, we could take into account this potential apnea episode and take a preventive action. For this purpose, we have applied the multilayer perceptron algorithm with a temporary encoding, as well as the recurrent neural network LSTM. We have achieved better results with the LSTM, making use of the heart rate and the oxygen level signals in order to predict the evolution of the oxygen level.

KEYWORDS

Overnight polygraphy, sleep disorder, apnea, correlation between biological signals, delay in multivariate time series, prediction of biological time series, neural networks, multilayer perceptron, recurrent neural networks, LSTM

ÍNDICE

1	Introducción	1
1.1	Poligrafía Nocturna	2
1.2	Apnea	3
1.3	Estudio series temporales	4
2	Estado del arte	5
3	Diseño e Implementación	7
3.1	Extracción y lectura datos	7
3.1.1	Noxturnal exportación directa - EDF	7
3.1.2	Noxturnal y Macro Recorder - CSV	8
3.2	Estudio correlación señales poligrafía nocturna	11
3.2.1	Diseño Arquitectura	11
3.2.2	Análisis de coeficientes de correlación	14
3.2.3	Análisis del retraso temporal en la correlación de señales	15
3.3	Predicción evolución variables	17
3.3.1	Preprocesado señal	17
3.3.2	Preparación dataset	20
3.3.3	Predicción multipaso y métricas	21
3.3.4	Perceptrón multicapa con codificación temporal recurrente	22
3.3.5	Redes neuronales recurrentes - LSTM	22
4	Experimentos y resultados	25
4.1	Correlación entre señales de la poligrafía nocturna	25
4.2	Predicción evolución saturación	30
4.2.1	Perceptrón multicapa	30
4.2.2	LSTM	36
5	Conclusiones y trabajo futuro	39
	Bibliografía	43
	Definiciones	45
	Acrónimos	47
	Apéndices	49
A	Código y documentación	51

B Figuras	53
C Tablas	67

LISTAS

Lista de ecuaciones

3.2a	Ejemplo predicción multipaso redes neuronales	21
3.3	Raíz de error cuadrático medio	22

Lista de figuras

1.1	Episodio de apnea en Noxturnal	3
3.1	Análisis tramo 1s Noxturnal	10
3.2	Diagrama UML Paciente	12
3.3	Diagrama de secuencia Paciente	13
3.4	Mapa de calor matriz de correlación 1 paciente	14
3.5	Diagrama de explicación de cálculo retraso señal	15
3.6	Ejemplo cálculo retraso señal	16
3.7	Ejemplo retraso señal de pulso frente a saturación	16
3.8	Suavizado de la señal de saturación	18
3.9	Valores artefactos señal de saturación	18
3.10	Eliminar valores artefactos señal de saturación	19
3.11	Distribuciones de valores más frecuentes de señal de saturación	19
3.12	Diagrama de preparación de muestras usando ventana deslizante	20
3.13	Diagrama división en conjuntos de entrenamiento, validación y test	21
3.14	Diagrama estructura red perceptrón multicapa con codificación recurrente	23
3.15	Diagrama estructura red neuronal recurrente LSTM	23
4.1	Mapa de calor matriz correlación múltiples pacientes	26
4.2	Correlación saturación frente a pulso en función de IAH	26
4.3	Representación correlación señales frente a saturación en función del IAH	28
4.4	Representación retraso señales frente a saturación en función del IAH	29
4.5	Evolución RMSE en función del número capas MLP. Predicción 1 observación	31
4.6	Evolución RMSE en función de número capas MLP. Predicción 30 observaciones	32
4.7	Comparativa RMSE en predicciones multipaso MLP	34
4.8	Predicción de desaturación en el contexto de una evento de apnea	34
4.9	Matrices confusión predicción episodio desaturación. Señal suavizada	35

4.10	Matrices confusión predicción episodio desaturación. Señal sin preprocesar	36
4.11	Resultados LSTM usando únicamente la señal de saturación	38
4.12	Resultados finales LSTM con señales de saturación y pulso	38
B.1	MacroRecorder para llevar a cabo la exportación de forma automatizada	53
B.2	Representación correlación señales frente a abdomen en función del IAH	54
B.3	Representación retraso señales frente a abdomen en función del IAH	55
B.4	Representación correlación señales frente a actividad motora en función del IAH	56
B.5	Representación retraso señales frente a actividad motora en función del IAH	57
B.6	Representación correlación señales frente a nivel de sonido en función del IAH	58
B.7	Representación retraso señales frente a nivel de sonido en función del IAH	59
B.8	Representación correlación señales frente a pulso en función del IAH	60
B.9	Representación retraso señales frente a pulso en función del IAH	61
B.10	Representación correlación señales frente a ronquido en función del IAH	62
B.11	Representación retraso señales frente a ronquido en función del IAH	63
B.12	Comparativa tramo real frente a tramo predicho señal saturación	64
B.13	Comparativa RMSE en predicciones multipaso MLP sobre paciente desconocido	65
B.14	Matrices confusión predicción episodio desaturación sobre paciente desconocido, MLP	66

Lista de tablas

3.1	Frecuencia de muestreo de las señales de la poligrafía nocturna	8
4.1	Resultados MLP predicción 1 observación	32
4.2	Resultados MLP predicción 30 observaciones	33
4.3	Mejores estructuras de MLP para predicción señal saturación	33
C.1	Resultados completos MLP predicción múltiples observaciones	67
C.2	Resultados completos MLP predicción 1 observación	68

INTRODUCCIÓN

Existen múltiples enfermedades de trastorno del sueño, las cuales reducen la calidad y cantidad de sueño de las personas que la sufren y que afectan a una gran parte de la población mundial. En particular, acorde con la American Sleep Association (ASA), en la sociedad estadounidense se estima que hay 50-70 millones de personas afectadas por algún trastorno de sueño (un 18 % de la población total) [1]. Dichos trastornos se encuentran clasificados según sus síntomas [2], siendo uno de estos los trastornos respiratorios (identificados por una alteración del flujo respiratorio), en donde predominan la apnea e hipopnea. La ASA reporta que 25 millones de adultos padece el síndrome de apnea obstructiva del sueño (SAS), representado por un 9-21 % de mujeres y un 24-31 % de hombres, cifras similares a las que reportan otros estudios del año 2020, que apuntan a un 17 % en mujeres y un 34 % en hombres [3]. Estos porcentajes representan únicamente una aproximación, ya que se estima que alrededor de un 90 % de las personas con SAS no se encuentran diagnosticadas [4].

El principal indicativo de existencia de dicha enfermedad es el cansancio a lo largo del día, aunque muchos pacientes son asintomáticos [3]. Otros efectos dañinos que tiene el SAS son la depresión, reducción de los niveles de alerta y reflejos, así como el aumento de la ansiedad, llegando a niveles más extremos en los que si no se trata correctamente, la esperanza de vida del paciente puede llegar a disminuir. Dicha enfermedad se manifiesta durante el sueño de la persona, en el que tienen lugar episodios repetidos en los que se interrumpe el flujo de aire del paciente. El método referente para el diagnóstico del SAS es la prueba de poligrafía nocturna, con la que analizando la evolución de ciertas señales del paciente, se puede determinar si este sufre o no apnea, y en qué grado de severidad.

Respecto al tratamiento de la enfermedad, se han explorado diferentes alternativas, pero a día de hoy no existe un fármaco capaz de controlar esta patología. Las técnicas actuales contemplan desde cambios llevados a cabo en el propio paciente (perder peso y hacer ejercicio regular), hasta tratamientos con dispositivos de presión positiva continua en las vías respiratorias (CPAP), sistemas bucales para desplazar la mandíbula durante el sueño, o incluso operaciones faciales o de vías respiratorias para mejorar el flujo de aire [3].

Los objetivos principales de este trabajo son dos: Por una parte, se desea caracterizar la correlación existente entre las distintas señales recogidas en la poligrafía nocturna. Por otra parte, con la

información proporcionada en la serie temporal de la saturación, se desea ser capaz de predecir cómo va a evolucionar la misma mediante la aplicación de algoritmos de inteligencia artificial. El motivo de escoger dicha señal para realizar su predicción es que el índice de desaturaciones por hora (ID) es un factor que se encuentra muy relacionado con el índice de apneas e hipopneas por hora (IAH), y generalmente un episodio de apnea va acompañado de una desaturación, por lo que es una señal interesante de estudiar para proponer soluciones en el contexto del tratamiento de la enfermedad. Cabe destacar que el ID e IAH no son equivalentes [5], pero en ausencia de otras señales, como puede ser el flujo respiratorio, puede resultar un buen indicativo.

La información disponible para llevar a cabo este estudio ha sido proporcionado por el Hospital Fundación de Alcorcón¹. En particular, se dispone de la información de la prueba de poligrafía nocturna domiciliar de 55 pacientes. De las señales disponibles en la prueba, se han considerado de interés a efectos del estudio del SAS las siguientes:

- 1.— Abdomen y Activity: Registran el movimiento abdominal y la actividad motora del paciente respectivamente.
- 2.— Snore y Audio Volume dB: Representan el ronquido del paciente y el nivel de sonido durante el sueño del paciente.
- 3.— Flow y Presión Nasal: Representa el flujo de aire y el bloqueo de las vías respiratorias, por lo que se espera que sean señales inversas; El crecimiento de una implica decrecimiento de la otra y viceversa.
- 4.— Pulso: Registra el pulso instantáneo del paciente.
- 5.— SpO2 (saturación): Representa la evolución del nivel de saturación en sangre.

Sobre dichas señales, se encuentran etiquetados los episodios de apnea e hipopnea que ha sufrido el paciente, así como las desaturaciones que ha sufrido el mismo a lo largo de la noche estudiada. Dicha información se puede visualizar mediante el uso de la herramienta Noxturnal².

1.1. Poligrafía Nocturna

La poligrafía nocturna es una prueba realizada en hospitales, en la que se monitoriza al paciente durante el sueño. En dicha prueba se monitorizan múltiples señales como el flujo respiratorio, frecuencia cardíaca, saturación en sangre, sonidos, ronquidos y movimientos corporales entre otras [6]. El objetivo principal de esta es analizar la calidad del sueño de paciente, y en particular se utiliza para detectar el SAS.

Existen diferentes alternativas a la poligrafía nocturna en hospital, como es la poligrafía nocturna domiciliar (realizada por paciente desde su domicilio sin la supervisión de un médico), o usar dispositivos que capturen un menor número de señales, como puede ser únicamente un oxímetro o un medidor de flujo de aire. Sin embargo, la prueba de referencia y que sigue proporcionando una mayor

¹ Página web del hospital: <https://www.comunidad.madrid/hospital/fundacionalcorcon/>

² Software para el manejo de las grabaciones nocturnas <https://noxmedical.com/products/noxturnal-software/>

fiabilidad, en cualquiera de sus modalidades hospitalaria y domiciliaria, es la poligrafía nocturna.

1.2. Apnea

Para ilustrar un episodio de apnea, podemos hacer uso de la herramienta noxturnal, tal y como observamos en la figura 1.1. Podemos ver que el episodio queda definido por el tramo en el que se ha interrumpido el flujo de aire (señal Flow).




Figura 1.1: Visualización de episodio de apnea en Noxturnal. Se puede observar que tras el episodio de apnea, tiene lugar una desaturación del 7 %.

De forma adicional, podemos observar en la figura 1.1 que tiene lugar un episodio de desaturación del 7 % tras el episodio de apnea, el cual también viene indicado en las etiquetas de la señal. Dicho comportamiento (evento de obstrucción, seguido de una desaturación), es el comportamiento esperado en un episodio de apnea, por lo que tanto el flujo como la señal de saturación serán las señales en las que centraremos el estudio.

Lo primero que se desea estudiar en este trabajo es cómo de correlacionadas están las señales que se están estudiando. Este análisis permite seleccionar señales candidatas para simplificar la tarea de análisis y proponer nuevos mecanismos de recomendación de diagnóstico. Antes de proceder a dicho análisis, deberán tenerse en cuenta dos factores:

- Cada señal tiene una frecuencia de muestreo diferente (por ejemplo, la frecuencia de muestreo de la saturación es de 3 Hz, mientras que el flujo de aire tiene una frecuencia de 200 Hz). Por esto motivo, será necesario submuestrear o interpolar información, en función de lo que nos proporcione mejores resultados.
- Algunas señales pueden ir retrasadas respecto a otras, tal y como hemos visto en la figura 1.1 con el flujo de aire y la saturación. Por ello, no solo se desea calcular la correlación entre las señales, sino también cuantificar el retraso temporal entre las señales.

1.3. Estudio series temporales

El objetivo de este trabajo, es utilizar las señales más significativas disponibles en la poligrafía nocturna y realizar un estudio sobre las mismas. Dicho estudio se puede dividir en dos objetivos principales:

- O-1.**– Estudio de la correlación entre las distintas señales de la prueba. Comprobar si esta correlación tiene algún tipo de dependencia con el IAH.
- O-2.**– Realizar una predicción local de la evolución de la señal del nivel de saturación en sangre del paciente.

Para llevar a cabo el primer objetivo, tal y como se ha comentado en la sección 1.2, se deberá analizar la correlación entre las señales desde dos puntos de vista: El punto en el que se estudia dicha relación de forma global para toda la señal sin desplazar, y el punto de vista en el que se estudia cómo evoluciona la correlación al desplazar alguna de las señales. De igual forma, será necesario calcular los índices de ID, IA e IAH para comparar los niveles de correlación con la severidad del SAS del paciente.

Respecto al segundo objetivo, en primer lugar se va a estudiar la aplicación de redes neuronales tradicionales, en particular el algoritmo del Perceptron multicapa (MLP) con una codificación que permite representar la estructura temporal de la señal, para la predicción de la evolución de la señal de saturación. Una vez estudiados los resultados, se aplicarán también redes neuronales recurrentes, en particular Long short-term memory (LSTM) , que son redes neuronales diseñadas específicamente para el tratamiento de series temporales. Con estos resultados, se realizará un estudio de si es posible predecir la evolución de dicha serie temporal, y bajo qué condiciones se pueden tomar como válidos los resultados obtenidos.

ESTADO DEL ARTE

Los estudios más recientes (2020) reportan que alrededor de un 17 % en mujeres y un 34 % de hombres sufren el SAS [3]. Dichos porcentajes corresponden a estudios realizados en la población de Estados Unidos, pero tiene una prevalencia similar en otros países. De igual forma, se estima que existe un gran porcentaje de personas sin diagnosticar (alrededor del 90 %) [4] por ser asintomáticas.

El SAS se define como la repetición de episodios en los que se interrumpe de forma parcial o total el flujo de aire durante la etapa de sueño [7]. Dichos episodios se pueden clasificar de dos formas: Apnea obstructiva o hipopnea. La apnea obstructiva se define como un descenso en el flujo respiratorio $\geq 90\%$ durante un periodo mínimo de 10 segundos, mientras que en la hipopnea el descenso tiene que ser $\geq 30\%$ acompañado de una caída del nivel de saturación en sangre $\geq 3\%$ o una excitación [8,9]. A partir de estos criterios, se pueden calcular el índice de apneas por hora (IA), índice de hipopneas por hora (ID) o IAH.

Respecto al diagnóstico de los pacientes que padecen dicha patología, existen múltiples dispositivos que se usan para monitorizar y poder detectar así el SAS [10]. Estos se dividen en dispositivos de tipo 1 (poligrafía nocturna en hospital), tipo 2 (poligrafía nocturna domiciliaria), tipo 3 (sistema de grabación con un mínimo de 4 canales) y tipo 4 (dispositivo de captación de una única señal). Los detalles y los resultados obtenidos en múltiples experimentos realizados con cada tipo de dispositivo se encuentran recopilados en [6]. El método que proporciona una mayor fiabilidad es la poligrafía nocturna en hospital seguida por la versión domiciliaria, pero el aspecto negativo es que son las que tienen un mayor coste, por lo que no siempre están disponibles. Un ejemplo de dispositivo de tipo 4 usado en ocasiones para la detección del SAS es el oxímetro, que mide únicamente el nivel de saturación en sangre, incluso existen alternativas más avanzadas que no solo sirven como dispositivo de detección sino también de tratamiento, como es el caso de la almohada inteligente publicada en [11, 12]. Otro método de tipo 4, basado en evaluar únicamente el flujo respiratorio del paciente [10], también ha demostrado obtener resultados significativamente buenos a la hora de identificar la presencia de SAS en un paciente que use el dispositivo durante varias noches.

En la actualidad, existen diversos métodos para tratar a los pacientes con SAS. En primer lugar existen tratamientos que no requieren dispositivos médicos que han demostrado ser efectivos, como

son la pérdida de peso, hacer ejercicio de forma regular y reducir el consumo de alcohol [13, 14]. En caso de que los anteriores no proporcionen buenos resultados, el método con mayor tasa de éxito es usar un dispositivo de CPAP, con el que se evita la interrupción del flujo de aire. Sin embargo, este dispositivo puede causar molestia a los pacientes y sensación de claustrofobia, y existen otras alternativas como el dispositivo de avance mandibular (MAD), con el que se corrige la posición de la mandíbula para permitir un mayor flujo de aire y ha demostrado obtener buenos resultados en el tratamiento del SAS [15]. Otros métodos a mencionar son la estimulación de la vía aérea superior [16], en el que pequeñas cargas eléctricas estimulan la lengua al dormir para facilitar la respiración. Finalmente destacar que existen otras alternativas más simples (pero generalmente menos efectivas) que tratan de solucionar la patología evitando que la persona duerma boca arriba, dado que esto suele incrementar el IAH [17], mediante la colocación de objetos en la cama que lo eviten (como una pelota de tenis [18]), o con sistemas que proporcionan pequeñas vibraciones en función de la posición del paciente [19]. Como última alternativa, en caso de que ninguno de los tratamientos previamente mencionados proporcionen buenos resultados, sería proceder a la cirugía, siendo la más común la uvulopalatofaringoplastia, en la que se elimina el tejido sobrante en la garganta para abrir las vías respiratorias superiores. Dicha cirugía reporta tener buenos resultados para aquellos pacientes que no pueden usar el CPAP [20].

La consecuencia y principal síntoma del SAS es el cansancio durante el día, debido a la falta de tiempo de descanso de calidad [21]. Otros síntomas y efectos de la enfermedad son alteraciones en el tiempo de reacción, nivel de alerta, depresión y ansiedad. Se han realizado estudios que confirman que aplicando el método de CPAP durante un corto plazo (12 meses), se ha reducido el nivel de cansancio y aumentado el de alerta, indicando mejoría en la situación del paciente [22]. Finalmente destacar que, a largo plazo, la apnea es un factor de mortalidad si no se trata de forma correcta [23–25]. Cabe destacar que muchos pacientes son asintomáticos, por lo que no padecen estos síntomas y por lo tanto no reciben ningún tratamiento, lo cual puede ser perjudicial a largo plazo.

DISEÑO E IMPLEMENTACIÓN

A lo largo de esta sección, se explicarán en detalle las decisiones de diseño que se han tomado, así como su implementación, respaldadas por el objetivo que perseguían estas decisiones. El lenguaje utilizado para desarrollar el proyecto ha sido Python, por la facilidad que proporciona a la hora de manejar conjuntos de datos complejos, y por las implementaciones de librerías externas de algoritmos de aprendizaje automático.

3.1. Extracción y lectura datos

La información disponible para realizar el estudio es la información de las señales de la prueba de poligrafía nocturna aplicada sobre 55 pacientes, a través de un dispositivo que almacena la información en formato .ndf. Dicha información puede ser interpretada usando el Software de Noxturnal ¹, el cual interpreta las series temporales, sincronizando las mismas teniendo en cuenta las diferentes frecuencias de muestreo. Por ello, para poder analizar los datos, el primer paso necesario era exportarlos a un formato a partir del cual pudiésemos extraerlos usando Python. La primera aproximación fue usar una opción de exportación proporcionada por Noxturnal de forma nativa y sencilla, con la cual obtuvimos cierta información relevante pero no suficiente, por lo que se recurrió a usar una herramienta adicional para llevar a cabo la exportación de forma “automatizada”.

3.1.1. Noxturnal exportación directa - EDF

En un primer momento, se optó por exportar los datos a formato European Data Format (EDF), el cual se define como un *“formato simple y flexible para el intercambio y almacenamiento de señales multicanal biológicas y físicas”* ². Con la información de un paciente exportada en dicho formato, se hizo uso de la librería de python pyEDFlib ³ para poder leer dicha información. Analizando la información leída, se pudo obtener la frecuencia de muestro de las variables que eran de interés, tal y como

¹<https://noxmedical.com/products/noxturnal-software/>

²<https://www.edfplus.info/>

³<https://pypi.org/project/pyEDFlib/>

vemos en la tabla 3.1. La información de dicha tabla nos permite observar que se trata de una serie temporal multivariada, y nos servirá a la hora de estudiar la correlación entre las señales y para tomar una decisión sobre qué variables es necesario interpolar o submuestrear.

	Frecuencia Muestreo (Hz)	Almacenamiento señal (MB)
Flujo de aire	200	35.19
Presión nasal	200	33.72
Ronquido	200	38.36
Abdomen	20	4.44
Volumen de audio	20	2.55
Actividad motora	10	1.70
Pulso	3	0.19
SpO2	3	0.19

Tabla 3.1: Frecuencia de muestreo de las señales registradas durante la poligrafía nocturna. El tamaño de almacenamiento es orientativo, y la estimación se ha realizado con los datos de un paciente que registró señales durante 6 horas y 15 minutos. Para la estimación de almacenamiento, se guardan las observaciones separadas por comas en un fichero con formato ASCII.

A pesar de que esta lectura de datos podía parecer suficiente, encontramos dos inconvenientes: El primero, que cada una de las series temporales (señales procedentes de los distintos sensores de la poligrafía nocturna) se leía de forma independiente, por lo que se perdían las marcas temporales de las mismas. Esto podía solucionarse teniendo en cuenta las frecuencias de muestreo, por lo que no suponía un motivo para usar un formato diferente. Sin embargo, el mayor problema es que al usar este formato también se perdían las anotaciones generadas de forma automática por Noxturnal y por el equipo médico, con lo que se perdía la información de cuándo tenían lugar los episodios de apnea, hipopnea y desaturaciones.

3.1.2. Noxturnal y Macro Recorder - CSV

Para resolver el problema que surgía al exportar en formato EDF, se exploraron otras alternativas de exportación que proporcionaba Noxturnal, entre las que estaba la exportación a formato CSV. Con dicha opción, teníamos la flexibilidad de escoger las señales que se querían exportar (que serían únicamente las que vemos en la tabla 3.1), así como escoger entre los eventos generados por la herramienta. De estos eventos podíamos exportar información sobre la postura del paciente al dormir, las desaturaciones, los eventos de ronquidos, y los más importante, los eventos de apneas e hipopneas.

Antes de realizar la exportación en este nuevo formato, decidimos analizar las ventajas e inconvenientes de exportar en CSV frente a EDF. La principal ventaja de la exportación a CSV, es que al ser un tipo de fichero ampliamente utilizado, se puede manejar de forma sencilla ya sea para abrirlo con

herramientas que nos permitan analizar los datos con una interfaz gráfica (como puede ser Excel), o con lenguajes de programación, como es nuestro caso Python. Sin embargo, este tipo de fichero tenía un problema, y era que se debía fijar de antemano una frecuencia común de muestreo para todas las señales. Esta decisión nos permite que cada dato recogido de los distintos sensores tenga la misma anotación temporal, pero a cambio se pierde información (en caso de submuestrear) o de introducir información adicional (si se aplica interpolación).

Una primera aproximación para abordar esta circunstancia podría ser añadir datos en aquellas señales con una menor frecuencia de muestreo. Tal y como vemos en la tabla 3.1, la mayor frecuencia es 200 Hz, por lo que se decidió usar dicha frecuencia en un primer momento. Teniendo en cuenta la fórmula 3.1a, y que las grabaciones de cada paciente son aproximadamente 6 horas, implicaría un total de 4.320.000 datos por cada señal. Además, como queremos exportar 15 atributos (la marca temporal, las 8 señales, y 6 índices indicando la presencia de apnea-hipopnea), nos daría un total de 64.800.000 datos (de acuerdo con la ecuación 3.1b) por cada paciente. Esto no solo implica una gran cantidad de espacio de almacenamiento para la información de cada paciente, sino que, además, enlentecería todos los cálculos al trabajar con tantos datos.

$$\text{Numero filas} = \text{Frecuencia (Hz)} * \text{Duracion Noche (Horas)} * 3600 \quad (3.1a)$$

$$\text{Datos totales} = \text{Numero filas} * \text{Numero atributos} \quad (3.1b)$$

Ante esta situación, se analizó el comportamiento de las señales con una mayor frecuencia de muestreo, haciendo uso del visualizador de series temporales de Noxturnal. Para ello, nos fijamos en tramos de 1s (figura 3.1), en particular nos interesan las señales Flow y Snore que son las que tenían una mayor frecuencia de muestreo. Podemos observar que la señal de flow tiene una evolución progresiva, mientras que la señal del ronquido tiene más saltos en sus valores. Ante esta situación, es necesario decidir cual es la menor frecuencia de muestreo que podemos tomar para perder la menor información posible, pero manteniendo un conjunto de datos que sea manejable. Tras realizar pruebas con distintos valores (3 Hz, 10 Hz, 20 Hz y 40 Hz), decidimos que 20 Hz era un valor aceptable, el cual reduce en 10 veces la estimación del número de datos original, quedándonos un total de 432.000 datos por cada atributo al aplicar la formula 3.1a. Con esta decisión de diseño, podemos ver que tomando 20 muestras por segundo, no consideraríamos ninguna pérdida de información sobre la señal flow, pero sí podría esperarse alguna perdida de información en la señal del ronquido. Por ello, en caso de querer analizarse en profundidad la señal del ronquido, sería necesario estudiar otras alternativas.

Una vez decididos los parámetros con los que íbamos a exportar los datos, faltaba decidir cómo realizar el submuestreo y el proceso de añadir datos en aquellas señales con distinta resolución de la decidida. Para generar nuevos datos, decidimos repetir la última medición de la señal hasta que se recibiese una nueva, mientras que para el submuestreo decidimos tomar la media de todos los datos que se encontraban en el intervalo que se estaba reduciendo.



Figura 3.1: Visualización de tramo 1s Noxturnal.

El proceso de selección de atributos y eventos, así como la exportación a CSV, era un proceso repetitivo que había que realizar para cada uno de los pacientes de forma individual. La secuencia de acciones a realizar en Noxturnal para llevar a cabo la exportación es la siguiente:

- 1.— En la pantalla de bienvenida: File → Open Recording → Seleccionar el paciente que deseamos.
- 2.— En la pantalla de resumen del paciente:
 - 2.1.— Periods → Analysis (para quedarnos con el tramo que ha sido etiquetado y analizado).
 - 2.2.— Respiratory → Add Sheet → Empty Signal Grid (En esta pantalla, se irán seleccionando las columnas a añadir al CSV).
- 3.— En la pantalla de Signal Grid:
 - 3.1.— Add Column → Time Stamp (Indicamos cada cuantos segundos se añade una observación)
 - 3.2.— Para cada señal que queremos añadir: Add Column → Signal → Seleccionamos señal → Seleccionamos estrategia de submuestreo (la media en nuestro caso)
 - 3.3.— Para cada tipo de evento que queremos añadir: Add Column → Event → Seleccionamos evento
 - 3.4.— Export → Comma Separated Values (*.csv)

Para automatizar dicho proceso, se decidió utilizar la herramienta MacroRecorder⁴ (captura de pantalla disponible en apéndice, figura B.1). Utilizando dicha herramienta, pudimos generar un ejecutable de Windows (.exe), el cual se encarga de realizar toda la secuencia de movimientos necesarios para iniciar el programa, preparar el entorno para exportar los datos del paciente, realizar la exportación de datos, y repetir sucesivamente el proceso para todos los pacientes que haya disponibles.

Una vez extraídos los datos de los pacientes, debíamos leer dicho fichero CSV desde Python,

⁴<https://www.macrotrecorder.com/>

lo cual realizamos utilizando la librería pandas⁵. Con toda esta información disponible, podíamos comenzar el trabajo de analizar las señales.

3.2. Estudio correlación señales poligrafía nocturna

A lo largo de esta sección, se va a analizar la implementación que se ha llevado a cabo para estudiar si existe alguna correlación entre las señales de un paciente durante la prueba de poligrafía nocturna. En primer lugar, se expondrá el diagrama de diseño que se ha utilizado para realizar un programa lo más modular posible en la sección 3.2.1. A continuación, se explicarán los distintos métodos que se han aplicado para el cálculo de la correlación y retraso entre las señales, así como algunos resultados obtenidos (secciones 3.2.2 y 3.2.3).

3.2.1. Diseño Arquitectura

Para llevar a cabo toda la gestión de los pacientes, se ha desarrollado una pequeña aplicación, cuyos requisitos funcionales se describen a continuación:

- RF-1.**— El usuario podrá instanciar un Paciente a partir de su fichero CSV exportando de Noxturnal, indicando cuáles son las señales relevantes para dicho paciente.
- RF-2.**— El sistema leerá el fichero CSV del paciente. De este fichero extraerá el `time_step` (distancia en segundos entre cada dato recogido por los sensores), y almacenará dicho fichero en una variable con una columna para cada señal. Los nombres de las columnas de esta variable serán independientes del paciente, traducándose al mismo idioma para evitar ambigüedades.
- RF-3.**— El usuario podrá comprobar si el conjunto de datos del paciente es válido, es decir, si el fichero CSV contiene información en todas sus señales, y si dicha información está completa a lo largo de toda la serie temporal.
- RF-4.**— El usuario podrá solicitar al sistema que se calculen los índices del paciente. En este caso se calculará el IA, ID e IAH.
- RF-5.**— El usuario podrá solicitar que se eliminen los valores atípicos de una señal.
- RF-6.**— El usuario podrá solicitar que se suavice una señal, reduciendo los saltos durante la evolución de la misma.
- RF-7.**— El usuario podrá solicitar al sistema que se calcule la matriz de correlación y podrá decidir si mostrar gráficamente los resultados o no. El sistema llevará a cabo el cálculo de correlación con todas las señales indicadas como relevantes.
- RF-8.**— El usuario podrá solicitar al sistema que se calcule el retraso entre dos señales, y podrá decidir si mostrar gráficamente los resultados o no.
- RF-9.**— El usuario podrá almacenar el Paciente que ha creado, y cargarlo más adelante para no repetir los cálculos.

En la figura 3.2 se expone el diagrama de diseño de la implementación que se ha realizado para satisfacer los requisitos funcionales. Podemos observar que hay únicamente una clase (Paciente), para cuya gestión se han utilizado dos módulos adicionales. El módulo “gestor_lectura” se usa para

⁵<https://pandas.pydata.org/>

manejar la lectura de la información disponible en el fichero CSV previamente exportado (sobre el que se realizan modificaciones en los nombres de las columnas, así como traducciones para que todos los pacientes contengan los mismos nombres de columna), mientras que el módulo “patient_manager” contiene la funcionalidad para calcular los índices de IAH, ID e IA y para estudiar la correlación y los retrasos que existen entre las señales.




Figura 3.2: Diagrama UML Paciente. El módulo “gestor_lectura” se encarga de la lectura y gestión del fichero CSV del paciente, y el módulo “patient_manager” contienen las funciones para calcular los índices del paciente así como la correlación y retraso entre señales.

A partir del diseño realizado, se puede extraer toda la información de cada uno de los pacientes siguiendo el diagrama de la figura 3.3. Como se puede observar en el mismo, en primer lugar se calculan los índice de IA, ID e IAH del paciente, y a continuación se calcula la correlación y retraso de las señales de la poligrafía nocturna. Destacar sobre la implementación que para llevar a cabo esta secuencia de cálculos sobre todos los pacientes, se ha hecho uso de la librería multiprocessing⁶ de Python, para paralelizar el trabajo y reducir el tiempo para llevar a cabo la tarea. En dicha implementación, cada uno de los procesadores que se indique que se desean utilizar se encargará de procesar y realizar todos los cálculos sobre un determinado paciente, hasta que se hayan finalizado todos los pacientes disponibles.

Para más detalles sobre la implementación y disponibilidad del código, consultar el apéndice A.

⁶ Librería que permite gestionar un Pool de procesos. <https://docs.python.org/3/library/multiprocessing.html>




Figura 3.3: Diagrama de secuencia Paciente. En este diagrama se ilustra el procesamiento de cada paciente, calculando los índices del mismo y la correlación y retraso entre las señales. Solo es necesario realizar las llamadas a las funciones entre el sujeto y la clase paciente, el resto de llamadas se realizan de forma automática.

3.2.2. Análisis de coeficientes de correlación

En la primera aproximación a resolver el problema, se decidió estudiar la correlación de cada una de las señales consideradas relevantes (tabla 3.1). Dicho estudio se va a llevar a cabo utilizando el coeficiente de correlación de Pearson, y se pueden analizar los resultados de forma conveniente mediante un mapa de calor (figura 3.4). En dicho gráfico estamos representando únicamente cómo se correlacionan las variables para un paciente en particular. Podemos observar en la diagonal principal la correlación de una variable consigo misma, la cual lógicamente es 1. De igual forma, vemos que las variables del flujo respiratorio y la presión nasal se encuentran inversamente correlacionadas (es el comportamiento esperado a-priori, ya que conforme aumenta la presión nasal se reduce el paso de aire en las vías respiratorias). Por otro lado, se observa una correlación apreciable entre el pulso y la saturación de oxígeno.




Figura 3.4: Mapa de calor matriz de correlación 1 paciente. Para el cálculo de la correlación se utiliza el coeficiente de correlación de Pearson.

A pesar de que podríamos intentar extraer más conclusiones a partir de la figura 3.4, nos interesa generalizar los resultados obtenidos para el resto de pacientes. En particular, queremos comprobar si el IAH influye de alguna forma en la correlación que existe entre las variables. Para ello, se desea calcular la matriz de correlación de cada uno de los pacientes, y realizar una valoración conjunta de la correlación y el IAH. Los resultados del experimento se analizarán en la sección 4.1.

3.2.3. Análisis del retraso temporal en la correlación de señales

Al trabajar con series temporales, uno de los factores más importantes a tener en cuenta es la evolución en función del tiempo de las mismas. Cada una de las series temporales que estamos tratando puede evolucionar de una forma frente a un cierto evento fisiológico; es decir, es posible que se vea reflejado antes en una de las señales que en otra, o que ni siquiera se vea reflejado. Por este motivo, es interesante caracterizar el retraso de las señales, estudiando cómo evoluciona la correlación entre las mismas cuando ocurren eventos relevantes en el contexto de la apnea.

Para llevar a cabo dicho análisis, a la hora de estudiar la correlación entre dos señales, se ha implementado un desplazamiento de una de las señales hacia delante y hacia atrás, y se estudia como varía la correlación al aplicar dichos desplazamientos. Podemos ver un diagrama de la idea que se persigue al realizar este desplazamiento en la figura 3.5. La serie temporal representada en dicha figura es un ejemplo de la evolución de la serie del atractor de Lorenz, y podemos observar que una de las señales se encuentra desfasada respecto a la otra (20 segundos en este ejemplo), pero en esencia se trata de la misma serie temporal.




Figura 3.5: Diagrama de explicación de cálculo retraso señal. Se muestra en la figura la misma señal dos veces pero una de ellas con un retraso de 20 segundos.

La funcionalidad para calcular el retraso de una señal frente a otra se encuentra implementada en el módulo de gestión de pacientes (ver figura 3.2). Podemos observar en la figura 3.6 un ejemplo de funcionamiento de dicho cálculo, en el que se calcula el pico de correlación, y con qué desplazamiento temporal se obtiene dicho pico. Como era de esperar, el pico de correlación en este caso es 1, ya que se trata de la misma serie temporal pero desplazada, y existe un offset entre las señales de 20 segundos.




Figura 3.6: Ejemplo cálculo retraso señal. Podemos observar como se encuentra el pico de correlación con 20 segundos de retraso.

Para caracterizar el retraso de cada par de señales disponibles en un paciente (tabla 3.1), se ha calculado el pico de correlación y retraso de cada par. Podemos ver un ejemplo de la señal de pulso frente a la de saturación en la figura 3.7. El comportamiento en este paciente particular nos indica que la señal del pulso se encuentra retrasada por 14.4 segundos, pero antes de sacar conclusiones nos interesa comprobar si este comportamiento tiene lugar en todos los pacientes. Por ello se ha repetido este cálculo con todos los pacientes disponibles, y se han estudiado los resultados obtenidos (sección 4.1).




Figura 3.7: Ejemplo retraso señal de pulso frente a saturación. La señal del pulso se encuentra adelantada frente a la señal de saturación en 14.4 segundos para el paciente particular que se está representando.

3.3. Predicción evolución variables

El objetivo de esta sección consiste en estudiar cómo se podría predecir la evolución de la señal de saturación del paciente, la cual se recoge en la poligrafía nocturna. Como se ha mencionado en la sección 1, dicha señal tiene una alta relación con el IAH y con los eventos de apnea, por lo que su predicción es de elevado interés. Para intentar resolver este problema de predicción de una serie temporal, que se puede tratar de forma multivariada (analizando todas o varias señales de forma conjunta) o univariada (analizando únicamente una señal, como se realizará inicialmente), se van a aplicar los algoritmos de inteligencia artificial del perceptrón multicapa (sección 3.3.4) y redes neuronales recurrentes, en particular redes LSTM (sección 3.3.5). Para realizar la implementación de dichos algoritmos, se ha hecho uso de la librería Keras⁷. Gracias a esta, nos aseguramos que la implementación del algoritmo de aprendizaje es óptimo, y podemos probar múltiples hiperparámetros de forma rápida.

Antes de comenzar con dicha etapa de predicción, es necesario analizar y preprocesar la señal (sección 3.3.1), al igual que preparar el conjunto de datos para que pueda ser correctamente interpretado por nuestras redes neuronales (sección 3.3.2).

Una vez preparados los datos para el entrenamiento, llega el proceso de optimización de hiperparámetros. Este problema de predicción de series temporales tiene múltiples parámetros que configurar, por lo que es necesario realizar una implementación que estudie las diferentes combinaciones de hiperparámetros y los resultados que se obtienen con cada una de ellas. Para ello, se ha implementado un algoritmo de Random Search utilizando la librería multiprocessing⁸ para poder entrenar de forma paralela varios modelos, aprovechando al máximo los procesadores del equipo en el que se esté ejecutando.



3.3.1. Preprocesado señal


Podemos observar en primer lugar la forma que tiene la señal de saturación en la figura 3.8(a). Como podemos ver es una señal que originalmente toma solo valores enteros, lo cual hace que la gráfica tenga saltos en la misma. Esto puede suponer un inconveniente para los mecanismos de aprendizaje, ya que les va a ser complicado predecir estos saltos. Por este motivo, se ha realizado un suavizado de la señal, mediante el cual haciendo uso de una ventana deslizante de 6 segundos, la evolución de la misma pasa a ser progresiva, tal y como vemos en la figura 3.8(b). Dicho parámetro se ha estimado de forma empírica, con el objetivo de generar series lo más progresivas posibles, pero sin perder la evolución original de la serie.

Otro aspecto a analizar, son los valores artefactos (valores erróneos de la muestra) a la hora de


⁷ Librería de Deep Learning. <https://keras.io/>

⁸ Librería que permite gestionar un Pool de procesos. <https://docs.python.org/3/library/multiprocessing.html>





(a) Análisis valores atípicos señal de saturación



(b) Eliminación valores atípicos señal de saturación

Figura 3.10: Eliminación de valores artefactos de la señal de saturación. Se observa en el primer histograma que existen ciertos valores atípicos alrededor del nivel de saturación 125, los cuales desaparecen al eliminar los artefactos y suavizar la señal, como se ve en la segunda figura.




Figura 3.11: Distribuciones de valores más frecuentes de la señal de saturación. Se observa que los valores de saturación de cada paciente pueden oscilar en rangos diferentes.

3.3.2. Preparación dataset

Una de las principales decisiones que tenemos que tomar a la hora de construir una red neuronal (independientemente del tipo de modelo de aprendizaje que apliquemos, en nuestro caso MLP o LSTM), es el aspecto que va a tener cada una de las muestras del dataset. Ya hemos discutido previamente que el problema que queremos resolver es la predicción de una serie temporal univariada, sin embargo, en este caso particular no queremos predecir un único punto de la evolución de la señal de saturación (que equivaldría, acorde con la tabla 3.1, a predecir el comportamiento en los próximos 0.33 segundos), sino que queremos predecir un mayor intervalo temporal. De igual forma, debemos decidir el número de observaciones previas que van a formar cada una de las muestras del conjunto de datos. Estas posibilidades de decisión las podemos ver de forma gráfica en la figura 3.12. En el ejemplo particular de la figura, vemos que cada muestra está formada por los últimos 30 segundos, y proporciona una predicción de los próximos 14 segundos. De igual forma, vemos un parámetro adicional, el tiempo de deslizamiento de la ventana de análisis (referido como “margen” en la figura 3.12), el cual es de especial interés cuando no queremos generar demasiadas muestras que sean muy similares, ya que con un deslizamiento de un único punto, dos muestras consecutivas serían muestras demasiado similares.




Figura 3.12: Diagrama de preparación de muestras usando ventana deslizante. En este ejemplo cada muestra tendrá 30 segundos de historia, y 14 segundos de predicción, con una separación entre una muestra y la siguiente de 5 segundos.

Es importante destacar, que independientemente del número de observaciones que se decida que va a predecir el algoritmo, existe la posibilidad de generar predicciones adicionales. Esto se explicará en la sección 3.3.3.

Respecto a los conjuntos de datos utilizados, en primer lugar (para el MLP) decidimos utilizar la información de un único paciente para entrenar el modelo. En esta aproximación, para no perder de-

masiados datos, únicamente se crearon dos particiones: La de *training* (o entrenamiento) para entrenar el modelo, con el 80 % de los datos, y la de *test* (para comprobar el resultado del modelo una vez entrenado) con un 20 % de los datos. Sin embargo, esta aproximación no proporcionaba resultados óptimos, como veremos en la sección 4.2.1. Para solucionar esto, al aplicar redes LSTM, decidimos utilizar los datos de varios pacientes. En este caso, al disponer de muchos más datos para entrenar y evaluar el modelo, generamos los conjuntos de entrenamiento, validación y test siguiendo el diagrama de la figura 3.13. Cabe destacar que las muestras para generar cada uno de los conjuntos no se pueden escoger de forma completamente aleatoria entre todos los datos disponibles (haciéndolo así estaríamos sesgando el conjunto de test), sino que se deben establecer dos puntos de corte que indicarán las divisiones en conjuntos. Esto es así porque si no en el conjunto de entrenamiento podríamos tener muestras muy similares al del conjunto de test (al poder ser muestras consecutivas), por lo que no se estaría haciendo una evaluación realista de la capacidad de generalización del modelo.




Figura 3.13: Diagrama división en conjuntos de entrenamiento, validación y test. Cada paciente generará sus propios conjuntos, y a continuación se realizará la combinación de los conjuntos de los pacientes para dar lugar a nuestro *dataset*.

3.3.3. Predicción multipaso y métricas

Como hemos visto en la sección 3.3.2, es importante definir a cuántos puntos va a realizar la predicción nuestro modelo. Sin embargo, es posible generar un número mayor de predicciones de las que se establezca inicialmente, para lo cual se ha implementado un algoritmo de predicción recursiva, cuyo esquema vemos en las ecuaciones 3.2a y 3.2b.

$$prediccion(t) = model(obs(t - n), \dots, obs(t - 2), obs(t - 1)) \quad (3.2a)$$

$$prediccion(t + 1) = model(obs(t - n + 1), \dots, obs(t - 2), obs(t - 1), prediccion(t)) \quad (3.2b)$$

En este ejemplo vemos que recursivamente se está prediciendo una observación adicional, y podemos repetir este paso tantas veces como se desee. De igual forma, si nuestra red predijese las 5 siguientes observaciones, recursivamente se podrían predecir 10, 15, 20, ..., observaciones. Al aplicar este esquema es importante diseñar una métrica que sea capaz de comparar dos modelos, con diferente longitud de predicciones, en igualdad de condiciones, ya que el error del modelo será menor

al predecir una única muestra que, por ejemplo, al predecir 10 muestras.

Para diseñar dicha métrica de evaluación, se ha utilizado Raíz del Error Cuadrático Medio (RMSE), con el objetivo de que el error represente en escala real la diferencia entre la estimación y el valor real. Dicha métrica viene definida por la ecuación 3.3. Teniendo en cuenta dicha métrica de evaluación, para comparar dos modelos que generen predicciones de longitudes diferentes, simplemente habrá que realizar predicciones de forma recursiva sobre el modelo que genere menos observaciones, hasta que estas se igualen. Una vez hecho esto para cada muestra del conjunto de entrenamiento, podemos comparar los errores de cada uno de los modelos.

$$RMSE = \sqrt{\frac{\sum_i^N (Prediccion_i - Real_i)^2}{N}} \quad (3.3)$$

3.3.4. Perceptrón multicapa con codificación temporal recurrente

El MLP es uno de los algoritmos de inteligencia artificial más ampliamente utilizados. Es un algoritmo que no está diseñado específicamente para su aplicación con series temporales, por lo que para poder utilizar el mismo con este objetivo, es un requisito indispensable que nuestros datos contengan de forma implícita la codificación temporal. Podemos ver en el diagrama de la figura 3.14 un posible diseño de la red neuronal. Como podemos observar, la capa de entrada recibe las muestras anteriores al instante (o instantes) de tiempo que se quieren predecir, mientras que la capa de salida representa las propias predicciones. Al realizar esta codificación estamos añadiendo recurrencia a los datos, ya que los datos de salida del perceptrón se utilizan de nuevo como entrada en las siguientes muestras, por lo que podemos considerar nuestra red como un perceptrón multicapa con recurrencia. Los tamaños de la capa de entrada y capa de salida son parámetros que hay que escoger a la hora de preprocesar los datos, y habrá que estudiar el comportamiento del modelo al modificar los mismos.

3.3.5. Redes neuronales recurrentes - LSTM

Las redes neuronales recurrentes (RNR) son un tipo de red diseñada específicamente para el tratamiento de series con estructura secuencial y dependencias temporales. En este estudio nos vamos a centrar en un caso particular de RNR, las redes LSTM, las cuales fueron introducidas en el año 1997 [26]. La principal diferencia entre las LSTM y el MLP es que las primeras tienen una “memoria” en cada una de las neuronas, que llamaremos unidades LSTM, y la salida generada por la red depende del conocimiento que tiene sobre entradas anteriores. Podemos ver en la figura 3.15 como la estructura de la red es similar a la que habíamos visto previamente en el MLP, pero las neuronas en este caso son unidades LSTM.




Figura 3.14: Diagrama estructura red perceptrón multicapa con codificación recurrente. La salida de la red se utiliza como entrada de la red en muestras posteriores.




Figura 3.15: Diagrama estructura red neuronal recurrente LSTM. Por simplicidad en el diagrama, no se incluyen las recurrencias temporales dentro de cada unidad LSTM. Las unidades LSTM en línea discontinua indican posible desactivación de la neurona al aplicar la regularización de *drop-out*.

Como se ha comentado previamente, para la implementación de las LSTM se va a utilizar la librería Keras. En dicha implementación, el conjunto de datos para entrenar y evaluar la red debe tener las siguientes dimensiones (teniendo en cuenta la codificación de la figura 3.14):

- Datos entrenamiento entrada: $[número_muestras][tam_capa_entrada][número_características]$
- Datos entrenamiento salida: $[número_muestras][tam_capa_salida]$

En este caso particular, el número de muestras dependerá del número de pacientes que tomemos para llevar a cabo el entrenamiento del modelo, y el tamaño de la capa de entrada y la capa de salida serán dos hiperparámetros a seleccionar, tal y como se ha comentado en la sección 3.3.4. Respecto al número de características, en primer lugar se realizará una implementación utilizando únicamente una característica (la propia señal de saturación), pero para intentar mejorar los resultados obtenidos (sección 4.2.1), se ampliarán los datos de entrada al modelo para que no reciba únicamente la señal de saturación, sino también la señal del pulso, que se encuentra muy correlacionada con la misma (sección 4.1).

Al realizar el entrenamiento de la LSTM, utilizando el conjunto de validación para ver la evolución del error conforme avanzaba el entrenamiento, se observó que el modelo realizaba sobre-ajuste. Para solventar dicho problema, se hizo uso de un algoritmo de regularización (*drop-out*) disponible en la librería Keras⁹, así como uso de funciones específicas para detener el entrenamiento cuando este empeoraba¹⁰ y para ir almacenando el mejor modelo¹¹. Estas decisiones se tomaban en función de la evolución del error sobre el conjunto de validación.

⁹https://keras.io/api/layers/regularization_layers/dropout/

¹⁰https://keras.io/api/callbacks/early_stopping/

¹¹https://keras.io/api/callbacks/model_checkpoint/

EXPERIMENTOS Y RESULTADOS

En esta sección se procederá a exponer y analizar los resultados obtenidos tras llevar a cabo experimentos con el diseño y la implementación detallados en la sección 3. Cabe destacar que al finalizar la implementación, se validó que se cumplían todos los requisitos funcionales indicados en la sección 3.2.1. En primer lugar, se expondrán las conclusiones extraídas a partir del estudio de la correlación de las señales de la poligrafía nocturna (sección 4.1). A continuación, se analizará la eficacia de la predicción de las series temporales, así como los distintos métodos implementados y sus resultados (sección 4.2).

4.1. Correlación entre señales de la poligrafía nocturna

Como hemos visto en la secciones 3.2.2 y 3.2.3, resulta imprescindible no solo estudiar la correlación entre las señales de forma directa usando el coeficiente de correlación de Pearson, sino también caracterizar el retraso temporal de dicha correlación.

En primer lugar, ya habíamos calculado previamente el coeficiente de correlación de Pearson, y representado en un mapa de calor (figura 3.4) la correlación entre todas las señales de un único paciente. Sin embargo, para generalizar los resultados al resto de pacientes y comprobar si existe alguna relación entre el nivel de IAH y la correlación entre las señales, hemos generado dos mapas de calor adicionales. En estos, se ha realizado una división entre aquellos pacientes que padecen un nivel moderado o severo de SAS [27] (32 pacientes tienen un IAH mayor que 15) y el resto (23 pacientes), y se ha calculado la media de las correlaciones, pudiendo observarse los resultados obtenidos en las figuras 4.1(a) y 4.1(b) respectivamente.

Analizando los resultados (figura 4.1), podemos ver que en rasgos generales son similares independientemente del IAH del paciente, pero es destacable que la correlación del pulso con el nivel de saturación es mayor en aquellos pacientes que no tienen un nivel alto de SAS. Para resaltar esta observación, hemos representado un gráfico adicional en la figura 4.2, en el que vemos con más detalle la correlación entre el pulso y la saturación. Como podemos observar, aparentemente en aquellos pacientes con un nivel de IAH menor existe una mayor correlación entre la señal del pulso y la de




Figura 4.1: Mapa de calor matriz correlación múltiples pacientes en función de IAH. Se muestra la media (con precisión de 3 decimales) y la desviación estándar (con precisión de 2 decimales) de las correlaciones de los pacientes que cumplen la condición de IAH.

saturación. Para poder confirmar esta hipótesis del análisis preliminar realizado en este trabajo, sería necesario realizar la evaluación sobre más pacientes.




Figura 4.2: Correlación saturación frente a pulso en función del IAH

Con los resultados de las figuras 4.1 y 4.2 podemos concluir que:

- Existe una correlación inversa entre el flujo de aire del paciente y la presión nasal del mismo.
- El pulso tiene una fuerte correlación positiva con la señal de saturación. Esta correlación es menor en aquellos pacientes con un IAH elevado. Si nos fijamos en la figura 4.2, podemos ver como de los 38 pacientes con un IAH < 30, el 90 % tienen una correlación > 40 %, mientras que de los 17 pacientes con un IAH > 30, el 47 % tienen una correlación < 40 %.

- Existe una ligera correlación positiva entre el abdomen y el volumen de sonido, así como la actividad motora y el volumen de sonido. Esto se debe a que tanto al aumentar la respiración abdominal, como al tener una mayor actividad, se incrementa el ruido que genera el paciente.
- Se observa también una correlación del 11-12% entre la actividad y el pulso, que se debe a que si el paciente tiene más actividad motora, se incrementan las pulsaciones.
- De forma general, a excepción de la relación entre el pulso y saturación, no existe evidencia clara de que la correlación entre el resto de las medidas de la poligrafía se encuentren condicionadas al nivel de IAH del paciente.

Para intentar extraer información adicional sobre la correlación de las señales recogidas en la poligrafía nocturna, se ha caracterizado el retraso, o adelanto, de cada una de las señales respecto al resto. Podemos ver los gráficos obtenidos para el nivel de saturación de oxígeno frente al resto de las señales analizadas en las figuras 4.3 y 4.4. En la primera de estas se representa la máxima correlación posible entre las señales al desplazar una de ellas, mientras que en la segunda se observa con qué desplazamientos temporales se alcanzan los picos de correlación. Dicho estudio se ha realizado también para el resto de señales disponibles, y se puede ver la totalidad del análisis en el apéndice B (figuras B.2 a B.10).

- El pulso es la señal que más correlacionada se encuentra con la saturación, y es una señal que se encuentra sincronizada (a excepción de 4 pacientes que podemos considerar valores atípicos) sin ningún desplazamiento con la saturación (figura 4.4(e)). En el resto de señales vemos que los valores de correlación son mucho más pequeños.
- Existe una menor correlación entre el pulso y la saturación en aquellos pacientes con SAS, pero sería necesario evaluar más pacientes para poder concluir esto con certeza (figura 4.3(e)).
- Los valores de los retrasos de las señales frente al nivel de saturación están dispersos en los gráficos (a excepción del pulso previamente comentado), lo que nos indica que no existe un retraso entre las señales que se pueda generalizar para todos los pacientes.

Respecto a las gráficas disponibles en el apéndice B (figuras B.2 a B.10), podemos observar en algunas gráficas de los retrasos una sincronización casi total (retraso cercano a 0), como consecuencia de las relaciones fisiológicas entre las señales. Cabe destacar que este retraso no se encuentra condicionado a un nivel de IAH particular, por lo que no resulta transcendental en este análisis. Esto tiene lugar por ejemplo entre las señales de nivel de sonido y abdomen (al respirar se aumenta el ruido de forma inmediata, figura B.3(c)), abdomen y flujo (el abdomen se mueve porque el paciente está respirando, figura B.3(d)), o el pulso y la actividad motora (al incrementar la actividad se incrementan las pulsaciones del paciente B.5(e)) entre otras.

A la vista de los resultados, se puede concluir que de forma general no existe una evidencia clara que nos indique que la correlación entre dos señal esté condicionado a una nivel de IAH (a excepción del pulso previamente comentado). Cabe destacar que hay una señal en particular, el ronquido (snore), que tiene una frecuencia de muestreo muy elevada (200 Hz), y es una señal que contiene mucha información. Por este motivo, es posible que para poder extraer características sobre la correlación de dicha señal con un episodio de apnea, fuese necesario realizar un estudio más a fondo sobre esta




Figura 4.3: Representación correlación señales frente a saturación en función del IAH.




Figura 4.4: Representación retraso señales frente a saturación en función del IAH.

señal. En particular, podrían analizarse características de las señales de audio como el Zero Crossing Rate o Short Time Energy y estudiar los resultados. Dicho análisis queda fuera del ámbito de este trabajo particular.

4.2. Predicción evolución saturación

En esta sección se van a exponer los resultados de la predicción de la señal de saturación. En primer lugar se realizarán experimentos con el MLP, utilizando únicamente la propia señal de saturación para realizar la predicción, y tomar los mejores resultados como base (sección 4.2.1). A continuación, se aplicarán redes neuronales recurrentes, para intentar mejorar los resultados, y se probará a utilizar no solo la señal de saturación, sino añadir al modelo la señal del pulso (sección 4.2.2). Cabe destacar que una vez entrenados los modelos para realizar las predicciones, para evaluar los mismos nos interesa analizar si estos son capaces de predecir un episodio de desaturación. En particular, estudiaremos si son capaces de predecir una caída en el nivel de saturación de al menos el 3%.

4.2.1. Perceptrón multicapa


En primer lugar se decidieron llevar a cabo experimentos con el Perceptrón multicapa (con la codificación temporal recurrente indicada en la sección 3.3.4), para tomar como referencia los resultados obtenidos a partir de este modelo, y así comprobar si mejorábamos dichos resultados al aplicar otros modelos de aprendizaje automático. Los diferentes parámetros a ir variando para comprobar el rendimiento del modelo han sido:

- Número de observaciones previas a la observación que se desean predecir. Define el tamaño de la capa de entrada (ver figura 3.14).
- Número de observaciones que se desea predecir. Define el tamaño de la capa de salida (ver figura 3.14).
- Número de capas ocultas, así como el número de neuronas en cada capa oculta.
- Funciones de activación de las neuronas en cada una de las capas.
- Batch_size, parámetro que indica cada cuántas muestras se actualizarán los pesos de la red.

Para la primera fase de experimentación, vamos a utilizar la información de un único paciente tanto para entrenar como para evaluar el modelo. Se ha seleccionado un paciente con índice de IAH muy elevado (130.56), ya que este paciente va a sufrir muchas desaturaciones a lo largo de la noche como consecuencia de la patología, y nos va a servir para comprobar la capacidad del modelo de predecir estos eventos. En los primeros experimentos, se fijaron dos valores distintos de tamaño de entrada, 90 y 180 (correspondientes a 30 segundos previos y 60 segundos previos respectivamente al momento en el que se va a iniciar la predicción). De igual forma, el número de las observaciones a predecir se decidió fijar en un solo punto de predicción en esta primera exploración.

Respecto a los hiperparámetros propios de la red (neuronas ocultas, funciones de activación y `batch_size`), se realizó un primer análisis empírico para descartar posibles configuraciones que no diesen buenos resultados. Dicho experimento consistió inicialmente en ejecutar el entrenamiento con 500 neuronas en la capa oculta, durante 1000 épocas de entrenamiento. Con los resultados de este, se observó que al utilizar la función de activación sigmoide, nuestra red realizaba un aprendizaje lento, y el RMSE se estancaba de forma rápida. Sin embargo, este comportamiento no tenía lugar al aplicar la función de activación ReLU, por lo que se decidió fijar esta función de activación para las neuronas de las capas ocultas. De igual forma, se observó que a pesar de realizar un entrenamiento con muchas épocas, y muchas neuronas, no había sobre-ajuste, por lo que se descartó introducir funciones de regularización para evitarlo (como podría haber sido, introducir *drop-out* en las capas ocultas).

Una vez decidida la función de activación de las capas ocultas, para explorar el resto de hiperparámetros de la red se aplicó el algoritmo Random Search multiprocesador (sección 3.3). En dicha exploración, se ha probado a modificar el número de capas ocultas, así como el número de neuronas en cada capa y el `batch_size` del entrenamiento. Podemos observar de forma visual los resultados de todos los entrenamientos en la figura 4.5. De igual forma, se han recogido algunos de los mejores resultados de entrenamiento en la tabla 4.1 (tabla completa disponible en la tabla C.2 del apéndice).



(a) Entrenamiento con número entradas = 90, salidas = 1

(b) Entrenamiento con número entradas = 180, salidas = 1

Figura 4.5: Evolución del error (RMSE) en función del número de capas ocultas. El error mostrado corresponde con la predicción de un único punto. Cada punto de las figuras corresponde con una ejecución con distinto número de neuronas en la capa oculta, para más detalles sobre los resultados consultar la tabla C.2 del apéndice.

Con los experimentos observados en la tabla 4.1, decidimos probar uno adicional, con una única capa oculta y 135 puntos de historia previa. Sin embargo, los resultados fueron de nuevo peores, como se puede ver en la tabla de resultados C.2 del apéndice.

A la vista de estos resultados, podemos extraer las siguientes conclusiones:


- En todos los casos se han obtenido mejores resultados con 90 puntos de historia previa.
- Incrementar el número de capas no ha supuesto una mejora en el aprendizaje del algoritmo.

# entradas	# salidas	# capas ocultas	Capas ocultas	batch_size	RMSE train	RMSE test
90	1	1	1500	32	0.054472	0.060784
90	1	1	750	32	0.054732	0.060951
90	1	1	4000	64	0.063413	0.071395
90	1	2	500-250	32	0.067412	0.076296
90	1	2	1000-500	32	0.068911	0.078135
180	1	1	3000	32	0.071399	0.081276
180	1	1	2000	32	0.071415	0.081381

Tabla 4.1: Resultados MLP con diferentes parámetros. Los resultados mostrados corresponden con la predicción de un único punto

- Mantener el batch_size bajo mejora los resultados de aprendizaje del algoritmo.
- Los mejores resultados se obtienen con una capa oculta, con un elevado número de neuronas, y con batch_size de 32.

Una vez analizados los experimentos en los que se consideraba únicamente la predicción de un punto de la señal, decidimos realizar experimentos con múltiples predicciones. En particular, decidimos realizar predicciones de 10 segundos, lo que implicaba una capa de salida de 30 neuronas. En este caso, y teniendo en cuenta los resultados que habíamos obtenido en el anterior experimento, decidimos explorar únicamente arquitecturas con 1 y 2 capas ocultas, con un tamaño de entrada de 90 o 135 neuronas. Podemos observar los resultados de dichos experimentos en la figura 4.6 y la tabla 4.2 (la tabla completa de todo el análisis paramétrico está disponible en la tabla C.1 del apéndice).



(a) Entrenamiento con número entradas = 90, salidas = 30

(b) Entrenamiento con número entradas = 135, salidas = 30

Figura 4.6: Evolución del error (RMSE) en función del número de capas ocultas. El error mostrado corresponde con la predicción de 30 puntos, correspondiente a 10 segundos. Cada punto de las figuras refleja una ejecución con distinto número de neuronas en la capa oculta, para más detalles sobre los resultados consultar la tabla C.1 del apéndice.

Podemos observar de nuevo como los mejores resultados se obtienen usando 90 entradas (es

# entradas	# salidas	# capas ocultas	Capas ocultas	batch_size	RMSE train	RMSE test
90	30	2	1000-500	64	1.639299	1.975932
90	30	2	2000-1000	64	1.671724	1.994340
90	30	2	500-500	64	1.582662	2.002480
135	30	2	500-500	32	1.707847	2.004986
90	30	1	750	32	1.687035	2.048266
135	30	2	1000-1000	64	1.659030	2.063159
135	30	2	1000-500	64	1.687679	2.067127

Tabla 4.2: Resultados MLP con diferentes parámetros. Los resultados mostrados corresponden con la predicción de 30 puntos, equivalente a 10 segundos.

decir, los 30 segundos previos a la muestra). Comparando las figuras 4.5 y 4.6, podemos observar como al realizar predicciones más largas, generalmente se obtienen mejores resultados utilizando un mayor número de capas ocultas.

Es importante destacar que no se pueden comparar de forma directa los RMSE de las tablas 4.1 y 4.2, ya que en la primera calculamos el error para una única predicción, mientras que en la segunda lo calculamos en 30 pasos. Para hacer una comparativa en el contexto de la aplicación para la detección de desaturaciones, aplicamos el algoritmo de predicción multipaso explicado en la sección 3.3.3 sobre el modelo que genera una única salida (el mejor de la tabla 4.1), para que este genere predicciones a 10 segundos. Una vez hecho dicho proceso, podemos ver la comparativa de la evolución del RMSE en función de la distancia a la que se realiza la predicción (figura 4.7). A partir de esta figura, podemos extraer las siguientes conclusiones:

- Observamos como las primeras predicciones son más precisas para el modelo que predice una única salida, pero estas van empeorando con mayor rapidez que en el otro modelo.
- Los resultados nos indican que es mejor utilizar el modelo que directamente genera las predicciones de todos los puntos, en vez de aplicar el algoritmo de predicción multipaso. Sin embargo, la diferencia es pequeña, por lo que habrá que realizar alguna prueba adicional para confirmar esto. Para ello, para las pruebas se utilizarán los dos modelos resumidos en la tabla 4.3.

# entradas	# salidas	# capas ocultas	Capas ocultas	batch_size
90	1	1	1500	32
90	30	2	1000-500	64

Tabla 4.3: Mejores estructuras de MLP para predicción señal saturación

Con ambos modelos entrenados, podemos representar algunas de las predicciones que realizan los modelos (figura B.12, disponible en apéndice). Observamos un comportamiento común para el modelo de una salida y de salida múltiple, en el que la precisión varía de una predicción a otra, y en





Figura 4.7: Comparativa RMSE en predicciones multipaso. El error se está cuantificando a 10 segundos, por lo que el modelo de salida individual ha generado sus predicciones de forma recursiva (ecuación 3.2b). De forma global es mejor el modelo de salida múltiple.

ocasiones solo es buena localmente pero no generaliza adecuadamente. Retomando la motivación inicial de la predicción que estamos realizando, nos interesa comprobar si el modelo predice de forma correcta los episodios de desaturación con el objetivo de predecir un episodio de apnea. Podemos ver gráficamente como se puede lograr esto, con una de las predicciones en la que se visualiza de forma clara el episodio de apnea (figura 4.8). En esta figura, vemos como el sistema es capaz de predecir la desaturación antes de que tenga lugar el episodio de apnea, y se podría tomar alguna medida preventiva para intentar evitarlo.



(a) Flujo de aire durante episodio de apnea

(b) Nivel de saturación de oxígeno durante episodio de apnea

Figura 4.8: Predicción de desaturación en el contexto de un evento de apnea. Se puede observar que el modelo ha sido capaz de predecir la desaturación que tiene lugar justo en el momento de la apnea (cuando se interrumpe el flujo de aire del paciente).

Para obtener alguna métrica adicional al RMSE, en una primera aproximación decidimos usar el *accuracy* (tasa de acierto), la cual resultó ser similar en ambos modelos, con un 84 % de acierto. Ante

esta situación decidimos usar una métrica que nos permitiese tener un mayor nivel de detalle, como es la matriz de confusión. Podemos ver los resultados de las matrices en la figura 4.9.




Figura 4.9: Matrices de confusión de la predicción de episodios de desaturación. Señal suavizada. Se compara el modelo de una salida con predicciones recursivas frente al modelo que directamente genera predicciones a 10 segundos.

En la figura 4.9, podemos ver hay una elevada tasa de verdadero positivo (TP) en ambos modelos, siendo mayor, y por lo tanto mejor, la del modelo de una salida. Lo que refleja esta medida, es que cuando el modelo predice que va a haber un episodio de desaturación, acierta su predicción en un 78 % y 73 % de las veces respectivamente. Sin embargo, existe una elevada cantidad de eventos de desaturación que el modelo no predice satisfactoriamente. Para mejorar el acierto del modelo, se decidió refinar la métrica utilizada, bajo la siguiente condición: Si se predice que va a haber una desaturación, y dicha desaturación no tiene lugar, pero si tiene lugar en los siguientes n tramos (en particular, se ha escogido 1 tramo, que equivale a 1 segundo), lo podemos contabilizar como un acierto. Esto resulta conveniente, ya que si se ha predicho la desaturación con 1 segundo de antelación también podría considerarse como una buena predicción, y con esta modificación se ha obtenido una ligera mejora en las tasas de TP del 78 % al 79 %, y del 73 % al 74 % respectivamente (matrices de confusión disponible en apéndice, figura B.14).

En este momento, se puede deshacer el suavizado que habíamos aplicado originalmente sobre la señal de saturación (sección 3.3.1), y comprobar sobre el conjunto de entrenamiento si nuestro modelo efectivamente ha aprendido cómo realizar predicciones sobre la señal de saturación, o si por el contrario ha aprendido demasiado la forma de la señal suavizada. Aplicando de nuevo un valor de caída de saturación del 3 %, y la refinación de métrica explicada previamente, podemos ver los resultados en la figura 4.10. Observamos que los resultados han empeorado considerablemente al perder la información sobre el suavizado de la señal. En particular, el *accuracy* total de los modelos ha pasado de ser del 84 % al 82 % (en el modelo de múltiples salidas) y 71 % (en el modelo de una salida), mientras que las tasas de TP han descendido al 62 % y 43 % (frente al 74 % y 79 % anterior) respectivamente. Con estos resultados podemos concluir que al eliminar el suavizado de la señal (simulando que el algoritmo funciona en tiempo real), es mejor realizar todas las predicciones de forma directa, y no aplicar el algoritmo de predicciones recursivas (es decir, es mejor crear un modelo con múltiples salidas).




Figura 4.10: Matrices confusión predicción episodio desaturación. Señal sin preprocesar. Se compara el modelo de una salida con predicciones recursivas frente al modelo que directamente genera predicciones a 10 segundos.

Con los experimentos finalizados sobre el paciente que se había entrenado el modelo, conviene intentar extrapolar los resultados al resto de pacientes, y ver si las predicciones siguen siendo igualmente válidas. Para ello, vamos a realizar las mismas pruebas de matrices de confusión (con y sin suavizar) y cálculo del RMSE sobre toda la noche de un paciente diferente, el cual el modelo no ha utilizado a la hora de entrenar. Se pueden observar los resultados gráficamente en las figuras B.13 y B.14 del apéndice. A partir de las mismas, se puede ver que el modelo de predicciones recursivas obtiene mejores resultados (en cuanto al RMSE), cuando se aplica el suavizado de la señal. Sin embargo, al eliminar este suavizado, las predicciones empeoran con una gran velocidad. Esto no ocurre con el modelo de múltiples salidas, en el que la eliminación del suavizado parece no perjudicarle tanto. Analizando las matrices de confusión sobre el nuevo paciente (figura B.14), vemos como los resultados han empeorado de forma considerable respecto a 4.10, obteniendo finalmente unas tasas de TP del 29 % y 53 % para los modelos de una salida y múltiples salidas respectivamente. Por lo que el modelo claramente no es capaz de extrapolar los “conocimientos” adquiridos durante el entrenamiento a otro paciente.

A la vista de los resultados, comprobamos que la predicción de la evolución de la señal de saturación se ha podido realizar con cierto éxito para un único paciente, pero dicho modelo no sirve para predecir otros pacientes. Por ello, se va a intentar entrenar un modelo que utilice múltiples pacientes, para mejorar la capacidad de generalización (ver sección 4.2.2).

4.2.2. LSTM

Como ya se ha comentado en la sección 3.3.5, las redes LSTM son un tipo de red neuronal diseñadas específicamente para su aplicación en series temporales. Con los resultados obtenidos en la sección 4.2.1, hemos adquirido una primera idea del comportamiento de las predicciones de nuestra

serie temporal univariada, con la que hemos extraído la siguiente información:

- Se obtiene un mejor resultado al usar arquitecturas que predicen de forma directa la salida que deseamos, frente a realizar predicciones de forma recursiva.
- Incrementar el tamaño de la entrada no nos proporciona mejores resultados, siendo suficiente secuencias de los últimos 30 segundos para realizar predicciones a 10 segundos.
- A pesar de que entrenar con un único paciente genera modelos que son válidos para el mismo, estos modelos no se pueden extrapolar a otros pacientes.
- El suavizado que hemos aplicado en este caso particular, ha empeorado el resultado del modelo.

Teniendo en cuenta estas conclusiones, se ha diseñado un *dataset* formado por 4 pacientes (con un total de 90000 datos) con un nivel de IAH>50, y se ha aplicado la división de los datos en subconjuntos de entrenamiento, test y validación (ver figura 3.13) para realizar el entrenamiento de los modelos. En una primera aproximación, comenzamos a entrenar la red LSTM utilizando la señal de saturación suavizada. Sin embargo, observamos que se repetía el mismo comportamiento que habíamos visto en el MLP, y es que la red aprendía la forma de la señal suavizada, pero no generalizaba correctamente. Ante esta situación, decidimos realizar el entrenamiento directamente con la señal sin suavizar.

Para encontrar la configuración de hiperparámetros óptima, se han llevado a cabo varios experimentos, variando el tamaño de la primera capa oculta entre 100 y 500 unidades, y probando con una y dos capas ocultas. De igual forma, se han probado distintos *batch_size* (aleatoriamente escogidos entre 32, 64 y 128). Con cada uno de estos experimentos, se ha monitorizado la evolución del RMSE y analizado la matriz de confusión (una vez entrenado el modelo) sobre el conjunto de datos de test. Cabe destacar que al aplicar la red LSTM, hemos observado que la modelo hacía sobre-ajuste, por lo que se ha utilizado la capa de regularización *drop-out* para intentar prevenirlo. Tras estos experimentos, el mejor modelo tenía la siguiente arquitectura:

- Una capa oculta, con 150 unidades LSTM y función de activación tangente hiperbólica.
- Una capa de dropout (tras la capa oculta), con un 10 % de dropout.
- Capa de salida con función de activación tangente hiperbólica.

En particular, podemos ver la evolución del RMSE en función de la distancia de la predicción en 4.11(a), y la matriz de confusión en la figura 4.11(b). En estas figuras observamos un comportamiento similar al del MLP, pero con mejores puntuaciones. Vemos de nuevo como el error en las predicciones a corto plazo es mucho menor que en las que son a más largo plazo, y podemos ver en la matriz de confusión que hemos obtenido una tasa de TP del 67 %, frente al 53 % que habíamos obtenido al aplicar el modelo sobre un paciente distinto al entrenado en el MLP (figura B.14(d)).

Para intentar aumentar la capacidad de predicción del modelo, se decidió proporcionar información adicional al mismo. En particular, como se había estudiado que la señal del pulso se encontraba sincronizada con la saturación (sección 4.1), se añadió dicha señal al conjunto de datos, de forma que cada muestra contiene los últimos 30 segundos de las señales de saturación y pulso, y realiza predicciones




Figura 4.11: Resultados LSTM usando únicamente la señal de saturación.

sobre los 10 segundos posteriores de la señal de saturación. Realizando de nuevo una exploración de hiperparámetros, llegamos a un modelo con las siguientes características:

- 2 capas ocultas con 200 y 100 unidades LSTM respectivamente, y función de activación ReLu.
- 2 capas de *drop-out* (tras cada una de las capas ocultas), con un 20 % de *drop-out*.
- Capa de salida con función de activación tangente hiperbólica.

Podemos ver los resultados en la figura 4.12. Observamos como gracias a esta mejora, hemos incrementado la tasa de TP del 67 % al 76 %, siendo este el modelo que nos ha proporcionado los mejores resultados de entre todos los modelos estudiados. Podemos observar también como el RMSE es menor, ya que al proporcionar más información al modelo para llevar a cabo el aprendizaje, este es capaz de realizar predicciones más precisas.




Figura 4.12: Resultados LSTM usando las señales de pulso y saturación. Podemos ver mejores resultados que en la figura 4.11 al proporcionar más información al modelo.

CONCLUSIONES Y TRABAJO FUTURO

El objetivo de este estudio era realizar un análisis del SAS, utilizando la prueba utilizada como método referente para el diagnóstico de dicha patología, que es la poligrafía nocturna. La motivación de dicho análisis era extraer conclusiones para intentar simplificar el diagnóstico de la enfermedad. Dicho estudio se ha llevado a cabo utilizando la información de 55 pacientes, que se han sometido a la prueba de poligrafía nocturna en su versión domiciliaria.

El trabajo se ha dividido en dos tareas principales: En primer lugar, estudiar la correlación entre las señales recogidas en la poligrafía nocturna y caracterizar el retraso entre las señales de la misma, y en segundo lugar realizar la predicción de la evolución de la señal de saturación, aplicando algoritmos de inteligencia artificial. Para llevar a cabo dicho estudio se ha hecho uso del lenguaje de programación Python.

Estudiando la correlación y retraso de las señales, la principal conclusión extraída ha sido la siguiente: Las señales de pulso y saturación se encuentran muy correlacionadas y no se encuentran retrasadas una frente a otra. Esta correlación es menor en aquellos pacientes que tienen un SAS moderado o severo ($IAH \geq 15$) (ver figura 4.1). En relación al resto de señales de la poligrafía nocturna podemos concluir que no se ha encontrado una correlación suficientemente significativa entre las mismas. Respecto al retraso de las señales recogidas, solo se ha confirmado la relación fisiológica entre las mismas, pero no se ha observado que el IAH del paciente influya en dicho retraso.

Respecto a la predicción de la evolución de la señal de saturación, como medio para anticiparse un evento de desaturación, hemos concluido que se pueden realizar predicciones locales, pero que la calidad de las predicciones se degrada conforme intentamos predecir a un plazo temporal superior o igual a los 10 segundos. Se ha comprobado también como la evolución de la señal de saturación no se comporta de forma idéntica en todos los pacientes, ya que al usar un único paciente para entrenar el modelo, dicho modelo no generalizaba correctamente a otros pacientes, por lo que es necesario incluir múltiples pacientes durante el entrenamiento. En dicho estudio, se ha aplicado el algoritmo del perceptrón multicapa con una codificación de los datos recurrente, así como una red LSTM (versión particular de red neuronal recurrente, las cuales están diseñadas específicamente para el tratamiento de series con estructura secuencial y dependencias temporales). Cabe destacar que los resultados

han sido mejores al aplicar este último tipo de red, con el que se ha llegado a obtener una tasa de TP del 76 % (figura 4.12), al ser su diseño óptimo para el problema que se ha tratado. Para obtener estos resultados, tras las pruebas con distintos hiperparámetros (ver apéndice tablas C.1 y C.2), se ha establecido que cada muestra se encuentra formada por los últimos 30 segundos (correspondiente a 90 observaciones), y se predicen 10 segundos (correspondiente a 30 observaciones).

En la predicción de los eventos de desaturación, hemos podido observar como al proporcionar al modelo no solo información de la señal que hemos decidido predecir (la saturación), sino también información sobre una señal adicional, que en este estudio ha sido el pulso, se ha mejorado el rendimiento del mismo (figura 4.11 vs 4.12). El motivo de escoger dicha señal es que se ha estudiado previamente que es la más correlacionada con la saturación.

Con los resultados obtenidos, existiría la posibilidad de implementar un sistema de predicción de eventos de desaturación en dispositivos sencillos y no intrusivos como puede ser un pulsioxímetro, o incluso un *smartwatch* actual con la funcionalidad de medir el pulso y el nivel de saturación. Midiendo estas señales y aplicando los algoritmos entrenados, podría anticiparse un evento de desaturación y alertar al paciente, por ejemplo, mediante una leve vibración.

Cabe destacar que este trabajo se ha podido llevar a cabo gracias a la disponibilidad de una base de datos con registros de múltiples pacientes que se han sometido a la prueba de poligrafía nocturna. Estas bases de datos son imprescindibles a la hora de realizar estudios de distintas enfermedades, y la calidad y cantidad de los datos es uno de los factores más importantes en este tipo de estudios.

Respecto al trabajo futuro, existe margen de mejora en el entrenamiento del algoritmo para predecir las desaturaciones. Por una parte, dadas las restricciones computacionales del equipo donde se ha llevado a cabo el entrenamiento, se ha limitado dicho entrenamiento a usar la información disponible en 4 pacientes. Sin embargo, es altamente probable que si se usase la información de todos los pacientes disponibles para entrenar un modelo, con la optimización de hiperparámetros correspondiente, se obtendría un modelo con una capacidad de predicción muy superior a la actual. Por otra parte, podría estudiarse cómo cambia la capacidad del modelo al incluir otras señales adicionales para hacer la predicción sobre la saturación, ya que este estudio se ha limitado a demostrar que incluir información adicional, en particular la señal del pulso, ha mejorado los resultados obtenidos. De forma adicional, podrían probarse otros modelos y analizar su rendimiento, como puede ser usar otras arquitecturas de RNR (por ejemplo, las *Gated recurrent units (GRUs)* [28]), u otro tipo de arquitectura como los *transformers* [29].

BIBLIOGRAFÍA

- [1] "American sleep association - sleep statistics." (Acceder).
- [2] J. G. Pérez-Larraya, J. B. Toledo, E. Urrestarazu, and J. Iriarte, "Clasificación de los trastornos del sueño," *Anales del Sistema Sanitario de Navarra*, vol. 30, pp. 19–36, 2007. (Acceder).
- [3] D. J. Gottlieb and N. M. Punjabi, "Diagnosis and management of obstructive sleep apnea: A review," *JAMA - Journal of the American Medical Association*, vol. 323, pp. 1380–1400, 4 2020. (Acceder).
- [4] M. Singh, P. Liao, S. Kobah, D. N. Wijesundera, C. Shapiro, and F. Chung, "Proportion of surgical patients with undiagnosed obstructive sleep apnoea," *British Journal of Anaesthesia*, vol. 110, pp. 629–636, 4 2013. (Acceder).
- [5] M. B. Peters and M. S. Jelic, "Learn about oxygen desaturation index (odi) in sleep," 3 2020. (Acceder).
- [6] U. Krishnaswamy, A. Aneja, R. Kumar, and T. Kumar, "Utility of portable monitoring in the diagnosis of obstructive sleep apnea," 10 2015. (Acceder).
- [7] "Aasm publishes new guideline for diagnostic testing for adult sleep apnea," 3 2017. (Acceder).
- [8] R. K. Malhotra, D. B. Kirsch, D. A. Kristo, E. J. Olson, R. N. Aurora, K. A. Carden, R. D. Chervin, J. L. Martin, K. Ramar, C. L. Rosen, J. A. Rowley, and I. M. Rosen, "Polysomnography for obstructive sleep apnea should include arousal-based scoring: An american academy of sleep medicine position statement," *Journal of Clinical Sleep Medicine*, vol. 14, pp. 1245–1247, 7 2018. (Acceder).
- [9] R. B. Berry, R. Budhiraja, D. J. Gottlieb, D. Gozal, C. Iber, V. K. Kapur, C. L. Marcus, R. Mehra, S. Parthasarathy, S. F. Quan, S. Redline, K. P. Strohl, S. L. Ward, and M. M. Tangredi, "Rules for scoring respiratory events in sleep: Update of the 2007 aasm manual for the scoring of sleep and associated events," *Journal of Clinical Sleep Medicine*, vol. 8, pp. 597–619, 2012. (Acceder).
- [10] K. K. H. Wong, D. Jankelson, A. Reid, G. Unger, G. Dungan, J. Redner, and R. R. Grunstein, "Diagnostic test evaluation of a nasal flow monitor for obstructive sleep apnea detection in sleep apnea research," *Behavior Research Methods*, vol. 40, pp. 360–366, 2008. (Acceder).
- [11] R. Jayaraj, M. Jagannath, and A. Kanagasabai, "A review on detection and treatment methods of sleep apnea," *Journal of Clinical and Diagnostic Research*, vol. 11, pp. VE01–VE03, 3 2017. (Acceder).
- [12] J. Zhang, Q. Zhang, Y. Wang, and C. Qiu, "A real-time auto-adjustable smart pillow system for sleep apnea detection and treatment," pp. 179–190, IEEE, 2013. (Acceder).
- [13] D. C. Cowan and E. Livingston, "Obstructive sleep apnoea syndrome and weight loss: Review," *Sleep Disorders*, vol. 2012, pp. 1–11, 2012. (Acceder).
- [14] E. Simou, J. Britton, and J. Leonardi-Bee, "Alcohol and the risk of sleep apnoea: a systematic review and meta-analysis," *Sleep Medicine*, vol. 42, pp. 38–46, 2 2018. (Acceder).

- [15] M. Sánchez-Moliní, A. Rollón, J. M. Benítez, F. Mayorga, S. Gallana, R. Lozano, J. J. Otero, and M. Gascón, "Manejo del sahs mediante dispositivos de avance mandibular: Estudio preliminar," *Revista Española de Cirugía Oral y Maxilofacial*, vol. 32, pp. 152–158, 2010. (Acceder).
- [16] P. J. Strollo, R. J. Soose, J. T. Maurer, N. de Vries, J. Cornelius, O. Froymovich, R. D. Hanson, T. A. Padhya, D. L. Steward, M. B. Gillespie, B. T. Woodson, P. H. V. de Heyning, M. G. Goetting, O. M. Vanderveken, N. Feldman, L. Knaack, and K. P. Strohl, "Upper-airway stimulation for obstructive sleep apnea," *New England Journal of Medicine*, vol. 370, pp. 139–149, 1 2014. (Acceder).
- [17] R. D. Cartwright, "Effect of sleep position on sleep apnea severity," *Sleep*, vol. 7, pp. 110–114, 1984. (Acceder).
- [18] J. A. A. D. Dios and S. D. Brass, "New and unconventional treatments for obstructive sleep apnea," *Neurotherapeutics*, vol. 9, pp. 702–709, 10 2012. (Acceder).
- [19] M. P. Boyce, "Sleep apnea treatment options," 6 2017. (Acceder).
- [20] L. Cabezas-Labrin and L. Hernández-Rivero, "Experiencia en pacientes operados de roncopatía y apnea obstructiva del sueño," *Revista de otorrinolaringología y cirugía de cabeza y cuello*, vol. 79, pp. 167–172, 6 2019. (Acceder).
- [21] S. Tavares, F. Alóe, V. Gentil, and M. Scaff, "Excessive somnolence.," *São Paulo medical journal = Revista paulista de medicina*, vol. 114, pp. 1231–1238, 1996. (Acceder).
- [22] A. Muñoz, L. R. Mayoralas, F. Barbé, J. Pericás, and A. G. Agustí, "Long-term effects of cpap on daytime functioning in patients with sleep apnoea syndrome," *European Respiratory Journal*, vol. 15, pp. 676–681, 2000. (Acceder).
- [23] J. He, M. H. Kryger, F. J. Zorick, W. Conway, and T. Roth, "Mortality and apnea index in obstructive sleep apnea. experience in 385 male patients," *Chest*, vol. 94, pp. 9–14, 7 1988. (Acceder).
- [24] F. Campos-Rodriguez, N. Peña-Griñan, N. Reyes-Nuñez, I. D. L. Cruz-Moron, J. Perez-Ronchel, F. D. L. Vega-Gallardo, and A. Fernandez-Palacin, "Mortality in obstructive sleep apnea-hypopnea patients treated with positive airway pressure," *Chest*, vol. 128, pp. 624–633, 2005. (Acceder).
- [25] S. Dodds, L. J. Williams, A. Roguski, M. Vennelle, N. J. Douglas, S.-C. Kotoulas, and R. L. Riha, "Mortality and morbidity in obstructive sleep apnoea–hypopnoea syndrome: results from a 30-year prospective cohort study," *ERJ Open Research*, vol. 6, pp. 00057–2020, 7 2020. (Acceder).
- [26] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, pp. 1735–1780, 11 1997. (Acceder).
- [27] S. B. Boyd, R. Upender, A. S. Walters, R. L. Goodpaster, J. J. Stanley, L. Wang, and R. Chandrasekhar, "Effective apnea-hypopnea index (.effective ahi): A new measure of effectiveness for positive airway pressure therapy," *Sleep*, vol. 39, pp. 1961–1972, 11 2016. (Acceder).
- [28] K. Cho, B. V. Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning phrase representations using rnn encoder-decoder for statistical machine translation," pp. 1724–1734, Association for Computational Linguistics (ACL), 6 2014. (Acceder).
- [29] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Łukasz Kaiser, and I. Polosukhin, "Attention is all you need," vol. 2017-December, pp. 5999–6009, Neural information

- processing systems foundation, 6 2017. (Acceder).
- [30] "Cpap for obstructive sleep apnea | cms." (Acceder).

DEFINICIONES

coeficiente de correlación de Pearson Medida de dependencia lineal entre dos variables aleatorias cuantitativas y continuas. Es independiente de la escala de medida de las variables.

desaturacion Descenso mínimo del 3 % [9], o 4 % [30], en el nivel de oxígeno en sangre.

oxímetro Dispositivo que se coloca, generalmente, en un dedo de la mano para medir el nivel de saturación en sangre.

poligrafía nocturna Prueba médica en la que se monitorizan, durante el sueño del paciente, múltiples señales como el flujo respiratorio, frecuencia cardíaca, saturación en sangre, sonidos, ronquidos y movimientos corporales entre otras [6].

pulsioxímetro Dispositivo que se coloca, generalmente, en un dedo de la mano para medir tanto el nivel de saturación en sangre y como la frecuencia cardíaca.

Random Search Método para la optimización de hiperparámetros de un modelo, en el que se define el espacio de búsqueda y el algoritmo escoge aleatoriamente valores entre los disponibles.

sobre-ajuste Fenómeno de sobreentrenamiento que tiene lugar en el aprendizaje automático, cuando un modelo “memoriza” las muestras de entrenamiento y pierde capacidad para predecir correctamente el resto de muestras.

ACRÓNIMOS

- ASA** American Sleep Association.
- CPAP** presión positiva continua en las vías respiratorias.
- EDF** European Data Format.
- IA** índice de apneas por hora.
- IAH** índice de apneas e hipopneas por hora.
- ID** índice de desaturaciones por hora.
- LSTM** Long short-term memory.
- MAD** dispositivo de avance mandibular.
- MLP** Perceptron multicapa.
- RMSE** Raíz del Error Cuadrático Medio.
- RNR** Red neuronal recurrente.
- SAS** síndrome de apnea obstructiva del sueño.
- TP** verdadero positivo.

APÉNDICES

CÓDIGO Y DOCUMENTACIÓN

El código desarrollado para la elaboración de todo el trabajo se encuentra accesible en el siguiente enlace: <https://github.com/Andresmena99/TFG>. Este repositorio contiene el código tanto de la implementación del diagrama de clases especificado en la figura 3.2, como las implementaciones y resultados obtenidos con las distintas redes neuronales que se han implementado. De forma adicional, se ha generado una documentación complementaria, la cual se encuentra disponible en <https://andresmena99.github.io/TFG/>.

FIGURAS

RECORD ▾ PLAY ▾ Settings			
Command			
DELAY	50		
MOUSE	LeftButtonUp	X = 968	Y = 607
REPEAT	8		
DELAY	1500		
MOUSE	Click	X = 14	Y = 110
DELAY	200		
MOUSE	Click	X = 56	Y = 136
DELAY	200		
WAIT FOR WINDOW	Add New Signal	appear	
DELAY	200		
MOUSE	Click	X = 834	Y = 330
DELAY	500		
if ITERATION EQUALS	1		
TYPE TEXT	Activity-Gravity		
END IF			
if ITERATION EQUALS	2		
TYPE TEXT	Snore.Envelope-Audio.dB		
END IF			
if ITERATION EQUALS	3		
TYPE TEXT	Resp.Pressure-Cannula.Nasal		
END IF			
if ITERATION EQUALS	4		
TYPE TEXT	Pulse.Averaged-Probe		
END IF			
if ITERATION EQUALS	5		
TYPE TEXT	Resp.Movement-Inductive.Abdomen		
END IF			
if ITERATION EQUALS	6		
TYPE TEXT	SpO2.Averaged-Probe		
END IF			
if ITERATION EQUALS	7		
TYPE TEXT	Resp.Flow-Cannula.Nasal		
END IF			
if ITERATION EQUALS	8		
TYPE TEXT	Resp.Snore-Cannula.Nasal		
END IF			
DELAY	2000		
MOUSE	Click	X = 716	Y = 352
DELAY	200		
MOUSE	Click	X = 1015	Y = 792
DELAY	2000		
MOUSE	Click	X = 1127	Y = 792
DELAY	1500		
END REPEAT			

Figura B.1: Captura de pantalla de MacroRecorder con parte de la secuencia de acciones para llevar a cabo la exportación de forma automatizada.




Figura B.2: Representación correlación señales frente a abdomen en función del IAH.




Figura B.3: Representación retraso señales frente a abdomen en función del IAH.




Figura B.4: Representación correlación señales frente a actividad motora en función del IAH. No se observan niveles de correlación que dependan del IAH.




Figura B.5: Representación retraso señales frente a actividad motora en función del IAH.




Figura B.6: Representación correlación señales frente a nivel de sonido en función del IAH. Se observan niveles de correlación muy bajos en todos los casos.




Figura B.7: Representación retraso señales frente a nivel de sonido en función del IAH. Podemos ver relaciones esperadas como que al roncar se incrementa el sonido, y lo mismo ocurre con el movimiento abdominal.




Figura B.8: Representación correlación señales frente a pulso en función del IA H. Se observan niveles de correlación bajos generalmente a excepción de la saturación, como se ha comentado en la sección 4.1.




Figura B.9: Representación retraso señales frente a pulso en función del IAH. Podemos observar principalmente la relación fisiológica entre las señales de actividad y pulso, ya que al aumentar la actividad motora se incrementan la frecuencia cardiaca.




Figura B.10: Representación correlación señales frente a ronquido en función del IAH. Se observan niveles de correlación muy bajos en todos los casos.






Figura B.11: Representación retraso señales frente a ronquido en función del IAH. Observamos relaciones fisiológicas principalmente en las figuras del volumen de audio (el ronquido incrementa el volumen de audio), en el flujo (al respirar se incrementa el sonido) y actividad motora y abdomen (al movernos se incrementa el sonido).



(a) Modelo con número entradas = 90, salidas = 1



(b) Modelo con número entradas = 90, salidas = 30

Figura B.12: Comparativa tramo real frente a tramo predicho en la señal de saturación. Se observa como los resultados generalmente parecen mejores para el modelo de 30 salidas, y que en ocasiones la predicción solo es buena localmente.




Figura B.13: Comparativa RMSE en predicciones multipaso MLP paciente nuevo. Se observa que eliminando el suavizado de la señal, es mejor el modelo de salidas múltiples.




Figura B.14: Matrices confusión predicción episodio desaturación sobre paciente nuevo con arquitectura MLP. Se compara el modelo de una salida con predicciones recursivas frente al modelo que directamente genera predicciones a 10 segundos. Se observan mayor tasa de TP en el modelo de múltiples salidas.

TABLAS

# entradas	# salidas	# capas ocultas	Capas ocultas	batch_size	RMSE train	RMSE test
90	30	2	1000-500	64	1.639299	1.975932
90	30	2	2000-1000	64	1.671724	1.994340
90	30	2	500-500	64	1.582662	2.002480
135	30	2	500-500	32	1.707847	2.004986
90	30	2	500-1000	64	1.607212	2.042077
90	30	1	750	32	1.687035	2.048266
135	30	2	1000-1000	64	1.659030	2.063159
135	30	2	1000-500	64	1.687679	2.067127
90	30	1	2000	32	1.721331	2.081666
90	30	2	1000-1000	64	1.828300	2.090038
135	30	2	500-1000	64	1.803917	2.090768
135	30	2	2000-1000	64	1.675817	2.123660
90	30	1	500	32	1.761861	2.124465
90	30	1	1500	32	1.760621	2.133248
135	30	1	1000	32	1.774484	2.136332
90	30	1	3000	32	1.773813	2.160548
90	30	1	1000	32	1.789509	2.162656
90	30	1	2500	32	1.781140	2.164706
135	30	1	500	32	1.810186	2.167213
135	30	1	750	32	1.811652	2.169923
135	30	1	1500	32	1.830769	2.248682
135	30	1	2000	32	1.843941	2.264480
135	30	1	2500	32	1.873312	2.305195

Tabla C.1: Resultados completos MLP con diferentes parámetros. Predicción múltiples observaciones.

# entradas	# salidas	# capas ocultas	Capas ocultas	batch_size	RMSE train	RMSE test
90	1	1	1500	32	0.054472	0.060784
90	1	1	750	32	0.054732	0.060951
90	1	1	500	32	0.054753	0.061251
90	1	1	1000	32	0.055870	0.062581
135	1	1	4000	32	0.060118	0.066874
135	1	1	2000	32	0.060206	0.067107
135	1	1	3000	32	0.060066	0.067145
135	1	1	1500	32	0.060557	0.067534
135	1	1	1000	32	0.060903	0.068051
90	1	1	2000	64	0.062425	0.070302
90	1	1	3000	64	0.063001	0.070969
90	1	1	4000	64	0.063413	0.071395
90	1	2	500-500	32	0.067181	0.076014
90	1	2	500-250	32	0.067412	0.076296
90	1	2	1000-1000	32	0.067507	0.076661
90	1	2	1000-500	32	0.068911	0.078135
180	1	1	3000	32	0.071399	0.081276
180	1	1	2000	32	0.071415	0.081381
180	1	1	1000	32	0.071450	0.081820
180	1	1	1500	32	0.072101	0.082410
180	1	1	500	32	0.072036	0.082613
180	1	1	750	32	0.072300	0.082812
180	1	1	250	32	0.072651	0.083391
180	1	2	1000-1000	32	0.072965	0.083736
90	1	4	500-350-200-50	64	0.082860	0.096108
90	1	3	500-400-300	64	0.083810	0.096659
90	1	3	1000-750-500	64	0.085371	0.098332
90	1	4	1000-750-500-250	64	0.086587	0.099117
180	1	2	1000-500	64	0.086954	0.101180
180	1	2	500-1000	64	0.088095	0.102410
180	1	2	2000-1000	64	0.088566	0.103137
180	1	2	500-500	64	0.088614	0.103711
180	1	2	1000-1000	64	0.089471	0.104407
90	1	2	2000-2000	32	0.093181	0.107691

Tabla C.2: Resultados completos MLP con diferentes parámetros. Predicción una observación.

