



GRADO EN INGENIERÍA EN TECNOLOGÍAS DE TELECOMUNICACIÓN

TRABAJO FIN DE GRADO

APLICACIÓN DE MODELOS DE APRENDIZAJE AUTOMÁTICO PARA LA DETECCIÓN DE ENTRADA EN SUEÑO A PARTIR DE VARIABLES FISIOLÓGICAS MEDIDAS POR PULSERAS DE ACTIVIDAD

Autor: Alfonso Serrano-Suñer García de Leyaristy

Director: Antonio Muñoz San Roque

Co-Director: Manuel Castillo Garzón

Madrid

Declaro, bajo mi responsabilidad, que el Proyecto presentado con el título
Aplicación de modelos de aprendizaje automático para la detección de entrada en sueño a partir de variables fisiológicas medidas por pulseras de actividad
en la ETS de Ingeniería - ICAI de la Universidad Pontificia Comillas en el
curso académico 2022/23 es de mi autoría, original e inédito y
no ha sido presentado con anterioridad a otros efectos.
El Proyecto no es plagio de otro, ni total ni parcialmente y la información que ha sido
tomada de otros documentos está debidamente referenciada.



Fdo.: Alfonso Serrano-Suñer García de Leyaristy Fecha: 2/ 6/ 2023

Autorizada la entrega del proyecto

EL DIRECTOR DEL PROYECTO



Fdo.: Antonio Muñoz San Roque

Fecha: 4/ 6/ 2023

Doctor Ingeniero Industrial

Universidad Pontificia de Comillas

EL CO-DIRECTOR DEL PROYECTO

Firmado por CASTILLO GARZON MANUEL
JOAQUIN - 24112245B el día 04/06/2023
con un certificado emitido por AC FNMT
Usuarios

Fdo.: Manuel Castillo Garzón

Fecha: 4/ 6/ 2023

Catedrático de Fisiología Médica

Universidad de Granada



GRADO EN INGENIERÍA EN TECNOLOGÍAS DE TELECOMUNICACIÓN

TRABAJO FIN DE GRADO

APLICACIÓN DE MODELOS DE APRENDIZAJE AUTOMÁTICO PARA LA DETECCIÓN DE ENTRADA EN SUEÑO A PARTIR DE VARIABLES FISIOLÓGICAS MEDIDAS POR PULSERAS DE ACTIVIDAD

Autor: Alfonso Serrano-Suñer García de Leyaristy

Director: Antonio Muñoz San Roque

Co-Director: Manuel Castillo Garzón

Madrid

Agradecimientos

Quisiera dar las gracias en primer lugar a mis padres, por haberme dado la oportunidad de estudiar esta carrera y haberme inculcado desde niño el valor del esfuerzo, la perseverancia ante la adversidad y la dignidad del trabajo bien hecho, así como por su apoyo incondicional en los momentos más difíciles de esta etapa que ahora se cierra.

Mis agradecimientos también a Antonio, mi director, de quien partió la iniciativa de comenzar este proyecto de investigación que ha fructificado en los resultados recogidos en estas páginas, y cuya orientación continua a lo largo del curso ha sido esencial para llevarlo a buen término. En este sentido, también debo dar las gracias al doctor Manuel Castillo por sus valiosas ideas y aportaciones, que resultaron determinantes para conferir al proyecto la orientación específica hacia el problema de detección de somnolencia al que trata de dar respuesta.

Por último, doy las gracias a la propia Universidad y a todos los amigos, profesores y compañeros que he conocido durante esta etapa formativa y que me han ayudado a crecer intelectualmente y como persona. Ante la nueva etapa que se abre ahora, confío en poder llevarme y poner en práctica el principio que esta institución ha tratado de transmitirme: la búsqueda constante de la excelencia en todo, conforme a los dones y talentos de cada uno. Todo ello, como reza la sentencia jesuita, *ad maiorem Dei gloriam*.

APLICACIÓN DE MODELOS DE APRENDIZAJE AUTOMÁTICO PARA LA DETECCIÓN DE ENTRADA EN SUEÑO A PARTIR DE VARIABLES FISIOLÓGICAS MEDIDAS POR PULSERAS DE ACTIVIDAD

Autor: Serrano-Suñer García de Leyaristy, Alfonso.

Director: Muñoz San Roque, Antonio.

Co-director: Castillo Garzón, Manuel.

Entidad Colaboradora: ICAI – Universidad Pontificia Comillas.

RESUMEN DEL PROYECTO

El presente proyecto aborda la problemática de la detección de entrada en sueño o somnolencia crítica en base a los registros fisiológicos – particularmente la frecuencia cardiaca – proporcionados por pulseras de actividad comerciales (Xiaomi Mi Band y Fitbit Charge 5/Inspire 2). Para ello se ha contado con la colaboración de una cohorte de ocho voluntarios, a partir de los cuales se han extraído los datos empleados en el proyecto. La solución que se explora se basa en la aplicación de algoritmos de aprendizaje automático para el desarrollo y evaluación de modelos capaces de realizar esta tarea predictiva. Se propone y aplica una metodología *end-to-end* para el procesamiento, análisis, modelización y validación final. La fase de modelización, incluyendo el ajuste de hiperparámetros, ha permitido entrenar e identificar para cada sujeto un modelo óptimo, alcanzándose tasas de acierto en *test* en varios casos superiores al 97%. La fase de validación final se ha basado en comparativas de las predicciones generadas por el modelo con mediciones reales del nivel de atención del sujeto, mediante una aplicación web que implementa un juego sencillo para medir tiempos de reacción. Los resultados de esta última fase son también muy prometedores, si bien se requiere de trabajos posteriores que permitan validar y confirmar las conclusiones.

Palabras clave: Aprendizaje automático, aprendizaje profundo, dispositivos portátiles, LSTM, CNN, ritmo cardiaco, somnolencia, entrada en sueño.

1. Introducción

Los accidentes de tráfico se cobran la vida de aproximadamente 1,3 millones de personas anualmente, y son la principal causa de fallecimiento en niños y jóvenes de entre 5 y 29 años [1]. La somnolencia es un factor significativo que puede incrementar sustancialmente el riesgo de accidente; estando implicada de manera directa o indirecta en un 15-30% de los accidentes en España [2]. La somnolencia al volante puede tener diversas causas, incluyendo alteraciones del ritmo circadiano o periodos de conducción prolongada e ininterrumpida, y repercute de manera negativa en el nivel de alerta, el tiempo de reacción y la coordinación mano-ojo (véase [3], [4]), todas ellas capacidades esenciales no sólo de cara a la conducción, sino para el desempeño de cualquier tarea que requiera de un nivel mínimo de atención para poder desarrollarse en condiciones de seguridad.

Dada la progresiva generalización en el uso de dispositivos portátiles (comúnmente referidos como *wearable*) y su creciente fiabilidad, se presenta una oportunidad para, tomando provecho de esta tendencia, explorar el potencial de soluciones de enfoque

fisiológico al problema de detección de somnolencia o entrada en sueño. Encuadrado en este contexto, el presente proyecto busca investigar y establecer las bases para un marco de detección de somnolencia aguda basado únicamente en las capacidades de medición de estos dispositivos.

2. Definición del Proyecto

En este proyecto se desarrollan y evalúan una serie de modelos de aprendizaje automático que, a partir del ritmo cardiaco, puedan proporcionar una probabilidad sobre si el sujeto al que se corresponden dichas mediciones se encuentra dormido/en un estado de somnolencia aguda, siguiendo una aproximación individualizada. El desarrollo de estos modelos se plantea como base de cara al potencial desarrollo de un sistema que alerte a los usuarios del dispositivo en el que esté integrado cuando detecte que éste pueda estar entrando en un estado crítico de pérdida de atención.

Por ello, su principal objetivo no es otro que (1) el desarrollo y validación de un modelo de aprendizaje automático para cada individuo, con las capacidades que se acaban de describir. En paralelo a este objetivo principal, encontramos varios objetivos paralelos de naturaleza complementaria: (2) explorar y entender el comportamiento del ritmo cardiaco durante el proceso de transición al estado de sueño; (3) recopilación, limpieza y preprocesamiento de las mediciones, con la consiguiente creación de una base de datos anonimizada que pueda ser utilizada en futuros estudios; y (4) identificación de un método adecuado para validar el modelo una vez entrenado. Como ya se ha comentado, dicho método de validación será una aplicación web que permita a los voluntarios acceder a un juego de velocidad de reacción, a través del cual se puedan registrar los tiempos de reacción e inferir el nivel de somnolencia del sujeto (a fin de contrastarlo con las predicciones del modelo).

3. Descripción de la metodología implementada y los modelos entrenados

La metodología implementada se estructura en cinco grandes fases (Ilustración 1): extracción de los datos, preprocesamiento básico y análisis exploratorio, modelización y validación final de los modelos óptimos.




Ilustración 1 – Metodología del proyecto

La extracción de datos requirió previamente el reclutamiento de voluntarios y la adquisición de los dispositivos. El preprocesamiento tuvo como propósito la limpieza de los datos y la homogeneización de su formato y estructura, y las conclusiones del análisis exploratorio sirvieron para orientar la fase de modelado. El procedimiento concreto de modelización se expone en la ilustración bajo estas líneas (Ilustración 2). Implica (1) el ajuste de parámetros y arquitectura para tres tipos distintos de modelo, (2) la evaluación del rendimiento del modelo en el conjunto de *test* y por último (3) la consiguiente identificación del modelo óptimo a partir de dicho rendimiento.




Ilustración 2 – Procedimiento para el ajuste de modelos

Téngase en cuenta que el procedimiento de modelización se aplica individualmente a los datos de cada voluntario, no se desarrollarán modelos genéricos debido a la elevada variabilidad entre sujetos en el comportamiento de la frecuencia cardiaca. Finalmente, tal y como se ha descrito antes, el método de validación final del modelo óptimo se basará en el registro de tiempos de reacción del sujeto para una noche concreta (en el momento en el que se disponga a dormir) y su contraste con las predicciones del modelo óptimo.




Ilustración 3 – Procedimiento de validación final

El *backend* de la aplicación se ha desarrollado en Python, empleándose el *microframework* Flask. El juego propiamente dicho está programado en Javascript, y se recurre a Ajax para el envío asíncrono de las mediciones al servidor.

4. Resultados

Para la tercera arquitectura propuesta (modelo híbrido constituido por una capa convolucional unidimensional con pooling seguida por tres capas LSTM) se obtuvieron los mejores resultados en *test* para casi todos los voluntarios, tanto en términos de tasa de acierto como en términos de *recall* y precisión.

<i>Sujeto</i>	<i>Modelo óptimo</i>	<i>Pulsera</i>	<i>AUC</i>	<i>F1 Score</i>	<i>Precisión</i>	<i>Recall</i>	<i>Tasa de acierto</i>
<i>ID1</i>	CNN + LSTM	Fitbit	0.98	0.89	90.63%	87.91%	97.23%
<i>ID3</i>	CNN + LSTM	MiBand	0.97	0.88	92.55%	83.36%	93.31%
<i>ID5</i>	LSTM	MiBand	0.97	0.85	91.54%	80.78%	92.16%
<i>ID6</i>	CNN + LSTM	MiBand	0.99	0.92	95.13%	89.23%	96.05%
<i>ID7</i>	CNN + LSTM	MiBand	0.95	0.85	88.87%	81.06%	91.04%
<i>ID8</i>	CNN + LSTM	Fitbit	0.99	0.96	93.90%	97.73%	97.48%

Tabla 1 – Resultados en test de los modelos óptimos

Por otra parte, a través de la representación de las regiones de decisión, los modelos XGBoost han permitido estudiar en mayor detalle los cambios a corto plazo de la frecuencia cardiaca al producirse la transición al sueño. Por último, dada la naturaleza voluntaria de la participación y la incomodidad que supone la realización de la prueba para medir los tiempos de reacción durante la transición al sueño, únicamente se ha podido validar el modelo óptimo con dos de los voluntarios (ID1 e ID8). En cualquier caso, los resultados son prometedores, verificándose en efecto una correlación (no lineal) entre los tiempos de reacción y las probabilidades del modelo.




Ilustración 4 – Relación entre probabilidades del modelo y tiempos de reacción para ID1 e ID8

Dado que la correlación es no lineal, se ha empleado el coeficiente de Spearman para cuantificarla (con valores de 0.68 y 0.82 para los sujetos ID1 e ID8, respectivamente).

5. Conclusiones

Se han logrado cubrir satisfactoriamente todos los objetivos establecidos al inicio del proyecto. Con todo, se hace necesario avanzar en el trabajo para poder confirmar las conclusiones, particularmente incluyendo un mayor número de voluntarios (dado que, a nuestro juicio, la metodología está bien definida y únicamente requiere escalarse a una muestra mayor).

6. Referencias

- [1] “Global status report on road safety 2018,” Jun. 2018. Accessed: Oct. 20, 2022. [Online]. Available: <https://www.who.int/publications/i/item/9789241565684>
- [2] “Conducir con sueño o cansancio,” *Dirección General de Tráfico*, Nov. 30, 2022. <https://www.dgt.es/muevete-con-seguridad/evita-conductas-de-riesgo/Conducir-con-sueno-o-cansancio> (accessed May 20, 2023).
- [3] A. Moradi, S. S. H. Nazari, and K. Rahmani, “Sleepiness and the risk of road traffic accidents: A systematic review and meta-analysis of previous studies,” *Transp Res Part F Traffic Psychol Behav*, vol. 65, pp. 620–629, Aug. 2019, doi: 10.1016/j.trf.2018.09.013.
- [4] Ji Hyun Yang, Zhi-Hong Mao, L. Tijerina, T. Pilutti, J. F. Coughlin, and E. Feron, “Detection of Driver Fatigue Caused by Sleep Deprivation,” *IEEE Transactions on Systems, Man, and Cybernetics - Part A: Systems and Humans*, vol. 39, no. 4, pp. 694–705, Jul. 2009, doi: 10.1109/TSMCA.2009.2018634.

APPLICATION OF MACHINE LEARNING TECHNIQUES FOR THE DETECTION OF SLEEP ONSET BASED ON PHYSIOLOGICAL VARIABLES MEASURED BY WEARABLE DEVICES

Author: Serrano-Suñer García de Leyaristy, Alfonso.

Supervisor: Muñoz San Roque, Antonio.

Co-Supervisor: Castillo Garzón, Manuel.

Collaborating Entity: ICAI – Universidad Pontificia Comillas.

ABSTRACT

This project addresses the challenge of detecting the onset of sleep or critical drowsiness based on physiological records - specifically heart rate - provided by commercial activity trackers (Xiaomi Mi Band and Fitbit Charge 5/Inspire 2). The study was conducted in collaboration with a cohort of eight volunteers, from whom the data used in the project was extracted. The solution explored involves the application of machine learning algorithms for the development and evaluation of models capable of performing this predictive task. An end-to-end methodology is proposed and applied, encompassing data processing, analysis, modeling, and final validation. The modeling phase, including hyperparameter tuning, has allowed for the training and identification of an optimal model for each subject, achieving test accuracy rates that in several cases exceed the 97% mark. The final validation phase was based on comparisons of the predictions generated by the model with actual measurements of the subject's attention level, using a web application that implements a simple game to measure reaction times. The results of this final phase are also very promising, although further work is needed to validate and confirm the conclusions.

Keywords: Machine learning, deep learning, wearable devices, LSTM, CNN, heart rate, drowsiness, sleep onset.

1. Introduction

Traffic accidents claim the lives of approximately 1.3 million people annually and are the leading cause of death in children and young people between the ages of 5 and 29 [1]. Drowsiness is a significant factor that can substantially increase the risk of accidents; it is directly or indirectly involved in 15-30% of accidents in Spain [2]. Drowsiness while driving can have various causes, including circadian rhythm disturbances or prolonged, uninterrupted periods of driving, and it negatively impacts alertness, reaction time, and hand-eye coordination (see [3], [4]). These are all essential capabilities not only for driving but also for performing any task that requires a minimum level of attention to be carried out safely.

Given the progressive generalization in the use of wearable devices and their increasing reliability, an opportunity arises to leverage this trend and explore the potential of physiologically-based solutions to the problem of drowsiness/sleep onset detection. Framed within this context, the present study seeks to investigate and establish the foundations for a framework for acute drowsiness detection based solely on the measurement capabilities of these devices.

2. Project definition

In this project, a set of machine learning models are developed and evaluated. These models, predicated on heart rate data, are trained to estimate the likelihood of a subject being asleep or in a state of acute drowsiness, adhering to an individualized approach. The formulation of these models serves as a foundation for the prospective development of a system capable of alerting users of an impending critical loss of attention.

The primary objective of this project is therefore (1) the development and validation of a machine learning model for each individual, trained to perform the aforementioned task. Alongside this main objective, there are several complementary goals: (2) to investigate and comprehend the dynamics of heart rate behavior during the transition to a sleep state; (3) to compile, cleanse, and preprocess the measurements, thereby creating an anonymized database for future research endeavors; and (4) to identify a suitable method for validating the model post-training. As previously stated, this validation method will be a web application that enables volunteers to engage in a reaction speed game. This game will allow for the recording of reaction times and the inference of the subject's level of drowsiness, providing a basis for comparison with the model's predictions.

3. Description of the methodology and trained models

The implemented methodology is structured into five major phases (Illustration 5): data extraction, basic preprocessing and exploratory analysis, modeling, and final validation of the optimal models.




Illustration 5 – Project methodology

Data extraction required the preliminary recruitment of volunteers and the acquisition of devices. The purpose of preprocessing was to cleanse the data and standardize its format and structure, while the conclusions from the exploratory analysis (EDA) were used to guide the modeling phase. The specific modeling procedure is depicted in the illustration below (Illustration 6). It involves (1) the adjustment of parameters and architecture for three different types of models, (2) the evaluation of model performance on the test set, and finally (3) the subsequent identification of the optimal model based on this performance.




Illustration 6 – Procedure for model training and evaluation

It should be noted that the modeling procedure is applied individually to the data of each volunteer; generic models will not be developed due to the high variability among subjects in heart rate behavior. Lastly, as previously described, the final validation method for the optimal model will be based on recording the subject's reaction times for a specific night (at the time they are about to sleep) and contrasting these with the predictions of the optimal model.




Illustration 7 – Final validation procedure

The backend of the application has been developed in Python, using Flask as microframework. The game itself is programmed in Javascript, and Ajax is used for asynchronous transmission of measurements to the server.

4. Results

For almost all volunteers, the third proposed architecture (a hybrid model consisting of a one-dimensional convolutional layer with pooling followed by three LSTM layers) achieved the best test results, both in terms of accuracy rate and in terms of recall and precision.

<i>Subject</i>	<i>Optimal model</i>	<i>Device</i>	<i>AUC</i>	<i>F1 Score</i>	<i>Precision</i>	<i>Recall</i>	<i>Accuracy</i>
<i>ID1</i>	CNN + LSTM	Fitbit	0.98	0.89	90.63%	87.91%	97.23%
<i>ID3</i>	CNN + LSTM	MiBand	0.97	0.88	92.55%	83.36%	93.31%
<i>ID5</i>	LSTM	MiBand	0.97	0.85	91.54%	80.78%	92.16%
<i>ID6</i>	CNN + LSTM	MiBand	0.99	0.92	95.13%	89.23%	96.05%
<i>ID7</i>	CNN + LSTM	MiBand	0.95	0.85	88.87%	81.06%	91.04%
<i>ID8</i>	CNN + LSTM	Fitbit	0.99	0.96	93.90%	97.73%	97.48%

Table 2 – Test results for optimal models

On the other hand, through the representation of decision regions, the XGBoost models have allowed for a more detailed study of short-term changes in heart rate during the transition to sleep state. Finally, given the voluntary nature of participation and the discomfort associated with the reaction time test (particularly due to the conditions under which it needs to be performed, as it has to take place at night while attempting to sleep), the optimal model could only be validated with two of the volunteers. Nevertheless, the results are promising, indeed verifying a (non-linear) correlation between reaction times and model probabilities.




Illustration 8 – Correlation between model probabilities and reaction times for ID1 and ID8

Given that the correlation is non-linear, the Spearman coefficient was used to quantify it (with values of 0.68 and 0.82 for subjects ID1 and ID8, respectively).

5. Conclusions

All the objectives set at the beginning of the project have been successfully met. However, further work is necessary to confirm the conclusions, particularly by including a larger number of volunteers. In our assessment, in spite of certain limitations the methodology is well-defined and should simply require scaling to a larger sample.

6. References

- [1] “Global status report on road safety 2018,” Jun. 2018. Accessed: Oct. 20, 2022. [Online]. Available: <https://www.who.int/publications/i/item/9789241565684>
- [2] “Conducir con sueño o cansancio,” *Dirección General de Tráfico*, Nov. 30, 2022. <https://www.dgt.es/muevete-con-seguridad/evita-conductas-de-riesgo/Conducir-con-sueno-o-cansancio> (accessed May 20, 2023).
- [3] A. Moradi, S. S. H. Nazari, and K. Rahmani, “Sleepiness and the risk of road traffic accidents: A systematic review and meta-analysis of previous studies,” *Transp Res Part F Traffic Psychol Behav*, vol. 65, pp. 620–629, Aug. 2019, doi: 10.1016/j.trf.2018.09.013.
- [4] Ji Hyun Yang, Zhi-Hong Mao, L. Tijerina, T. Pilutti, J. F. Coughlin, and E. Feron, “Detection of Driver Fatigue Caused by Sleep Deprivation,” *IEEE Transactions on Systems, Man, and Cybernetics - Part A: Systems and Humans*, vol. 39, no. 4, pp. 694–705, Jul. 2009, doi: 10.1109/TSMCA.2009.2018634.

Índice de la memoria

Capítulo 1. Introducción	7
1.1 Contexto y motivación	7
Capítulo 2. Descripción de las Tecnologías.....	9
2.1 Herramientas para la adquisición de datos: Pulseras Xiaomi y Fitbit.....	9
2.2 Fotopletismografía (PPG)	12
2.3 TensorFlow/Keras	13
2.4 Flask	14
2.4.1 Componentes y funcionalidad	14
2.4.2 Ejemplo y uso en el contexto del Proyecto.....	15
2.5 JavaScript/Ajax	16
2.6 SQLite	16
2.7 Azure Web Apps.....	17
Capítulo 3. Estado del Arte.....	18
3.1 Aproximaciones al problema en la literatura primaria.....	18
3.1.1 Enfoques conductuales.....	18
3.1.2 Enfoques basados en el análisis del comportamiento ocular	20
3.1.3 Enfoques basados en la fisiología del sujeto	20
3.2 Estado actual de la tecnología wearable.....	23
3.3 Técnicas de aprendizaje automático.....	25
3.3.1 Extreme Gradient Boosting	25
3.3.2 Long-Short Term Memory (LSTM) Recurrent Neural Networks (RNN).....	26
3.3.3 Redes Neuronales Convolucionales (CNN)	31
3.3.4 Optimización Bayesiana de hiperparámetros	34
3.3.5 Métricas básicas de evaluación: Tasa de acierto, precisión y recall	36
Capítulo 4. Objetivos y Metodología	39
4.1 Justificación.....	39
4.2 Objetivos	40
4.3 Metodología	41
4.3.1 Selección de voluntarios y adquisición de los datos	42

4.3.2 Preprocesamiento básico y Análisis Exploratorio	45
4.3.3 Ajuste de modelos e identificación del modelo óptimo	46
4.3.4 Validación final del modelo óptimo	47
4.4 Planificación.....	49
Capítulo 5. Análisis exploratorio de los datos	50
5.1 Lectura y preprocesamiento de los datos	50
5.1.1 Preprocesamiento de los datos Xiaomi MiBand 6	50
5.1.2 Preprocesamiento de los datos Fitbit (Charge 5 e Inspire 2).....	52
5.2 Análisis exploratorio de los datos (EDA)	57
Capítulo 6. Desarrollo de los modelos	62
6.1 Ajuste de modelos XGBoost.....	64
6.1.1 Preparación de los datos.....	64
6.1.2 Ajuste de hiperparámetros e identificación del modelo óptimo.....	65
6.1.3 Interpretación de las predicciones del modelo	76
6.2 Ajuste de modelos de Aprendizaje Profundo.....	80
6.2.1 Preparación de los datos.....	80
6.2.2 Redes LSTM puras	81
6.2.3 Arquitectura Híbrida (CNN & LSTM)	86
6.3 Comparativa final de resultados.....	92
Capítulo 7. Validación final	94
7.1 Descripción de la herramienta de validación: Juego de tiempo de reacción.....	95
7.2 Resultados de validación.....	96
7.2.1 Resultados para el sujeto ID1	97
7.2.2 Resultados para el sujeto ID8.....	100
7.3 Consideraciones de cara a la implantación del modelo en sistemas reales de alerta	102
Capítulo 8. Conclusión y Trabajos Futuros	104
8.1 Limitaciones en el estudio.....	104
8.1.1 Limitaciones en la muestra de voluntarios	104
8.1.2 Limitaciones en la metodología de validación.....	104
8.2 Cumplimiento de objetivos y evaluación de resultados.....	105
8.3 Trabajos futuros	106

Capítulo 9. Bibliografía	108
ANEXO I: ALINEACIÓN DEL PROYECTO CON LOS ODS.....	113
ANEXO II: CÓDIGO FUENTE	114

Índice de figuras

Figura 1: Comparativa visual de las señales de PPG y ECG [7].	13
Figura 2: Esquema de una red neuronal recurrente para una única neurona.	27
Figura 3: Esquema de una RNN con los pesos representados.	27
Figura 4: Esquema de una neurona LSTM [24].	31
Figura 5: Ejemplo de una capa convolucional 2D [27]	33
Figura 6: Ejemplo de red CNN completa para procesamiento de imágenes [28].	34
Figura 7: Precisión y recall en una matriz de confusión [32].	36
Figura 8: Metodología del proyecto	42
Figura 9: Distribución de voluntarios por edad	43
Figura 10: Distribución de voluntarios por sexo	44
Figura 11: Flujo de modelización	47
Figura 12: Metodología para la validación de los modelos finales.	48
Figura 13: Flujo de lectura y preprocesamiento para datos MiBand 6.	50
Figura 14: Flujo de lectura y preprocesamiento de datos Fitbit	56
Figura 15: Segmento de la serie temporal de ritmo cardiaco para ID1	57
Figura 16: Segmento de la serie de ritmo cardiaco para ID1, con periodos de sueño marcados	58
Figura 17: Serie temporal de ritmo cardiaco para varios sujetos	59
Figura 18: Distribución de ritmo cardiaco para los periodos de sueño (azul) y vigilia (amarillo)	59
Figura 19: Diagrama de modelización ampliado	62
Figura 20: Diagrama de entradas y salida del modelo XGBoost	64
Figura 21: Matriz de confusión XGBoost para ID1	68
Figura 22: Curva ROC de XGBoost para ID1	69
Figura 23: Matriz de confusión XGBoost para ID1 con umbral de clasificación ajustado.	70
Figura 24: Ejemplo de probabilidades asignadas por XGBoost para una noche.	71

Figura 25: Matriz de confusión en test y ROC de XGBoost para ID3.....	73
Figura 26: Matriz de confusión XGBoost para ID3 con umbral de clasificación ajustado .	73
Figura 27: Segmento de la serie temporal de ritmo cardiaco de ID7	75
Figura 28: Segmento de ID7 con los periodos de sueño señalados.....	75
Figura 29: Región de decisión XGBoost de ID3 para una ventana de 10 muestras	77
Figura 30: Cambios en la región de decisión XGBoost en función del tamaño de ventana	78
Figura 31: Comparativa de regiones de decisión XGBoost (ventanas de 10-15 minutos)..	79
Figura 32: Transición al sueño de ID8 representada sobre la región de decisión XGBoost	79
Figura 33: Diagrama de la red LSTM.	82
Figura 34: Matriz de confusión en test y ROC de LSTM para ID1	84
Figura 35: Matriz de confusión LSTM para ID1 con umbral de clasificación ajustado	84
Figura 36: Ejemplo de probabilidades LSTM para una noche	85
Figura 37: Diagrama de la red híbrida CNN + LSTM	88
Figura 38: Matriz de confusión en test y ROC de CNN + LSTM para ID1.....	89
Figura 39: Matriz de confusión CNN + LSTM para ID1 con umbral de clasificación ajustado	90
Figura 40: Ejemplo de probabilidades CNN + LSTM para una noche	90
Figura 41: Recordatorio de la metodología de validación.....	94
Figura 42: Diagrama de la aplicación web para el juego de velocidad de reacción	96
Figura 43: Procedimiento de validación tras la realización de la prueba	97
Figura 44: Velocidad de reacción de ID1 (remuestreada).....	98
Figura 45: Velocidad de reacción y probabilidad de transición al sueño para ID1	98

Índice de tablas

Tabla 1: Comparativa de prestaciones de las pulseras empleadas en el proyecto.	11
Tabla 2: Campos de los datos de sueño en bruto proporcionados por las pulseras Fitbit ...	54
Tabla 3: Espacio de búsqueda para modelos XGBoost	66
Tabla 4: Resultado de optimización XGBoost para ID1	68
Tabla 5: Métricas en test de los modelos XGBoost para datos Fitbit.....	72
Tabla 6: Resultado de optimización XGBoost para ID3	72
Tabla 7: Métricas en test de los modelos XGBoost para datos MiBand	74
Tabla 8: Configuración del optimizador y espacio de búsqueda para LSTM	83
Tabla 9: Métricas en test de los modelos LSTM para datos Fitbit	85
Tabla 10: Métricas en test de los modelos LSTM para datos MiBand.....	86
Tabla 11: Espacio de búsqueda de hiperparámetros para la red híbrida.....	88
Tabla 12: Métricas en test de los modelos CNN + LSTM para datos Fitbit	91
Tabla 13: Métricas en test de los modelos CNN + LSTM para datos MiBand	91
Tabla 14: Modelos óptimos	92

Capítulo 1. INTRODUCCIÓN

1.1 CONTEXTO Y MOTIVACIÓN

En torno a 1,3 millones de personas mueren cada año como consecuencia de accidentes de tráfico, siendo esta la principal causa de muerte en niños y jóvenes de entre 5 y 29 años de edad [1]. Así mismo, los accidentes de tráfico tienen para la mayoría de países un coste del 3% de su producto interior bruto, y la mortalidad asociada a los mismos afecta de manera particularmente severa a los países con un nivel de desarrollo bajo o medio. De acuerdo con la Dirección General de Tráfico (DGT), dependiente del Ministerio del Interior de España, la somnolencia está implicada directa o indirectamente en el 15-30% de los accidentes de tráfico en España [2].

Las causas de la somnolencia o fatiga durante la conducción son variadas, pudiendo ir desde la disrupción de los ritmos circadianos o la privación del sueño, hasta el consumo de ciertos medicamentos o la conducción ininterrumpida durante un periodo de tiempo excesivo; y ejerce un impacto notable y perjudicial en capacidades esenciales para el desempeño seguro de tareas como la conducción, incluyendo el nivel de atención, el tiempo de reacción, la coordinación mano-ojo y la vigilancia [3]. Como se verá en la siguiente sección, su efecto tiende a ser mucho más acentuado en la capacidad de reacción a eventos imprevistos [4], un elemento crítico para evitar colisiones y otros accidentes. Y la conducción por carretera no es el único contexto en el que el impacto de la somnolencia puede ser perjudicial. Desde el pilotaje de todo tipo de vehículos, hasta el desempeño de tareas de vigilancia o custodia, son innumerables las situaciones que requieren de un nivel mínimo de atención y capacidad de reacción para cumplir con la función que se esté desempeñando y evitar poner en riesgo la seguridad personal y de terceros.

Por otro lado, podemos constatar en el momento presente una tendencia hacia la progresiva integración de la tecnología en nuestra vida ordinaria, incluyendo los campos de la salud y el deporte. Una nota definitoria de estas tendencias la encontramos en el creciente uso y

popularización de pulseras inteligentes y otros dispositivos de similar naturaleza (comúnmente referidos como dispositivos *wearable*, o ‘llevables’) por parte de la población general, que ha venido acompañada además de una progresiva ampliación de la gama de variables biométricas registradas por estos dispositivos, y una notable mejora en la precisión de sus mediciones. Siendo este el contexto, el presente proyecto tiene como objetivo explorar y tratar de asentar las bases para un marco de detección de somnolencia aguda basado exclusivamente en las capacidades de medición ofrecidas por estos dispositivos.

Por tanto, partiendo de la serie temporal de medidas de diversas variables fisiológicas tomadas por pulseras inteligentes comerciales (concretamente de las marcas *Xiaomi Mi Smart Band* y *Fitbit*), se aplican diversas técnicas de aprendizaje automático con la finalidad de generar modelos capaces de detectar, con un cierto margen de anticipación temporal, la transición del sujeto portador del dispositivo de un estado de vigilia a un estado crítico de somnolencia caracterizado por una alta probabilidad de entrada en sueño. Esta detección, al depender exclusivamente de parámetros fisiológicos medibles por la mayoría de dispositivos *wearable* comerciales, podría emplearse en una gran variedad de entornos y con múltiples fines, incluyendo la prevención de accidentes de tráfico, todo ello con bajo coste económico.

Capítulo 2. DESCRIPCIÓN DE LAS TECNOLOGÍAS

En este capítulo se describen las tecnologías y protocolos utilizados durante la realización de este proyecto. Para cada una de estas tecnologías, se proporciona una breve descripción de la misma y de su papel dentro del trabajo desarrollado.

2.1 *HERRAMIENTAS PARA LA ADQUISICIÓN DE DATOS: PULSERAS XIAOMI Y FITBIT*

Dados los objetivos del proyecto, un aspecto esencial del trabajo es el empleo de datos que puedan obtenerse de dispositivos *wearable*. La elección de las pulseras de actividad a emplear vino condicionada por las siguientes dos consideraciones: por un lado, han de ser de nivel comercial, pues un aspecto diferencial de la solución cuya viabilidad se explora en este proyecto radica en tomar como base exclusivamente mediciones procedentes de dispositivos no invasivos y accesibles al conjunto de la población. Esto excluye el empleo de instrumentación médica orientada a la investigación clínica, pero también el uso de equipamiento altamente especializado y dirigido a deportistas profesionales (a saber, dispositivos costosos concebidos para mediciones precisas pero puntuales de diversas variables fisiológicas, como pueden ser las cintas pectorales), ya que se ha de garantizar su fácil integración en la rutina diaria de los usuarios.

En segundo lugar, los dispositivos deberán contar con un nivel aceptable de precisión en las mediciones, de modo particular la de ritmo cardiaco. Dado que esta consideración y la anterior pueden entrar en conflicto, se ha de procurar alcanzar un equilibrio razonable entre fiabilidad y calidad de las mediciones, por una parte; y precio, por otra parte.

Después de valorar las prestaciones y calidad de medición de varias pulseras, hemos optado por los siguientes tres modelos: de la marca Fitbit, la pulsera Charge 5 e Inspire 2; y de la

marca Xiaomi, la versión sexta del modelo Mi Smart Band (Mi Band 6). A continuación se exponen en detalle las prestaciones más relevantes de cara al proyecto:

- a) Pulsera Mi Smart Band 6 (MiBand6), de la empresa tecnológica Xiaomi. Registra la frecuencia cardiaca de forma continua en intervalos mínimos de 1 minuto, empleando tecnología PPG (fotopletismografía, en el siguiente apartado de este capítulo se expondrá brevemente en qué consiste esta técnica de medición). En lo relativo al registro de sueño, la pulsera proporciona información sobre el inicio y final del periodo nocturno de sueño, pero no desglosa dicho periodo en función de la fase de sueño en la que estima que se encuentra el sujeto, ni ofrece detalles sobre los periodos de la noche en los que pueda haberse despertado, salvo que sean muy prolongados.

La frecuencia de muestreo del ritmo cardiaco presenta inconvenientes al ser un tanto baja, y la información sobre el estado del sujeto es limitada, lo que dificulta el entrenamiento del modelo (dado que las etiquetas dormido/desperto asociadas a cada observación de la frecuencia cardiaca serán inevitablemente algo imprecisas). Sin embargo, esta pulsera presenta la ventaja de ofrecer un precio muy asequible, por lo que juzgamos que puede ser de interés emplearla en el proyecto, de cara a evaluar la posibilidad de aplicación de la solución planteada en este trabajo para el problema de detección de la somnolencia aguda o transición inminente al sueño en dispositivos con menores prestaciones pero más accesibles en términos económicos.

- b) Pulseras Fitbit *Charge 5* e *Inspire 2*. Estas pulseras, en línea con la anterior, también recurre a la tecnología PPG para la toma continua de mediciones de frecuencia cardiaca. Sin embargo, en este caso nos proporcionan una frecuencia de muestreo sensiblemente mayor: una medición cada 5 segundos. Además, incluyen una variable indicando el nivel de confianza de las mediciones. La *Charge 5* también proporciona información sobre la fase de sueño estimada del sujeto, sobre siestas (si bien han de ser de cierta duración para que queden registradas) y sobre momentos en los que el

sujeto puede estar despierto dentro del periodo de sueño. También incluye otras prestaciones, como el registro de la variabilidad del ritmo cardiaco durante el sueño, o la capacidad para tomar ECG, si bien esto último solo a solicitud del usuario, que debe colocar los dedos pulgar e índice sobre los electrodos ubicados en cada uno de los laterales del reloj. Su precio es superior al de la MiBand6, aunque se mantiene dentro de un rango razonable.

A continuación se presenta una pequeña tabla comparativa exponiendo de manera sintetizada las prestaciones de cada uno de los modelos.

<i>Característica</i>	<i>Fitbit Charge 5</i>	<i>Fitbit Inspire 2</i>	<i>Xiaomi Smart Band 6</i>
<i>Ritmo cardiaco</i>	Sí, registro continuo en intervalos mínimos de <u>5 segundos</u>	Sí, registro continuo en intervalos mínimos de <u>5 segundos</u>	Sí, registro continuo en intervalos mínimos de <u>1 minuto</u>
<i>Variabilidad del Ritmo Cardiaco (HRV)</i>	Sí, durante el periodo de sueño	Sí, durante el periodo de sueño	No
<i>Registro de sueño</i>	Sí	Sí	Sí
<i>Recuento de pasos diarios</i>	Sí	Sí	Sí
<i>Oxígeno en sangre</i>	Sí	No	Sí
<i>Temperatura cutánea</i>	Sí	No	No
<i>Autonomía de la batería</i>	Hasta 7 días	Hasta 10 días	Hasta 14 días
<i>Precio</i>	\$\$ (moderado)	\$ (económico)	\$ (económico)

Tabla 1: Comparativa de prestaciones de las pulseras empleadas en el proyecto.

Las métricas verdaderamente relevantes para este estudio, esencialmente el registro de ritmo cardiaco y el registro del periodo de sueño, son proporcionadas por los tres modelos con los que trabajaremos. La variabilidad que podemos constatar respecto a la disponibilidad de otros parámetros, como la estimación de temperatura cutánea o la variabilidad del ritmo

cardíaco, refuerza las decisiones metodológicas relativas a las métricas a emplear para el modelado: considerando los objetivos del proyecto, hemos de circunscribir nuestro análisis a la predicción de entrada en sueño basada exclusivamente en las métricas más ampliamente extendidas entre las pulseras comerciales de seguimiento de actividad (ritmo cardíaco y registro de sueño nocturno, si bien esta última métrica solo será relevante de cara al ajuste inicial del modelo).

Por lo demás, en la elección de los modelos se ha buscado deliberadamente mantener una cierta variedad en cuanto a precio y prestaciones, a fin de explorar cuan generalizable es la aproximación que se sigue en el proyecto.

2.2 FOTOPLETISMOGRAFÍA (PPG)

Como se ha comentado en el apartado anterior, las pulseras de nivel comercial emplean la fotopletismografía (PPG) como técnica de medición de la frecuencia cardíaca. Esta técnica se basa en las propiedades ópticas de la sangre humana (particularmente, en su capacidad de absorción de la luz verde dentro del espectro visible) para detectar las variaciones rítmicas del volumen de sangre en las arterias periféricas [5], y a partir de las mismas inferir el ritmo cardíaco medio dentro de un segmento de tiempo determinado. Por ello, a diferencia de la ECG (electrocardiografía), no requiere el contacto permanente de la piel con varios electrodos.

La ECG ofrece una mayor precisión y nivel de detalle que la PPG [6], ya que se basa en la detección directa de las señales eléctricas originadas por la actividad cardíaca, mientras que la PPG emplea un método indirecto basado en los cambios de presión sanguínea del sistema vascular periférico; además, de la señal en bruto de un ECG se puede inferir no solo el ritmo cardíaco sino otras métricas de interés, como la variabilidad de la frecuencia cardíaca (HRV). Por todo ello, esta última tiende a ser preferida como técnica de medición en contextos clínicos.




Figura 1: Comparativa visual de las señales de PPG y ECG [7].

La señal PPG requiere además de tratamiento de artefactos que puedan producirse fruto de movimientos bruscos del sujeto, por lo que el registro en bruto no es en sí mismo muy valioso. Dada la necesidad de preprocesar las lecturas de los sensores y la improbabilidad de que dichas lecturas se tomen siempre bajo condiciones idóneas (esto es, pulsera perfectamente colocada y muñeca inmóvil), en lugar de trabajar con la señal en bruto, se tiende a preferir un valor promediado de la frecuencia cardiaca (en ppm) sobre un intervalo de tiempo que será más amplio (1 minuto) o más reducido (5 segundos), en función del nivel de precisión del sensor utilizado.

Con todo, la tecnología ECG tiene el importante inconveniente de requerir varios electrodos posicionados en lugares del cuerpo precisos y seleccionados previamente para interpretar correctamente los datos de diferencia de potencial eléctrico. Los sensores PPG, por el contrario, pueden ubicarse en cualquier parte del cuerpo en la que las variaciones periódicas de las propiedades de reflexión de la piel producidas por las pulsaciones del corazón sean detectables [5], incluyendo la muñeca. Es por esta razón que la práctica totalidad de dispositivos *wearable* comerciales han adoptado esta tecnología como medio indirecto para registrar la frecuencia cardiaca.

2.3 *TENSORFLOW/KERAS*

TensorFlow (versión 2.0) es una librería de código abierto desarrollada por Google y concebida para la creación y ajuste de modelos de aprendizaje automático y aprendizaje

profundo. Se puede utilizar para una amplia variedad de tareas, pero tiene un enfoque particular en el entrenamiento de redes neuronales profundas. TensorFlow ofrece un conjunto de módulos que permiten definir y entrenar modelos de aprendizaje automático, así como ejecutarlos en múltiples plataformas, incluyendo CPUs, GPUs y TPUs.

Keras, por su parte, es una API de redes neuronales de alto nivel que se ejecuta sobre TensorFlow. Su enfoque es la facilidad de uso y permite un rápido prototipado. Ofrece soporte para redes neuronales de todo tipo, incluyendo redes convolucionales (CNN), redes neuronales recurrentes (RNN) y combinaciones de ambas. En este proyecto, TensorFlow y Keras se emplearán para construir y entrenar los modelos de aprendizaje profundo para la detección del sueño.

2.4 FLASK

Flask es un *microframework* de Python para el desarrollo de aplicaciones web. A pesar de su simplicidad, es extremadamente flexible y potente, e incluye soporte para el enrutamiento de URLs, manejo de solicitudes HTTP, plantillas Jinja2 para la generación de HTML y un servidor de desarrollo incorporado.

2.4.1 COMPONENTES Y FUNCIONALIDAD

Flask está constituido por dos componentes principales: Werkzeug y Jinja2.

1. **Werkzeug:** Werkzeug es una biblioteca de utilidades WSGI (*Web Server Gateway Interface*) para Python. Es la base de Flask y se ocupa de todo lo relativo al manejo de las solicitudes y respuestas HTTP, el enrutamiento de URLs, y en términos generales todas las utilidades relacionadas con HTTP.
2. **Jinja2:** Se trata de un motor de plantillas HTML para Python. Se utiliza en Flask para la renderización de páginas HTML dinámicas.

La modularidad y extensibilidad que ofrecen estos componentes encapsulan la filosofía de Flask: al adherirse al principio *do one thing well* ('haz una cosa bien', en lugar de muchas mal), se mantiene ligero y flexible en su implementación base, permitiendo a los

desarrolladores aumentar su funcionalidad a través de extensiones según sea necesario, en lugar de incluir numerosas características por defecto.

A pesar de ser un "micro" framework, Flask es rico en cuanto a funcionalidades:

- *Enrutamiento de URLs*: Proporciona una forma sencilla e intuitiva de definir rutas (URL). Para ello, permite asociar funciones de Python (denominadas ‘vistas’, o views) con URLs específicas mediante decoradores.
- *Solicitudes y Respuestas*: Proporciona objetos para la gestión de las solicitudes y respuestas HTTP, que encapsulan los datos entrantes y salientes entre el cliente y el servidor.
- *Servidor de desarrollo y depurador*: Viene con un servidor de desarrollo integrado y un depurador para localizar errores durante el desarrollo.
- *Extensiones*: Una de las características clave de Flask es su extensibilidad. Hay numerosas extensiones disponibles que pueden añadir funcionalidad adicional a Flask, como la validación de formularios, tecnologías de autenticación...
- *Sesiones*: puede mantener la información específica del usuario entre múltiples solicitudes utilizando el concepto de ‘sesión’.
- Soporte para pruebas unitarias.

2.4.2 EJEMPLO Y USO EN EL CONTEXTO DEL PROYECTO

La creación de aplicaciones web con Flask es extremadamente sencilla. Véase, a modo de ejemplo, la siguiente aplicación:

```
from flask import Flask, render_template
app = Flask(__name__)

@app.route('/')
def index():
    return render_template("index.html")

if __name__ == '__main__':
    app.run()
```

Donde *'index.html'* puede ser cualquier archivo HTML que queramos convertir en página principal de nuestra aplicación web. Al instanciar la clase *'Flask'*, estamos creando una aplicación WSGI (el parámetro *'__name__'* es una forma genérica y abreviada de especificar el nombre del módulo o paquete de la aplicación, necesario para que Flask sepa dónde buscar los distintos recursos, incluyendo plantillas HTML o archivos estáticos). Como puede verse, y tal y como se explica más arriba, unos sencillos decoradores permiten asociar rutas a funciones. La renderización de páginas HTML se puede hacer a través de la función de Python *'render_template'*, proporcionada por la propia librería de Flask.

En el contexto de este proyecto, Flask se utiliza para construir la aplicación web que sirve como *backend* del juego de JavaScript para medir la capacidad de reacción del usuario, aceptando y procesando las solicitudes de Ajax enviadas desde el *frontend*. Recordemos que el propósito de este juego es la medición indirecta del nivel de somnolencia del sujeto a partir del registro de tiempos de reacción.

2.5 JAVASCRIPT/AJAX

JavaScript es el lenguaje de programación dominante para el desarrollo web en el lado del cliente, e idóneo para el desarrollo de juegos web sencillos. Por su parte, Ajax (*Asynchronous JavaScript and XML*) es un conjunto de técnicas JavaScript empleadas para el envío y recepción de datos de un servidor de forma asincrónica, sin interferir con la visualización y comportamiento de la página. Como comentábamos anteriormente, JavaScript y Ajax se utilizarán para el desarrollo del juego interactivo propiamente dicho, a través del cual se medirán los tiempos de reacción del usuario. Las lecturas a su vez se enviarán de forma asíncrona al backend de Flask conforme se vayan tomando.

2.6 SQLITE

SQLite es un sistema de gestión de bases de datos relacionales (RDBMS). A diferencia de la gran mayoría de sistemas de gestión de bases de datos SQL, SQLite no tiene un proceso de servidor separado: lee y escribe directamente en los archivos de disco. Ello facilita la

configuración y uso para proyectos pequeños y medianos, como es el caso con la aplicación para la medición de tiempos de reacción. Por ello, en este proyecto, SQLite se utiliza para almacenar los tiempos de reacción enviados desde el *frontend* vía Ajax.

2.7 AZURE WEB APPS

Azure Web Apps es un servicio de Microsoft Azure para alojar aplicaciones web en la nube. Es un servicio muy utilizado, que soporta una amplia variedad de lenguajes de programación, incluyendo .NET, Java, Node.js, Python y PHP. Los desarrolladores pueden automatizar el despliegue de aplicaciones utilizando herramientas de integración y despliegue continuo como GitHub, Docker Hub y Azure DevOps. En este proyecto, Azure Web Apps se utiliza para desplegar la aplicación web Flask con el juego de JavaScript.

Capítulo 3. ESTADO DEL ARTE

El objetivo del presente proyecto es, como se ha comentado, el desarrollo de un modelo para detectar la transición del sujeto a un estado de somnolencia que afecte de forma crítica la capacidad de atención y respuesta, con un margen temporal suficiente para permitir su reacción. Dada la naturaleza del problema que aquí se aborda, no es de sorprender que gran parte de la literatura publicada en torno al mismo objetivo tienda a estar particularmente orientada al ámbito de la conducción, ya que es un contexto en el que una pérdida crítica de reflejos presenta un peligro evidente para la vida e integridad física del propio sujeto y de terceros, además de poder derivar en daños materiales de cuantía económica potencialmente notable. Aun teniendo esto presente, ciertos elementos de algunas soluciones halladas en la revisión pueden ser potencialmente generalizables a un mayor rango de contextos, por lo que las examinaremos a fin de considerar todas las soluciones disponibles e identificar sus limitaciones.

3.1 APROXIMACIONES AL PROBLEMA EN LA LITERATURA PRIMARIA

3.1.1 ENFOQUES CONDUCTUALES

En las publicaciones y estudios revisados se aprecian tres grandes enfoques o modos de aproximación al problema. Por un lado, encontramos los sistemas que podríamos denominar conductuales, esto es, sistemas basados en el análisis de los patrones de conducción del usuario (o de los cambios en la interacción usuario-vehículo). Algunos estudios se basan exclusivamente en la búsqueda de correlaciones entre los patrones de interacción del conductor con el vehículo y su estado de somnolencia o fatiga.

Así, mediante un análisis de descomposición PCA, un estudio en particular [8] hallaba una fuerte correlación entre las medidas de variabilidad de los movimientos del volante y la fatiga del sujeto, estimada a través de una prueba de vigilancia psicomotriz. Estas variables asociadas al movimiento del volante guardaban de hecho mayor correlación que las

asociadas a la posición lateral del vehículo en el carril, pudiéndose además derivar estas últimas a partir de las primeras, por lo que proponen emplear la información relativa al volante como la base más adecuada sobre la que construir e implementar de forma relativamente sencilla un sistema de detección basado en la interacción del conductor con el vehículo [8].

Otros estudios que siguen esta línea ponen el enfoque en la detección y análisis de errores cometidos por el usuario durante la conducción, buscando identificar aquellos que respondan a una pérdida de la capacidad de atención y reflejos provocada por la somnolencia. Un estudio en particular [4] hallaba que la privación del sueño afecta en mayor medida a las funciones cognitivas basadas en reglas que a las basadas en habilidades. Traducido a la conducción, ello implica que la somnolencia empeora notablemente la capacidad de los conductores de responder a eventos inesperados, mientras que su desempeño en las tareas rutinarias de conducción se ve menos afectado [4].

Y aún otras propuestas combinan variables estrictamente vinculadas con el movimiento y comportamiento del vehículo, como la aceleración, con otras que reflejan la interacción del conductor con el mismo, como el uso de los pedales, alcanzándose en un trabajo concreto tasas de acierto superiores al 99% mediante la aplicación de redes neuronales convolucionales para distinguir no solo el estado de fatiga o somnolencia del estado normal, sino también otros estados o patrones de comportamiento como la distracción, la conducción agresiva o la conducción bajo los efectos del alcohol [9]; si bien ha de tenerse en cuenta que los datos etiquetados que se emplearon para el entrenamiento se obtuvieron especificando a los voluntarios la conducta que debían exhibir a fin de imitar artificialmente cada una de las cinco categorías que hemos mencionado. Un interesante artículo de temática relacionada propone el empleo de máquinas de soporte virtual (SVM) y redes neuronales para la detección de patrones anómalos de comportamiento en carretera basándose en datos recogidos por sensores de un smartphone en entornos reales de conducción [10].

En general, la principal limitación de los sistemas basados en la interacción sujeto-vehículo es su acotación estricta al ámbito de la conducción, al derivarse la mayor parte de la

información de variables medidas por sistemas integrados en propio vehículo, o directamente asociadas con el movimiento y orientación del mismo.

3.1.2 ENFOQUES BASADOS EN EL ANÁLISIS DEL COMPORTAMIENTO OCULAR

Una segunda familia de propuestas cambia el foco de atención exclusivamente hacia el sujeto, sin entrar a considerar su interacción con el vehículo, centrándose particularmente en el análisis del comportamiento de los ojos o en las expresiones faciales. Algunos de los parámetros que se suelen emplear para cuantificar el comportamiento de los ojos incluyen la frecuencia de parpadeo, la dirección de la mirada, el tiempo de fijación, o el PERCLOS (el porcentaje de cierre de los párpados sobre la pupila a lo largo del tiempo, es un parámetro que refleja el cierre lento de los párpados más que los parpadeos) [11], [12].

Generalmente, los modelos basados en este tipo de análisis tienden a alcanzar tasas de acierto elevadas [11][12][13], y algunos estudios han observado que el desempeño de modelos específicos para cada usuario es muy superior al de modelos genéricos, sugiriendo que las diferencias entre usuarios pueden ser significativas a la hora de evaluar el comportamiento de los ojos [11]. La principal limitación de estos modelos radica en su dependencia de algún dispositivo que capture con suficiente calidad e idealmente procese a tiempo real la imagen del rostro de los sujetos, lo cual de nuevo limita el rango de entornos en los que se podría emplear un sistema de estas características.

3.1.3 ENFOQUES BASADOS EN LA FISIOLÓGÍA DEL SUJETO

El tercer enfoque general identificado en la literatura revisada, dentro del cual se insertaría la solución cuya viabilidad exploramos en este trabajo, buscaría basar las predicciones en los patrones y cambios registrados en la fisiología del sujeto, e identificar aquellos vinculados a una próxima transición a un estado de somnolencia o sueño. Este enfoque es bastante amplio, pues son muchas las variables que se pueden seleccionar y medir para evaluar su correlación con la somnolencia/entrada en sueño o la fatiga. Algunos estudios se aproximan al problema desde la neurofisiología, optando directamente por el análisis de los patrones de actividad eléctrica en el cerebro mediante el uso de señales EEG

(electroencefalogramas). Emplear un EEG de nivel médico es impráctico, pero existen algunas alternativas interesantes. Por ejemplo, en uno de estos estudios se decidió emplear auriculares comerciales con capacidad de medir señales EEG dentro de ciertas bandas de frecuencia [14]. La señal del EEG se filtró en bandas de frecuencia alfa baja/alta y beta baja/alta, y posteriormente se analizaron la media y desviación típica para cada banda de frecuencia a fin de identificar los cambios de actividad cerebral asociados con la entrada en fase 1 del sueño. Este método en particular alcanzó tasas de acierto del 81% (siendo el grueso de errores falsos positivos).

Dada la dificultad que supone medir señales EEG de calidad suficiente sin recurrir a equipamientos médicos costosos (y cuyo uso habitual en la rutina diaria sería además inviable), la mayoría de estudios que siguen el enfoque fisiológico se centran en el análisis de variables biométricas derivadas de la actividad cardiaca y tomadas mediante electrocardiogramas o cintas pectorales. Encontramos, por ejemplo, un estudio que plantea un sistema basado en redes neuronales para la detección temprana de fatiga a partir de parámetros de variabilidad del ritmo cardiaco (HRV, por sus siglas en inglés) en el dominio de la frecuencia, derivados de la señal en bruto de un electrocardiograma (ECG); la red neuronal alcanzó tasas de acierto del 90% [14].

La relación entre el HRV derivado de señales ECG o cintas pectorales y la somnolencia también se ha podido verificar en otros estudios [15]–[17], si bien cabe recalcar que los múltiples factores que afectan al valor numérico de la variabilidad de ritmo cardiaco merman el rendimiento de modelos que buscan ser genéricos y aplicables a cualquier sujeto [16]. Entre estos factores encontramos las diferencias fisiológicas entre individuos vinculadas con la edad, sexo o estilo de vida; o el impacto de las circunstancias en las que el sujeto se ubica al manifestarse la somnolencia, no siendo igual un entorno en el que el sujeto trata conscientemente de evitar la entrada en sueño, como es el caso de la conducción, que un entorno más relajado.

Parecen por tanto más prometedores aquellos modelos específicamente entrenados para capturar los patrones y cambios propios de cada sujeto individual a la hora de trabajar con

señales fisiológicas vinculadas con la actividad cardiaca, pues así eliminamos el problema asociado a la variación inter-sujeto (aunque no la inducida por factores como el contexto en el que se encuentra el propio sujeto). Entre los modelos que los anteriores estudios han explorado para esta tarea predictiva encontramos una amplia variedad, incluyendo *ensembles* como *Random Forest*, o estructuras más complejas (por ejemplo, redes neuronales LSTM).

Dada su naturaleza, las propuestas pertenecientes al enfoque fisiológico pueden emplearse en un rango de contextos y situaciones muy amplio, ciertamente mucho mayor que el que nos ofrecen los enfoques previos. Sin embargo, los estudios revisados no están exentos de limitaciones: muchos de los modelos planteados basan sus predicciones en datos obtenidos mediante electrocardiogramas, que requieren de al menos dos electrodos en permanente contacto con la piel; otros recurren a cintas pectorales, que no están concebidas para dejarse puestas de manera continua sino para obtener mediciones precisas y puntuales de variables como la HRV o la frecuencia cardiaca. Esto limita en la práctica los escenarios en los que se podrían implementar los sistemas propuestos: es improbable que el usuario final vaya a encontrar este tipo de equipamiento atractivo o práctico para los casos de uso que se le puedan presentar. Parece necesario que un sistema de estas características requiera al mismo tiempo de un soporte hardware para la toma de mediciones que ofrezca la mayor comodidad y portabilidad posible, sea razonablemente económico y pueda integrarse plenamente en la rutina diaria del usuario final. Las pulseras inteligentes y otros dispositivos *wearable* pueden proporcionar una solución al problema de las mediciones que satisface en gran medida estos requisitos.

Diversos estudios han evidenciado la utilidad de los dispositivos *wearable* de consumo para fines vinculados al ámbito sanitario y la investigación biomédica. La progresiva mejora en la precisión de las mediciones realizadas por dispositivos *wearable* o aplicaciones para móvil está permitiendo acceder y realizar un seguimiento continuo de muchas métricas de interés para el presente proyecto, de manera fácil, económica y con un nivel creciente de fiabilidad [18]. Existen ya en el mercado marcas y modelos que han podido emplearse con éxito en la detección o seguimiento de desórdenes y enfermedades vinculados a diversos campos de salud, incluyendo la salud cardiovascular, metabólica, de sueño, mental y neurológica [19].

Es por ello que los modelos que se explorarán en este proyecto partirán de mediciones fisiológicas tomadas exclusivamente mediante este tipo de dispositivos. Siendo una solución de tipo software, los métodos y modelos que demuestren ser viables y alcancen un rendimiento satisfactorio tendrán además el potencial de una fácil implementación en cualquier dispositivo wearable, pudiendo incorporarse como una funcionalidad más dentro de la gama de servicios biométricos prestados por este tipo de dispositivos (si bien esto último excede los objetivos del proyecto, que se centrará en explorar la viabilidad del empleo de modelos de aprendizaje automático para la detección de una inminente transición a un punto de pérdida crítica de reflejos por somnolencia o fatiga, basándose en datos recogidos por este tipo de dispositivos).

En síntesis, la solución que proponemos se distingue de otras soluciones exploradas en este apartado por su potencial para aplicarse prácticamente en cualquier entorno y circunstancia en la que el sujeto desarrolle una tarea que le obligue a mantener atención pero pueda verse afectado por la somnolencia.

3.2 ESTADO ACTUAL DE LA TECNOLOGÍA WEARABLE

En términos generales, se constata una tendencia hacia la mejora paulatina e incremental de la precisión de las mediciones de estos dispositivos para muchas de las métricas más relevantes de cara a la investigación sanitaria y la bioingeniería, incluyendo la frecuencia cardíaca, la duración y calidad del periodo de sueño, la saturación de oxígeno, la contabilización del número de pasos diarios, o el registro de actividad física, entre otras; todo ello además sin necesidad de procedimientos invasivos, y con un coste económico muy inferior al de equipos médicos especializados [18].

Con todo, existen aún limitaciones a tener en consideración. En una revisión sistemática realizada en 2020, los autores [20] analizaron varios de los modelos más utilizados en investigación, evaluando su precisión en la medición de cuatro variables: ritmo cardíaco, estimación del consumo energético del sujeto, recuento de pasos y patrones de sueño. A tal efecto, los investigadores se valieron de los resultados de los estudios revisados para

contrastar las mediciones tomadas con estos dispositivos respecto a las obtenidas con equipos de nivel clínico, parametrizando la proximidad (o divergencia) entre ambas mediante dos métricas: el error porcentual absoluto (APE), y el coeficiente de correlación (r). El APE se empleó como medida de la discrepancia entre ambas mediciones, mientras que el coeficiente de correlación capturaría su grado de consistencia.

Los resultados de dicho análisis pusieron de manifiesto una notable variabilidad en la precisión entre los distintos modelos, con algunos superando a otros en función de la variable que se esté evaluando. En lo que respecta al recuento de pasos, aproximadamente la mitad de los dispositivos examinados en el estudio mostraron tasas de error (APE) inferiores al 5%, un umbral generalmente aceptado como satisfactorio. En lo relativo a la consistencia respecto a mediciones de nivel clínico, algunos modelos (de las marcas Apple y Fitbit) alcanzaron coeficientes de correlación de hasta el 99%, aunque de nuevo se volvió a observar una apreciable variabilidad en los resultados.

En cuanto a las mediciones de frecuencia cardiaca, si bien las cintas pectorales alcanzaron (como es esperable) los niveles más elevados de precisión, las cifras de correlación y error porcentual absoluto para los dispositivos de muñeca (como las pulseras de actividad o los relojes inteligentes) resultaron bastante aceptables; del mismo modo, la precisión respecto al registro de sueño resultó por lo general bastante satisfactoria. A pesar de todo, los autores sí quisieron hacer notar la carencia de procedimientos de validación estandarizados en la literatura primaria para este tipo de dispositivos, lo cual obstaculiza la comparabilidad de resultados entre distintos estudios. En cualquier caso, y aun teniendo en cuenta algunas de las limitaciones todavía existentes, publicaciones posteriores verifican la progresiva mejora en precisión a la que hacíamos referencia al inicio de este apartado [18].

Por último, también cabe mencionar que se han producido avances significativos en el desarrollo de algoritmos para la inferencia de métricas fisiológicas o de actividad a partir de las señales en bruto procedentes de los sensores. Al exponerse en el capítulo anterior la tecnología PPG para la estimación indirecta del ritmo cardiaco, se puso de manifiesto la importancia de este procesamiento básico para dispositivos de nivel comercial, pero dicho

caso solo constituía un ejemplo. También son imprescindibles, por ejemplo, para la detección y contabilización de pasos a partir de las lecturas de los acelerómetros y giroscopios, véase [21].

3.3 TÉCNICAS DE APRENDIZAJE AUTOMÁTICO

El aprendizaje automático, o *machine learning*, es una campo de la computación que tiene como objeto el desarrollo y aplicación de algoritmos a través de los cuales entrenar sistemas informáticos capaces de extraer y modelar (‘aprender’) la estructura, patrones o relaciones existentes entre diferentes variables, con el fin de desempeñar tareas complejas de predicción o clasificación que les permitan resolver problemas sin seguir instrucciones explícitas introducidas por el programador, sino derivadas de los propios datos.

Existen una infinidad de modelos aplicables a tareas de clasificación similares a la que constituye el foco de este proyecto. Entre los que fueron empleados en los trabajos de investigación anteriormente revisados se incluyen algoritmos más sencillos desde el punto de vista computacional, como los Random Forest o las SVM; y algoritmos que presentan una mayor complejidad, como los autoencoders, las redes neuronales convolucionales o las redes LSTM, todos ellos generalmente clasificados dentro del subcampo del aprendizaje profundo o *deep learning*. Ciertos trabajos recurrieron también a técnicas de aprendizaje no supervisado (algoritmos que buscan únicamente capturar la estructura existente en los datos, en lugar de predecir o clasificar), como el análisis de descomposición PCA. A continuación se expondrán brevemente algunos de los modelos que por sus características pueden ser de especial interés y relevancia para el presente trabajo.

3.3.1 EXTREME GRADIENT BOOSTING

Los algoritmos de *Gradient Boosting* son un subtipo de algoritmos de *ensemble* (‘ensamblaje’) que combinan numerosos modelos débiles – por ejemplo, árboles de decisión muy sencillos – para obtener un rendimiento global muy superior [22]. Se basa en la aplicación de descenso de gradiente sobre una función de pérdida, que puede ser de cualquier tipo con tal de que sea derivable. *Extreme Gradient Boosting* (XGBoost) es una

implementación eficiente y escalable de este algoritmo, ampliamente utilizada por investigadores y analistas de datos debido a su alto rendimiento con datos tabulares en tareas de regresión y clasificación de todo tipo, pudiendo capturar correctamente relaciones complejas no lineales entre la variable a predecir y los atributos explicativos [23].

Dado que los datos con los que se trabajará en este proyecto son secuenciales, para poder emplear este algoritmo deberemos previamente ‘tabularizarlos’, sintetizando variables cuyo valor capture la tendencia de la serie en el pasado inmediato (por ejemplo, obteniendo la media y desviación típica del ritmo cardiaco para ventanas deslizantes cuya longitud se habrá de definir).

3.3.2 LONG-SHORT TERM MEMORY (LSTM) RECURRENT NEURAL NETWORKS (RNN)

Las redes neuronales recurrentes (RNN, por sus siglas en inglés) son un subtipo de redes neuronales artificiales caracterizadas por su capacidad para ‘memorizar’ información del pasado, al permitir que el valor actual de salida de sus neuronas se vea influenciado no únicamente por el valor actual de la variable de entrada, sino también por los valores previos. Esto se logra convirtiendo la salida de la neurona en el instante $t-1$ en una de las variables de entrada para la misma neurona en t (ver Figura 2). Dicha variable se suele denominar estado (ht), su diferencia respecto a Y_t radica en que esta última es igual a la variable estado multiplicada por un peso de salida, que se habrá de ajustar durante el entrenamiento.




Figura 2: Esquema de una red neuronal recurrente para una única neurona.

Si ‘desenrollamos’ esta conexión en bucle (de nuevo, véase figura 2) obtenemos una red equivalente en la que cada capa oculta se corresponde a cada uno de los instantes temporales anteriores al instante actual [24]. Cada neurona individual cuenta con tres pesos: un peso de entrada, que podemos llamar W_{xh} , un peso para el estado del instante temporal anterior, al que nos referiremos como W_{hh} , y un peso de salida, que denotaremos W_{yh} . Es importante recalcar que **todos los pasos temporales de una misma neurona comparten los mismos pesos**. A fin de clarificar este punto, en la figura siguiente (Figura 3) se incorporan al diagrama anterior los tres pesos a los que acabamos de hacer referencia.




Figura 3: Esquema de una RNN con los pesos representados.

En términos matemáticos, podemos expresar la relación entre las distintas variables de la neurona mediante las siguientes ecuaciones [25]:

$$h_t = f(W_{hh} \cdot h_{t-1} + W_{xh} \cdot X_t + b_h)$$

$$Y_t = W_{hy} \cdot h_t + b_y$$

Donde f es una función de activación típicamente no lineal, como la tangente hiperbólica o la función ReLU (siglas de *Rectified Linear Unit*); y b_h y b_y son los sesgos (no mostrados en las figuras anteriores). En caso de emplearse para problemas de clasificación, sobre la salida se puede aplicar una función *softmax* a fin de que su valor pueda ser interpretado como una ‘probabilidad’.

$$Y_t = \text{softmax}(W_{hy} \cdot h_t + b_y)$$

A colación de esto, se debe señalar que aunque en sentido estricto las salidas de una red neuronal (recurrente o no) no pueden interpretarse literalmente como probabilidades – pues el valor exacto de dichas ‘probabilidades’ es sensible a la inicialización aleatoria de los pesos de la red antes del entrenamiento, por lo que no solo depende de los valores de las variables de entrada –, de aquí en adelante, cada vez que se haga referencia a la salida de los modelos finales, por razones de economía de lenguaje se hablará en todo momento de probabilidades.

Dada la naturaleza secuencial de las variables de entrada, en la que el orden temporal entre los valores previos y los actuales es relevante, las RNN están concebidas para emparejarse con datos secuenciales o series temporales: expresado de manera sencilla, son capaces de aprender **contexto**. Esto las convierte en una opción de especial interés para el proyecto, ya que se trabajará con mediciones de diversas variables fisiológicas tomadas de forma continua en intervalos de tiempo regulares, donde la evolución temporal es tan significativa como su valor instantáneo.

El principal problema asociado con las RNN clásicas es, de hecho, una manifestación más (si bien un tanto idiosincrática) de un fenómeno muy presente en el campo del aprendizaje profundo: el **desvanecimiento de gradiente**. Para entender el origen e implicaciones de este problema, examinemos brevemente cómo se entrenan estas redes.

El ajuste de pesos de neuronas recurrentes se basa – como cualquier otra red neuronal – en la técnica de descenso estocástico de gradientes; concretamente, se aplica una variante del algoritmo de retropropagación denominada ‘retropropagación a través del tiempo’ (BPTT, siglas de *Back Propagation Through Time*). Para aplicar dicho algoritmo, hemos de partir de una función de error derivable. El valor global de función de pérdida para una neurona individual no es más que la suma de las métricas de pérdida de cada paso temporal:

$$\mathcal{L}(\hat{y}, y) = \sum_{t=0}^T \mathcal{L}(\hat{y}_t, y_t)$$

Donde $\mathcal{L}$ representa la función de pérdida (que puede ser, por ejemplo, la entropía cruzada binaria para redes de clasificación), y_t es el valor real de la variable de salida para el instante temporal t , e $\hat{y}_t$ es la predicción de la neurona para ese mismo paso temporal. Los gradientes quedarían de la siguiente forma:

$$\frac{\partial \mathcal{L}}{\partial W_{ih}} = \sum_{t=0}^T \frac{\partial \mathcal{L}_t}{\partial W_{ih}} \text{ para } i = h, X \text{ e } Y$$

Dichos gradientes, ponderados por la tasa de aprendizaje, determinarían el ajuste de cada uno de los pesos de la neurona. Como se puede ver, el BPTT y la retropropagación ‘clásica’ son muy similares, el BPTT se puede entender como una variante peculiar algoritmo de retropropagación aplicado a la red RNN en su versión ‘desenrollada’, donde cada paso temporal se asemeja mucho a una capa oculta de una red neuronal de tipo ‘*feedforward*’. La diferencia radica en que tenemos no una sino tres matrices de pesos a ajustar, en que los pesos son compartidos por todos los pasos temporales, y en que el gradiente de cada salida

depende no sólo de los cálculos del paso de tiempo actual, sino también de los pasos de tiempo anteriores.

Bien, si desglosamos la ecuación para el cálculo de gradientes para el ajuste del peso W_{hh} , obtenemos la siguiente expresión [25]:

$$\frac{\partial \mathcal{L}}{\partial W_{hh}} = \sum_{t=0}^T \sum_{k=1}^{t+1} \frac{\partial \mathcal{L}_{t+1}}{\partial \hat{y}_{t+1}} \cdot \frac{\partial \hat{y}_{t+1}}{\partial h_{t+1}} \cdot \frac{\partial h_{t+1}}{\partial h_k} \cdot \frac{\partial h_k}{\partial W_{hh}}$$

El problema de desvanecimiento de gradientes emerge del hecho de que, para el cálculo de $\frac{\partial h_{t+1}}{\partial h_k}$, se debe computar el producto de la multiplicación recursiva de derivadas parciales de la función de activación (recuérdese que h_t se obtiene de la aplicación de una función de activación no lineal, como la sigmoide o la tangente hiperbólica, sobre la expresión $W_{hh} \cdot h_{t-1} + W_{xh} \cdot X_t + b_h$). Esta multiplicación conlleva un decaimiento del gradiente para cada paso temporal, resultando en que la influencia de los pasos temporales ubicados más atrás hacia el pasado será muy pequeña de cara al ajuste de los pesos de la neurona. En consecuencia, se vuelve imposible que la red aprenda durante el entrenamiento a capturar dependencias a largo plazo; dicho de otro modo, solo es capaz de ‘recordar’ la información más cercana en el tiempo, solo tiene memoria a corto plazo.

Las redes LSTM son un subtipo de RNN que mejoran sustancialmente – aunque no eliminan completamente – el problema de desvanecimiento de gradientes, tratando de retener (como su nombre indica), memoria a largo plazo de los valores pasados de la variable de entrada. Para ello, se introducen algunos cambios importantes en el diseño de la neurona (ver Figura 4).




Figura 4: Esquema de una neurona LSTM [24].

Como puede apreciarse en el diagrama, aparece una nueva variable de estado C_t , denominada *cell state* (estado de la celda). Este estado es el que recoge la memoria a largo plazo de la neurona o celda, y en cada paso temporal ésta deberá determinar qué información extraer y trasladar a la memoria a corto plazo (h_t), qué información nueva introducir en la memoria a largo plazo, y qué información eliminar ('olvidar') de la memoria a largo plazo. A tal efecto, se definen tres puertas: *output gate*, *input gate* y *forget gate*, cada una de las cuales se ajustará durante el entrenamiento y desempeñará las tres funciones que se acaban de describir. Por último, la salida Y_t se obtiene a partir de h_t de la misma forma que en las redes recurrentes originales: $Y_t = \text{softmax}(W_{hY} \cdot h_t + b_Y)$. Para mayor profundización, véase [24], [26].

3.3.3 REDES NEURONALES CONVOLUCIONALES (CNN)

En el contexto del aprendizaje profundo, las redes neuronales convolucionales (CNN, siglas de *Convolutional Neural Networks*) son una clase de redes neuronales caracterizadas por su capacidad para tomar en consideración la estructura espacial de los datos a la hora de realizar predicciones, aprendiendo en el entrenamiento las potenciales relaciones espaciales entre puntos de datos dentro de un mismo entramado multidimensional. Fueron concebidas inicialmente para el procesamiento de imágenes, pero existen variantes unidimensionales (para el procesamiento de datos secuenciales) y tridimensionales en adición a la variante bidimensional.

Para conferir a la red esta capacidad, se introduce a su arquitectura una capa convolucional en la que las neuronas aplican la operación de convolución de las entradas con los pesos, en lugar del producto escalar. A fin de exponer con mayor claridad esta idea, considere el computo de la variable de salida para una neurona convencional: se multiplican las entradas por sus pesos correspondientes, y se aplica la función de activación correspondiente:

$$y = f(w_o + \sum_{i=1}^N x_i \cdot w_i)$$

Donde w_o es el sesgo de la neurona, w_i representa el peso de la neurona para la entrada x_i , y f es la función de activación (que puede ser, por ejemplo, una sigmoide o una ReLU). En las neuronas de una red convolucional, la salida se computa de la siguiente manera:

$$y = f(w_o + X * W)$$

Donde W es el vector de pesos para dicha neurona, X es el vector de entrada, y el símbolo ‘*’ denota la operación de convolución. Por su parte, y ya no es un valor unidimensional sino un vector con el mismo número de dimensiones espaciales que X y W . La longitud de y para cada dimensión espacial será igual a $n - m + 1$, siendo n la longitud de X para la dimensión correspondiente, y m la longitud de W para la dimensión correspondiente.

Como se puede ver, cada neurona (denominada ‘*kernel*’ en el contexto de las CNN) se comporta a todos los efectos como un **filtro**, de modo que la capa convolucional se puede entender como una colección de filtros, cuyos pesos se ajustarán durante el entrenamiento para que la red aprenda a detectar patrones relevantes en la configuración espacial de los datos de entrada. Por su parte, los vectores de salida resultantes de la aplicación de los filtros se denominan **mapas de características**, o *feature maps* en inglés.

A fin de adquirir una intuición visual de esta operación, en la Figura 5 se presenta un ejemplo en el que tanto los datos de entrada como los *kernels* son vectores bidimensionales (matrices). Este sería el caso, por ejemplo, para el procesamiento de imágenes.




Figura 5: Ejemplo de una capa convolucional 2D [27]

La misma idea puede aplicarse para secuencias unidimensionales de datos (por ejemplo, series temporales); en tal caso, los *kernels* también habrían de ser vectores unidimensionales de longitud igual o inferior a la de la ventana de contexto de la secuencia.

Otro componente importante de las redes neuronales convolucionales son las capas de *pooling* (o ‘agrupamiento’), que suelen colocarse entre dos capas convolucionales. Reducen el tamaño del mapa de características resultante de la operación de convolución, disminuyendo así el número de parámetros que se deben ajustar durante el aprendizaje y acelerando el proceso de entrenamiento. Además, contribuyen a que la representación interna de la red sea invariante a pequeñas variaciones en la entrada.

La capa de *pooling* no tiene parámetros ajustables durante el proceso de entrenamiento, pero el tamaño de la ventana de *pooling* y el tipo de función de agrupación aplicada a los píxeles de esta ventana son hiperparámetros que deben ajustarse antes de entrenar la red. Hay muchos tipos de operaciones de *pooling* que se pueden emplear para modelos CNN, pero el *max pooling* (tomar el valor máximo dentro de la ventana de pooling) y el *average pooling*

(sustituir la ventana de *pooling* por el valor medio de todos sus elementos) son los más utilizados.




Figura 6: Ejemplo de red CNN completa para procesamiento de imágenes [28].

Por último, para arquitecturas convolucionales ‘puras’, los mapas de características resultantes de la última capa oculta se deben aplanar, a fin de que la representación pueda procesarse mediante una última capa densa (o varias, según la complejidad de la red) para finalmente generar las predicciones de la red (Figura 6). Para una mayor profundización en las redes convolucionales, ver [27], [29].

3.3.4 OPTIMIZACIÓN BAYESIANA DE HIPERPARÁMETROS

Esta última técnica no es un algoritmo de aprendizaje automático propiamente dicho, sino un método para aproximarse de manera computacionalmente eficiente a los valores óptimos de hiperparámetros de un modelo dado [30]. Los hiperparámetros son los parámetros que hemos de definir antes de proceder al entrenamiento del modelo, y que controlan o limitan el propio proceso de entrenamiento [31], pudiendo tener un impacto muy grande en el rendimiento final del modelo pese a no poder derivarse de los datos en el entrenamiento propiamente dicho. Son ejemplos de hiperparámetros el número de neuronas en una LSTM, o la profundidad máxima permitida en los árboles de un *ensemble*.

El ámbito de aplicación de la optimización bayesiana es en realidad más general: se trata de una estrategia para hallar el máximo de cualquier función, especialmente en los casos en que la función sea costosa de evaluar en términos computacionales, no es derivable, o carece de formulación analítica. Por esa razón, resulta especialmente útil en el ajuste de hiperparámetros para modelos de aprendizaje automático, en los que la función objetivo (a menudo el error del modelo en validación tras su ajuste con los hiperparámetros especificados) es costosa de evaluar.

La idea fundamental detrás de esta estrategia es la siguiente: de entrada, se emplea un proceso gaussiano para obtener una distribución a priori de la función objetivo. Tras la observación de puntos de datos (esto es, resultados de la función objetivo para una cierta combinación de valores de hiperparámetros), se procede a actualizar la distribución (distribución posterior). Las actualizaciones iterativas del modelo probabilístico de la función desconocida a optimizar permiten ir reduciendo la incertidumbre en las predicciones realizadas a partir de dicho modelo. Podemos distinguir dos componentes en el proceso:

1. **Modelo subrogado:** El modelo probabilístico que se utiliza para aproximarnos a la función objetivo desconocida. Proporciona una medida de la incertidumbre de la predicción en cada punto del espacio de entrada (el espacio de posibles valores que pueden tomar las variables de entrada, en este caso los hiperparámetros). Para estos modelos se suelen emplear procesos gaussianos (GP), debido a su capacidad para proporcionar estimaciones de la incertidumbre.
2. **Función de adquisición:** función que determina, a partir del modelo subrogado, en qué región del espacio de hiperparámetros muestrear para la siguiente actualización. Busca mantener un equilibrio entre la *explotación* del modelo subrogado tal y como se tiene ahora mismo (muestreo de las regiones en las que el modelo subrogado predice un alto rendimiento) y la *exploración* de nuevas regiones para las que la incertidumbre en las predicciones del modelo subrogado es muy alta.

El uso combinado e iterativo de ambas componentes permite optimizar el proceso de búsqueda, dirigiéndolo hacia las regiones más prometedoras del espacio de hiperparámetros. La búsqueda bayesiana se puede emplear para cualquier modelo, basta con definir una función de coste adecuada que devuelva para cualquier combinación de hiperparámetros una métrica de error que refleje el desempeño del modelo resultante.

3.3.5 MÉTRICAS BÁSICAS DE EVALUACIÓN: TASA DE ACIERTO, PRECISIÓN Y RECALL

Antes de concluir este capítulo, repasemos brevemente las tres métricas básicas para cuantificar el desempeño de un modelo de clasificación ante datos de validación o de *test*. Bajo estas líneas (Figura 7) se muestra el diagrama de una matriz de confusión para un modelo de clasificación binaria.




Figura 7: Precisión y recall en una matriz de confusión [32].

La esquina superior derecha recoge el número de verdaderos negativos (TN, siglas de *True Negatives*), esto es, el número de observaciones realmente pertenecientes a la clase negativa que el modelo ha clasificado correctamente como tales. La esquina inferior derecha, por su

parte, recoge el número de verdaderos positivos (TP, siglas de *True Positives*), esto es, el número de observaciones verdaderamente positivas correctamente clasificadas como tales por el modelo. Ambas magnitudes (TP + TN) suman el total de observaciones que el modelo ha clasificado correctamente. Las restantes dos esquinas de la matriz recogen el número de observaciones clasificadas incorrectamente: por un lado tenemos los falsos positivos (FP, siglas de *False Positives*), es decir, las observaciones realmente negativas que el modelo ha clasificado incorrectamente como positivas; y en la esquina inferior izquierda se encuentran los falsos negativos (FN, siglas de *False Negatives*), que como puede suponerse se refiere al número de observaciones realmente positivas que el modelo ha clasificado como negativas.

A partir de estos cuatro valores (TP, TN, FP y FN), las tres métricas fundamentales para la evaluación del desempeño de un modelo se definen de la siguiente manera.

$$tasa\ de\ acierto = \frac{TP + TN}{TP + TN + FP + FN} = \frac{total\ de\ aciertos}{total\ de\ observaciones}$$

$$precisión = \frac{TP}{TP + FP}$$

$$recall = \frac{TP}{TP + FN}$$

Como se puede ver, la **tasa de acierto** proporciona una medida global del desempeño del modelo en la tarea de clasificación. Presenta, sin embargo, un inconveniente importante: si las clases se encuentran muy desbalanceadas el valor de esta métrica por sí solo puede llevar a engaño. Por ejemplo, para un conjunto de datos en el que el 95% de las observaciones pertenecen a la clase mayoritaria, si un modelo predice que todas las observaciones pertenecen a dicha clase, tendrá un 95% de tasa de acierto. Para conjuntos de datos moderadamente desbalanceados, como será el caso en este proyecto (dentro de un periodo de 24 horas, solemos dormir entre un 40% y un 30% del tiempo), esta métrica sí puede ser útil, pero ha de acompañarse de la precisión y *recall* para caracterizar adecuadamente los resultados.

La **precisión** expresa la proporción de las clases predichas como positivas (normalmente la clase minoritaria) que realmente lo son; el **recall** o **sensibilidad** del modelo expresa la probabilidad de que el modelo identifique una observación como perteneciente a la clase positiva cuando en efecto realmente pertenece a dicha clase. Frecuentemente aparece un compromiso entre ambas magnitudes: si el modelo, por ejemplo, predice todas las clases como positivas, el *recall* será del 100%, pero la precisión será muy pobre; si al contrario se trata de maximizar la precisión, el *recall* se puede ver perjudicado. Los mejores modelos tienen valores altos para ambas magnitudes.

Capítulo 4. OBJETIVOS Y METODOLOGÍA

4.1 JUSTIFICACIÓN

Tal y como constatábamos en el apartado introductorio, la somnolencia durante la conducción supone una amenaza grave para la vida, salud e integridad física de conductores y de terceros, además de un importante problema de salud pública, dada su implicación en un porcentaje apreciable de los accidentes cada año. En paralelo, y como también mencionábamos en la introducción, encontramos en el momento presente una proliferación de los dispositivos inteligentes ‘portátiles’, referidos comúnmente como *wearables* por su denominación en inglés, capaces de medir múltiples variables fisiológicas vinculadas con el sueño, la actividad física o la frecuencia cardíaca y concebidos para ser portados como una prenda más por sus usuarios finales, al modo de las pulseras y relojes tradicionales. Si junto a ello consideramos una tendencia hacia la mejora en las prestaciones de estos dispositivos, tanto en lo que se refiere a la gama de variables que pueden medir como a la calidad de las observaciones, podemos ver en ellos una excelente base para el desarrollo de un sistema que alerte al usuario cuando éste se encuentre en un estado de somnolencia severa o próxima entrada en sueño.

El elemento esencial para un sistema de esta naturaleza sería el desarrollo de un modelo capaz de detectar este punto crítico de somnolencia (que puede conllevar una pérdida grave de la capacidad de atención, reacción y coordinación); dicho punto quedaría definido como aquel estado para el cual la probabilidad de entrar en sueño en los siguientes minutos supera un cierto umbral que habrá de definirse. La construcción de un modelo de estas características permitiría sentar las bases para el desarrollo posterior de una aplicación que integre un marco de detección similar al que aquí proponemos, traduciendo las detecciones en una alerta al usuario (si bien esto último sobrepasa los objetivos del proyecto).

Este sistema podría incluso convertirse en un servicio adicional ofrecido por las propias marcas fabricantes de dispositivos *wearable* o por terceros, abriendo de este modo el rango

de entornos y situaciones en las que pueda emplearse (más allá de la conducción), a la par que reduciendo notablemente el coste económico y simplicidad del mismo en relación con otras propuestas, superando en definitiva las limitaciones que observamos en las soluciones propuestas por los trabajos de investigación anteriormente revisados.

4.2 OBJETIVOS

El objetivo central que define el presente proyecto y que ha orientado el trabajo a lo largo del curso es el siguiente:

1. El desarrollo de un modelo de aprendizaje automático que nos permita predecir a partir de variables biométricas y con un cierto margen de anticipación temporal la entrada del sujeto a un estado crítico de somnolencia, que pueda conllevar una pérdida notable de los reflejos y capacidad de reacción ante eventos imprevistos, y que conlleve además una elevada probabilidad de entrada en sueño en un periodo corto de tiempo.

Dado que este punto crítico, tal y como lo hemos descrito, por definición implica una probabilidad alta de entrada en sueño en los instantes siguientes, usaremos los datos de sueño proporcionados por las propias pulseras (en particular, la fecha de inicio de sueño para aquellos periodos de tiempo que identifique como periodos de sueño) como modo de aproximación a dicho punto crítico, entendiendo que este ha de ubicarse en su entorno temporal inmediatamente anterior. El rendimiento final del modelo se verá inevitablemente limitado por la naturaleza de los datos con los que estaremos trabajando, pero todo el trabajo desarrollado permitirá al menos explorar en profundidad la viabilidad de la solución que proponemos para el problema al que responde el proyecto.

La consecución exitosa de dicho objetivo implica necesariamente trabajar en los siguientes objetivos secundarios:

2. Explorar y entender el comportamiento de las variables fisiológicas con las que se está trabajando durante el proceso de transición al estado de sueño.

3. Recopilación, limpieza y pre-procesamiento de las mediciones, con la consiguiente creación de una base de datos anonimizada que pueda ser utilizada en futuros estudios.
4. Identificación de un método adecuado para validar el modelo una vez entrenado. Dicho método habrá de evaluar la pérdida de reflejos y capacidad de atención del sujeto para poder contrastarla con las predicciones del modelo.

4.3 METODOLOGÍA

Para definir adecuadamente la metodología y recursos a emplear, se hubo de estructurar primero el trabajo en distintas fases o bloques, descomponiendo la meta global del proyecto en objetivos concretos que fueron los que delimitaron y caracterizaron cada una de estas fases. A tal efecto, podemos identificar cuatro grandes bloques de trabajo: en primer lugar, la recogida de datos, indispensable para la consecución de los restantes objetivos. Ello requirió de la colaboración con voluntarios y la elección de los dispositivos más adecuados para la toma de mediciones. Los dispositivos elegidos y las justificaciones técnicas que apoyan dicha elección se detallan en apartado 2.1 (*Herramientas para la adquisición de datos: Pulseras Xiaomi y Fitbit*) del segundo capítulo de esta memoria.

El segundo bloque se corresponde con el preprocesamiento de los datos recogidos, acompañado de un análisis exploratorio de los mismos. Las conclusiones derivadas de esta fase permitieron orientar el trabajo y modular las expectativas relativas a la siguiente fase del proyecto: el ajuste de los modelos a partir de los datos de la pulsera. En esta fase se realiza un análisis comparativo del desempeño de diversas arquitecturas, efectuando para cada una de ellas un ajuste de hiperparámetros; la modelización se realiza a nivel de individuo pero el procedimiento es idéntico para todos los voluntarios. Por último, se hubo de plantear y desarrollar un procedimiento/sistema de validación de los modelos finales, tarea que se presentó como la más compleja. Esta última fase conllevó, como ya se ha mencionado en secciones previas de la memoria, el desarrollo de un juego sencillo que pueda medir tiempos de reacción, de forma que se pudiese verificar si existe una correlación entre pérdida de dicha capacidad de atención y reacción (como proxy del nivel de somnolencia

del sujeto) con un incremento en la probabilidad de entrada en sueño asignada por el modelo para las mediciones de frecuencia cardiaca correspondientes a dicho periodo de tiempo. Para asegurar que el aumento en tiempos de reacción sea una manifestación de la somnolencia del sujeto, las pruebas se realizaron por la noche cuando el sujeto se disponga a dormir (idealmente, se debía quedar dormido mientras juega). La siguiente gráfica (Figura 8) sintetiza la metodología que se acaba de describir.




Figura 8: Metodología del proyecto

El procedimiento concreto seguido para cada una de las fases se detalla y desglosa en los siguientes subapartados.

4.3.1 SELECCIÓN DE VOLUNTARIOS Y ADQUISICIÓN DE LOS DATOS

A fin de garantizar que la muestra que sea suficientemente representativa de la población general y pueda aportar información válida y concluyente, se definieron y aplicaron criterios específicos de inclusión y exclusión en la elección de los participantes.

4.3.1.1 Criterios de inclusión

Los participantes debieron cumplir los siguientes requisitos para su inclusión en el estudio:

1. Edad comprendida entre los 18 y 60 años.
2. Estado de salud: No debían tener antecedentes de enfermedades cardiovasculares graves, ni padecer de afecciones médicas crónicas o agudas que pudieran afectar significativamente su frecuencia cardiaca. Tampoco debían estar tomando

medicación que pudiera alterar de manera notable el comportamiento normal del ritmo cardíaco.

3. Consentimiento: Debían expresar su disposición para participar en el estudio y contar con la capacidad legal de dar su consentimiento informado.

4.3.1.2 Demografía de la muestra

En concordancia con los criterios anteriores, se reclutó un total de ocho voluntarios de diversas edades, sexos y niveles de actividad física, garantizando de este modo una cierta heterogeneidad.




Figura 9: Distribución de voluntarios por edad




Figura 10: Distribución de voluntarios por sexo

La muestra consta de 3 mujeres y 5 hombres (Figura 9: Distribución de voluntarios por edad), con edades distribuidas de la siguiente manera: 4 entre 20-30 años, 1 entre 40-50 años y 3 entre 50-60 años (Figura 10). Pese a su tamaño reducido, dado que los modelos a construir serán a nivel de individuo, resulta a nuestro juicio suficiente para explorar la viabilidad del enfoque planteado en la introducción (esto es, modelización y predicción a partir de lecturas de frecuencia cardiaca en exclusiva). La diversidad en la distribución de edad y género permitirá verificar la validez general de dicha aproximación, aun teniendo en cuenta las posibles variaciones en el comportamiento de la frecuencia cardiaca en función de estos factores demográficos. En cualquier caso, en los capítulos finales de esta memoria se abordarán las limitaciones del estudio derivadas del tamaño muestral.

4.3.1.3 Protocolo para la extracción de datos

Tras la selección de los participantes del estudio y la adquisición de las pulseras de actividad, se procedió al reparto de los dispositivos (dos Fitbit Charge 5, una Fitbit Inspire 2, y siete pulseras Xiaomi MiBand 6, ya que dos voluntarios iniciaron su participación en el estudio con pulseras MiBand 6 y tras dos meses las sustituyeron por modelos Charge 5). Las instrucciones transmitidas a los participantes fueron las siguientes: debían portar las pulseras durante un periodo mínimo de dos meses, y durante el transcurso del mismo se les solicitaría

– con una periodicidad de aproximadamente dos meses – la transferencia de los datos recopilados desde el inicio del periodo de medición. Antes de comenzar, todos recibieron información sobre el tratamiento y uso que se le daría a sus datos, así como sobre su derecho a abandonar la prueba en cualquier momento que lo desearan (sin perjuicio alguno); y se requirió que diesen su consentimiento explícito e informado. Por último, también se les dio indicaciones relativas a la correcta configuración de la pulsera.

Todos los datos recibidos se anonimizaron por completo antes de ser tratados o analizados, eliminando cualquier instancia de información personal identificable (IPI) contenida en los mismos y asignando para cada sujeto un número de identificación. Dicho número sería empleado también para identificar los tiempos de reacción de los usuarios cuando éstos interactúen con el juego diseñado a tal efecto, a fin de poder asociar dichas mediciones con las lecturas de frecuencia cardiaca del mismo sujeto para la fecha correspondiente, y así evaluar las predicciones de los modelos finales ajustados en la fase anterior.

4.3.2 PREPROCESAMIENTO BÁSICO Y ANÁLISIS EXPLORATORIO

El preprocesamiento básico de los datos realizado en esta fase tendrá la finalidad de garantizar consistencia y compatibilidad entre las variables de relevancia (ritmo cardiaco y registro de sueño), lo cual habrá de concretarse en un flujo de lectura y procesamiento distinto según el modelo de pulsera de la cual procedan dichos datos. Independientemente de ello, en todos los casos el preprocesamiento habrá de contar con las siguientes fases:

1. Lectura de los datos, revisión de los formatos de las variables, y tratamiento de valores nulos (de haberlos).
2. Sincronización de los registros de frecuencia cardiaca y sueño procedentes de una misma pulsera (formato y huso horario idénticos para ambas series temporales)
3. Homogenización del periodo intermuestral para una misma fuente de datos (no se forzará a que los intervalos entre muestras sean idénticos para datos de origen Fitbit y de origen MiBand – de hecho, no lo van a ser –, sino que se buscará que para los datos procedentes **de una misma pulsera** dicho intervalo sea constante a lo largo de toda la serie temporal).

4. Asignación de etiquetas dormido (0) / despierto (1) a los registros de la serie de ritmo cardiaco empleando la información contenida en los registros de periodos de sueño.

Este procesamiento preliminar buscará conferir a los datos una estructura similar, de forma que toda la manipulación que deba realizarse en las subsiguientes fases de análisis y modelización sea muy parecida para todos los voluntarios, con independencia de la fuente original de los datos. Ello facilitará la reutilización de código entre los distintos voluntarios, redundando en una mayor eficiencia de programación.

Tras este preprocesamiento básico, se procederá a un análisis exploratorio más exhaustivo de los datos disponibles. El análisis pondrá el foco de atención únicamente sobre las variables relevantes para el estudio. Uno de los puntos más importantes que se habrán de verificar a través de este análisis será si existen diferencias en el comportamiento de la serie temporal de ritmo cardiaco durante los periodos de sueño y de vigilia, a fin de comprobar si la hipótesis de partida (que el ritmo cardiaco por sí solo es suficiente para identificar si un individuo está muy somnoliento o dormido) es una hipótesis razonable sobre la que se puede trabajar de cara a la siguiente fase (modelización).

4.3.3 AJUSTE DE MODELOS E IDENTIFICACIÓN DEL MODELO ÓPTIMO

La metodología para el desarrollo de modelos será la misma en todos los casos: los datos se prepararán para el modelado conforme a los requisitos del modelo en cuestión: para el caso de XGBoost, se habrán de convertir a un formato tabular, de modo que las variables para cada observación sinteticen de algún modo la evolución temporal del ritmo cardiaco en un pasado inmediato. Para tal fin, se propone recurrir a ventanas deslizantes (cuya longitud habrá de ajustarse) a partir de las cuales extraer la media y desviación típica, y convertir estas variables en las entradas del modelo. Para el caso de los modelos de aprendizaje profundo, no se realizará ningún procesamiento sobre las mediciones originales, pero estas habrán de reestructurarse de manera que adopten la configuración tensorial requerida por estos modelos, lo cual requerirá también ajustar la ventana de contexto deseada.

Tras esta preparación, se recurrirá a la Optimización Bayesiana para el ajuste de los hiperparámetros que se consideren más relevantes. Los valores óptimos se utilizarán para ajustar un modelo final de cada tipo (XGBoost, LSTM puro, y arquitectura híbrida que combinará capas convolucionales y LSTM). Por último, se comparará el rendimiento de los tres modelos resultantes empleando el conjunto de *test*; el modelo que exhiba los mejores resultados se elegirá para la última fase (validación). En la siguiente figura (Figura 11) se puede visualizar el procedimiento completo.




Figura 11: Flujo de modelización

Nótese que en la fase de validación sólo se empleará el modelo óptimo para cada voluntario. Los modelos restantes no se tendrán en cuenta.

4.3.4 VALIDACIÓN FINAL DEL MODELO ÓPTIMO

Una vez identificado y ajustado el modelo final, se les enviará a los voluntarios un enlace mediante el cual podrán acceder a la aplicación que contiene el juego para la medición de tiempos de reacción. Dicho juego, programado en Javascript, consistirá en una figura que emergerá desde un punto aleatorio de los laterales del área de juego de la pantalla; el usuario deberá pulsar sobre cualquier punto de la pantalla tan pronto como identifique la figura. El

tiempo en segundos transcurrido entre la entrada de la figura en el campo visual del usuario y su detección se enviará vía Ajax al *backend* de la aplicación web (basada en Flask). Los datos se guardarán en una pequeña base de datos e incluirán el número de identificación del sujeto al que se correspondan.

Tras realizar la prueba, se solicitará al voluntario correspondiente una última transferencia de los datos de la pulsera, se identificarán las mediciones correspondientes a la fecha en la que el sujeto interactuó con el juego, se introducirán como entradas al modelo entrenado y se verificará la correlación entre las mediciones de tiempos de reacción y la probabilidad asignada por el modelo. Esta comparativa también nos permitirá identificar el umbral óptimo para la detección de somnolencia. En la siguiente figura se muestra el procedimiento completo (Figura 12).





Figura 12: Metodología para la validación de los modelos finales.

Dado el carácter estrictamente voluntario de la participación de los sujetos en el proyecto, la incomodidad de la prueba (se debe ‘jugar’ hasta quedarse dormido o al borde mismo del sueño) conlleva que no todos los voluntarios llegaron a realizarla; pese a ello, sí se lograron obtener resultados de validación para un porcentaje mayoritario de voluntarios.

4.4 PLANIFICACIÓN

El siguiente cronograma recoge la distribución temporal de las fases definidas en la sección previa.



La duración real de las fases de modelización y validación se extendió en la práctica hasta finales de mayo, al realizarse numerosas iteraciones del proceso en función de los resultados y la entrada de nuevos datos, si bien todo ello entraba dentro de lo previsto.

Capítulo 5. ANÁLISIS EXPLORATORIO DE LOS DATOS

En este capítulo se detalla el procedimiento completo de extracción, limpieza y preprocesamiento básico de los registros en bruto, así como las conclusiones derivadas del análisis exploratorio de los datos.

5.1 LECTURA Y PREPROCESAMIENTO DE LOS DATOS

Tal y como expresábamos en el capítulo anterior, las variaciones significativas en el formato de los datos en bruto (en función del dispositivo del que se originaron) hicieron necesaria una etapa de preprocesamiento previo al análisis, a fin de conferir a los mismos una cierta consistencia y de este modo simplificar y homogeneizar su manipulación.

5.1.1 PREPROCESAMIENTO DE LOS DATOS XIAOMI MiBAND 6

El procedimiento para la lectura y preprocesamiento de datos MiBand 6, idéntica en todos los casos, se sintetiza en el siguiente diagrama (Figura 13).




Figura 13: Flujo de lectura y preprocesamiento para datos MiBand 6

Los registros en bruto extraídos de este modelo de pulsera venían recogidos en un único fichero para cada tipo de variable, de formato CSV: un fichero contenía todas las lecturas de ritmo cardiaco del sujeto desde que éste comenzó a usar el dispositivo, y otro fichero recogía información relativa al periodo de sueño (fecha, inicio, final y duración, además de varias columnas adicionales para las siestas). La pulsera MiBand 6 también registra otras variables, como el nivel de actividad física del sujeto o el recuento de pasos diarios, pero solo la frecuencia cardiaca y el registro de sueño tienen relevancia directa para el proyecto. En términos generales, los datos estaban bien estructurados, por lo que su lectura no presentó dificultades significativas (si bien la manera en la que se incorporaba la información relativa al inicio y final de siestas – se insertaban en las filas de la fecha correspondiente en forma de columnas adicionales sin nombre – sí requirió de un cierto tratamiento para que la lectura del fichero de sueño fuese correcta). En esta fase del proyecto se recurrió a la librería *Pandas* para la carga, manipulación y almacenamiento de los datos desde el entorno de ejecución.

Tras la lectura de los datos, se procedió a revisar los formatos de las variables de tipo fecha en ambas fuentes de datos. Se pudo verificar una inconsistencia en el huso horario empleado para los registros de ritmo cardiaco (GMT + 1 o GMT + 2, esto es, el horario español de invierno y de verano) respecto al utilizado para referenciar las variables de tipo fecha de los registros de inicio y final del periodo de sueño (GMT + 0), por lo que se procedió a sincronizar ambas fuentes de datos, a fin de que el segundo registro pueda emplearse para la asignación de etiquetas dormido/desperto en las observaciones de ritmo cardiaco.

Resuelta esta inconsistencia, el procesamiento básico no presentó mayores dificultades. Los ficheros CSV de ritmo cardiaco contaban con tres columnas: Fecha (date), hora (time) y frecuencia cardiaca (*heartRate*) expresada en pulsaciones por minuto (ppm). Tras cargar los datos en un conjunto de datos (empleando la librería *pandas*), se unificó la fecha y la hora en una única columna que quedó fijada como índice. Los ficheros de sueño presentaban siete columnas principales (*date*, *deepSleepTime*, *shallowSleepTime*, *wakeTime*, *start*, *stop*, y *REMTIME*) y varias columnas adicionales indicando el inicio y final de los periodos de siesta

identificados por la pulsera. Centrándonos en las siete columnas principales, la primera de ellas recoge el día al que corresponde cada registro; las siguientes tres contienen el tiempo total en minutos en el que el dispositivo estima que el usuario ha estado en fase de sueño profundo, sueño ligero o despierto en la cama, respectivamente; las columnas *start* y *stop* recogen la fecha y hora de inicio y final del periodo de sueño nocturno, y la quinta columna (*REMTIME*) recoge el tiempo total en minutos en el que el usuario ha entrado en fase REM dicha noche.

Dado que no se constató ninguna irregularidad en los intervalos entre muestras de ritmo cardiaco (las muestras presentaban una separación temporal de 1 minuto a lo largo de toda la serie temporal, salvo en los periodos en los que el sujeto no estuviese usando el dispositivo), se procedió directamente al etiquetado de la serie. Para ello, se creó una columna adicional en el conjunto de datos de ritmo cardiaco y se le asignó un valor ‘1’ a todas las observaciones cuya fecha y hora se ubicase entre el inicio y el final de un periodo de sueño; las restantes se asignaron a ‘0’. De cara al ajuste de los modelos, ésta será la variable a predecir (si bien se introducirá un desfase temporal en la misma, a fin de forzar una cierta anticipación temporal en las predicciones).

5.1.2 PREPROCESAMIENTO DE LOS DATOS FITBIT (CHARGE 5 E INSPIRE 2)

Los datos en bruto procedentes de los modelos de marca Fitbit – tanto Charge 5 como Inspire 2 – sí presentaron mayores dificultades en cuanto a su lectura y preprocesamiento, si bien ofrecían como contraparte una mayor riqueza de información, tanto en términos de variables proporcionadas como en cuanto a la granularidad de los datos (por ejemplo, proporcionaban una mayor frecuencia de muestreo del ritmo cardiaco, hasta 12 muestras por minuto). A diferencia de los datos MiBand, los registros de un mismo tipo de variable fisiológica o de actividad – sueño, ritmo cardiaco, variabilidad del ritmo cardiaco y demás variables biométricas – estaban almacenados no en uno sino en múltiples ficheros de diversos formatos.

Los registros relevantes para el proyecto (ritmo cardiaco y sueño) presentaban en concreto un formato JSON con numerosos campos y sub-campos; la estructura de los ficheros de

sueño resultó particularmente enrevesada. Estos últimos contenían una larga lista de objetos, cada uno de los cuales recogía toda la información relevante relativa a una única sesión de sueño (duración, tiempo que tarda el sujeto en dormirse, inicio y final de cada una de las fases de sueño dentro de una misma sesión, etc.). En la siguiente tabla (Tabla 2) se puede visualizar en detalle dicha estructura, donde cada campo se acompaña de un resumen del tipo de información contenida.

CAMPO	CONTENIDO	FORMATO
<i>logId</i>	Identificador único de cada sesión de sueño.	Entero
<i>dateOfSleep</i>	Fecha de la sesión de sueño	"AAAA-MM-DD"
<i>startTime</i>	Hora de inicio de la sesión de sueño	ISO 8601 ¹
<i>endTime</i>	Hora de finalización de la sesión de sueño	ISO 8601
<i>duración</i>	Duración total de la sesión de sueño, en milisegundos	Entero
<i>minutesToFallAsleep</i>	Tiempo que tarda en dormirse el sujeto, en minutos	Entero
<i>minutesAsleep</i>	Tiempo total en el que el sujeto está dormido, en minutos	Entero
<i>minutesAwake</i>	Tiempo total en el que el sujeto está despierto, en minutos	Entero
<i>minutesAfterWakeup</i>	Tiempo transcurrido tras despertarse, en minutos	Entero
<i>timeInBed</i>	Tiempo total en la cama, en minutos	Entero
<i>levels</i>	<i>summary</i> <i>deep</i> : incluye subcampo de recuento de	Entero

¹ Formato estandarizado para fechas, de tipo "AAAA-MM-DDTHH:mm:ss.SSS"

	(resumen del periodo de sueño, con recuento de etapas y duración total de las mismas)	ocurrencias de sueño profundo y tiempo total.	
		wake: ídem	Entero
		light: ídem	Entero
		rem: ídem	Entero
	data	dateTime	ISO 8601
	(lista de objetos, cada uno representando una ocurrencia de etapa de sueño)	level (tipo de evento, puede ser "wake", "light", "deep" o "rem")	String
		seconds (duración del evento, en segundos)	Entero
	shortData (solo para ocurrencias de muy corta duración)	Subcampos idénticos a 'data', pero generalmente todos los eventos son breves momentos en los que el sujeto está despierto	

Tabla 2: Campos de los datos de sueño en bruto proporcionados por las pulseras Fitbit

La estructura de los registros de ritmo cardiaco era más sencilla: en cada fichero encontrábamos de nuevo una lista de objetos, donde cada objeto representaba una única medición de frecuencia cardiaca (expresada en pulsaciones por minuto), acompañada de un campo de fecha en formato ISO 8601 y una variable indicando el nivel de confianza en dicha medición (expresada mediante un número de 0 a 3, donde '3' representa la confianza más elevada).

La carga de los datos en el entorno de ejecución requirió de la lectura sucesiva de los distintos ficheros, accediendo a los campos relevantes de tal forma que los conjuntos de datos resultantes de la lectura presentasen una estructura idéntica a la conferida a los datos de origen MiBand. La única diferencia, más allá de la mayor frecuencia de muestreo en los

datos Fitbit – que por otra parte no es una diferencia relacionada con la estructura de los *datasets* – se encuentra en que los datos se sueño recogen en cada observación el inicio y final de una etapa concreta de sueño, en lugar del inicio y final del periodo de sueño completo para una noche. Por esa razón, la información relevante se recogió del subcampo ‘*data*’ (ver Tabla 2).

A partir de este punto, el procedimiento fue muy similar (Figura 14): se identificó y corrigió de nuevo una inconsistencia en los husos horarios empleados para referenciar la información temporal de los datos de sueño y de ritmo cardiaco; y se comprobó la longitud de los intervalos de tiempo entre muestras a lo largo de la serie. En esta ocasión, **el periodo intermuestral resultó no ser constante**: si bien para la mayoría de muestras consecutivas tenía una duración de 5 segundos, frecuentemente el intervalo entre muestras se extendía hasta los 10, 15 o incluso 20 segundos.

Por ello, se hubo de remuestrear la serie temporal a fin de homogeneizar dichos intervalos, para lo cual se aplicó el método *spline* de interpolación. La interpolación *spline* es una técnica muy utilizada para reconstruir una función continua a partir de un conjunto de puntos de datos discretos. Para este caso concreto se empleó una interpolación *spline* de orden 3 (cúbica), esto es, se recurrió a polinomios cúbicos ‘a trozos’ para aproximar la función continua subyacente, la cual fue posteriormente re-muestreada a un intervalo constante de cinco segundos. Dado el reducido intervalo de tiempo entre cada muestra, un orden cúbico resultó más que suficiente.




Figura 14: Flujo de lectura y preprocesamiento de datos Fitbit

Por último, se procedió a la asignación de etiquetas dormido/desperto, de modo idéntico al seguido para el procesamiento de datos MiBand. En este caso, sin embargo, el etiquetado será más preciso, pues el mayor detalle de información proporcionada por estos modelos permite identificar los intervalos de tiempo dentro del periodo de sueño en los que el sujeto se encuentre despierto, y por tanto marcar las observaciones de ritmo cardiaco tomadas dentro de dichos intervalos con el valor '0' (despierto) en lugar del valor '1' (dormido). Esta distinción fina no se puede realizar con datos MiBand debido a la mayor pobreza de detalles en la información relativa al sueño (solo podemos conocer el inicio y final del periodo de sueño completo).

5.2 ANÁLISIS EXPLORATORIO DE LOS DATOS (EDA)

El análisis exploratorio que se presenta a continuación tuvo como objetivo fundamental derivar conclusiones relativas al comportamiento del ritmo cardiaco y la relación del mismo con los ciclos de vigilia y sueño del sujeto, que nos permitan evaluar la potencial viabilidad de la hipótesis de partida (predicción de somnolencia o pérdida de atención en base al comportamiento de la frecuencia cardiaca) y orientar la fase de modelado. A tal efecto, nuestro análisis debe comenzar examinando el comportamiento de la serie en el dominio del tiempo; la gráfica que se presenta a continuación expone un segmento de la serie temporal para uno de los voluntarios (concretamente, el sujeto ID1).




Figura 15: Segmento de la serie temporal de ritmo cardiaco para ID1

Las medidas de ritmo cardiaco vienen expresadas en unidades de pulsaciones por minuto (ppm, o *bpm* en inglés). Como puede apreciarse, se perciben variaciones cíclicas en el comportamiento de la serie con un periodo aproximado de 24 horas. Se distinguen dos patrones de comportamiento claramente diferenciables: encontramos segmentos en los que tanto el valor medio como la desviación típica de la frecuencia cardiaca son más elevadas, seguidos por segmentos en los que el valor medio baja y la dispersión en los datos es menor.

Si sobre esta misma porción de la serie añadimos un sombreado para marcar las regiones de la gráfica en las que el sujeto está dormido, observamos lo siguiente (Figura 16).




Figura 16: Segmento de la serie de ritmo cardiaco para ID1, con periodos de sueño marcados

Como es previsible (a la vista de los horarios en los que tienen lugar las subidas y bajadas del valor medio de la serie), se puede constatar una correlación muy estrecha entre estas variaciones periódicas y el ciclo de vigilia y sueño del voluntario. Esta correspondencia no se circunscribe a los datos procedentes del sujeto ID1: puede verificarse en todos los participantes del estudio, tal y como evidencian las gráficas que se muestran a continuación.




Figura 17: Serie temporal de ritmo cardiaco para varios sujetos

Si representamos mediante histogramas superpuestos la distribución de ritmo cardiaco para el periodo de vigilia y sueño, esta diferencia puede nuevamente verificarse.




Figura 18: Distribución de ritmo cardiaco para los periodos de sueño (azul) y vigilia (amarillo)

Como se puede apreciar, tanto la media como la mediana de las distribuciones correspondientes al periodo de sueño aparecen desplazadas respecto a sus homólogos en las distribuciones de ritmo cardiaco diurno; así mismo, estas últimas distribuciones presentan también un sesgo mayor en la cola derecha de la distribución. Por ello, los valores más extremos de ritmo cardiaco tienden a encontrarse en la distribución de mediciones de vigilia. Con todo, se debe señalar que en algunos casos ambas distribuciones se encuentran muy solapadas, por lo que el valor instantáneo de la frecuencia cardiaca por sí solo no permitiría discriminar entre ambos estados.

Retornando brevemente a las representaciones en el dominio del tiempo de los valores de frecuencia cardiaca, tras la representación etiquetada de la serie completa de datos de ID2 se pudo constatar que la información relativa al sueño se encontraba muy incompleta, hasta tal punto que una porción considerable de las noches no habían sido correctamente etiquetadas. Si bien se exploró la posibilidad de un etiquetado manual de las muestras, acabó haciéndose evidente que dicha solución era inviable, por lo que se finalmente se hubo de **descartar** la totalidad de los datos de ID2. Esta desafortunada situación nos lleva a desaconsejar la Inspire 2 para futuros estudios, recomendando en su lugar la Charge 5.

La representación completa de la serie de ID4 también evidenció un problema en la configuración de la pulsera no identificado hasta la recuperación de los datos (la participación de este voluntario en el estudio fue de corta duración, por lo que solo se realizó una única extracción). Concretamente, se observó que los datos diurnos solo ofrecían una muestra cada 30 minutos, lo cual también hizo inevitable la exclusión de estos datos de cara a la siguiente fase (si bien en esta ocasión fueron pocos los datos perdidos).

Un problema similar pero de menor calado se pudo comprobar en el sujeto ID5, cuyos registros de datos diurnos ofrecían muestras cada 5 minutos, mientras que durante el periodo de sueño se había muestreado correctamente al ritmo de una medición por minuto. Para abordar el problema y hacer los datos diurnos y nocturnos comparables (en caso contrario la clasificación sería evidentemente muy fácil), se re-muestreo la serie, a fin de que el intervalo

entre muestras tuviese una longitud uniforme de 5 minutos a lo largo de toda la serie, también en los periodos nocturnos. Este hecho habrá de tenerse presente en la sección de modelización, de cara a interpretar correctamente la longitud temporal de las ventanas deslizantes.

De este análisis exploratorio pueden derivarse las siguientes conclusiones: (1) por sí solo, el valor instantáneo de ritmo cardiaco resulta insuficiente para determinar si el sujeto se encuentra dormido o se aproxima a un periodo de sueño: el modelo ha de recibir de una u otra forma información sobre la evolución temporal de la serie en el pasado inmediato. Por otra parte, (2) se aprecia una fuerte variabilidad inter-sujeto en el comportamiento de la serie, lo cual vuelve inevitable la aplicación de un enfoque individualizado de cara al ajuste de modelos (incluyendo la optimización de hiperparámetros). Los resultados son en cualquier caso prometedores de cara a la construcción de un modelo capaz de identificar la transición a un estado de sueño o somnolencia aguda.

Capítulo 6. DESARROLLO DE LOS MODELOS

La fase de preprocesado y consiguiente uniformización del formato y estructura de los registros hace posible definir y aplicar un mismo procedimiento de modelización para todos los sujetos; únicamente se deberá tener en cuenta la longitud del intervalo entre muestras, pues confiere a las ventanas de contexto con las que se habrá de trabajar – expresadas en términos de número de muestras – una interpretación temporal diferente. Como ya se expuso en el tercer apartado del capítulo cuatro, el procedimiento para el ajuste de modelos es el siguiente (Figura 19).




Figura 19: Diagrama de modelización ampliado

Los datos se prepararán conforme a los requisitos de cada tipo de modelo (XGBoost, LSTM puro, y arquitectura híbrida que combinará una capa convolucional y varias LSTM). Seguidamente, se ajustarán los hiperparámetros combinando Optimización Bayesiana y adaptación manual de la arquitectura, en función de los límites impuestos por la capacidad computacional de la que se dispone. En todos los casos, el ajuste de hiperparámetros seguirá las siguientes dos reglas básicas:

1. En igualdad de condiciones (esto es, para combinaciones con rendimiento muy próximo), se favorecerán ventanas de contexto más pequeñas. Esto es especialmente importante para tratar de alcanzar en los modelos *deep learning* un compromiso entre tasa de acierto y coste computacional del entrenamiento y predicción.
2. Para los modelos *deep learning*, se favorecerá que estos mantengan, con independencia del sujeto, una arquitectura idéntica o similar en términos de neuronas y capas (salvo que algún cambio en la misma derive en mejoras claras y significativas del rendimiento del modelo en el conjunto de validación).

Por último, se entrenará para cada individuo un modelo de cada uno de los tres tipos de arquitectura (empleando los hiperparámetros ajustados) y se evaluará su rendimiento en el conjunto de *test*. El desempeño en *test* será el que determine el modelo óptimo.

La metodología para el desarrollo de modelos será la misma en todos los casos: los datos se prepararán para el modelado conforme a los requisitos del modelo en cuestión: para el caso de XGBoost, se habrán de convertir a un formato tabular, de modo que las variables para cada observación sinteticen de algún modo la evolución temporal del ritmo cardiaco en un pasado inmediato. Para tal fin, se propone recurrir a ventanas deslizantes (cuya longitud habrá de ajustarse) a partir de las cuales extraer la media y desviación típica, y convertir estas variables en las entradas del modelo. Para el caso de los modelos de aprendizaje profundo, no se realizará ningún procesamiento sobre las mediciones originales, pero éstas habrán de reestructurarse de manera que adopten la configuración tensorial requerida por estos modelos, lo cual requerirá también ajustar la ventana de contexto deseada.

Tras esta preparación, se recurrirá a la Optimización Bayesiana para el ajuste de los hiperparámetros que se consideren más relevantes. Los valores óptimos se utilizarán para ajustar un modelo final de cada tipo. Por último, se comparará el rendimiento de los tres modelos resultantes empleando el conjunto de *test*; el modelo que exhiba los mejores resultados se elegirá para la última fase (validación).

6.1 AJUSTE DE MODELOS XGBOOST

El algoritmo XGBoost, acrónimo de *Extreme Gradient Boosting*, es una variante altamente eficiente y muy popular del algoritmo de *Gradient Boosting* clásico. Presenta un muy buen desempeño en problemas de regresión y clasificación basados en datos tabulares, a la par que resulta una opción mucho más ligera en términos computacionales frente a alternativas *deep learning*, y proporciona mayores facilidades de interpretabilidad (al menos en contraste con las ofrecidas por redes recurrentes LSTM), motivo por el cual se ha querido incorporar a este proyecto.

6.1.1 PREPARACIÓN DE LOS DATOS

Como ya se comentaba en la revisión del estado del arte, puesto que los datos con los que se cuenta son secuenciales, para poder emplear este algoritmo deberán ser ‘tabularizarlos’, sintetizando variables cuyo valor instantáneo capture la tendencia de la serie en el pasado cercano. Para tal fin se emplearán ventanas deslizantes de las cuales se extraerán la media y la desviación típica del ritmo cardiaco; a cada valor de media y desviación típica se le asignará la fecha y hora de la última muestra de la ventana a la que se correspondan. Se extraerán únicamente estas dos variables para facilitar la interpretabilidad del modelo, ya que si bien se espera que los rendimientos óptimos se alcancen con arquitecturas *deep learning*, estos modelos serán de particular interés para cubrir satisfactoriamente el segundo de los objetivos del proyecto: explorar y entender el comportamiento del ritmo cardiaco durante el proceso de transición al estado de sueño.



Figura 20: Diagrama de entradas y salida del modelo XGBoost

Uno de los parámetros a definir será el tamaño de la ventana deslizante, en términos de número de muestras. Dado que el tamaño de ventana puede ejercer un impacto decisivo en el rendimiento del modelo, y su interacción con diversos hiperparámetros posiblemente altere el valor óptimo de estos últimos, es preferible tratar esta métrica como un hiperparámetro más y ajustarlos todos conjuntamente. Por ello, el único ajuste preparatorio de los datos previo a la optimización bayesiana consistió en introducir un desplazamiento de dos minutos (24 muestras) para datos de origen Fitbit, y de tres minutos (3 muestras) para datos de origen MiBand, a fin de intentar forzar una ligera anticipación temporal en las predicciones del modelo, y obligar a que durante el ajuste éste adquiriera mayor sensibilidad a los signos previos a la transición al sueño identificables en el ritmo cardiaco. El desfase temporal mayor en datos MiBand viene motivado por el hecho de que, al contar con solo una muestra por minuto – en lugar de 12 –, un desplazamiento de tan solo dos muestras se juzgó excesivamente reducido. El restante procesamiento previo queda fusionado con la fase de ajuste.

6.1.2 AJUSTE DE HIPERPARÁMETROS E IDENTIFICACIÓN DEL MODELO ÓPTIMO

La técnica de Optimización Bayesiana busca identificar de manera eficiente el máximo de una función objetivo costosa de evaluar, mediante actualizaciones sucesivas de la estimación de dicha función a fin de centrar la búsqueda en las regiones más prometedoras del espacio de hiperparámetros (ver detalles en el apartado 3.3.4 de la memoria). Para implementar esta técnica, se ha de definir tanto el espacio de búsqueda como la función objetivo a optimizar, lo cual requiere de una selección previa de los hiperparámetros en cuestión que se deseen ajustar.

Los modelos XGBoost cuentan con una elevado número de hiperparámetros ajustables, por lo que se decidió focalizar el ajuste en los siguientes tres:

- Tasa de aprendizaje
- Profundidad máxima de los estimadores (árboles)
- Número de estimadores (árboles)

Así mismo, como se ha dicho, también se tratará el tamaño de ventana como un hiperparámetro más a optimizar. De esta manera, el procedimiento de búsqueda quedó definido como sigue:

1. **Función objetivo:** La función toma como entrada los cuatro hiperparámetros a ajustar: tamaño de la ventana, número de árboles, profundidad máxima de los árboles y tasa de aprendizaje. A partir del tamaño de ventana, se define y aplica una ventana deslizante sobre los datos de frecuencia cardíaca, extrayendo la media y la desviación típica. Estas características se utilizan para entrenar el clasificador XGBoost, cuyos hiperparámetros tomarán los valores definidos en la entrada de la función. La métrica de salida será la tasa de acierto media en validación cruzada estratificada (de tipo 5-fold). Al emplear estratificación, no nos hemos de preocupar por el desbalanceo moderado de los datos. La validación cruzada ofrece una estimación más confiable que la evaluación del modelo mediante un conjunto de validación, por lo que se pudo emplear la totalidad de datos de train (80% del total) para el ajuste y entrenamiento. Se puede encontrar una explicación detallada tanto de la técnica de validación cruzada como de su variante estratificada en [33].
2. **Espacio de búsqueda:** El espacio de búsqueda no es más que el rango de valores posibles para cada hiperparámetro, cuyos límites superior e inferior se han de establecer antes de proceder a la optimización. Según la fuente de los datos, el espacio de búsqueda se delimitó de la siguiente manera (Tabla 3).

<i>Fuente de datos</i>	<i>T. ventana</i>	<i>Número de estimadores</i>	<i>Profundidad máxima</i>	<i>Tasa de aprendizaje</i>
<i>Fitbit</i>	(12, 240)	(100, 1000)	(3, 6)	(0.001, 0.1)
<i>MiBand</i>	(12, 120)	(500, 1000)	(3, 6)	(0.001, 0.1)

Tabla 3: Espacio de búsqueda para modelos XGBoost

Como puede verse, el tamaño máximo de ventana es más reducido para datos MiBand. Esto se debe a la distinta frecuencia de muestreo de las dos fuentes de datos, lo que conlleva que la duración temporal de una misma longitud de ventana cambie mucho: una ventana de 120 muestras equivale a 10 minutos para datos Fitbit, y a 2 horas para datos MiBand. Para evitar ventanas de duración temporal excesiva en los modelos entrenados con datos MiBand (algo poco práctico de cara a un sistema real de detección de entrada en sueño), se decidió limitar la duración máxima a dos horas. Por otra parte, no se emplearon ventanas superiores a 240 muestras en datos Fitbit (20 minutos) debido a la enorme cantidad de registros proporcionada por esta pulsera, lo cual podía traducirse en excesivos costes computacionales para ventanas muy grandes.

3. **Optimizador:** el optimizador que implementa el algoritmo de búsqueda se ejecutó definiendo **20 iteraciones** y 5 puntos iniciales para datos Fitbit; y **40 iteraciones** con 5 inicializaciones aleatorias para datos MiBand. Los puntos iniciales son puntos elegidos al azar en el espacio de búsqueda que se evalúan antes de que comience la optimización propiamente dicha. El número de iteraciones es el número de pasos del proceso de optimización bayesiana. El menor número de iteraciones para datos Fitbit responde a la elevada cantidad de observaciones y, consiguientemente, el mayor coste computacional del ajuste.

A fin de exponer un ejemplo completo, a continuación se detallan los resultados de modelización XGBoost para los datos del sujeto ID1 (datos Fitbit). Más adelante se expondrá también un ejemplo completo para datos MiBand. La optimización de hiperparámetros se efectuó para ID1 bajo los parámetros y límites que se acaban de describir. Tras ejecutar la optimización, la combinación óptima identificada para ID1 resultó ser la siguiente.

T. ventana	N. estimadores	Profundidad máx.	Tasa de aprendizaje
240 (20 min.)	995	4	0.022

Tabla 4: Resultado de optimización XGBoost para ID1

Tras el ajuste, se procedió a entrenar el modelo XGBoost óptimo con los datos completos de entrenamiento y a evaluar su rendimiento en *test*, tal y como se indica en el diagrama al inicio del capítulo (Figura 19). Para un umbral de clasificación de 0.50 (es decir, clasificando como ‘dormido’ aquellas observaciones para las que la probabilidad es igual o superior a 0.5), se obtuvo una tasa de acierto del 84.44%, con una precisión del 57.48% y un *recall* del 53.45%. La matriz de confusión para los datos de *test* es la siguiente.




Figura 21: Matriz de confusión XGBoost para ID1

Los resultados son mejorables, especialmente el *recall*, pero dada la sencillez de esta aproximación (predecir el estado de sueño del sujeto a partir de tan solo dos variables de entrada y mediante un modelo no secuencial), resultan aceptables a modo de primera

aproximación. La curva ROC – *Receiver Operating Characteristic*, una gráfica extremadamente útil para la caracterización de modelos de clasificación, que representa la tasa de falsos positivos contra la tasa de verdaderos negativos para múltiples umbrales de clasificación – es la siguiente (Figura 22). Nótese que se está representado la curva completa, no la correspondiente a un único umbral de decisión.




Figura 22: Curva ROC de XGBoost para ID1

Cuanto mayor sea el área bajo la curva, mejor es el desempeño del modelo. La línea diagonal discontinua representa la curva resultante de un modelo de clasificación aleatoria; esto permite derivar a partir de la ROC un umbral de clasificación óptimo: será aquel punto de la curva más alejado de la diagonal o, visto de otra manera, el punto más próximo a la esquina superior derecha del gráfico. Dicho esto, el umbral de detección más adecuado viene en la práctica determinado por las necesidades específicas del problema de clasificación al que el modelo se ha ajustado (pues dichas necesidades serán las que determinen, por ejemplo, la importancia relativa del *recall* respecto a la precisión). Para este proyecto resultaría a priori preferible mejorar el *recall* a costa de disminuir la precisión, pero en última instancia serán las pruebas de validación final con el juego las que permitirán obtener una idea general sobre qué umbrales tienden a ser adecuados, y qué métrica concreta ha de recibir prioridad.

Con todo, resulta en cualquier caso relevante explorar el impacto en la clasificación del umbral ‘óptimo’ derivado de la curva ROC. Conforme a la definición dada anteriormente, el umbral de clasificación más cercano a la esquina superior izquierda sería de 0.31; la matriz de confusión asociada a dicho umbral se muestra a continuación (Figura 23).




Figura 23: Matriz de confusión XGBoost para ID1 con umbral de clasificación ajustado

Dicho umbral deriva en una tasa de acierto del 79%, con una precisión del 45.21% y un *recall* del 80.64%. Como puede verse, este criterio de identificación del umbral óptimo tiende a favorecer el *recall* a costa de la precisión (este es un fenómeno observado en la gran mayoría de sujetos, tanto Fitbit como MiBand, y no tan solo una observación puntual para ID1). Dado que este ajuste de umbral tiende a favorecer la reducción de falsos negativos a costa de aumentar un poco los falsos positivos, no es una mala estrategia en caso de carecer de la posibilidad de validar el modelo, si bien la métrica de precisión debería superar como mínimo el 65% o 70% para que la estrategia sea viable (como se verá más adelante, esta condición se cumplirá para los modelos *deep learning*). Dicho esto, de este punto en adelante las métricas de evaluación del rendimiento de los modelos serán las obtenidas para umbrales de probabilidad de 0.5.

A fin de adquirir una idea más concreta del comportamiento del modelo, la gráfica (Figura 24) que se muestra a continuación recoge la probabilidad (en rojo) asignada por el modelo

para cada instante temporal en el momento de transición al sueño del día 10 de marzo, junto con la señal dormido/desperto (en azul).




Figura 24: Ejemplo de probabilidades asignadas por XGBoost para una noche

En consonancia con las cifras de precisión y *recall* antes comentadas, la cifra exacta de probabilidad es poco útil para el desarrollo de un sistema preciso de detección de somnolencia; dicho esto, el comportamiento del modelo sí parece cambiar dentro del periodo nocturno, donde el valor medio de la probabilidad tiende a ser más alto. Ello nos permite inferir que el modelo sí ha podido en cualquier caso capturar correctamente algo de la relación entre la frecuencia cardíaca y el estado de sueño del sujeto.

A continuación se muestra una pequeña tabla comparativa de resultados de modelos XGBoost para todos los usuarios Fitbit. Se incluyen los hiperparámetros óptimos, y las métricas de evaluación en *test* más relevantes (el *F1 Score* es la media armónica de la precisión y el *recall*).

<i>Sujeto</i>	<i>Tasa de aprendizaje</i>	<i>Número de estimadores</i>	<i>Profund. máxima</i>	<i>Tamaño ventana</i>	<i>AUC</i>	<i>F1 Score</i>	<i>Tasa de acierto</i>
ID1	0.022	995	4	240	0.85	0.60	81.03%
ID8	0.003	480	3	170	0.97	0.91	94.68%

Tabla 5: Métricas en test de los modelos XGBoost para datos Fitbit

Las métricas para ID8 son, en cambio, sorprendentemente mejores, incluso pese a contar con una ventana de contexto más reducida. Este hecho apunta a que los modelos XGBoost parecen tener mucha mayor sensibilidad a la variabilidad inter-sujeto en el comportamiento de la serie temporal de ritmo cardiaco, al menos respecto a la observada para los modelos *deep learning*, tal y como se verá en el apartado siguiente.

El procedimiento de ajuste seguido para datos MiBand, como ya se ha comentado antes, es prácticamente idéntico. Únicamente cambian los límites impuestos al espacio de hiperparámetros que el optimizador ha de explorar, en respuesta a la enorme cantidad de observaciones para los registros Fitbit y al mayor intervalo entre muestras de los datos de origen MiBand. A continuación se detalla un ejemplo completo de resultados XGBoost para datos MiBand (sujeto ID3).

De entrada, el ajuste de hiperparámetros para ID3 halló un óptimo en torno a la siguiente combinación.

T. ventana	N. estimadores	Profundidad máx.	Tasa de aprendizaje
60 (1 hora)	590	4	0.01

Tabla 6: Resultado de optimización XGBoost para ID3

Para esta combinación de hiperparámetros se obtuvo una tasa de acierto en test del 90.25%, con una precisión del 88.93% y un *recall* del 75.34%.




Figura 25: Matriz de confusión en test y ROC de XGBoost para ID3

Si se realizase un ajuste del umbral de clasificación a partir de la curva ROC, de nuevo volvemos a observar una mejora en el *recall* (87%) a costa de un empeoramiento en la precisión (75%), la matriz de confusión que se muestra a continuación (Figura 26) sintetiza estos resultados.




Figura 26: Matriz de confusión XGBoost para ID3 con umbral de clasificación ajustado

La siguiente tabla (Tabla 7) recoge y compara los resultados de modelos XGBoost para los usuarios MiBand, nuevamente incluyendo parámetros óptimos, AUC, F1 y tasa de acierto.

<i>Sujeto</i>	<i>Tasa de aprendizaje</i>	<i>Número de estimadores</i>	<i>Profund. máxima</i>	<i>Tamaño ventana</i>	<i>AUC</i>	<i>F1 Score</i>	<i>Tasa de acierto</i>
<i>ID3</i>	0.01	590	4	60 (1 h.)	0.94	0.82	90.25%
<i>ID5</i>	0.017	590	3	10 (50 min.)	0.96	0.83	90.77%
<i>ID6</i>	0.02	570	3	30 (30 min.)	0.97	0.87	93.52%
<i>ID7</i>	0.004	590	3	50 (50 min.)	0.84	0.66	78.68%

Tabla 7: Métricas en test de los modelos XGBoost para datos MiBand

En general, los resultados son muy buenos para la mayor parte de voluntarios a excepción del sujeto ID7. Resulta llamativo, de hecho, el rendimiento notablemente inferior de XGBoost para los datos de este individuo en comparación con las tasas de acierto y métricas F1 de los demás voluntarios. Si examinamos una pequeña sección de la serie temporal de frecuencia cardíaca de ID7, el origen de esta divergencia se vuelve evidente.




Figura 27: Segmento de la serie temporal de ritmo cardiaco de ID7

Como puede verse, las variaciones periódicas en el valor medio y desviación típica de la frecuencia cardiaca son mucho más sutiles que en otros casos (ver EDA). Tanto es así, que de no estar etiquetado el eje temporal x , resultaría prácticamente imposible estimar dónde se ubican los periodos de sueño.




Figura 28: Segmento de ID7 con los periodos de sueño señalados

Siendo este el comportamiento de la serie, es comprensible e incluso esperable que la aproximación XGBoost basada en ventanas deslizantes y ‘tabularización’ de los datos resulta excesivamente simple. Por ello, pese a los resultados aceptables obtenidos con este algoritmo, se hace necesario explorar soluciones más potentes, capacitadas para tratar datos de tipo secuencial (de manera que no se produzca la inevitable pérdida de información que ocurre al sintetizar las ventanas temporales en estadísticos-resumen). Antes, sin embargo, aprovecharemos la sencillez relativa de estos modelos para estudiar con mayor detalle los cambios en la media y desviación típica de la frecuencia cardíaca al producirse la entrada en sueño.

6.1.3 INTERPRETACIÓN DE LAS PREDICCIONES DEL MODELO

Esta sección adicional, como decíamos, es de relevancia para el análisis de los cambios en la frecuencia cardíaca durante la transición al sueño. Para poder estudiar estas variaciones, dado que los modelos solo cuentan con dos variables de entrada, se representará la región de decisión marcando en azul las regiones en las que la probabilidad de que el sujeto esté dormido se sitúe por debajo de 0.5, y en rojo las regiones para las que la probabilidad sea superior a 0.5.

Comencemos este análisis con ID3. Dado que resulta de mayor relevancia para este objetivo secundario los cambios a corto plazo, se re-entrenó un modelo XGBoost con una ventana de contexto de únicamente 10 muestras (esto es, 10 minutos). La región de decisión resultante se puede visualizar bajo estas líneas (Figura 29).




Figura 29: Región de decisión XGBoost de ID3 para una ventana de 10 muestras

Como puede apreciarse, para valores de desviación típica más altos el valor medio es determinante, mientras que para valores de desviación típica muy bajos la probabilidad de que el sujeto esté dormido es alta incluso para valores elevados de ritmo cardiaco medio. Resulta interesante observar cómo los valores muy altos de desviación típica también parecen asociados a una mayor probabilidad de sueño, salvo que el valor medio sea también excesivamente alto (superior 80 ppm).

La apariencia de la región de decisión es sensible al tamaño de la ventana de contexto. Las siguientes gráficas (Figura 30) muestran, para el mismo sujeto ID3, ejemplos de región de decisión asociados (de derecha a izquierda: regiones de decisión para una ventana de 10 muestras, de 30 muestras, de 60 muestras – la ventana óptima para ID3 – y de 90 muestras).




Figura 30: Cambios en la región de decisión XGBoost en función del tamaño de ventana

Este es un patrón general constatable en otros sujetos: a medida que aumenta el tamaño de la ventana deslizante, el valor medio de ritmo cardiaco va cobrando menos relevancia y la desviación típica se vuelve determinante. El caso de ID3 es particularmente llamativo en este sentido, por ser la desviación típica prácticamente la única variable relevante para ventanas muy grandes; en otros sujetos el peso de esta variable también crece notablemente en relación con el valor medio, pero esta última continúa siendo de relevancia para las predicciones.

Regresando a tamaños de ventana de 10-15 minutos – esto es, ventanas pequeñas, para que nos den un contexto real de los cambios a corto plazo de la serie – el patrón que se podía apreciar en la Figura 29 reaparece en muchos otros sujetos (si bien con ciertas variaciones). Se muestran a continuación (Figura 31) ejemplos para ID3, ID8 MiBand, ID5, e ID6.




Figura 31: Comparativa de regiones de decisión XGBoost (ventanas de 10-15 minutos)

Como se vio anteriormente, valores muy altos o muy bajos de desviación típica se asocian a una mayor probabilidad de sueño, lo cual se traduce en términos visuales en una apariencia similar a un ‘golfo’, que será más o menos pronunciada en función del comportamiento idiosincrático del ritmo cardiaco de cada sujeto. Por último, si tomamos una de las gráficas (la asociada al sujeto ID8) y representamos la transición de la vigilia al sueño en una noche concreta, obtenemos lo siguiente.




Figura 32: Transición al sueño de ID8 representada sobre la región de decisión XGBoost

Cada uno de los puntos que se muestran representados sobre la región de decisión se corresponde con una observación concreta (media y desviación típica de las últimas 10

muestras de ritmo cardiaco). El color de estos puntos (no el de la propia región, que como se explicó antes se corresponde con las probabilidades asignadas por el modelo) varía en función del orden cronológico de cada observación: los colores rojos se corresponden a las primeras observaciones del segmento considerado – en las cuales el sujeto está claramente despierto – y las más azules se corresponden a las últimas muestras – en las que el sujeto está ya dormido. Como se puede ver, la trayectoria se adentra, tras un amago probablemente asociado a un fenómeno de repudio del sueño, en la región inferior izquierda de la gráfica, donde se atraviesa el umbral de probabilidad de 0.5 y se produce la entrada en sueño propiamente dicha. Si bien hay mucha variabilidad (tanto para un mismo sujeto como entre sujetos), muchas de las transiciones tienden a ocurrir en la misma zona de la región de decisión, esto es, con valores bajos de desviación típica.

6.2 AJUSTE DE MODELOS DE APRENDIZAJE PROFUNDO

6.2.1 PREPARACIÓN DE LOS DATOS

Como ya se comentaba en la revisión del estado del arte, puesto que los datos con los que se cuenta son secuenciales, para poder emplear este algoritmo deberán ser ‘tabularizarlos’, sintetizando variables cuyo valor instantáneo capture la tendencia de la serie en el pasado cercano. Para tal fin se emplearán ventanas deslizantes de las cuales se extraerán la media y la desviación típica del ritmo cardiaco; a cada valor de media y desviación típica se le asignará la fecha y hora de la última muestra de la ventana a la que se correspondan. Se extraerán únicamente estas dos variables para facilitar la interpretabilidad del modelo, ya que si bien se espera que los rendimientos óptimos se alcancen con arquitecturas *deep learning*, estos modelos serán de particular interés para cubrir satisfactoriamente el segundo de los objetivos del proyecto: explorar y entender el comportamiento del ritmo cardiaco durante el proceso de transición al estado de sueño.

Los modelos que consideraremos en esta sección tienen la capacidad de procesar datos secuenciales; esto es, aceptan secuencias de entrada a fin de conocer el contexto completo de la serie temporal para la ventana definida. Por ello, ya no es necesario sintetizar las

ventanas deslizantes mediante estadísticos; únicamente se requiere reestructurar los datos en tensores (o *arrays* de *NumPy*) con las siguientes dimensiones: (número de observaciones, tamaño de ventana, número de atributos). De este modo, el modelo procesará la ventana completa y a partir de la misma estimará una probabilidad. Dado que el tamaño de ventana se considera nuevamente un hiperparámetro ajustable, se volverá a aplicar una búsqueda bayesiana para adquirir una idea general del tamaño óptimo de la misma; por ello, la fase de preparación de los datos queda de nuevo parcialmente fusionada con la de ajuste del modelo. Antes de realizar dicho ajuste, se introdujo un ligero desfase en la etiqueta/dormido despierto (2 minutos para datos Fitbit, 3 minutos para datos MiBand) para tratar de forzar al modelo a anticiparse ligeramente a la entrada en sueño propiamente dicha.

En relación con la preparación de los datos de entrada y la creación de ventanas de contexto, aparece también otro cambio respecto a XGBoost: dado que se observó que los datos Fitbit incluyen junto al ritmo cardiaco una medida (del 0 al 3) del nivel de confianza de la pulsera respecto a la estimación de frecuencia cardiaca, puede ser interesante introducir esta variable en la red, de modo que (presumiblemente) ésta aprenda a dar un mayor peso y relevancia a aquellas medidas de alta confianza. Por ese motivo, la red recibirá – solo para datos procedentes de pulseras Fitbit – no una sino dos secuencias de entrada: la ventana correspondiente a las medidas de ritmo cardiaco, y otra ventana con los niveles de confianza asociados a cada muestra. Esto será así tanto para las redes LSTM puras como para las redes híbridas. Por último, como se comentará a continuación, en esta ocasión el conjunto global de datos se fraccionó no en dos sino en tres conjuntos: entrenamiento (70% de los datos), validación (10% de los datos) y *test* (20% de los datos). Esto responde a que, de cara a definir la función objetivo para la optimización bayesiana, es inviable aplicar validación cruzada sin asumir tiempos de ajuste desorbitados, aún con pocas iteraciones. Por ello, la función objetivo devolverá la tasa de acierto del modelo para el conjunto de validación.

6.2.2 REDES LSTM PURAS

Dados los tiempos de entrenamiento de estas redes y el elevado número de observaciones disponibles para el ajuste del modelo, un ajuste completo de la red mediante optimización

bayesiana resulta inviable. solo se ajustará mediante optimización bayesiana la ventana de contexto; el resto del ajuste es manual – de prueba y error – para adquirir una idea general del número apropiado de capas y neuronas. En todos los casos, la arquitectura que se muestra a continuación exhibió un buen rendimiento tanto en validación como en test.

1. Capa de entrada de dimensiones *tamaño de ventana* $\times$ *número de atributos*
2. **Capa LSTM** de **30** neuronas
3. Dropout de 0.2 en el entrenamiento
4. **Capa LSTM** de **30** neuronas
5. Dropout de 0.2 en el entrenamiento
6. **Capa LSTM** de **30** neuronas
7. Dropout de 0.1 en el entrenamiento
8. **Capa densa de salida** de una única neurona, con función de activación **sigmoide**

El siguiente diagrama muestra la configuración de las distintas capas dentro de la red (no se incluye dropout por activarse solo durante el entrenamiento).




Figura 33: Diagrama de la red LSTM.

Tras verificar el buen rendimiento de esta arquitectura en varios sujetos, se trató de preservar la misma estructura para distintos sujetos y fuentes de datos, salvo que cambios importantes en la misma – por ejemplo, cuarenta o veinte neuronas por capa en lugar de treinta, o dos/cuatro capas en lugar de tres – derivasen en una mejora significativa del rendimiento, algo que no se llegó a observar (antes al contrario, en muchos de los casos el rendimiento de arquitecturas alternativas tendía a ser inferior).

También debido al elevado coste computacional del entrenamiento se decidió fijar un número menor de iteraciones para datos Fitbit (8 frente a 40) por la misma razón. Por último, en igualdad de resultados (resultados muy próximos, con diferencias en el orden de fracciones de puntos porcentuales) nuevamente se ha favorecido un tamaño de ventana reducido frente a uno más amplio. La siguiente tabla recoge y sintetiza la diferencia en la configuración del optimizador y el espacio de búsqueda para datos Fitbit y MiBand.

<i>Fuente de datos</i>	<i>Número de iteraciones</i>	<i>Puntos iniciales</i>	<i>Tamaño de batch</i>	<i>T. ventana</i>
<i>Fitbit</i>	5	3	10000	(120, 360)
<i>MiBand</i>	40	3	1000	(10, 150)

Tabla 8: Configuración del optimizador y espacio de búsqueda para LSTM

Pongamos de nuevo como ejemplo los resultados para ID1. En términos de coste computacional y tasa de acierto, el tamaño óptimo de ventana parece ubicarse en torno a las 120 muestras (10 minutos, dado que hablamos de datos Fitbit). La tasa de acierto del modelo final alcanzó la cifra de 96.59% en *test*, una enorme mejora en términos tanto cuantitativos (Figura 34) como cualitativos (Figura 36) en relación con los resultados XGBoost.




Figura 34: Matriz de confusión en test y ROC de LSTM para ID1

Podemos nuevamente emplear la curva ROC para ajustar el umbral de detección. Como puede apreciarse observando los cambios en la matriz resultante, el ajuste vuelve a favorecer al *recall* frente a la precisión.




Figura 35: Matriz de confusión LSTM para ID1 con umbral de clasificación ajustado

Una vez más, téngase en cuenta que todas las métricas que se expresen a continuación hacen referencia a umbrales de detección de 0.5, no al umbral ajustado a partir de la curva ROC. Por último, si se representa la probabilidad asignada por el modelo para la misma noche que la estudiada en el apartado XGBoost, la magnitud de la mejora se vuelve evidente.




Figura 36: Ejemplo de probabilidades LSTM para una noche

La tabla comparativa de resultados de modelos LTSM para usuarios con datos de origen Fitbit se puede consultar a continuación.

<i>Sujeto</i>	<i>Tamaño ventana</i>	<i>AUC</i>	<i>F1 Score</i>	<i>Tasa de acierto</i>
ID1	120 (10 minutos)	0.98	0.86	96.56%
ID8	220 (~18 min.)	0.99	0.95	97.07%

Tabla 9: Métricas en test de los modelos LSTM para datos Fitbit

El procedimiento para datos de origen MiBand es idéntico, con la salvedad de las diferencias antes comentadas en la definición del espacio de búsqueda y la configuración del optimizador.

<i>Sujeto</i>	<i>Tamaño ventana</i>	<i>AUC</i>	<i>F1 Score</i>	<i>Tasa de acierto</i>
ID3	120 (2 horas)	0.97	0.87	92.66%
ID5	24 (2 horas)	0.97	0.85	92.16%
ID6	100 (1 h. 40 min.)	0.99	0.91	95.53%
ID7	70 (1h. 10 min.)	0.88	0.73	79.91%

Tabla 10: Métricas en test de los modelos LSTM para datos MiBand

Una vez más, vuelve a destacar el resultado para ID7, muy inferior en términos comparativos al de los demás sujetos. En cualquier caso, sí se aprecia al menos una cierta mejora en la tasa de acierto, que se sitúa virtualmente en el 80%. En todos los demás resultados (especialmente para datos de origen Fitbit) la mejora es sustancial, y los resultados son menos sensibles a la variabilidad inter sujeto.

6.2.3 ARQUITECTURA HÍBRIDA (CNN & LSTM)

Finalmente, la tercera y última arquitectura a evaluar es la descrita a continuación. Se trata de un modelo *deep learning* híbrido que introduce, antes de las capas recurrentes (LSTM), una capa convolucional unidimensional constituida por 30 filtros o kernels de longitud 8 (esto es, constituidos por 8 pesos ajustables) y una capa de *pooling* que comprime las secuencias de salida de la capa convolucional: de cada cuatro muestras, mantiene solo aquella que cuente con el valor máximo.

1. Capa de entrada de dimensiones *tamaño de ventana* $\times$ *número de atributos*
2. **Capa convolucional** (convolución en 1 dimensión) con **30** filtros y un tamaño de kernel de **8 pesos**.
3. **Capa de max pooling** con un tamaño de tramo (*stride*) de longitud 4. Esto es, se divide el mapa de características en segmentos de 4 muestras y para cada segmento se conserva únicamente la muestra de valor máximo.

4. **Capa LSTM** de **30** neuronas
5. Dropout de 0.2 en el entrenamiento
6. **Capa LSTM** de **30** neuronas
7. Dropout de 0.2 en el entrenamiento
8. **Capa LSTM** de **30** neuronas
9. Dropout de 0.1 en el entrenamiento
10. **Capa densa de salida** de una única neurona, con función de activación **sigmoide**

Este cambio viene motivado por el hecho de que la capa convolucional permite reducir sustancialmente el tamaño de las secuencias que las neuronas LSTM deben procesar (respecto al tamaño de la secuencia original). Ello se traduce en que:

- Se pueden explorar tamaños de ventanas superiores y, al mismo tiempo, reducir apreciablemente el coste computacional del entrenamiento. Debido a que la secuencia a la que deben ajustarse las neuronas recurrentes es cuatro veces menor a la secuencia de entrada, mientras que la cantidad de hiperparámetros añadidos por la capa convolucional no es excesivamente grande – se trata de una única capa y los *kernels* son más bien pequeños – la mejora es muy sustancial en términos de tiempo de entrenamiento.
- Aunque las neuronas LSTM son mucho más robustas que las neuronas recurrentes clásicas ante el problema de desvanecimiento de gradiente, para secuencias relativamente grandes las LSTM también pueden verse afectadas. Al reducirse el tamaño de la secuencia, el desempeño de la red en test puede mejorar.

De este modo, los filtros de la capa convolucional extraerán de la secuencia original las características más relevantes, y las LSTM procesarán los datos filtrados para generar las predicciones finales.




Figura 37: Diagrama de la red híbrida CNN + LSTM

El procedimiento de optimización y ajuste es, por lo demás, el mismo. En respuesta a la superior capacidad de esta arquitectura para manejar longitudes de ventana grandes, el espacio de búsqueda de dicho hiperparámetro se delimitó de la siguiente forma.

<i>Fuente de datos</i>	<i>Número de iteraciones</i>	<i>Puntos iniciales</i>	<i>Tamaño de batch</i>	<i>T. ventana</i>
<i>Fitbit</i>	5	3	10000	(120, 360)
<i>MiBand ID5</i>	40	3	1000	(10, 150)
<i>Restantes MiBand</i>	40	3	1000	(120, 360)

Tabla 11: Espacio de búsqueda de hiperparámetros para la red híbrida

Si bien no se ha alterado el rango para datos Fitbit, sí se ha tratado de forzar que el modelo ajustado a datos MiBand procese ventanas de contexto más amplias en cuanto a número de muestras, aprovechando que el desvanecimiento de gradiente no supone un problema serio

en esta arquitectura. Para ID5 se ha mantenido un espacio de búsqueda reducido debido a que, al ser el intervalo entre muestras de 5 minutos, no es razonable emplear ventanas de más de 12 horas de duración (aunque la longitud en términos absolutos – es decir, en términos de número de observaciones – sea más bien reducida). Una vez más, se resumen a continuación los resultados para ID1 (a modo de ejemplo). El modelo óptimo, con una ventana de 280 muestras (algo más de 23 minutos), obtuvo una tasa de acierto del 97.23%, con una precisión del 90.63% y un valor de *recall* del 87.91%.




Figura 38: Matriz de confusión en test y ROC de CNN + LSTM para ID1

Tomando el umbral óptimo derivado de la curva ROC, vemos que de nuevo se impulsa el recall (hasta el 93%) a costa de la precisión (que baja hasta el 77%); dicho de otra forma, el umbral se ubica muy por debajo de 0.5, en el entorno de probabilidades del 0.15-0.25.




Figura 39: Matriz de confusión CNN + LSTM para ID1 con umbral de clasificación ajustado

La mejora en términos cualitativos respecto al modelo anterior (LSTM puro) también vuelve a ser notable, como puede apreciarse en la siguiente gráfica (Figura 40).




Figura 40: Ejemplo de probabilidades CNN + LSTM para una noche

En la siguiente tabla se muestra un resumen de resultados para los datos de origen Fitbit; como puede verse, para ambos sujetos se alcanzan métricas excelentes.

<i>Sujeto</i>	<i>Tamaño ventana</i>	<i>AUC</i>	<i>F1 Score</i>	<i>Tasa de acierto</i>
ID1	280 (23 min.)	0.98	0.89	97.23%
ID8	120 (10 min.)	0.99	0.96	97.48%

Tabla 12: Métricas en test de los modelos CNN + LSTM para datos Fitbit

La mejora en rendimiento también es muy notable con los datos MiBand, encontrándose la mejora de mayor magnitud en el modelo del sujeto ID7.

<i>Sujeto</i>	<i>Tamaño ventana</i>	<i>AUC</i>	<i>F1 Score</i>	<i>Tasa de acierto</i>
ID3	120 (2 horas)	0.97	0.88	93.31%
ID5	24 (2 horas)	0.96	0.84	91.45%
ID6	120 (2 horas)	0.99	0.92	96.05%
ID7	340 (5 h. y 36 min.)	0.95	0.85	91.04%

Tabla 13: Métricas en test de los modelos CNN + LSTM para datos MiBand

Como puede verse, la tasa de acierto para ID7 supera ahora el 90%, a la par con los demás modelos. Ha sido necesario admitir una ventana enorme en términos temporales (340 muestras se traduce para el caso de pulseras MiBand en más de 5 horas y media), ya que la diferencia de resultados respecto a ventanas más reducidas sí era en esta ocasión demasiado significativa para decantarse por intervalos más reducidos. Pese a ello, la mejora es digna de mencionarse, considerando la dificultad de identificar patrones claros en los datos de entrada. Este resultado, por encima incluso de las excelentes métricas obtenidas con los datos Fitbit, evidencia el potencial de la arquitectura propuesta en esta sección. Únicamente en

ID5 el rendimiento de la red LSTM ha sido superior (con una diferencia mínima), lo cual responde al hecho de que en ambos casos se manejan secuencias pequeñas en términos de número de muestras, longitudes perfectamente asumibles por la red LSTM pura.

6.3 COMPARATIVA FINAL DE RESULTADOS

La siguiente tabla presenta los modelos óptimos para cada uno de los sujetos participantes en el estudio, mostrando todas las métricas relevantes para caracterizar con precisión su desempeño en el conjunto de *test*.

<i>Sujeto</i>	<i>Modelo óptimo</i>	<i>Pulsera</i>	<i>AUC</i>	<i>F1 Score</i>	<i>Precisión</i>	<i>Recall</i>	<i>Tasa de acierto</i>
<i>ID1</i>	CNN + LSTM	Fitbit	0.98	0.89	90.63%	87.91%	97.23%
<i>ID3</i>	CNN + LSTM	MiBand	0.97	0.88	92.55%	83.36%	93.31%
<i>ID5</i>	LSTM	MiBand	0.97	0.85	91.54%	80.78%	92.16%
<i>ID6</i>	CNN + LSTM	MiBand	0.99	0.92	95.13%	89.23%	96.05%
<i>ID7</i>	CNN + LSTM	MiBand	0.95	0.85	88.87%	81.06%	91.04%
<i>ID8</i>	CNN + LSTM	Fitbit	0.99	0.96	93.90%	97.73%	97.48%

Tabla 14: Modelos óptimos

Los resultados son en todos los casos muy satisfactorios, especialmente los obtenidos con datos Fitbit. Los valores de *recall* son bastante aceptables en términos generales, y en cualquier caso un sencillo ajuste del umbral de decisión empleando la curva ROC – como hemos visto repetidamente a lo largo del capítulo – puede elevar esta métrica a valores superiores al 90% sin que el detrimento en cuanto a precisión sea excesivo. Queda, finalmente, validar las predicciones de estos modelos contrastándolas con una medición real del nivel de atención de los sujetos, al menos para aquellos individuos que hayan decidido participar en esta última fase.

Capítulo 7. VALIDACIÓN FINAL

El objetivo de esta última fase del proyecto es el de obtener una verificación experimental de la validez del procedimiento propuesto en el proyecto para dar respuesta al problema que motiva el trabajo: la obtención de modelos que realmente puedan servir de base para un sistema de alerta al usuario en caso de somnolencia o pérdida crítica de atención. Para tal fin, se ha de verificar si las probabilidades proporcionadas por los modelos óptimos se pueden asociar a una pérdida real de la capacidad de reacción del sujeto, como medida de aproximación a su estado de alerta o somnolencia. El sistema propuesto para realizar dicha verificación se realizará mediante una aplicación sencilla a modo de juego concebido para medir y registrar la velocidad de reacción del sujeto, con el cual éste deberá interactuar durante una noche concreta hasta – idealmente – quedarse dormido o al borde del sueño. Durante la realización de la prueba, el sujeto deberá mantener puesta la pulsera, de modo que se pueda posteriormente acceder a las medidas de ritmo cardiaco y a partir de las mismas obtener las estimaciones del modelo.




Figura 41: Recordatorio de la metodología de validación

Dado que, como se comentó anteriormente, la participación en el estudio es estrictamente voluntaria, esta última fase solo se ha podido realizar con un pequeño subconjunto de voluntarios, por requerir de los mismos una mayor implicación (realizar correctamente la prueba implica un esfuerzo adicional que los participantes no están obligados a realizar). En cualquier caso, dado que el fin último no es el de validar los modelos uno por uno sino evaluar la forma de aproximación global al problema, los resultados para los modelos que sí se hayan podido validar permitirán adquirir una idea general sobre la viabilidad de la metodología (conclusión que se deberá confirmar en estudios futuros).

7.1 DESCRIPCIÓN DE LA HERRAMIENTA DE VALIDACIÓN: JUEGO DE TIEMPO DE REACCIÓN

Como se ha dicho, la herramienta básica para realizar la validación será un sencillo juego de velocidad de reacción, programado en Javascript. La mecánica del juego es extremadamente sencilla: tras introducir su número de identificación e iniciar el juego, el usuario deberá estar atento a la pantalla de su dispositivo pendiente de la aparición de una pequeña figura (un cuadrado verde). La figura emergerá desde un punto aleatorio de los laterales del área de juego de la pantalla; el usuario deberá pulsar sobre cualquier punto de la pantalla tan pronto como identifique la figura. El tiempo en segundos transcurrido entre la entrada de la figura en el campo visual del usuario y su detección se enviará vía Ajax al *backend* de la aplicación web (basada en Flask).

Los datos, debidamente identificados, se guardarán en una pequeña base de datos con los siguientes campos: **id** (identificador unívoco de cada observación, que servirá como clave principal), **user_id** (número de identificación del usuario, a fin de poder asociar posteriormente las medidas de ritmo cardiaco con los tiempos de reacción medidos por el juego), y **reaction_time** (el tiempo de reacción propiamente dicho). La arquitectura de la aplicación web sobre la que se implementa el juego es la siguiente.




Figura 42: Diagrama de la aplicación web para el juego de velocidad de reacción

Para facilitar el despliegue, se recurrirá al servicio de aplicaciones web de la plataforma Azure. Dado que los datos son desde origen completamente anónimos, se accederá a los mismos mediante una impresión de los registros de la base de datos en una página HTML de la propia aplicación (si bien se debe conocer la ruta URL exacta para acceder a dicha página, ya que no es directamente accesible desde la página del juego).

7.2 RESULTADOS DE VALIDACIÓN

Como ya se detalló en el capítulo relativo a la metodología, tras realizar la prueba, se solicitará al voluntario correspondiente una última transferencia de los datos de la pulsera y se identificarán las mediciones correspondientes a la fecha en la que el sujeto interactuó con el juego. Estas últimas se introducirán como entradas en el modelo óptimo y se verificará la correlación entre las mediciones de tiempos de reacción y la probabilidad asignada por el modelo. Dicha comparativa también permitirá identificar un umbral de probabilidad razonable para la detección de somnolencia; en este sentido, será interesante contrastar dicho umbral con el derivado de la curva ROC. El diagrama a continuación (Figura 43) resume este procedimiento.




Figura 43: Procedimiento de validación tras la realización de la prueba

Se lograron obtener resultados de validación para dos de los siete sujetos. Dos voluntarios más mostraron interés en participar en esta fase, pero una deficiencia en la comunicación de las instrucciones derivó en que las pruebas fuesen inválidas. En cualquier caso, dos resultados son a nuestro juicio suficientes para adquirir una idea general de la validez de la metodología, lo cual recordemos es el objetivo principal de esta última fase (si bien será necesario replicar los resultados con más voluntarios a fin de confirmar las conclusiones).

7.2.1 RESULTADOS PARA EL SUJETO ID1

A continuación se describe el resultado de validación para el modelo óptimo del sujeto ID1. Tras la extracción de las medidas de ritmo cardíaco y tiempos de reacción, y el remuestreo de estas últimas para poder comparar ambas variables, la evolución de la capacidad de reacción del sujeto ID2 a lo largo de la prueba se muestra en la siguiente gráfica (Figura 44).




Figura 44: Velocidad de reacción de ID1 (remuestreada)

Parecen distinguirse dos momentos de mayor somnolencia o casi transición al sueño, con un periodo entre medias en el que el sujeto regresa a un estado algo más despierto (aunque nótese que los tiempos de reacción no bajan a niveles iniciales, por lo que aun en ese periodo intermedio se puede presumir un estado más somnoliento que al inicio de la prueba); esta interpretación se pudo corroborar y confirmar con el propio voluntario. A continuación, se muestra superpuesto con el ritmo cardiaco (ambas magnitudes normalizadas). Esta vez hay un cambio en los colores: la línea roja representa los tiempos de reacción, y la línea azul indica la probabilidad asignada por el modelo para cada instante temporal.





Figura 45: Velocidad de reacción y probabilidad de transición al sueño para ID1

Si bien con un muy ligero retardo, el ascenso y disminución en los tiempos de reacción tiene su reflejo en una correspondiente elevación o caída de la probabilidad de transición al sueño. Los datos representados en la anterior gráfica reflejan la evolución temporal de estas dos variables, pero un gráfico de dispersión puede ayudar a visualizar mejor la correlación entre ambas magnitudes.



Aun teniendo presente que hay un ligero retraso (inferior a un minuto) en el incremento de la probabilidad de transición al sueño – algo que no queda en cambio bien reflejado en esta última figura – este gráfico de dispersión confirma en cualquier caso la correlación que podía identificarse en la Figura 45. Nótese además que para tiempos de reacción de más de dos segundos son muy pocas las observaciones que presentan una probabilidad inferior a 0.2, y las mediciones más extremas (tiempos de reacción superiores a los cuatro segundos, que empiezan a señalar un nivel crítico de somnolencia) no bajan de 0.4 en ningún caso. Así mismo, los tiempos de reacción más reducidos tienden a agruparse en el extremo inferior izquierdo del gráfico, asociados a valores de probabilidad igualmente bajos.

Por otra parte, dentro del periodo de somnolencia moderada (e incluso dentro de los dos periodos de mayor somnolencia) existen todavía algunas observaciones con tiempos de


reacción inferiores a los dos segundos; esto deriva del hecho de que, como vimos en la gráfica de línea anterior (Figura 45), la somnolencia se manifiesta ante todo en la tendencia general de los tiempos de reacción, y no en cada valor instantáneo. Por ello, es natural que existan probabilidades elevadas asociadas a tiempos de reacción de 1-2 segundos. A la luz de este análisis, un umbral de somnolencia razonable – y en particular, que minimice los falsos negativos – podría ubicarse en torno a $P = 0.25$.

Por último, dado que la relación entre ambas variables es claramente no lineal, se propone el coeficiente de *Spearman* como alternativa más robusta al coeficiente de *Pearson* para cuantificar dicha correlación: el primero, a diferencia del segundo, no hace ninguna suposición sobre la distribución de los datos y es más robusto frente a valores atípicos. Al ser una medida no paramétrica de correlación, proporciona una medida de la intensidad y dirección de la relación monotónica entre dos variables (una relación monotónica es aquella para la que se cumple una de las siguientes condiciones: (1) a medida que aumenta el valor de una variable, aumenta también el valor de la otra; o (2) a medida que aumenta el valor de una variable, disminuye el valor de la otra).


El valor del coeficiente de *Spearman* entre la probabilidad del modelo y los tiempos de reacción es de **0.68**, más que suficiente a nuestro juicio para inferir que existe una correlación significativa entre ambas variables.

7.2.2 RESULTADOS PARA EL SUJETO ID8

El procedimiento de validación de ID8 fue idéntico al seguido con el sujeto ID1. A continuación vienen nuevamente representados los tiempos de reacción del sujeto (re-muestreados y normalizados) y la probabilidad de transición asignada por el modelo durante dicho periodo de tiempo.



Se vuelve a observar una clara correlación positiva entre el tiempo medio de reacción y la probabilidad. Esta correlación viene corroborada por el siguiente gráfico de dispersión.



La correlación de *Spearman* es de 0.83. Parece que un umbral adecuado se podría ubicar en un rango similar al del sujeto anterior, en torno a $P = 0.25$ o 0.30 , si bien esto es en última instancia modulable en función de la sensibilidad que se le quiera otorgar al sistema de detección.

7.3 CONSIDERACIONES DE CARA A LA IMPLANTACIÓN DEL MODELO EN SISTEMAS REALES DE ALERTA

Dado que no es viable hacer a todos los usuarios medir su gradual incremento en el tiempo de reacción durante su transición al sueño mediante un juego, a la vista de las conclusiones extraídas de las pruebas anteriores se proponen las siguientes opciones:

- a) Permitir que la sensibilidad del sistema sea modulable por el usuario. El propio usuario puede luego hacer pruebas mientras alguna noche para comprobar si la sensibilidad a la que ha ajustado el sistema es demasiado alta o demasiado baja. Podría fijarse por defecto una probabilidad en torno a 0.3 para los sistemas basados en datos Fitbit (se requerirían pruebas similares para comprobar en torno a qué niveles tiende a ubicarse el umbral óptimo para datos MiBand), si bien es una opción arriesgada dada la variabilidad inter-sujeto identificada en la fase EDA (y cuyo impacto es bien visible en la fase de modelización).
- b) Emplear una técnica de ajuste del umbral de decisión a nivel de individuo (por ejemplo, a partir de la curva ROC), dado que tiende a favorecer el *recall* y por ende a bajar el umbral de detección a niveles similares a los derivados de los resultados de validación que se acaban de comentar. Además, se evita el riesgo de una aproximación genérica y no adaptada al comportamiento específico de la frecuencia cardiaca de cada usuario particular.
- c) Combinación de ambas aproximaciones.

En cualquier caso, como se ha venido expresando repetidamente a lo largo del informe, la función principal de esta fase era ante todo la de verificar si las probabilidades del modelo en efecto muestran algún tipo de correlación con la pérdida de atención real del sujeto, lo cual nos permitiría validar el enfoque. Dicho objetivo se ha cubierto satisfactoriamente, pero se hace necesario ampliar el número de pruebas en estudios futuros, a fin de confirmar esta conclusión. Así mismo, se deberá clarificar mejor el protocolo para la realización de pruebas

y buscar mecanismos para favorecer una mayor participación de los voluntarios en esta fase final.

Capítulo 8. CONCLUSIÓN Y TRABAJOS FUTUROS

8.1 LIMITACIONES EN EL ESTUDIO

8.1.1 LIMITACIONES EN LA MUESTRA DE VOLUNTARIOS

Tal y como se comentó en el apartado 4.3.1, si bien la diversidad demográfica en la muestra de voluntarios y la aproximación individualizada de la metodología del proyecto resultan suficientes para alcanzar conclusiones sólidas y (hasta cierto punto) generalizables de cara a los objetivos del estudio, dado que se está evaluando la validez general de la metodología defendida e implementada en el proyecto, la cifra modesta de voluntarios no deja de ser un factor que limita el alcance de las conclusiones. Así mismo, y en parte a consecuencia del número reducido de muestras, la distribución de edades y sexos es poco uniforme. Con todo, la notable variabilidad inter-sujeto de la que se ha hecho constancia en múltiples ocasiones durante el análisis exploratorio y la modelización, y las demás consideraciones presentadas anteriormente nos permiten juzgar el tamaño muestral como suficiente dentro de los objetivos y alcance del proyecto.

8.1.2 LIMITACIONES EN LA METODOLOGÍA DE VALIDACIÓN

Aunque la metodología de validación ha demostrado ser adecuada de realizarse correctamente, se ha evidenciado la necesidad de, por una parte, mejorar y estandarizar la comunicación de las instrucciones para la correcta realización de la prueba (de modo que quede enfatizada la importancia de mantener la interacción con el juego hasta el momento de entrada en sueño, o al menos hasta un momento muy próximo a dicha transición), y en segundo lugar, estudiar la posibilidad de introducir incentivos para que los usuarios decidan participar y sigan de manera precisa y hasta el final las instrucciones de la prueba. Alternativamente, se pueden explorar opciones basadas en el análisis de sueño dentro de un entorno clínico controlado, pero ello queda fuera del alcance del proyecto y habría de considerarse de cara a futuros estudios.

8.2 CUMPLIMIENTO DE OBJETIVOS Y EVALUACIÓN DE RESULTADOS

El objetivo principal que motiva este proyecto quedó definido en los siguientes términos: “partiendo de la serie temporal de medidas de ritmo cardiaco tomadas por pulseras inteligentes comerciales, se aplicarán diversas técnicas de aprendizaje automático con la finalidad de generar modelos capaces de detectar, con un cierto margen de anticipación temporal, la transición del sujeto portador del dispositivo de un estado de vigilia a un estado crítico de somnolencia caracterizado por una alta probabilidad de entrada en sueño.”

A la vista de los resultados expuestos a lo largo de esta memoria, se puede constatar lo siguiente: (1) mediante la aplicación de diversos algoritmos de aprendizaje automático, se ha obtenido para cada voluntario de la prueba un modelo con tasas de acierto en la clasificación del estado del sujeto superiores en todos los casos al 90% (por encima del 97% para datos de origen Fitbit); y (2) para los modelos óptimos de los únicos dos sujetos que han podido realizar correctamente la prueba de validación, se ha podido verificar una correlación significativa entre las probabilidades de transición al sueño y los tiempos de reacción del sujeto, entendiendo estos como *proxy* del nivel de atención y estado de somnolencia de dicho sujeto. Así mismo, (3) los modelos de tipo XGBoost han hecho posible un análisis en profundidad de los cambios a corto y largo plazo de la serie temporal de ritmo cardiaco durante la transición al estado de sueño. Por todo ello, se puede considerar dicho objetivo cubierto, con resultados muy satisfactorios y prometedores de cara a futuras líneas de investigación.

Dada la estrecha relación entre el objetivo principal y los tres objetivos secundarios (análisis y caracterización de los cambios en el ritmo cardiaco durante la transición al sueño, obtención de una base de datos anonimizada de registros de variables fisiológicas, y desarrollo de un método de validación que permita comprobar la aplicabilidad de los modelos para el objetivo específico del proyecto, esto es, la detección de somnolencia crítica), éstos también han podido cubrirse satisfactoriamente. En relación con el primero de los objetivos secundarios, en futuros trabajos puede ser de interés incorporar a los modelos XGBoost variables adicionales que caractericen con mayor detalle las ventanas deslizantes,

no solo para explorar en mayor profundidad el potencial de este algoritmo para dar respuesta al objetivo principal del proyecto, sino también para analizar en mayor detalle las condiciones de transición al sueño.

Como nota final, resulta sorprendente y significativo el hecho de que se han alcanzado tasas de acierto muy elevadas (en algunos casos superiores al 97%) a partir de una única variable fisiológica de entrada (el ritmo cardiaco) y – solo en algunos casos – el nivel de confianza de la pulsera en cada una de las observaciones de frecuencia cardiaca. Esta variable es además una de las más sencillas de adquirir: la proporcionan la práctica totalidad de dispositivos comerciales disponibles en el mercado, y el coste de la tecnología de fotoplethysmografía necesaria para alcanzar niveles aceptables de fiabilidad en la estimación es a fecha de hoy muy económico. Es aquí donde radica la aportación más relevante del proyecto: a diferencia de las aproximaciones revisadas en la literatura, la solución que aquí se presenta – o, más correctamente, los modelos base a partir de los cuales se puede implementar la solución propiamente dicha – no requiere de equipamiento médico sofisticado, se apoya únicamente en el ritmo cardiaco, y emplea métodos nada invasivos para la toma de medidas, convirtiéndolo en una solución fácilmente integrable en la rutina diaria y con un ámbito de aplicación que se puede potencialmente extender más allá de la conducción.

8.3 TRABAJOS FUTUROS

A raíz de las consideraciones anteriores, las futuras líneas de trabajo que tomen las conclusiones de este proyecto como punto de partida se han de orientar en dos direcciones: por un lado, (1) la realización de un nuevo estudio de idéntica metodología para una cohorte más amplia de voluntarios, que mantenga un mayor equilibrio y proporción en la distribución de las variables demográficas de control. En este sentido, sería muy recomendable focalizar el estudio en una única fuente de datos (por ejemplo, pulseras Fitbit Charge 5) y tratar de abordar de manera más sistemática el ajuste de la arquitectura de los modelos *deep learning*, tomando como base y punto de referencia la del modelo híbrido CNN-LSTM implementado en el presente proyecto. Por otra parte, se deberá verificar si la correlación observada entre

probabilidades y tiempos de reacción se mantiene en otros sujetos, si bien esto último requerirá de una planificación cuidadosa para tratar de incentivar entre los voluntarios la participación en dicha fase final.

También se propone, de cara a la evaluación de los modelos finales, la confección de una métrica específica para el proyecto que otorgue más peso a las predicciones del modelo durante los momentos de transición al sueño, o bien algún cambio en el modo de entrenamiento que fuerce al modelo a minimizar el error sobre todo en dichos periodos de transición. Una opción podría ser la maximización del área izquierda entre la curva de probabilidades del modelo y el escalón dormido/desperto de la señal de la pulsera, o bien la introducción de múltiples repeticiones en las observaciones que tienen lugar de 20 minutos antes a 20 minutos después del momento de transición. Con todo, esto se debe tomar con cautela, ya que la señal de la pulsera indicando si el sujeto está dormido no es muy precisa en el momento en el que se produce la transición de la vigilia al sueño. Los resultados de mayor autoridad en este sentido serán los que se deriven del procedimiento de validación del modelo con el juego de tiempos de reacción.

En segundo lugar, (2) dado que los modelos obtenidos en este proyecto presentan en cualquier caso un muy buen desempeño en *test*, la segunda línea de trabajos habría de focalizarse hacia la integración práctica de estos modelos dentro de un sistema para alertar al usuario ante indicios de somnolencia crítica. Aunque se podría plantear un diseño desde cero del dispositivo que realiza la toma de mediciones, resultaría más práctico implementar este sistema dentro de dispositivos ya existentes a modo de servicio *software*. Habría de investigarse a fondo las opciones que puedan existir en este sentido (algunos de los dispositivos *wearable* más populares admiten aplicaciones de terceros).

Capítulo 9. BIBLIOGRAFÍA

- [1] “Global status report on road safety 2018,” Jun. 2018. Accessed: Oct. 20, 2022. [Online]. Available: <https://www.who.int/publications/i/item/9789241565684>
- [2] “Conducir con sueño o cansancio,” *Dirección General de Tráfico*, Nov. 30, 2022. <https://www.dgt.es/muevete-con-seguridad/evita-conductas-de-riesgo/Conducir-con-sueno-o-cansancio> (accessed May 20, 2023).
- [3] A. Moradi, S. S. H. Nazari, and K. Rahmani, “Sleepiness and the risk of road traffic accidents: A systematic review and meta-analysis of previous studies,” *Transp Res Part F Traffic Psychol Behav*, vol. 65, pp. 620–629, Aug. 2019, doi: 10.1016/j.trf.2018.09.013.
- [4] Ji Hyun Yang, Zhi-Hong Mao, L. Tijerina, T. Pilutti, J. F. Coughlin, and E. Feron, “Detection of Driver Fatigue Caused by Sleep Deprivation,” *IEEE Transactions on Systems, Man, and Cybernetics - Part A: Systems and Humans*, vol. 39, no. 4, pp. 694–705, Jul. 2009, doi: 10.1109/TSMCA.2009.2018634.
- [5] J. Allen, “Photoplethysmography and its application in clinical physiological measurement,” *Physiol Meas*, vol. 28, no. 3, pp. R1–R39, Mar. 2007, doi: 10.1088/0967-3334/28/3/R01.
- [6] W.-H. Lin, D. Wu, C. Li, H. Zhang, and Y.-T. Zhang, “Comparison of Heart Rate Variability from PPG with That from ECG,” 2014, pp. 213–215. doi: 10.1007/978-3-319-03005-0_54.
- [7] Lief Team, “How To Measure Heart Rate Variability: ECG vs. PPG,” *Lief Therapeutics*, Sep. 04, 2020. <https://blog.getlief.com/how-to-measure-heart-rate-variability-ecg-vs-ppg/> (accessed Jun. 01, 2023).

- [8] P. M. Forsman, B. J. Vila, R. A. Short, C. G. Mott, and H. P. A. Van Dongen, “Efficient driver drowsiness detection at moderate levels of drowsiness,” *Accid Anal Prev*, vol. 50, pp. 341–350, Jan. 2013, doi: 10.1016/j.aap.2012.05.005.
- [9] M. Shahverdy, M. Fathy, R. Berangi, and M. Sabokrou, “Driver behavior detection and classification using deep convolutional neural networks,” *Expert Syst Appl*, vol. 149, p. 113240, Jul. 2020, doi: 10.1016/j.eswa.2020.113240.
- [10] J. Yu, Z. Chen, Y. Zhu, Y. Chen, L. Kong, and M. Li, “Fine-Grained Abnormal Driving Behaviors Detection and Identification with Smartphones,” *IEEE Trans Mob Comput*, vol. 16, no. 8, pp. 2198–2212, Aug. 2017, doi: 10.1109/TMC.2016.2618873.
- [11] L. M. Bergasa, J. Nuevo, M. A. Sotelo, R. Barea, and M. E. Lopez, “Real-Time System for Monitoring Driver Vigilance,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 7, no. 1, pp. 63–77, Mar. 2006, doi: 10.1109/TITS.2006.869598.
- [12] L. Jin, Q. Niu, Y. Jiang, H. Xian, Y. Qin, and M. Xu, “Driver Sleepiness Detection System Based on Eye Movements Variables,” *Advances in Mechanical Engineering*, vol. 5, p. 648431, Jan. 2013, doi: 10.1155/2013/648431.
- [13] R. Oyini Mbouna, S. G. Kong, and M.-G. Chun, “Visual Analysis of Eye State and Head Pose for Driver Alertness Monitoring,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 14, no. 3, pp. 1462–1469, Sep. 2013, doi: 10.1109/TITS.2013.2262098.
- [14] B. Van Hal, S. Rhodes, B. Dunne, and R. Bossemeyer, “Low-cost EEG-based sleep detection,” in *2014 36th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, IEEE, Aug. 2014, pp. 4571–4574. doi: 10.1109/EMBC.2014.6944641.
- [15] H. Iwamoto, K. Hori, K. Fujiwara, and M. Kano, “Real-driving-implementable drowsy driving detection method using heart rate variability based on long short-term

- memory and autoencoder,” *IFAC-PapersOnLine*, vol. 54, no. 15, pp. 526–531, 2021, doi: 10.1016/j.ifacol.2021.10.310.
- [16] A. Persson, H. Jonasson, I. Fredriksson, U. Wiklund, and C. Ahlstrom, “Heart Rate Variability for Classification of Alert Versus Sleep Deprived Drivers in Real Road Driving Conditions,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 22, no. 6, pp. 3316–3325, Jun. 2021, doi: 10.1109/TITS.2020.2981941.
- [17] M. Mahachandra, Yassierli, I. Z. Sitalaksana, and K. Suryadi, “Sensitivity of heart rate variability as indicator of driver sleepiness,” in *2012 Southeast Asian Network of Ergonomics Societies Conference (SEANES)*, IEEE, Jul. 2012, pp. 1–6. doi: 10.1109/SEANES.2012.6299577.
- [18] M. Altini and L. E. Dunne, “What’s Next For Wearable Sensing?,” *IEEE Pervasive Comput*, vol. 20, no. 4, pp. 87–92, Oct. 2021, doi: 10.1109/MPRV.2021.3108377.
- [19] J. Dunn, R. Runge, and M. Snyder, “Wearables and the medical revolution,” *Per Med*, vol. 15, no. 5, pp. 429–448, Sep. 2018, doi: 10.2217/pme-2018-0044.
- [20] G. Cosoli, S. Spinsante, and L. Scalise, “Wrist-worn and chest-strap wearable devices: Systematic review on accuracy and metrological characteristics,” *Measurement*, vol. 159, p. 107789, Jul. 2020, doi: 10.1016/j.measurement.2020.107789.
- [21] D. R. Witt, R. A. Kellogg, M. P. Snyder, and J. Dunn, “Windows into human health through wearables data analytics,” *Curr Opin Biomed Eng*, vol. 9, pp. 28–46, Mar. 2019, doi: 10.1016/j.cobme.2019.01.001.
- [22] J. H. Friedman, “Greedy Function Approximation: A Gradient Boosting Machine,” *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001, [Online]. Available: <http://www.jstor.org/stable/2699986>
- [23] T. Chen *et al.*, “Xgboost: extreme gradient boosting,” *R package version 0.4-2*, vol. 1, no. 4, pp. 1–4, 2015.

- [24] Y. Yu, X. Si, C. Hu, and J. Zhang, “A Review of Recurrent Neural Networks: LSTM Cells and Network Architectures,” *Neural Comput*, vol. 31, no. 7, pp. 1235–1270, Jul. 2019, doi: 10.1162/neco_a_01199.
- [25] Mustafa Murat, “Backpropagation Through Time for Recurrent Neural Network,” *Mustafa Murat ARAT*, Feb. 07, 2019. <https://mmuratarat.github.io/2019-02-07/bptt-of-rnn> (accessed Jun. 02, 2023).
- [26] J. Chung, C. Gulcehre, K. Cho, and Y. Bengio, “Empirical evaluation of gated recurrent neural networks on sequence modeling,” *arXiv preprint arXiv:1412.3555*, 2014.
- [27] I. Goodfellow, Y. Bengio, and A. Courville, “Convolutional networks,” in *Deep learning*, MIT Press Cambridge, MA, USA, 2016, pp. 330–372.
- [28] Chen, Zhong, and Tan, “Multiple-Oriented and Small Object Detection with Convolutional Neural Networks for Aerial Image,” *Remote Sens (Basel)*, vol. 11, no. 18, p. 2176, Sep. 2019, doi: 10.3390/rs11182176.
- [29] J. Gu *et al.*, “Recent advances in convolutional neural networks,” *Pattern Recognit*, vol. 77, pp. 354–377, May 2018, doi: 10.1016/j.patcog.2017.10.013.
- [30] J. Snoek, H. Larochelle, and R. P. Adams, “Practical bayesian optimization of machine learning algorithms,” *Adv Neural Inf Process Syst*, vol. 25, 2012.
- [31] K. Nyuytiymbiy, “Parameters and Hyperparameters in Machine Learning and Deep Learning,” *Towards Data Science*, Dec. 30, 2020.
- [32] Rohit Kundu, “Precision vs. Recall: Differences, Use Cases & Evaluation,” *V7 Labs*, Sep. 19, 2022. <https://www.v7labs.com/blog/precision-vs-recall-guide> (accessed Jun. 04, 2023).
- [33] D. Berrar, “Cross-Validation,” in *Encyclopedia of Bioinformatics and Computational Biology*, Elsevier, 2019, pp. 542–545. doi: 10.1016/B978-0-12-809633-8.20349-X.

-
- [34] “Desarrollo sostenible: salud,” *Organización de las Naciones Unidas*.
<https://www.un.org/sustainabledevelopment/es/health/> (accessed May 20, 2023).
- [35] “Desarrollo sostenible: ciudades,” *Organización de las Naciones Unidas*.
<https://www.un.org/sustainabledevelopment/es/health/> (accessed May 20, 2023).

ANEXO I: ALINEACIÓN DEL PROYECTO CON LOS ODS

La finalidad de este proyecto se enmarca de forma natural en el ODS 3: “Garantizar una vida sana y promover el bienestar para todos en todas las edades”. Destaca en particular su relevancia de cara a la meta 3.6 de dicho objetivo social, esto es, “Para 2020, reducir a la mitad el número de muertes y lesiones causadas por accidentes de tráfico en el mundo” [34]. Las razones de su relevancia son evidentes considerando lo expuesto en los capítulos introductorios: la obtención de un modelo capaz de predecir con antelación suficiente la entrada del sujeto (por ejemplo, el conductor de un vehículo) en un estado de somnolencia crítico o de sueño inminente, empleando únicamente variables biométricas adquiribles mediante sensores de dispositivos *wearable* comerciales, permite el desarrollo de un sistema capaz de alertar al sujeto a tiempo real y con el margen necesario para evitar un accidente, además de poder integrarse de una manera económica y cómoda en la vida diaria de los usuarios. Considerando por tanto la alineación del objetivo principal del proyecto con el ODS 3, entendemos que éste ejerce un rol primario y fundamental en el trabajo.

Junto a este objetivo principal, ejerce un rol secundario pero igualmente importante el ODS 11: “Lograr que las ciudades y asentamientos humanos sean más inclusivos, seguros, resilientes y sostenibles”. Dentro de este objetivo, el proyecto puede contribuir a la consecución de la meta 11.2, “De aquí a 2030, proporcionar acceso a sistemas de transporte seguros, asequibles, accesibles y sostenibles para todos y mejorar la seguridad vial, en particular mediante la ampliación del transporte público, prestando especial atención a las necesidades de las personas en situación de vulnerabilidad, las mujeres, los niños, las personas con discapacidad y las personas de edad” [35]. Las estadísticas que se han compartido en la introducción exponen por sí solas el valor de cualquier esfuerzo orientado a la reducción de accidentes vinculados con la fatiga y somnolencia; por ello y por las razones que se han ido reiterando a lo largo del documento consideramos que el trabajo de investigación que se desarrollará en el marco de este proyecto supondrá una contribución relevante hacia la mejora de la seguridad en las carreteras.

ANEXO II: CÓDIGO FUENTE

A través del enlace que se proporciona a continuación, se puede consultar un ejemplo completo de procesamiento de los datos y modelización en Python para el sujeto ID1 (el código es prácticamente idéntico para los demás voluntarios): <https://github.com/AlfonsoSerranoS/sleep-onset-detection>.

Por otra parte, el código fuente de la aplicación que contiene el juego de validación se puede consultar a través del enlace <https://github.com/AlfonsoSerranoS/game>.