




UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería de la Salud



INGENIERÍA
DE LA SALUD

**TFG del Grado en Ingeniería de la
Salud**

**Aplicación web para la
predicción de trastornos del
sueño con apoyo del
dispositivo O2Ring.
Documentación Técnica**

Presentado por Marina Martín Marijuán
en Universidad de Burgos

8 de junio de 2025

Tutores: Telmo Miguel Medina – nombre tutor 2

Índice general

Índice general	i
Índice de figuras	iii
Índice de tablas	v
Apéndice A Plan de Proyecto Software	1
A.1. Introducción	1
A.2. Planificación temporal	1
A.3. Planificación económica	6
A.4. Viabilidad legal	9
Apéndice B Documentación de usuario	13
B.1. Requisitos software y hardware para ejecutar el proyecto. . .	13
B.2. Instalación / Puesta en marcha	14
B.3. Manuales y/o Demostraciones prácticas	15
Apéndice C Manual del desarrollador	21
C.1. Estructura de directorios	21
C.2. Compilación, instalación y ejecución del proyecto	22
C.3. Pruebas del sistema	26
C.4. Instrucciones para la modificación o mejora del proyecto. . .	26
Apéndice D Descripción de adquisición y tratamiento de datos	29
D.1. Descripción formal de los datos	29
D.2. Tratamiento y preprocesamiento de los datos	32
D.3. Descripción clínica de los datos	33

Apéndice E Manual de especificación de diseño	37
E.1. Diseño arquitectónico	37
E.2. Diagrama de flujo del funcionamiento	38
Apéndice F Especificación de Requisitos	41
F.1. Diagrama de casos de uso	41
F.2. Explicación casos de uso	42
F.3. Prototipos de interfaz o interacción con el proyecto	47
Apéndice G Estudio experimental	51
G.1. Cuaderno de trabajo	51
G.2. Detalle de resultados	58
G.3. Validación externa con datos reales del O2Ring	59
G.4. Conclusión del estudio experimental	64
Apéndice H Anexo de sostenibilización curricular	65
H.1. Introducción	65
Bibliografía	69

Índice de figuras

A.1. Diagrama de Gantt del proyecto.	6
B.1. QR para acceder a la aplicación.	14
B.2. Vista inicial de la aplicación en Streamlit Cloud.	15
B.3. Formulario con datos clínicos y de estilo de vida.	16
B.4. Resultado de la predicción con las probabilidades asociadas. . . .	17
B.5. Interpretación SHAP individual de un caso clínico simulado. . . .	17
B.6. Importancia global de las variables según el modelo (gráfico SHAP). .	18
B.7. Vista previa del informe PDF generado.	19
C.1. Captura de pantalla del entorno de Anaconda Navigator, señalando PowerShell y la terminal (cmd) como opciones de ejecución. .	24
C.2. Acceso al directorio del proyecto desde Anaconda Prompt.	24
C.3. Ejecución del script principal y generación de la URL de acceso local.	24
D.1. Estructura del dataset original: nombre, tipo de dato y recuento de valores no nulos por columna.	31
D.2. Valores que pueden tomar las variables categóricas.	32
D.3. Estadísticas descriptivas de las variables numéricas.	32
D.4. Distribución de las categorías de IMC en función del tipo de trastorno del sueño.	34
D.5. Distribución de la frecuencia cardíaca por tipo de trastorno del sueño.	35
D.6. Distribución del nivel de estrés según el diagnóstico de trastorno del sueño.	36
E.1. Diseño arquitectónico funcional de la aplicación, estructurado en capas lógicas de entrada, procesamiento y salida.	38

E.2. Diagrama de flujo del funcionamiento interno de la aplicación web.	39
F.1. Diagrama de casos de uso de la aplicación web.	42
F.2. Formulario de entrada de datos clínicos y de estilo de vida. . . .	48
F.3. Resultado de la predicción en pantalla, con distribución porcentual por clase.	48
F.4. Gráfico SHAP que representa la importancia de cada variable en la predicción global.	49
F.5. Explicación individualizada mediante SHAP para un caso concreto.	49
F.6. Informe clínico en PDF descargado de la aplicación.	50
G.1. Test de Pittsburgh realizado mediante Google Forms.	52
G.2. Dispositivo O2Ring (Viatom) utilizado en la fase exploratoria inicial del proyecto. Fuente: [iF Design Award, 2021].	53
G.3. Primera página del informe del dispositivo O2Ring para el Paciente A.	63
H.1. Objetivos del Desarrollo Sostenible (ODS).	66

Índice de tablas

A.1. Estimación de costes personales del proyecto.	7
A.2. Amortización del ordenador	8
A.3. Amortización del dispositivo O2Ring.	8
A.4. Software utilizado.	8
A.5. Resumen de costes materiales.	9
A.6. Coste total del proyecto.	9
A.7. Licencias de software utilizadas.	10
F.1. CU-1 Introducir datos clínicos.	43
F.2. CU-2 Ejecutar predicción.	44
F.3. CU-3 Interpretar resultado con SHAP.	45
F.4. CU-4 Generar informe PDF.	46
F.5. Relación entre requisitos funcionales y casos de uso.	47
G.1. Métricas del modelo Random Forest calibrado sobre el conjunto de test.	58
G.2. Comparativa entre versiones del modelo para los tres perfiles clínicos reales.	59
G.3. Resumen de resultados en la validación externa con datos reales.	60
G.4. Resumen de parámetros extraídos del informe del Paciente A. .	62

Apéndice A

Plan de Proyecto Software

A.1. Introducción

Antes de abordar el desarrollo técnico del sistema, se ha considerado necesario realizar una planificación inicial que contemple tres dimensiones fundamentales: la organización temporal del trabajo, una estimación económica de los recursos invertidos y un análisis de la viabilidad legal del proyecto. Este apartado tiene como objetivo reflejar el esfuerzo realizado desde una perspectiva realista, asegurando la coherencia entre las fases de trabajo, la sostenibilidad de su ejecución y el cumplimiento del marco normativo vigente. A continuación, se detalla la planificación temporal llevada a cabo durante el TFG, seguida de una estimación económica del proyecto y un análisis de su viabilidad legal.

A.2. Planificación temporal

Antes de iniciar cualquier proyecto de ingeniería, y especialmente en el contexto de un Trabajo Fin de Grado, es fundamental contar con una planificación estructurada que permita organizar el tiempo, priorizar tareas y realizar un seguimiento ordenado del avance. Para ello, se ha utilizado la plataforma GitHub, ampliamente reconocida en entornos académicos y profesionales, no solo como sistema de control de versiones, sino también como herramienta de gestión de proyectos.

GitHub permite trabajar de forma colaborativa, registrar cambios, documentar decisiones técnicas y organizar tareas en forma de issues, que a su vez pueden agruparse en milestones (hitos). Gracias a este enfoque, ha sido

posible estructurar el desarrollo del TFG en bloques coherentes de trabajo, visualizar el progreso y mantener una trazabilidad completa de cada fase.

A lo largo del desarrollo del proyecto se definieron los siguientes milestones, cada uno de ellos compuesto por una serie de tareas específicas:

- **M1. Revisión bibliográfica inicial.** En esta primera fase se realizó una búsqueda exhaustiva de literatura científica y técnica para contextualizar el proyecto. Se identificaron fuentes relevantes sobre trastornos del sueño, variables clínicas y métodos de predicción. Esto permitió asentar las bases teóricas del TFG y justificar la necesidad del sistema desarrollado. Las principales tareas asociadas a este hito fueron:
 - Búsqueda de información.
 - Estado del Arte: revisión bibliográfica.
- **M2. Investigación y recolección de datos.** Se exploraron diferentes fuentes de datos, incluyendo un dataset estructurado de Kaggle y datos reales obtenidos mediante el dispositivo O2Ring. Se analizaron las variables clínicas más relevantes, se revisaron cuestionarios estandarizados como el test de Pittsburgh y se definieron los criterios de calidad de los registros empleados en la validación. Esta fase fue esencial para garantizar que el modelo predictivo estuviera respaldado por datos representativos y estructurados. Las tareas desarrolladas fueron:
 - Clasificación de enfermedades relacionadas con el sueño.
 - Identificación de métricas clave para el análisis.
 - Exploración y limpieza de datos O2Ring.
 - Revisión y análisis del test de Pittsburgh.
 - Recolección de datos O2Ring para la validación.
- **M3. Extracción de características y análisis exploratorio.** En este hito se aplicaron técnicas de codificación de variables categóricas, detección de valores atípicos y análisis de correlación entre variables. El objetivo fue transformar el conjunto de datos en una estructura adecuada para el entrenamiento de modelos de machine learning, eliminando redundancias y mejorando la calidad estadística de las variables seleccionadas. Las tareas incluyeron:

- Extracción de características y codificación de variables categóricas.
 - Preprocesamiento y estructuración del dataset.
 - Identificación y análisis de outliers.
 - Análisis de correlaciones.
- **M4. Desarrollo y entrenamiento del modelo.** Durante esta fase se evaluaron diferentes algoritmos de clasificación multiclase, como Regresión Logística, Random Forest, SVM o Redes Neuronales, con el objetivo de identificar el más adecuado para predecir trastornos del sueño. Se ajustaron hiperparámetros mediante técnicas como Grid-SearchCV, se entrenaron los modelos y se aplicó validación cruzada para comprobar su estabilidad. Esta etapa permitió seleccionar un modelo final robusto, calibrado y balanceado, garantizando una base sólida para su futura integración en la aplicación web. Las tareas principales fueron:
- Prueba de primeros modelos y ajuste de hiperparámetros.
 - Entrenamiento y validación del modelo.
 - Validación cruzada.
- **M5. Implementación de la aplicación web.** Se diseñó una interfaz interactiva con Streamlit para facilitar el uso del modelo por parte de usuarios sin conocimientos técnicos. La app permite introducir datos, obtener predicciones, visualizar probabilidades por clase y generar informes PDF automáticos. También se incorporaron explicaciones mediante SHAP y pruebas funcionales para garantizar la fiabilidad del sistema. Las actividades realizadas en esta fase fueron:
- Diseño del formulario de entrada de datos.
 - Integración del modelo predictivo en Streamlit.
 - Visualización de resultados e interpretabilidad (SHAP).
 - Generación automática del informe PDF.
 - Inserción de código QR en la interfaz.
 - Pruebas de interfaz y control de errores.
- **M6. Redacción de la memoria.** A medida que avanzaban las fases técnicas, se fue construyendo la memoria del TFG. Se redactaron

todos los capítulos principales del documento, cuidando especialmente la claridad en la exposición de métodos, la justificación técnica y la calidad formal. También se revisó el estilo y se adaptaron las figuras al formato final. Las tareas asociadas fueron:

- Primeras redacciones: introducción y objetivos.
 - Redacción del apartado conceptos teóricos.
 - Redacción del apartado de metodología.
 - Redacción del capítulo de resultados.
 - Redacción del capítulo de conclusiones.
 - Redacción de líneas de trabajo futuras.
 - Revisión ortográfica, técnica y de estilo de todo el documento.
 - Adaptación al formato final y preparación para la exportación a PDF.
- **M7. Redacción de los anexos.** Los anexos complementaron la memoria principal con documentación técnica estructurada del sistema y del proceso seguido. Su elaboración garantizó la trazabilidad y replicabilidad del proyecto, así como su alineación con criterios éticos y sostenibles. Las tareas realizadas fueron:
- Anexo A – Planificación: estructura temporal, económica y legal del proyecto.
 - Anexo B – Documentación de usuario: requisitos, puesta en marcha y demostración práctica.
 - Anexo C – Manual del desarrollador / programador: estructura del proyecto, ejecución y posibles mejoras.
 - Anexo D – Adquisición y tratamiento de datos: descripción formal y clínica del dataset.
 - Anexo E – Especificación de diseño: estructura arquitectónica y flujos de funcionamiento.
 - Anexo F – Requisitos: diagrama y explicación de casos de uso, prototipos de interfaz.
 - Anexo G – Estudio experimental: cuaderno de trabajo, resultados y validación externa.
 - Anexo H – Sostenibilización curricular: alineación con los ODS.
 - Revisión final de formato, figuras y consistencia técnica entre anexos y memoria principal.

Etiquetas utilizadas (labels)

Con el fin de clasificar y priorizar las tareas de manera eficiente, se utilizaron etiquetas dentro del repositorio de GitHub. Estas etiquetas facilitaron la organización del trabajo y permitieron el filtrado por tipo de tarea. Entre ellas se encuentran:

- **documentation**: creación o mejora de documentación.
- **writing**: redacción de contenidos de memoria.
- **analysis**: análisis exploratorio, correlaciones, outliers.
- **data**: limpieza, transformación y estructuración de datos.
- **modeling**: tareas de desarrollo y validación del modelo.
- **urgent**: tareas prioritarias.
- **bug**: detección de errores durante la implementación.
- **good first issue**: tareas iniciales adecuadas para comenzar el trabajo.
- **robustness**: mejoras en el manejo de errores y entradas incompletas.
- **testing**: pruebas del sistema y procedimientos de validación/verificación.
- **frontend**: tareas relacionadas con la interfaz de Streamlit e interacciones del usuario.
- **backend**: tareas relacionadas con el modelo, procesamiento de datos o la funcionalidad interna.
- **usability**: mejoras en la experiencia del usuario; diseño, navegación y claridad.
- **enhancement**: tareas para nuevas funciones o solicitudes.
- **fpdf**: tareas que involucran la generación de PDF (bibliotecas **fpdf** o **fpdf2**).
- **report**: tareas relacionadas con la creación o formateo de informes para su descarga desde la aplicación.
- **app-development**: tareas relacionadas con la aplicación en Streamlit.

- **explainability**: tareas relacionadas con la interpretabilidad del modelo y visualización de características.
- **visualization**: representaciones visuales (gráficos, diagramas SHAP o distribución de variables).

Diagrama de Gantt

Con el fin de representar visualmente la planificación y ejecución del proyecto, se ha elaborado un diagrama de Gantt, una herramienta común en la gestión de proyectos que permite visualizar las tareas distribuidas en el tiempo, su duración, inicio y fin, así como el posible solapamiento entre fases.

Cada barra horizontal del diagrama corresponde a un bloque de trabajo (*milestone*), mostrando su relación temporal con respecto al conjunto del proyecto. Gracias a esta representación gráfica, es posible detectar los periodos de mayor carga, los cuellos de botella y las dependencias entre tareas.

La Figura A.1 muestra el diagrama de Gantt generado a partir de los datos recogidos en GitHub. <https://github.com/marinamartinm/TFG-Marina-Martin>




Figura A.1: Diagrama de Gantt del proyecto.

A.3. Planificación económica

A continuación, se presenta una estimación detallada de los costes asociados al desarrollo del Trabajo Fin de Grado (TFG), diferenciando entre costes personales, materiales y de infraestructura. Aunque el proyecto no ha requerido financiación directa, esta evaluación permite reflejar el valor del trabajo realizado y explorar su posible viabilidad económica en contextos reales.

Costes personales

El proyecto ha sido desarrollado por una única estudiante desde octubre hasta junio, con una duración aproximada de **8 meses**. La dedicación ha abarcado todas las fases: revisión bibliográfica, diseño metodológico, análisis de datos, desarrollo del sistema predictivo, validación, implementación web, documentación y pruebas.

Aunque el número de horas asignado oficialmente al TFG es de 360, se estima una dedicación real aproximada de **520 horas**.

Para estimar el coste de este trabajo se ha tomado como referencia que un salario bruto mensual de un/a ingeniero/a biomédico/a recién graduado/a en España oscila entre los **2.250-2.500 €**, según portales de empleo especializados como InfoJobs y Glassdoor [InfoJobs, 2025, Glassdoor, 2025]. Además, se han tenido en cuenta los costes sociales que asumiría la empresa al contratar a dicho profesional, estimados en un 31 % del sueldo bruto, correspondientes a la cotización a la Seguridad Social en el Régimen General.

Cálculo del coste por hora:

$$\text{Coste por hora} = \frac{\text{Coste mensual total}}{\text{Horas por mes}} = \frac{2250 \text{ €} + 698 \text{ €}}{160 \text{ h}} = \frac{2948 \text{ €}}{160 \text{ h}} = 18,43 \text{ €/h} \quad (\text{A.1})$$

Cálculo del coste total personal:

$$\text{Coste total personal} = \text{Coste por hora} \times \text{Horas estimadas} = 18,43 \text{ €/h} \times 520 \text{ h} = 9583 \text{ €} \quad (\text{A.2})$$

Concepto	Valor estimado
Sueldo mensual bruto	2.250 €
Seguridad Social (31 %)	698 €
Coste mensual total	2.948 €
Coste por hora (basado en 160 h/mes)	18,43 €/h
Total de horas estimadas	520 h
Coste total personal	9.583 €

Tabla A.1: Estimación de costes personales del proyecto.

Costes materiales y de infraestructura

Aunque el desarrollo se ha realizado íntegramente con software libre y en un equipo personal, se consideran los siguientes costes asociados al uso de hardware y recursos complementarios.

Amortización del ordenador portátil

$$\text{Amortización} = \frac{\text{Precio}}{\text{Vida Útil(Años)}} \times \frac{\text{Meses Usado}}{12} \quad (\text{A.3})$$

Concepto	Valor estimado
Precio del equipo (Lenovo ThinkBook 15-IIL)	839 €
Vida útil estimada	5 años
Meses utilizados	8 meses
Amortización calculada	112 €

Tabla A.2: Amortización del ordenador

Amortización del dispositivo O2Ring

Concepto	Valor estimado
Valor aproximado del dispositivo	150 €
Vida útil estimada	4 años
Meses utilizados	4 meses
Amortización calculada	12,50 €

Tabla A.3: Amortización del dispositivo O2Ring.

Costes de software

Recurso	Coste estimado
Python, Jupyter, Streamlit, GitHub, etc.	0 €

Tabla A.4: Software utilizado.

Resumen de costes materiales

Categoría	Importe
Amortización portátil	112,00 €
Amortización dispositivo O2Ring	12,50 €
Software y plataformas	0 €
Total costes materiales	124,50 €

Tabla A.5: Resumen de costes materiales.

Coste total del proyecto

Categoría	Importe (€)
Costes personales	9.583,00
Costes materiales	124,50
Total estimado	9.707,50

Tabla A.6: Coste total del proyecto.

A.4. Viabilidad legal

La viabilidad legal de este Trabajo Fin de Grado ha sido tenida en cuenta durante todas las fases del desarrollo. Aunque el proyecto no ha requerido acceso a historiales clínicos ni ha sido implementado en un entorno sanitario, sí se han utilizado datos personales reales de forma voluntaria para validar el comportamiento del sistema. Dado que su finalidad está orientada al cribado de trastornos del sueño, se ha prestado especial atención al cumplimiento del marco normativo vigente en materia de protección de datos personales, software, propiedad intelectual y usos futuros.

Protección de datos personales

Durante la fase de validación se utilizaron datos reales de personas voluntarias, introducidos manualmente con el fin de evaluar el comportamiento del sistema frente a perfiles clínicos reales. Aunque no se han recogido historiales médicos ni diagnósticos clínicos formales, algunos de los datos utilizados (como edad, sexo, nivel de estrés, IMC, frecuencia cardíaca o niveles de oxígeno registrados mediante el dispositivo O2Ring) pueden considerarse datos personales protegidos por el Reglamento General de Protección de Datos (RGPD) [rgp, 2016] y la Ley Orgánica 3/2018 (LOPDGDD) [lop, 2018].

En cumplimiento de los principios de minimización, privacidad por diseño y protección de la identidad, se han tomado las siguientes medidas:

- Los datos se han introducido únicamente para validaciones manuales y nunca han sido compartidos ni procesados en servidores externos.
- El sistema no genera historiales ni conserva registros de las sesiones de predicción.
- La única retención opcional es la descarga local **opcional** de un informe PDF por parte del propio usuario, sin persistencia digital.
- En este documento, todos los datos presentados han sido completamente anonimizados, eliminando cualquier vínculo identificable con las personas participantes.

Este enfoque garantiza que la privacidad de los participantes ha sido preservada en todo momento. Para una posible evolución futura hacia un uso clínico o multiusuario, se recomienda implementar mecanismos de consentimiento informado, encriptación de datos y control de accesos conforme a la normativa vigente.

Licencias de software utilizadas

El proyecto ha sido desarrollado íntegramente con herramientas y bibliotecas de código abierto. A continuación se muestra un resumen de sus licencias:

Herramienta / Librería	Tipo de licencia
Python	PSF License
Streamlit	Apache License 2.0
Scikit-learn	BSD License
SHAP, Pandas, NumPy	MIT / BSD License
fpdf2, qrcode	MIT License

Tabla A.7: Licencias de software utilizadas.

Estas licencias permiten libre uso, distribución y modificación, incluso con fines comerciales, siempre que se reconozca la autoría original. Por tanto, el sistema puede ser publicado, compartido o ampliado sin restricciones legales derivadas de las herramientas empleadas.

Para más información sobre las licencias citadas, véanse sus textos oficiales en la *Open Source Initiative*: <https://opensource.org/licenses>.

Propiedad intelectual y licencia del proyecto

El código fuente, documentación y elementos originales generados durante este TFG están protegidos por la legislación vigente en materia de propiedad intelectual:

- Directiva (UE) 2009/24/CE sobre la protección jurídica de programas de ordenador [dir, 2009].
- Real Decreto Legislativo 1/1996 por el que se aprueba el texto refundido de la Ley de Propiedad Intelectual [lpi, 1996].

El software puede ser licenciado bajo una modalidad de código abierto, como la **MIT License**, lo que permitiría su difusión libre, respetando los derechos morales de autoría. Alternativamente, si se opta por una explotación comercial, podría reservarse la titularidad mediante una licencia más restrictiva.

Consideraciones futuras: software médico

Si la aplicación evolucionase hacia una herramienta con implicaciones diagnósticas en el ámbito clínico, debería evaluarse su clasificación como producto sanitario software, conforme a:

- Reglamento (UE) 2017/745 sobre productos sanitarios [reg, 2017].
- Real Decreto 192/2023, por el que se regulan los productos sanitarios en España [rd1, 2023].
- Requisitos del **Marcado CE**, supervisados por la Agencia Española de Medicamentos y Productos Sanitarios (AEMPS) ¹

Apéndice B

Documentación de usuario

B.1. Requisitos software y hardware para ejecutar el proyecto.

El sistema ha sido diseñado para que su uso sea accesible a cualquier profesional clínico sin necesidad de conocimientos técnicos. La aplicación se encuentra desplegada en la nube, por lo que para su utilización no requiere ninguna instalación de software ni configuración específica.

Requisitos software

Como requisitos software únicamente serán necesarios:

- Navegador web actualizado, como Google Chrome, Microsoft Edge, Mozilla Firefox o Safari.
- Visualizador de archivos PDF: en los navegadores anteriores viene incluido pero por si fuera necesario, Adobe Acrobat u otro similar.

Requisitos hardware

En cuanto a los requisitos hardware mínimos están incluidos:

- Ordenador, tablet o smartphone con acceso a internet de forma estable.
- Aunque la aplicación es compatible con cualquier resolución de pantalla, es recomendable acceder con un ordenador o tablet para una mejor experiencia visual.

No se requiere instalación de Python ni de librerías adicionales. El acceso se realiza directamente desde el navegador, a través del siguiente enlace:

[Acceso a la aplicación web alojada en Streamlit.](#)

También se puede acceder mediante escaneo del código QR, mostrado en la Figura B.1, disponible también en la propia aplicación.



Figura B.1: QR para acceder a la aplicación.

B.2. Instalación / Puesta en marcha

El sistema está alojado en la plataforma Streamlit Cloud, lo que permite su ejecución directa desde cualquier navegador web. Esto facilita su uso por parte de profesionales clínicos sin experiencia técnica, tanto en consulta como en entornos remotos.

Pasos para la puesta en marcha:

1. Acceder al [enlace web](#) proporcionado o escanear el código QR disponible en la Figura B.1.
2. Esperar unos segundos mientras se carga la interfaz de la aplicación en el navegador ¹.

¹La aplicación está desplegada en *Streamlit Cloud*, una plataforma gratuita que puede entrar en modo suspensión tras 24 horas de inactividad. En ese caso, puede aparecer como

3. Comenzar a introducir los datos clínicos del paciente en el formulario mostrado y pulsar el botón de 'Realizar predicción'.

La ejecución es completamente automática. No es necesario instalar ningún programa ni realizar configuraciones adicionales.

En caso de que se prefiera realizar la instalación local por motivos de privacidad o personalización, los pasos técnicos están detallados en el Anexo C - Manual del desarrollador.

B.3. Manuales y/o Demostraciones prácticas

Este apartado describe el flujo habitual de uso por parte de un profesional sanitario y presenta capturas de pantalla reales que ilustran el funcionamiento del sistema.

Acceso a la aplicación

El usuario accede al sistema a través de la URL oficial o mediante escaneo de un código QR. Esto carga automáticamente la interfaz de inicio en el navegador.

Acceso desde el móvil

Escanea el QR para acceder

O copia y pega este enlace: t3a2.clic.sgu

Predicción de Trastornos del Sueño

Bienvenido a esta herramienta interactiva desarrollada como parte del Trabajo de Fin de Grado en Ingeniería de la Salud.

Esta aplicación permite predecir la probabilidad de padecer **insomnio**, **apnea del sueño** o no presentar trastornos, a partir de información clínica, personal y de hábitos de vida.

Introduce tus datos a continuación y pulsa el botón para obtener el resultado.

Análisis de Apnea del Sueño

Modelo cargado correctamente

Datos del paciente

Género	☒ Hembra ☐ Masculino	¿Cuántos días a la semana haces deporte?	0
Edad	30	¿Cómo calificarías tu nivel de estrés?	Muy bajo
Ocupación	Doctor	Presión arterial (ej: 120/80)	120/80

Figura B.2: Vista inicial de la aplicación en Streamlit Cloud.

“dormida” durante unos segundos al acceder, y será necesario pulsar el botón “Wake-up” para reactivarla. Esta es una limitación propia del servicio y no afecta al funcionamiento general de la aplicación una vez activada.

Introducción de datos

El usuario completa el formulario con su edad, género, ocupación, calidad del sueño, frecuencia cardíaca, presión arterial, pasos diarios, etc. El sistema valida automáticamente que los campos obligatorios estén correctamente rellenos y que los datos introducidos tengan un formato válido (por ejemplo, la presión arterial debe seguir el formato '120/80'). Cualquier error impide avanzar a la siguiente fase, asegurando la consistencia de entrada.

 **Datos del paciente**

Género ☒ Female ☐ Male	Días de ejercicio a la semana 0
Edad 30	Nivel de estrés Muy bajo
Ocupación Doctor	Presión arterial (ej. 120/80) 120/80
Peso (kg) 70,00	Frecuencia cardíaca (bpm) 72
Altura (cm) 170,00	Pasos diarios 8000
Duración del sueño (h) 0.00 — 7.00 — 12.00	
Calidad del sueño (1-10) 1 — 7 — 10	
Realizar predicción	

Figura B.3: Formulario con datos clínicos y de estilo de vida.

Generación de predicción

Tras completar el formulario, se realiza una predicción automática del posible trastorno del sueño. El sistema utiliza un modelo Random Forest calibrado y previamente entrenado, que clasifica al paciente en una de las siguientes categorías:

- Insomnio
- Apnea del sueño
- Ausencia de trastorno (None)




Figura B.4: Resultado de la predicción con las probabilidades asociadas.

Explicación de la predicción

Se muestra un gráfico de interpretabilidad basado en SHAP (SHapley Additive exPlanations) que indica la influencia relativa de cada variable sobre la predicción realizada. Esta visualización ayuda al profesional a comprender qué factores han motivado la clasificación del modelo. La aplicación permite interpretar los resultados mediante gráficos SHAP (SHapley Additive exPlanations), una técnica que descompone la predicción del modelo en contribuciones individuales de cada variable.

En primer lugar, se proporciona una explicación individualizada para el caso introducido, mostrando qué variables han influido de forma positiva o negativa en el diagnóstico sugerido. Este análisis ayuda al profesional a entender el razonamiento detrás de la predicción concreta para un paciente específico.




Figura B.5: Interpretación SHAP individual de un caso clínico simulado.

Además, el sistema incluye una visualización global que muestra, en promedio, qué variables tienen mayor peso en las decisiones del modelo para todos los casos. Esta vista general es útil para identificar los factores clínicos más relevantes en la predicción automática.




Figura B.6: Importancia global de las variables según el modelo (gráfico SHAP).

Generación del informe

El sistema permite descargar un informe clínico personalizado en formato PDF que incluye:

- Datos introducidos
- Clase predicha
- Probabilidades por clase
- Explicación visual

El informe puede guardarse localmente o imprimirse para su incorporación al historial del paciente, facilitando su uso como documento complementario en procesos de cribado o seguimiento clínico.

INFORME CLÍNICO DE SUEÑO

Fecha: 04/06/2025 - 16:06

DATOS PERSONALES	
Edad	30 años
Sexo	Femenino
Ocupación	Doctor
IMC (categoría)	Normal
Frecuencia cardíaca	72 bpm
Presión arterial	120 / 80 mmHg

HÁBITOS DE VIDA	
Duración del sueño	7.0 h
Calidad del sueño	7 / 10
Nivel de estrés (escala 1-9)	1
Pasos diarios	8000

RESULTADOS DE LA PREDICCIÓN

Trastorno detectado: None

Insomnia: 19.5%

None: 43.6%

Sleep Apnea: 36.9%

Nota: Este informe ha sido generado automáticamente como parte de una herramienta de ayuda para la predicción de trastornos del sueño. No sustituye el diagnóstico clínico profesional.

Figura B.7: Vista previa del informe PDF generado.

Durante el desarrollo se ha verificado que la aplicación funciona de forma fluida y estable desde el punto de vista técnico, permitiendo una interacción clara con el usuario, la visualización de resultados interpretables y la generación automática de informes PDF. Aunque existen aspectos mejorables en cuanto al comportamiento predictivo del modelo, esta herramienta representa una base funcional sólida sobre la que podrían construirse futuras versiones con validación clínica ampliada.

Apéndice C

Manual del desarrollador

C.1. Estructura de directorios

Todos los ficheros que forman parte del desarrollo de este Trabajo de Fin de Grado se encuentran alojados en el repositorio de GitHub disponible en el siguiente enlace:

<https://github.com/marinamartinm/TFG-Marina-Martin>

El contenido completo y actualizado del proyecto puede consultarse directamente en el repositorio online.

En este apartado se describe la estructura general del proyecto y el contenido de sus archivos principales, con el objetivo de facilitar su comprensión, mantenimiento y posible reutilización por parte de futuros desarrolladores o evaluadores.

A continuación se detalla el contenido del directorio principal del repositorio, que organiza todos los recursos del sistema de forma estructurada:

- **.devcontainer/**: configuración del entorno de desarrollo para su ejecución en contenedores (Visual Studio Code).
- **app/**: contiene el script principal de la aplicación en Streamlit y los archivos necesarios para su ejecución local.
- **articulos/**: carpeta que recopila los artículos científicos revisados durante el desarrollo del estado del arte y que han sido considerados más relevantes, ordenados por carpetas según su utilidad en el trabajo desarrollado.

- `datos/`: conjunto de archivos relacionados con la fase experimental, como registros o resultados intermedios. El archivo principal es `'Sleep_health_and_lifestyle_dataset.csv'`.
- `diagramas/`: contiene los diagramas de clases, casos de uso y estructuras incluidas en la documentación.
- `imagenes/`: carpeta con todos los recursos gráficos utilizados en la memoria y anexos.
- `memoria/`: carpeta que contiene la versión final de la memoria y los anexos en formato PDF.
- `notebooks/`: cuadernos Jupyter utilizados durante la fase de análisis exploratorio, entrenamiento del modelo, evaluación y visualización de resultados.
- `OverLeaf-LaTeX/`: carpeta que contiene toda la documentación de la memoria y los anexos elaborada en LaTeX, compatible con Overleaf (proyecto completo).
- `README.md`: archivo de presentación del proyecto con instrucciones de ejecución y estructura del repositorio.
- `requirements.txt`: listado de librerías necesarias para la ejecución de la aplicación localmente.
- `runtime.txt`: archivo auxiliar usado para indicar la versión de Python en entornos de despliegue.

C.2. Compilación, instalación y ejecución del proyecto

Instalación del entorno de trabajo

Para facilitar la gestión de dependencias y entornos virtuales, se recomienda instalar la distribución de Python mediante **Anaconda** [Anaconda, 2025], aunque también puede utilizarse una instalación directa desde `python.org`. [Python Software Foundation, 2025]

A continuación, se muestra el código necesario para la instalación de la librerías requeridas, se realizará desde la terminal de Anaconda:

- `streamlit` → `pip install streamlit`
- `scikit-learn` → `pip install scikitlearn`
- `shap` → `pip install shap`

- `pandas` → `pip install pandas`
- `numpy` → `pip install numpy`
- `matplotlib` → `pip install matplotlib`
- `seaborn` → `pip install seaborn`
- `fpdf2` → `pip install fpdf2`
- `qrcode` → `pip install qrcode`

Una vez finalizada la instalación de las librerías necesarias, el sistema puede ejecutarse de forma local en cualquier equipo que cumpla con los requisitos indicados previamente. Para ello, es imprescindible disponer de los siguientes archivos en la misma carpeta del proyecto:

- `appPrediccion.py`: script principal de la aplicación.
- `random_forest_model.joblib`: archivo del modelo de predicción entrenado.
- `scaler.pkl`: archivo del objeto `MinMaxScaler` utilizado durante el preprocesamiento.
- `columnas_entrenamiento.joblib`: lista ordenada de las columnas empleadas durante el entrenamiento del modelo. Este archivo garantiza que los datos introducidos en la aplicación mantengan el mismo orden, nombre y estructura que el conjunto de entrenamiento original, evitando errores en el preprocesamiento y la predicción.
- `logoApp.png`: logotipo visual del sistema, utilizado como icono en la pestaña del navegador (favicon).

Se recomienda además que el entorno local tenga instalada una distribución de Python 3.10, y que las librerías estén correctamente instaladas como se detalló en el apartado anterior.

1. Abrir Anaconda Prompt o terminal.




Figura C.1: Captura de pantalla del entorno de Anaconda Navigator, señalando PowerShell y la terminal (cmd) como opciones de ejecución.

2. Acceder a la carpeta donde se encuentra el archivo del proyecto:

```
cd C:\Users\Marina\OneDrive - Universidad de Burgos
\Escritorio\TFG-Marina-Martin\app
```




Figura C.2: Acceso al directorio del proyecto desde Anaconda Prompt.

3. Ejecutar la aplicación con:

```
streamlit run appPrediccion.py
```

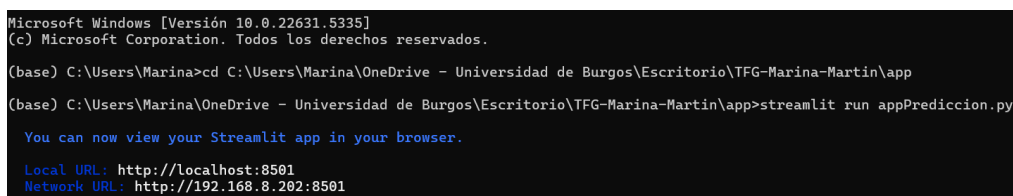


Figura C.3: Ejecución del script principal y generación de la URL de acceso local.

Al ejecutar este comando, se abrirá automáticamente una pestaña en el navegador con la interfaz de la aplicación. El usuario podrá introducir los datos solicitados, obtener la predicción y descargar el informe en PDF.

Ejecución en la nube mediante Streamlit Cloud

Además de su ejecución local, la aplicación ha sido desplegada en la plataforma **Streamlit Cloud**, lo que permite acceder al sistema desde cualquier navegador, sin necesidad de instalar software adicional (Explicado anteriormente en el Anexo [B](#)).

Esta opción facilita la difusión y el uso de la herramienta por parte de profesionales externos, validadores o cualquier usuario no técnico, ya que sólo requiere conexión a Internet.

Ventajas de la ejecución en la nube:

- No requiere instalación de Python ni librerías.
- Acceso multiplataforma (ordenador, móvil, tablet).
- Actualizaciones automáticas al modificar el repositorio de GitHub.
- Fácilmente accesible y sin necesidad de conocimientos técnicos.

Requisitos mínimos:

- Navegador web actualizado.
- Conexión estable a Internet.
- El acceso se realiza a través del siguiente enlace: [aplicación web](#).

Flujo de uso desde la nube:

1. El usuario accede al enlace o escanea el QR.
2. En caso de que la aplicación esté en estado de suspensión (por inactividad superior a 24 horas), puede ser necesario pulsar el botón “*Wake-up*” y esperar unos segundos a que el sistema se reactive.
3. Introduce los datos personales en el formulario.
4. Visualiza la predicción y la explicación gráfica del resultado.
5. Descarga, si desea, el informe en PDF.

No es necesario disponer localmente de los archivos del proyecto para utilizar la versión en la nube.

C.3. Pruebas del sistema

Esta sección no ha sido objeto de una validación formal, pero se ha llevado a cabo una verificación funcional mediante pruebas realizadas por la autora del proyecto y con la colaboración de usuarios no expertos. Las pruebas incluyeron:

- Validación del correcto funcionamiento del formulario y del flujo completo de predicción.
- Comprobación de la generación de informes en PDF con datos realistas.
- Verificación del comportamiento del sistema ante valores extremos o formatos no válidos (ej. presión arterial mal introducida).
- Revisión de la interfaz en distintos navegadores y dispositivos móviles, confirmando su correcta visualización y funcionalidad.

Estas pruebas confirmaron que la aplicación funciona de forma estable y accesible desde un punto de vista técnico, aunque su utilidad en entornos clínicos reales requeriría una validación más amplia del modelo predictivo.

C.4. Instrucciones para la modificación o mejora del proyecto.

El proyecto está diseñado de forma modular, con componentes independientes y claramente diferenciables. Esta estructura facilita su mantenimiento, personalización y evolución futura. A continuación, se presentan posibles líneas de mejora clasificadas por áreas:

Mejora del modelo predictivo

- El modelo actual fue entrenado con un conjunto de datos compuesto por 374 registros. La incorporación de un mayor número de observaciones, idealmente con diagnósticos clínicos confirmados, podría mejorar significativamente la robustez y capacidad generalizadora del sistema.

- Se podrían explorar otros algoritmos más complejos o especializados (como XGBoost, LightGBM o redes neuronales), que permitan detectar patrones no lineales más complejos.
- Automatizar el proceso de entrenamiento y validación mediante notebooks o scripts separados facilitaría futuros reentrenamientos con nuevos datos.

Ampliación del conjunto de variables y calidad clínica

- El sistema podría enriquecerse incorporando nuevas variables objetivas, especialmente recogidas mediante sensores biométricos (como pulseras de actividad o pulsioxímetros).
- Variables como la saturación de oxígeno, frecuencia cardíaca nocturna o ciclos de sueño podrían permitir construir un modelo más ajustado a la realidad clínica.

Interfaz y accesibilidad

- Implementar un sistema de selección de idioma (por ejemplo, español e inglés) mejoraría la accesibilidad para usuarios internacionales.
- Se podrían adaptar los estilos visuales de la aplicación a distintos perfiles de usuario, o permitir configuraciones específicas (modo oscuro, tamaño de fuente, accesibilidad visual).

Personalización del informe en PDF

- Integrar ayuda contextual dentro de la app (tooltips, glosario de términos médicos) facilitaría su uso por personas no expertas.

Almacenamiento y conectividad

- Integrar la aplicación con sistemas de almacenamiento como SQLite o Firebase permitiría registrar y consultar informes anteriores, tanto en local como en la nube.
- Se podrían generar identificadores únicos para cada sesión o usuario, permitiendo un seguimiento longitudinal (por ejemplo, para estudios clínicos).

- Un panel de gestión para profesionales médicos, con acceso a los informes generados y sus gráficos asociados, ampliaría su utilidad en contextos reales.

Este anexo proporciona los recursos necesarios para comprender, instalar, ejecutar y continuar el desarrollo de la aplicación, facilitando su evolución por parte de otros desarrolladores, investigadores o profesionales clínicos interesados en su mejora.

Apéndice *D*

Descripción de adquisición y tratamiento de datos

D.1. Descripción formal de los datos

El conjunto de datos empleado en este proyecto fue obtenido de la plataforma pública **Kaggle** [Alnour, 2024], y se titula *Sleep Health and Lifestyle Dataset*. Se trata de un archivo en formato `.csv` que contiene **374 registros**, cada uno correspondiente a un individuo, con un total de **13 variables** relacionadas con aspectos clínicos, personales y de estilo de vida. El objetivo de este conjunto es facilitar la predicción de trastornos del sueño, concretamente **insomnio**, **apnea del sueño** o **ninguno**.

Características técnicas del archivo:

- **Tipo de archivo:** CSV (texto plano delimitado por comas)
- **Codificación:** UTF-8
- **Separador de campos:** ,
- **Número de registros:** 374
- **Número de columnas:** 13

Estructura detallada de las columnas del dataset:

A continuación se describen las 13 variables incluidas en el conjunto de datos, detallando su significado, tipo, rango de valores y relevancia en el contexto del análisis de trastornos del sueño.

1. **Person ID:** identificador numérico único para cada registro. No tiene valor predictivo, pero se utiliza como referencia interna. Sus valores están comprendidos entre el 1 y el 374.
2. **Gender:** variable categórica binaria que indica el sexo del individuo, con valores ‘Male’ y ‘Female’. La distribución es equilibrada, con un 51 % de hombres y un 49 % de mujeres.
3. **Age:** variable numérica que recoge la edad en años. Los valores oscilan entre 27 y 59, con una media de 42,18 y una desviación estándar de 8,67.
4. **Occupation:** variable categórica con 11 clases distintas, que incluyen profesiones como ‘Software Engineer’, ‘Doctor’, ‘Teacher’ o ‘Sales Representative’. Se considera una posible fuente de variabilidad en el estilo de vida y nivel de estrés.
5. **Sleep Duration:** número medio de horas de sueño por noche. Es una variable numérica con valores entre 5,8 y 8,5 horas.
6. **Quality of Sleep:** calidad del sueño percibida en una escala de 1 a 10. En el conjunto de datos, los valores se sitúan entre 4 y 9.
7. **Physical Activity Level:** variable numérica que representa el nivel de actividad física semanal, expresado en una escala de 0 a 100. En el dataset, los valores se encuentran entre 30 y 90.
8. **Stress Level:** variable numérica que indica el nivel de estrés autopercebido, medido en una escala de 1 a 10. En los registros analizados, los valores varían entre 3 y 8.
9. **BMI Category:** variable categórica que clasifica el índice de masa corporal del individuo. Presenta cuatro categorías: ‘Normal’, ‘Normal Weight’, ‘Overweight’ y ‘Obese’.
10. **Blood Pressure:** originalmente registrada como una cadena de texto con el formato ‘sistólica/diastólica’ (por ejemplo, ‘120/80’). Esta variable fue posteriormente descompuesta en dos columnas numéricas para análisis individualizado.
11. **Heart Rate:** frecuencia cardíaca en reposo, medida en pulsaciones por minuto (bpm). Se observan valores entre 65 y 86, con una media de 70,16 y desviación estándar de 4,14.
12. **Daily Steps:** variable numérica que indica el número promedio de pasos diarios. Los valores oscilan entre 3.000 y 10.000 pasos, con una media de 6.816.

13. **Sleep Disorder:** variable objetivo del estudio. Presenta tres clases posibles: **None**, **Sleep Apnea** e **Insomnia**. Se trata de una variable categórica multiclase.

Como resumen gráfico de esta descripción, en las Figuras [D.1](#), [D.2](#) y [D.3](#) se presenta la estructura inicial del dataset. La primera muestra los nombres, tipos de datos y completitud de cada variable; la segunda recoge los valores únicos observados en las variables categóricas; y la tercera resume las estadísticas descriptivas de las variables numéricas.

Data columns (total 13 columns):

#	Column	Non-Null Count	Dtype
0	Person ID	374 non-null	int64
1	Gender	374 non-null	object
2	Age	374 non-null	int64
3	Occupation	374 non-null	object
4	Sleep Duration	374 non-null	float64
5	Quality of Sleep	374 non-null	int64
6	Physical Activity Level	374 non-null	int64
7	Stress Level	374 non-null	int64
8	BMI Category	374 non-null	object
9	Blood Pressure	374 non-null	object
10	Heart Rate	374 non-null	int64
11	Daily Steps	374 non-null	int64
12	Sleep Disorder	374 non-null	object

dtypes: float64(1), int64(7), object(5)

memory usage: 38.1+ KB

Figura D.1: Estructura del dataset original: nombre, tipo de dato y recuento de valores no nulos por columna.

Gender - Valores únicos:
['Male' 'Female']

Occupation - Valores únicos:
['Software Engineer' 'Doctor' 'Sales Representative' 'Teacher' 'Nurse'
'Engineer' 'Accountant' 'Scientist' 'Lawyer' 'Salesperson' 'Manager']

BMI Category - Valores únicos:
['Overweight' 'Normal' 'Obese' 'Normal Weight']

Sleep Disorder - Valores únicos:
['None' 'Sleep Apnea' 'Insomnia']

Figura D.2: Valores que pueden tomar las variables categóricas.

	Person ID	Age	Sleep Duration	Quality of Sleep	Physical Activity Level	Stress Level	Heart Rate	Daily Steps
count	374.000000	374.000000	374.000000	374.000000	374.000000	374.000000	374.000000	374.000000
mean	187.500000	42.184492	7.132086	7.312834	59.171123	5.385027	70.165775	6816.844920
std	108.108742	8.673133	0.795657	1.196956	20.830804	1.774526	4.135676	1617.915679
min	1.000000	27.000000	5.800000	4.000000	30.000000	3.000000	65.000000	3000.000000
25%	94.250000	35.250000	6.400000	6.000000	45.000000	4.000000	68.000000	5600.000000
50%	187.500000	43.000000	7.200000	7.000000	60.000000	5.000000	70.000000	7000.000000
75%	280.750000	50.000000	7.800000	8.000000	75.000000	7.000000	72.000000	8000.000000
max	374.000000	59.000000	8.500000	9.000000	90.000000	8.000000	86.000000	10000.000000

Figura D.3: Estadísticas descriptivas de las variables numéricas.

D.2. Tratamiento y preprocesamiento de los datos

Para su uso en el modelo de clasificación multiclase, fue necesario aplicar un proceso riguroso de tratamiento y transformación del conjunto de datos original. Las tareas realizadas se agrupan en las siguientes fases:

1. Revisión inicial y limpieza:

Se verificó que no existían valores nulos ni campos vacíos en ninguna de las columnas. También se estudió la posible presencia de registros duplicados. El análisis estadístico descriptivo permitió identificar la presencia de valores extremos en algunas variables numéricas, como **Heart Rate**, que fueron conservados tras confirmar su validez clínica.

2. Transformaciones estructurales del dataset:

- La columna **Blood Pressure**, originalmente en formato texto con el patrón ‘sistólica/diastólica’, fue dividida en dos nuevas variables numéricas (**Systolic BP** y **Diastolic BP**) mediante una transformación de tipo **split**.
- Las variables categóricas fueron tratadas de forma diferenciada:
 - Se aplicó **Label Encoding** en variables binarias como **Gender**.
 - Se utilizó **One-Hot Encoding** para columnas multiclase como **Occupation** y **BMI Category**, eliminando una de las clases por cada variable para evitar redundancia (colinealidad perfecta).
- Las variables numéricas fueron **escaladas mediante Min-MaxScaler** con el objetivo de normalizar los valores en el rango $[0,1]$, lo que facilita la convergencia de ciertos algoritmos de clasificación y garantiza una homogeneidad en el espacio vectorial.

3. Análisis de valores atípicos (outliers):

El análisis gráfico mediante boxplots y la aplicación del método de rango intercuartílico (IQR) permitieron identificar valores extremos en algunas variables cuantitativas. No obstante, dado que estos no representaban errores, se decidió conservarlos en el conjunto de datos para preservar la variabilidad natural de la muestra.

4. Revisión del equilibrio de clases:

La variable objetivo **Sleep Disorder** presenta un leve desbalance entre clases, siendo más frecuentes los casos sin trastorno. No se aplicaron técnicas de sobremuestreo ni submuestreo durante esta fase para mantener la distribución original. El balanceo se abordó posteriormente durante el proceso de entrenamiento y validación del modelo mediante técnicas específicas como SMOTE.

D.3. Descripción clínica de los datos

El conjunto de datos empleado simula una recopilación de variables clínicas, demográficas y de estilo de vida habitualmente asociadas a la aparición de trastornos del sueño. Su estructura permite explorar

perfiles de riesgo a partir de datos no invasivos y fácilmente recopilables. A continuación, se describen las principales variables de interés desde una perspectiva clínica:

- **Edad:** el riesgo de apnea del sueño incrementa con la edad. En el conjunto de datos, las personas diagnosticadas con apnea se concentran en los rangos de edad más elevados (mayores de 50 años).
- **Índice de masa corporal (BMI Category):** las categorías *Overweight* y *Obese* se encuentran sobrerrepresentadas entre los pacientes con apnea del sueño, lo que concuerda con la literatura médica sobre comorbilidades metabólicas. Tal como se observa en la Figura D.4, los individuos diagnosticados con apnea presentan una distribución desplazada hacia categorías de mayor índice de masa corporal.




Figura D.4: Distribución de las categorías de IMC en función del tipo de trastorno del sueño.

- **Presión arterial:** valores elevados de presión sistólica y diastólica aparecen más frecuentemente en individuos con apnea, lo que refuerza su asociación con el riesgo cardiovascular.

- **Frecuencia cardíaca:** valores superiores a la media son más comunes en personas con insomnio, lo que podría indicar una mayor activación simpática o peor calidad de descanso. Esta diferencia se refleja de forma clara en la Figura D.5, donde se observa que los individuos con insomnio presentan una distribución más elevada en frecuencia cardíaca en reposo.




Figura D.5: Distribución de la frecuencia cardíaca por tipo de trastorno del sueño.

- **Nivel de estrés:** los individuos con diagnóstico de insomnio presentan, en general, valores de estrés autopercebido superiores al resto. Esta relación es clínicamente esperable, dado el vínculo bidireccional entre estrés e insomnio. Esta observación se refleja claramente en la Figura D.6, donde se visualiza la distribución del nivel de estrés en función del tipo de trastorno del sueño. El grupo con insomnio presenta una concentración notable de

valores en el rango superior de la escala (6–8), mientras que los individuos sin trastorno tienden a mostrar niveles más bajos.




Figura D.6: Distribución del nivel de estrés según el diagnóstico de trastorno del sueño.

- **Duración y calidad del sueño:** ambas variables son auto-reportadas. Los valores más bajos aparecen en los grupos con trastornos, especialmente en el caso del insomnio, donde la duración del sueño raramente supera las 6 horas.
- **Actividad física y pasos diarios:** los individuos sin trastornos suelen mostrar niveles más altos de actividad física semanal y pasos diarios. Estos factores pueden actuar como elementos protectores frente a alteraciones del sueño.

En conjunto, estas variables permiten construir perfiles clínicos diferenciados entre los tres grupos de diagnóstico, lo que respalda su idoneidad como variables predictoras en sistemas de aprendizaje automático orientados al cribado de trastornos del sueño.

Apéndice E

Manual de especificación de diseño

Este apartado describe la estructura interna y el flujo funcional de la aplicación web desarrollada en el proyecto. Aunque la aplicación no sigue una arquitectura orientada a objetos compleja, se ha estructurado en componentes claramente diferenciados que permiten comprender su funcionamiento y facilitar su mantenimiento. Para ello, se incluyen dos representaciones visuales que ilustran cómo se organizan los elementos del sistema y cómo se comporta la herramienta desde la entrada del usuario hasta la presentación de resultados.

E.1. Diseño arquitectónico

El siguiente esquema representa la arquitectura funcional de la aplicación web, organizada en capas lógicas. Esta representación se centra exclusivamente en los módulos que componen la aplicación desarrollada (basada en Streamlit), sin incluir otros aspectos metodológicos del TFG como el análisis previo de datos o la evaluación del modelo.




Figura E.1: Diseño arquitectónico funcional de la aplicación, estructurado en capas lógicas de entrada, procesamiento y salida.

E.2. Diagrama de flujo del funcionamiento

El diagrama siguiente representa el flujo interno de la aplicación, desde el momento en que el usuario accede al sistema hasta que se genera la predicción y, opcionalmente, el informe en PDF. Este flujo refleja la secuencia real de operaciones ejecutadas en la aplicación al recibir datos de entrada, realizar la predicción mediante el modelo entrenado y generar las salidas asociadas, como la explicación con SHAP y el informe en PDF.




Figura E.2: Diagrama de flujo del funcionamiento interno de la aplicación web.

Ambas representaciones permiten visualizar de forma clara la lógica interna del sistema y servirán de referencia para su futura adaptación, mejora o extensión por parte de otros desarrolladores o equipos clínicos.

Especificación de Requisitos

Este apéndice recoge la especificación funcional del sistema desarrollado, incluyendo los casos de uso definidos, los requisitos asociados y los prototipos de interacción implementados en la aplicación. Su objetivo es proporcionar una visión estructurada de las funcionalidades del sistema desde la perspectiva del usuario final.

Los principales casos de uso definidos son:

- CU-1 – Introducir datos clínicos
- CU-2 – Ejecutar predicción
- CU-3 – Interpretar resultado con SHAP
- CU-4 – Generar informe PDF

F.1. Diagrama de casos de uso

El diagrama que se muestra a continuación representa gráficamente los principales casos de uso del sistema desde la perspectiva del usuario. Cada uno de estos casos está descrito en detalle en las secciones posteriores de este apéndice.




Figura F.1: Diagrama de casos de uso de la aplicación web.

F.2. Explicación casos de uso

CU-1 – Introducir datos clínicos

CU-2 – Ejecutar predicción

CU-3 – Interpretar resultado

CU-4 – Generar informe PDF

CU-1	Introducir datos clínicos
Versión	1.0
Autor	Marina Martín Marijuán
Requisitos asociados	RF-01, RF-02
Descripción	El usuario introduce las variables clínicas y de estilo de vida necesarias para realizar la predicción.
Precondición	La aplicación ha sido cargada correctamente en el navegador.
Acciones	1. Acceder al formulario. 2. Introducir edad, género, ocupación, duración/calidad del sueño, IMC, estrés, FC, PA, pasos. 3. Revisar y validar que los datos introducidos cumplen el formato requerido.
Postcondición	El sistema almacena los datos temporalmente y permite realizar la predicción.
Excepciones	Algún campo no válido o sin completar. El sistema muestra advertencia.
Importancia	Alta

Tabla F.1: CU-1 Introducir datos clínicos.

CU-2	Ejecutar predicción
Versión	1.0
Autor	Marina Martín Marijuán
Requisitos asociados	RF-03
Descripción	El sistema ejecuta la predicción del trastorno del sueño en función de los datos introducidos.
Precondición	Formulario completo con datos válidos.
Acciones	1. Pulsar botón “Realizar predicción”. 2. Ejecutar modelo y obtener clase predicha con probabilidades.
Postcondición	Se muestra el resultado de la predicción en pantalla.
Excepciones	Error de ejecución del modelo o fallo en la interfaz.
Importancia	Alta

Tabla F.2: CU-2 Ejecutar predicción.

CU-3	Interpretar resultado con SHAP
Versión	1.0
Autor	Marina Martín Marijuán
Requisitos asociados	RF-04
Descripción	Se muestran dos gráficos SHAP: uno individual que explica la predicción concreta realizada para el usuario, y otro global que representa la importancia de cada variable en el modelo.
Precondición	Se ha realizado una predicción.
Acciones	1. Visualizar los gráficos SHAP generado. 2. Analizar variables con mayor peso positivo o negativo en ambos contextos.
Postcondición	El usuario comprende los factores que han influido en su predicción individual, así como los que el modelo considera más relevantes de forma general.
Excepciones	Alguno de los gráficos no se carga correctamente.
Importancia	Media

Tabla F.3: CU-3 Interpretar resultado con SHAP.

CU-4	Generar informe PDF
Versión	1.0
Autor	Marina Martín Marijuán
Requisitos asociados	RF-05
Descripción	El sistema permite descargar un informe en PDF con los datos introducidos, resultados y explicación visual.
Precondición	El sistema ya ha generado la predicción.
Acciones	1. Pulsar botón “Descargar informe”. 2. El sistema genera el archivo PDF.
Postcondición	El usuario dispone del archivo descargado localmente.
Excepciones	Error en la generación o guardado del informe.
Importancia	Alta

Tabla F.4: CU-4 Generar informe PDF.

Resumen de requisitos funcionales y casos de uso asociados

Requisito	Descripción	Casos de uso asociados
RF-01	Introducción de datos personales	CU-1
RF-02	Validación de entrada	CU-1
RF-03	Ejecución del modelo	CU-2
RF-04	Visualización interpretativa (SHAP)	CU-3
RF-05	Generación del informe PDF	CU-4

Tabla F.5: Relación entre requisitos funcionales y casos de uso.

F.3. Prototipos de interfaz o interacción con el proyecto

A continuación se presentan capturas reales de la aplicación web desarrollada, que ilustran las principales interacciones del usuario con el sistema. Estas imágenes complementan los casos de uso definidos previamente y muestran visualmente cómo se lleva a cabo cada acción funcional.

La Figura F.2 muestra el formulario principal en el que el usuario introduce sus datos clínicos y de estilo de vida. Este formulario recoge variables como edad, género, ocupación, duración y calidad del sueño, frecuencia cardíaca, presión arterial, nivel de estrés e índice de masa corporal, entre otras. El diseño del formulario ha sido concebido para ser accesible y usable tanto desde dispositivos de escritorio como móviles.

Una vez introducidos los datos, el usuario puede ejecutar la predicción y visualizar el resultado, como se aprecia en la Figura F.3. La aplicación muestra las probabilidades estimadas para cada clase (insomnio, apnea del sueño o ausencia de trastornos), de forma clara y visualmente destacada.

Además del resultado numérico, el sistema ofrece una interpretación visual del modelo mediante gráficos SHAP. En la Figura F.4 se representa la importancia relativa de cada variable en la predicción a nivel global. La Figura F.5 muestra, por su parte, una explicación individualizada para un caso concreto, facilitando la comprensión personalizada del diagnóstico sugerido.

Finalmente, si el usuario lo desea, puede generar un informe en formato PDF con todos los datos introducidos, el resultado de la predicción y los gráficos de explicación, como se muestra en la Figura F.6. El informe puede ser descargado localmente y está diseñado con un formato clínico que facilita su uso profesional.

Cada una de estas pantallas se corresponde con uno o varios de los casos de uso descritos en este anexo, y permite validar que la interfaz implementada satisface los requisitos funcionales definidos para el sistema.

Datos del paciente

Género: ☒ Female ☐ Male

Edad: 30

Ocupación: Doctor

Peso (kg): 70,00

Altura (cm): 170,00

Duración del sueño (h): 7,00

Calidad del sueño (1-10): 7

Días de ejercicio a la semana: 0

Nivel de estrés: Muy bajo

Presión arterial (ej: 120/80): 120/80

Frecuencia cardíaca (bpm): 72

Pasos diarios: 8000

[Realizar predicción](#)

Figura F.2: Formulario de entrada de datos clínicos y de estilo de vida.

Resultado de la predicción




Figura F.3: Resultado de la predicción en pantalla, con distribución porcentual por clase.




Figura F.4: Gráfico SHAP que representa la importancia de cada variable en la predicción global.




Figura F.5: Explicación individualizada mediante SHAP para un caso concreto.

INFORME CLÍNICO DE SUEÑO

Fecha: 04/06/2025 - 16:06

DATOS PERSONALES	
Edad	30 años
Sexo	Femenino
Ocupación	Doctor
IMC (categoría)	Normal
Frecuencia cardíaca	72 bpm
Presión arterial	120 / 80 mmHg

HÁBITOS DE VIDA	
Duración del sueño	7.0 h
Calidad del sueño	7 / 10
Nivel de estrés (escala 1-9)	1
Pasos diarios	8000

RESULTADOS DE LA PREDICCIÓN

Trastorno detectado: None

Insomnia: 19.5%

None: 43.6%

Sleep Apnea: 36.9%

Nota: Este informe ha sido generado automáticamente como parte de una herramienta de ayuda para la predicción de trastornos del sueño. No sustituye el diagnóstico clínico profesional.

Figura F.6: Informe clínico en PDF descargado de la aplicación.

En conjunto, este anexo demuestra que el sistema cumple los requisitos funcionales previstos y ofrece una experiencia de usuario intuitiva, estructurada y coherente con los casos de uso definidos.

Apéndice G

Estudio experimental


G.1. Cuaderno de trabajo

Fase exploratoria inicial: predicción basada en datos reales del O2Ring

El desarrollo del presente Trabajo de Fin de Grado comenzó con un enfoque centrado en la integración de variables fisiológicas reales, obtenidas mediante el dispositivo portátil **O2Ring** de Viatom. La idea inicial del proyecto era diseñar un sistema capaz de predecir alteraciones del sueño, no a partir de datos clínicos estáticos, sino utilizando señales biométricas registradas durante el descanso nocturno.

Para llevarlo a cabo, se combinó el uso del O2Ring con la administración del cuestionario de Pittsburgh (Pittsburgh Sleep Quality Index - PSQI) en formato digital ¹. Este cuestionario permite evaluar la calidad subjetiva del sueño del paciente y estaba destinado a complementar la información objetiva recogida por el wearable.

¹Enlace al Test de Pittsburgh generado mediante Google Forms.



Índice de Calidad de Sueño de Pittsburgh (PSQI)

Las siguientes preguntas hacen referencia a cómo usted **ha dormido durante el último mes**. Por favor, conteste a todas las preguntas de la manera más exacta posible. Sus respuestas contribuirán a una investigación académica que busca mejorar nuestra comprensión sobre estos temas.

Escriba su nombre: *

Texto de respuesta corta

¿Cuál es su edad? *

Texto de respuesta corta

Figura G.1: Test de Pittsburgh realizado mediante Google Forms.

En esta primera fase, participaron varios voluntarios que utilizaron el anillo durante una o dos noches en su domicilio, con el objetivo de obtener mediciones completas y representativas. El O2Ring registró variables como la saturación de oxígeno (SpO_2), la frecuencia cardíaca, el número de eventos de desaturación y el índice de desaturación de oxígeno. De forma paralela, los participantes rellenaron el PSQI, cuyos resultados fueron codificados en una escala numérica.

La idea era construir un modelo de predicción que, a partir de estas variables fisiológicas, clasificara la calidad del sueño en tres clases: buena, regular o mala. Para ello, se integraron todos los datos en cuadernos Jupyter y se procesaron con librerías como Pandas, Scikit-learn, Matplotlib y Seaborn. También se experimentó con técnicas de aumento de datos, como la generación de ejemplos sintéticos mediante redes generativas adversarias (GANs) y autoencoders variacionales (VAEs).

Sin embargo, esta línea de trabajo resultó poco viable debido a la escasa disponibilidad de registros reales. Las dificultades para reunir una muestra lo suficientemente grande y balanceada, junto con la variabilidad individual de las señales, imposibilitaron el entrenamiento de un modelo robusto con garantías mínimas de generalización. La opción de aumentar los datos sintéticamente no solucionó del todo este problema, ya que los patrones de sueño requieren cierta estabilidad y validez clínica.

A pesar de que esta fase no pudo completarse con un modelo funcional, resultó verdaderamente útil para la comprensión de las variables

fisiológicas recogidas, así como el verdadero proceso de adquisición de datos reales y su preprocesamiento.



Figura G.2: Dispositivo O2Ring (Viatom) utilizado en la fase exploratoria inicial del proyecto. Fuente: [iF Design Award, 2021].

Cambio de enfoque: utilización de datos clínicos estructurados

Tras analizar los límites del enfoque inicial, y en coordinación con el tutor, se decidió reformular el enfoque del proyecto para adaptarlo a las limitaciones reales del entorno y los datos disponibles. El nuevo objetivo consistía en desarrollar una aplicación web predictiva utilizando un conjunto de datos clínico abierto y tabular, que facilitara el uso de algoritmos de aprendizaje automático con mayor volumen de registros y variables estructuradas.

El nuevo dataset, obtenido de la plataforma Kaggle², incluía información clínica, demográfica y de estilo de vida de más de 370 personas, con variables como edad, ocupación, duración del sueño, presión arterial, frecuencia cardíaca, pasos diarios y calidad del sueño percibida. Este conjunto permitía abordar un problema de clasificación multiclase con tres categorías: insomnio, apnea del sueño y sin trastorno.

A partir de este nuevo enfoque, se llevaron a cabo distintas fases: la exploración del conjunto de datos, su preprocesamiento, el entrenamiento y evaluación de distintos modelos de clasificación, la calibración

²Dataset utilizado para el proyecto: [Alnour, 2024]

de probabilidades, la explicación de resultados mediante SHAP y el desarrollo de la aplicación web.

Configuración y parametrización de las técnicas

Durante la fase experimental se evaluaron distintos algoritmos de clasificación con el objetivo de seleccionar el modelo más adecuado para la predicción multiclase del tipo de trastorno del sueño. Para ello, se utilizaron técnicas de validación cruzada, balanceo de clases y ajuste de hiperparámetros mediante `GridSearchCV` o `RandomizedSearchCV`, según el modelo.

Regresión logística

Se utilizó el modelo `LogisticRegression` de `scikit-learn`, con un número máximo de iteraciones ajustado a 5000 para asegurar la convergencia. La búsqueda de hiperparámetros se llevó a cabo mediante `GridSearchCV`, ya que se trata de un modelo con pocos parámetros, lo que permite evaluar exhaustivamente todas las combinaciones.

- **penalty**: tipo de regularización aplicada.
 - **l1**: penaliza la suma de los valores absolutos de los coeficientes. Favorece modelos más simples eliminando algunos coeficientes (lleva a cero).
 - **l2**: penaliza la suma de los cuadrados de los coeficientes. Reduce su magnitud sin eliminarlos.
- **C**: inverso de la fuerza de regularización. Valores pequeños implican regularización fuerte (modelo más simple), valores grandes permiten más flexibilidad.
- **solver**: algoritmo de optimización.
 - **liblinear**: eficiente en conjuntos de datos pequeños, compatible con **l1** y **l2**.
 - **saga**: escalable y compatible con regularización **l1**.

La validación cruzada se realizó con `cv=5` usando precisión como métrica. La mejor combinación fue `penalty='l2'`, `C=10` y `solver='liblinear'`.

Árboles de decisión

El modelo `DecisionTreeClassifier` se entrenó ajustando sus hiperparámetros con `GridSearchCV`. Este tipo de modelo tiene como ventaja

su capacidad de interpretar fácilmente las decisiones, aunque tiende a sobreajustarse si no se limita su complejidad.

- **max_depth**: controla la profundidad máxima del árbol. Profundidades mayores permiten mayor capacidad de aprendizaje, pero también riesgo de sobreajuste.
- **min_samples_split**: número mínimo de muestras necesarias para dividir un nodo. Valores más altos impiden que el árbol crezca innecesariamente.
- **min_samples_leaf**: número mínimo de muestras necesarias en una hoja del árbol. Ayuda a mantener ramas robustas.
- **criterion**: función usada para medir la calidad de una división.
 - **gini**: mide la impureza de Gini.
 - **entropy**: basada en la entropía de la teoría de la información.

Se probaron varias combinaciones con `cv=5`. La mejor configuración utilizó `criterion= 'gini'` y sin límite de profundidad.

Máquinas de vectores soporte (SVM)

Se empleó la clase `SVC` y se utilizó `RandomizedSearchCV` para reducir el coste computacional, dado el número de combinaciones posibles entre hiperparámetros.

- **C**: penalización por error. Valores altos intentan clasificar todos los datos correctamente, lo que puede derivar en sobreajuste.
- **kernel**: función que transforma los datos en un espacio de mayor dimensión.
 - **linear**: separador lineal.
 - **rbf**: radial basis function, muy flexible.
 - **poly**: permite fronteras polinómicas.
 - **sigmoid**: imita comportamiento de redes neuronales.
- **gamma**: controla la influencia de cada punto.
 - **scale**: valor adaptado automáticamente.
 - **auto**: inverso del número de características.

Se probaron 20 combinaciones con `cv=5`. El mejor modelo tuvo `kernel='poly'`, `gamma='scale'` y `C=10`.

Perceptrón multicapa (MLP)

Se utilizó `MLPClassifier`, un modelo de red neuronal que permite aprender patrones no lineales complejos. Se aplicó `RandomizedSearchCV`, ya que el ajuste fino de parámetros puede ser costoso computacionalmente.

- **hidden_layer_sizes**: número y tamaño de las capas ocultas. Se probaron estructuras como (50,), (100,) y (50,50).
- **activation**: función de activación en cada neurona.
 - `relu`: rectificador lineal unipolar.
 - `tanh`: función hiperbólica, útil en redes profundas.
- **solver**: algoritmo de optimización.
 - `adam`: adaptativo, robusto para muchos problemas.
 - `sgd`: descenso por gradiente estocástico.
- **alpha**: regularización L2 para evitar sobreajuste.
- **learning_rate**: tipo de estrategia para modificar la tasa de aprendizaje durante el entrenamiento.

El mejor modelo utilizó `activation='tanh'`, `alpha=0.01`, `solver='adam'` y estructura (50,).

Random Forest

Finalmente, se utilizó `RandomForestClassifier`, un modelo de conjunto basado en árboles de decisión. Se aplicó `RandomizedSearchCV` para evaluar combinaciones de hiperparámetros de forma eficiente.

- **n_estimators**: número de árboles en el bosque. Más árboles generalmente mejoran el rendimiento, pero aumentan el tiempo de entrenamiento.
- **max_depth**: profundidad máxima de cada árbol.
- **min_samples_split**: número mínimo de muestras necesarias para dividir un nodo.
- **min_samples_leaf**: número mínimo de muestras por hoja.
- **bootstrap**: si se realiza muestreo con reemplazo al construir los árboles.

Se probaron 20 combinaciones con validación cruzada. El modelo final utilizó `n_estimators=200`, `max_depth=None` y `bootstrap=True`, mostrando gran robustez, precisión y compatibilidad con técnicas de interpretación como SHAP.

Resumen y elección del modelo final

Tras comparar el rendimiento de los modelos evaluados, el clasificador **Random Forest** fue seleccionado como el modelo final a integrar en el sistema. Esta decisión se basó en su:

- Alto rendimiento general en precisión, F1-score y estabilidad.
- Capacidad para manejar conjuntos de datos con variables categóricas y numéricas sin necesidad de transformaciones complejas.
- Robustez frente al sobreajuste, gracias a la agregación de múltiples árboles.
- Compatibilidad con técnicas de interpretabilidad, como SHAP, que permiten explicar la predicción individual y global de manera visual y comprensible.

En el siguiente apartado ([Detalle de resultados](#)), se presentan las métricas obtenidas en la validación cruzada y los resultados más representativos del modelo entrenado y calibrado.

Desarrollo de la aplicación y síntesis de resultados

Como parte final del desarrollo, se diseñó e implementó una aplicación web interactiva mediante **Streamlit**. Esta app permite introducir manualmente variables clínicas y de estilo de vida, ejecutar el modelo predictivo, visualizar una explicación local de la predicción (mediante SHAP) y generar un informe en formato PDF con los resultados.

Durante esta fase, se abordaron cuestiones como la validación de entrada, el formateo automático del informe, la exportación de gráficos y la integración con el modelo calibrado previamente entrenado y almacenado con **joblib**.

La app fue probada con diversos perfiles clínicos simulados, y se validó su funcionamiento en sesiones reales. Además, se realizaron ajustes en el diseño visual y en la generación de resultados con fines interpretativos y de presentación clínica.

En cuanto a los resultados, el modelo seleccionado (Random Forest calibrado) obtuvo una precisión media del 84 % en validación cruzada. La clase ‘None’ fue la más fácilmente reconocible, mientras que la clase ‘Sleep Apnea’ fue la más proclive a falsos positivos. Estos patrones se confirmaron también en la validación externa con datos reales del O2Ring, lo que destaca tanto las capacidades actuales del sistema como las áreas de mejora futura.

G.2. Detalle de resultados

El modelo final, Random Forest calibrado, fue evaluado sobre un conjunto de test independiente compuesto por 75 muestras. Las métricas por clase se muestran a continuación:

Clase	Precisión	Recall	F1-score	Soporte
Insomnia	0.93	0.93	0.93	15
None	1.00	1.00	1.00	44
Sleep Apnea	0.94	0.94	0.94	16
Media macro	0.96	0.96	0.96	75
Media ponderada	0.97	0.97	0.97	75

Tabla G.1: Métricas del modelo Random Forest calibrado sobre el conjunto de test.

Evaluación comparativa: impacto de la variable Occupation

Con el objetivo de analizar el impacto de la variable `Occupation` en el rendimiento clínico del modelo, se desarrolló una versión alternativa del sistema predictivo excluyendo dicha variable. Esta decisión se fundamenta en la posibilidad de que ciertas ocupaciones actúen como proxies de factores estructurales no controlados, como el estilo de vida o el nivel socioeconómico, generando sesgos en el diagnóstico automático.

Para comparar el comportamiento de ambas versiones, se evaluaron tres perfiles clínicos reales (Pacientes A, B y C) con ambos modelos, registrando las clases predichas y sus probabilidades asociadas. Se mantuvieron fijos los parámetros clínicos extraídos de los informes del O2Ring (edad, sexo, IMC, FC) y se ajustaron únicamente las variables no presentes en dichos informes (como pasos diarios, nivel de estrés o

calidad del sueño) para evitar contradicciones y mejorar la coherencia diagnóstica esperada.

Paciente	Diagnóstico esperado	Con Occupation	Sin Occupation
A – Apnea	Apnea moderada-grave	Apnea (70.0 %)	Insomnio (59.0 %)
B – Sano	Sin trastornos	Apnea (59.0 %)	None (98.0 %)
C – Insomnio	Insomnio leve	Apnea (58.0 %)	None (79.0 %)

Tabla G.2: Comparativa entre versiones del modelo para los tres perfiles clínicos reales.

Los resultados muestran un patrón claro: el modelo entrenado con la variable **Occupation** tiende a sobrediagnosticar apnea del sueño, clasificando todos los perfiles como tal incluso cuando no existe evidencia clínica suficiente (como en los pacientes B y C).

Por el contrario, el modelo sin **Occupation** mostró un comportamiento más prudente y alineado con los perfiles clínicos reales, especialmente en el caso del paciente sano (B), al que clasificó correctamente con una alta probabilidad. Si bien aún existen errores en el diagnóstico de insomnio, la eliminación de **Occupation** permitió reducir el sesgo observado hacia la clase de apnea.

Este experimento refuerza la necesidad de evaluar cuidadosamente el impacto de variables socioeconómicas en sistemas de ayuda al diagnóstico. En consecuencia, se optó por incluir **Occupation** en la versión final del modelo desplegado en la aplicación, priorizando la robustez y la interpretabilidad.

G.3. Validación externa con datos reales del O2Ring

Con el fin de evaluar el comportamiento del modelo ante datos reales, se utilizó información fisiológica de tres pacientes reales monitorizados mediante el dispositivo O2Ring. Los casos fueron seleccionados para representar tres perfiles clínicos distintos: apnea del sueño, sujeto sano e insomnio leve.

Paciente A – Apnea del sueño

- Edad: 57 años, IMC: 31.8

- SpO₂ media: 89 %, mínima: 70 %
- ODI 3 %: 43.3/h, FC media: 61 bpm
- Predicción del modelo: **Sleep Apnea** (70.4 %)

Paciente B – Perfil sano

- Edad: 31 años, IMC: 25.1
- SpO₂ media: 97 %, mínima: 95 %
- ODI 3 %: 0.0/h, FC media: 58 bpm
- Predicción del modelo: **Sleep Apnea** (59.3 %)

Paciente C – Insomnio leve

- Edad: 55 años, IMC: 25.4
- Duración del sueño: 7.0h, calidad baja, estrés muy alto
- SpO₂ media: 95 %, ODI 3 %: 4.1/h
- FC media: 48 bpm
- Predicción del modelo: **Sleep Apnea** (72.7 %)

Paciente	Diagnóstico esperado	Predicción	Probabilidad	¿Acertó?
A	Apnea del sueño	Sleep Apnea	70.4 %	Sí
B	Sin trastornos	Sleep Apnea	59.3 %	No
C	Insomnio leve	Sleep Apnea	72.7 %	No

Tabla G.3: Resumen de resultados en la validación externa con datos reales.

Discusión

Aunque el modelo mostró un rendimiento sólido en validación cruzada, la validación externa con datos fisiológicos reales puso de manifiesto varias limitaciones importantes. En concreto, dos de los tres pacientes fueron clasificados incorrectamente como casos de apnea del sueño, a pesar de presentar valores normales de saturación de oxígeno (SpO₂), frecuencia cardíaca y un índice ODI bajo o compatible con insomnio leve.

Este comportamiento sugiere una tendencia del sistema a sobrediagnosticar apnea, probablemente como resultado del desbalance en el

dataset original o del peso excesivo asignado a variables indirectas como la ocupación. La comparación con una versión alternativa del modelo que excluía la variable **Occupation** confirmó esta hipótesis: dicho modelo mostró un comportamiento más prudente y, en varios casos, ofreció predicciones más acordes con el perfil clínico real.

No obstante, se optó por mantener el modelo con **Occupation** en la versión final de la aplicación por motivos de estabilidad técnica, calibración ya validada, y compatibilidad con el sistema de visualización e interpretación integrado. Esta decisión no implica ignorar sus limitaciones, sino gestionarlas de forma responsable: la aplicación incorpora un informe clínico descargable, un sistema de interpretabilidad mediante SHAP y una advertencia explícita sobre la naturaleza orientativa del sistema.

En conjunto, la validación externa desempeñó un papel clave al evidenciar las debilidades reales del modelo y al permitir evaluar su comportamiento en un contexto clínico simulado. Esta experiencia pone de manifiesto la necesidad de integrar señales fisiológicas en futuras versiones del sistema (como SpO₂ u ODI en tiempo real), así como de ampliar y diversificar el conjunto de entrenamiento con perfiles reales y clínicamente etiquetados. Solo mediante ese enfoque podrá garantizarse que este tipo de herramientas ofrezcan una ayuda diagnóstica fiable y sin sesgos.

Informe clínico del dispositivo O2Ring

Los datos fisiológicos utilizados en la validación externa fueron extraídos directamente de los informes generados por el dispositivo **O2Ring** tras su uso durante una noche completa de sueño. Estos informes, generados en formato PDF mediante el software oficial O₂ Insight Pro, recogen métricas como la saturación de oxígeno (SpO₂), los eventos de desaturación (ODI 3 % y 4 %), la frecuencia cardíaca (FC) y el tiempo acumulado con valores críticos de oxígeno.

A continuación, se presenta como ejemplo el informe correspondiente al **Paciente A**, en el que se puede observar una puntuación O₂ reducida, una SpO₂ media de 89 %, con desaturaciones severas frecuentes y un índice ODI 3 % de 43.3 eventos por hora, lo que es clínicamente compatible con un caso de apnea del sueño moderada-grave.

Parámetro	Valor
Duración total	5h 53m
SpO ₂ media	89 %
SpO ₂ mínima	70 %
ODI 3 %	43.3 eventos/hora
Frecuencia cardíaca media	61 bpm

Tabla G.4: Resumen de parámetros extraídos del informe del Paciente A.

Además de los valores numéricos, el informe incluye gráficas de evolución temporal de SpO₂, frecuencia cardíaca y movimiento. A nivel visual, se aprecia un patrón repetitivo de desaturaciones rápidas seguido de recuperaciones bruscas, visibles especialmente entre las 02:30 y las 05:30. Durante este intervalo, la SpO₂ cae de forma reiterada por debajo del umbral clínico del 90 %, alcanzando incluso valores mínimos cercanos al 70 %.

También se observan variaciones sincronizadas en la frecuencia cardíaca, que muestra picos coincidentes con algunos eventos de desaturación, así como incrementos en el movimiento. Esta combinación de oscilaciones de SpO₂, activación autonómica y actividad motora nocturna es característica de pacientes con apnea obstructiva del sueño y refuerza la validez clínica del informe.




Figura G.3: Primera página del informe del dispositivo O2Ring para el Paciente A.

G.4. Conclusión del estudio experimental

Este anexo ha recogido todo el proceso experimental llevado a cabo para el desarrollo del sistema predictivo. A lo largo del trabajo se ha evaluado un conjunto diverso de algoritmos de clasificación, explorado técnicas de calibración e interpretabilidad, y finalmente desplegado un modelo funcional dentro de una aplicación web.

La validación externa con datos reales reveló fallos importantes, como la incapacidad del sistema para discriminar adecuadamente entre insomnio leve y apnea del sueño. Sin embargo, estos errores no invalidan el enfoque, sino que ponen de manifiesto la necesidad de enriquecer el entrenamiento con datos fisiológicos reales.

En conjunto, el estudio experimental demuestra que es viable desarrollar un sistema de predicción del tipo de trastorno del sueño basado en datos clínicos estructurados. No obstante, también subraya que la fiabilidad clínica de este tipo de sistemas depende en gran medida del tipo de variables disponibles y de su validación en entornos reales.

Este estudio no solo permitió desarrollar un sistema funcional, sino también comprender con mayor profundidad las limitaciones reales de los modelos clínicos basados únicamente en datos autodeclarados. El proceso completo ha sido esencial para identificar futuras líneas de mejora y consolidar una base sólida para trabajos posteriores.

Apéndice H

Anexo de sostenibilización curricular

H.1. Introducción

Las Naciones Unidas definen el desarrollo sostenible como aquel que satisface las necesidades del presente sin comprometer la capacidad de las generaciones futuras para satisfacer las suyas. Este principio se concreta en la **Agenda 2030 para el Desarrollo Sostenible**, adoptada en 2015, que establece **17 Objetivos de Desarrollo Sostenible (ODS)** como hoja de ruta global para erradicar la pobreza, proteger el planeta y asegurar la prosperidad para todos [[Organización de las Naciones Unidas, 2015](#)].

Estos objetivos, de carácter integrador y multidimensional, afectan directamente al ámbito de la salud, la educación, la igualdad, la sostenibilidad tecnológica y el uso responsable de los recursos. El desarrollo de este Trabajo de Fin de Grado, centrado en el diseño de una herramienta digital para la predicción de trastornos del sueño mediante inteligencia artificial, se alinea con varios de estos objetivos.



Figura H.1: Objetivos del Desarrollo Sostenible (ODS).

ODS 3: Salud y Bienestar

El objetivo principal del TFG ha sido el desarrollo de una herramienta predictiva de trastornos del sueño (insomnio, apnea, o sueño normal), accesible y explicable, basada en modelos de machine learning. Esta herramienta tiene un claro impacto en el ámbito del ODS 3, ya que promueve la detección temprana de problemas de salud que afectan al bienestar físico y mental de la población.

Además, el sistema facilita el acceso a la información y la concienciación sobre la importancia del sueño como parte fundamental de la salud, lo que refuerza su valor como apoyo preventivo y no invasivo. Al diseñar una interfaz intuitiva y multiplataforma, se ha buscado llegar a un público diverso, contribuyendo a mejorar el bienestar desde una perspectiva integradora y proactiva.

ODS 4: Educación de calidad

El proyecto está disponible públicamente en GitHub y documentado paso a paso para que pueda ser replicado, adaptado o ampliado por otros estudiantes o investigadores. Esta filosofía de trabajo fomenta el acceso abierto al conocimiento, promueve el aprendizaje autónomo y facilita la reutilización de recursos educativos.

ODS 5 y ODS 10: Igualdad de Género e Inclusión

Desde el inicio del desarrollo del modelo predictivo se ha tenido en cuenta la importancia de evitar sesgos discriminatorios relacionados con el género u otras variables personales. El dataset empleado incluía variables como sexo, nivel de estrés, ocupación o hábitos saludables, lo que ha permitido entrenar el modelo con una perspectiva más inclusiva.

Asimismo, al tratarse de una herramienta accesible, sin barreras económicas ni tecnológicas, se contribuye a reducir las desigualdades en el acceso a recursos de salud digital, especialmente en contextos con menos recursos. El enfoque explicativo del modelo también refuerza la equidad al permitir comprender cómo influyen los factores individuales en el resultado, en lugar de presentar una predicción como una “caja negra”.

ODS 9: Industria, Innovación e Infraestructuras

El uso de tecnologías emergentes como el aprendizaje automático, unido al desarrollo de una aplicación interactiva mediante Streamlit, representa una forma innovadora de abordar el diagnóstico preliminar en salud. La combinación entre rigor técnico y accesibilidad convierte el proyecto en un ejemplo de solución digital con vocación realista, útil y sostenible.

Además, se ha optado por el uso exclusivo de herramientas de software libre y bibliotecas mantenidas por la comunidad científica, lo que permite una implementación sin dependencia de soluciones propietarias ni altos costes de infraestructura.

ODS 12: Producción y Consumo Responsables

Durante todo el desarrollo se han priorizado prácticas sostenibles: la herramienta se ejecuta de forma digital, sin necesidad de imprimir documentación, ni utilizar recursos físicos. Tampoco requiere instalación local obligatoria, ya que está disponible en la nube, lo que reduce el impacto medioambiental y el consumo innecesario de hardware.

Del mismo modo, al evitar la generación de residuos físicos, y promover el trabajo completamente digitalizado, el proyecto encarna una forma de producción responsable basada en eficiencia, reutilización y simplicidad.

En conjunto, este proyecto se alinea con múltiples Objetivos de Desarrollo Sostenible al proponer una solución tecnológica accesible, educativa, ética y respetuosa con el entorno, demostrando que la innovación digital puede contribuir activamente a una sociedad más equitativa y sostenible.

Bibliografía

- [lpi, 1996] (1996). Real decreto legislativo 1/1996, por el que se aprueba el texto refundido de la ley de propiedad intelectual.
- [dir, 2009] (2009). Directiva 2009/24/ce del parlamento europeo y del consejo sobre la protección jurídica de programas de ordenador.
- [rgp, 2016] (2016). Reglamento (ue) 2016/679 del parlamento europeo y del consejo, de 27 de abril de 2016, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos (rgpd).
- [reg, 2017] (2017). Reglamento (ue) 2017/745 del parlamento europeo y del consejo, de 5 de abril de 2017, sobre productos sanitarios.
- [lop, 2018] (2018). Ley orgánica 3/2018, de protección de datos personales y garantía de los derechos digitales (lopdgdd).
- [rd1, 2023] (2023). Real decreto 192/2023, de 21 de marzo, por el que se regulan los productos sanitarios.
- [Alnour, 2024] Alnour, A. (2024). Sleeping disorders detection - outliers removal. <https://www.kaggle.com/code/alnourabdalrahman9/sleeping-disorders-detection-outliers-removal/input>.
- [Anaconda, 2025] Anaconda, I. (2025). Anaconda documentation – getting started. <https://www.anaconda.com/docs/getting-started/anaconda/install#windows-installation>.
- [Glassdoor, 2025] Glassdoor (2025). Sueldos para ingeniero biomédico en españa (estimaciones). <https://www.glassdoor.es>.

- [iF Design Award, 2021] iF Design Award (2021). O₂Ring – Wearable Pulse Oximeter. <https://ifdesign.com/es/winner-ranking/project/o2ring/342383>. Accedido el 24 de mayo de 2025.
- [InfoJobs, 2025] InfoJobs (2025). Salario medio de un ingeniero biomédico en España. <https://www.infojobs.net>.
- [Organización de las Naciones Unidas, 2015] Organización de las Naciones Unidas (2015). La Asamblea General adopta la agenda 2030 para el desarrollo sostenible.
- [Python Software Foundation, 2025] Python Software Foundation (2025). Python programming language – official website. <https://www.python.org/>.